

分类号_____

UDC _____

博士学位论文

题 目 _____ Logistic 回归、决策树和神经网络在预测 2 型糖尿病

_____ 并发末梢神经病变中的性能比较

作者姓名 _____ 李 长 平

指导教师 _____ 胡 良 平 教 授

培养单位 _____ 军 事 医 学 科 学 院 科 技 部

专业名称 _____ 流 行 病 与 卫 生 统 计 学

论文提交日期 _____ 2009 年 05 月 30 日

学位授予单位 _____ 中 国 人 民 解 放 军 军 事 医 学 科 学 院

答辩委员会主席 _____

中国人民解放军军事医学科学院制

Logistic 回归、决策树和神经网络在预测 2 型糖尿病
并发末梢神经病变中的性能比较

博 士 生 李 长 平
年 级 2005 级
导 师 胡 良 平 教 授
申请学位 医学博士
专业名称 流行病与卫生统计学
培养单位 军事医学科学院科技部

论文工作起止日期 2005 年 8 月至 2009 年 4 月
论文答辩日期 2009 年 6 月

**A Performance Comparison between Logistic Regression,
Decision Trees, and Neural Networks in Predicting Peripheral
Neuropathy in Type 2 Diabetes Mellitus**

by

Li Changping

Dissertation Supervisor: Professor Hu Liangping

April, 2009

Academy of Military Medical Sciences, China

军事医学科学院研究生学位论文独创性声明

秉承军事医学科学院严谨的学风和科研作风,本人声明所呈交的学位论文是本人在导师指导下独立进行的研究工作和取得的研究成果,除了文中特别加以标注和致谢之处外,论文中不包含其他人已经发表或撰写过的研究成果,也不包含为获得军事医学科学院或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

论文作者签字: 李长平 签字日期: 2009 年 6 月 12 日

军事医学科学院保护知识产权声明

本学位论文作者完全了解军事医学科学院对研究生在学期间撰写的论文知识产权保护的相关规定。本人撰写的论文是在导师具体指导下,并得到相关研究经费支持下完成的,其数据和研究成果归属于导师和作者本人,知识产权单位属军事医学科学院。本人保证毕业后,以本论文数据和资料发表论文或使用论文工作成果时署名第一单位仍然为军事医学科学院。军事医学科学院有权保留学位论文及其电子版,公布论文的全部或部分内容,可以采用影印、缩印或其他复制手段保存论文、汇编以供查阅和借阅。

(保密学位论文在解密后适用本声明)

论文作者签字: 李长平 签字日期: 2009 年 6 月 12 日
指导教师签字: 胡良平 签字日期: 2009 年 6 月 12 日

摘要

Logistic 回归、决策树和神经网络在预测 2 型糖尿病 并发末梢神经病变中的性能比较

近年来,数学方法和计算机技术的发展使复杂的模型预测成为可能。目前能够建立预测模型的方法主要有统计学方法和数据挖掘方法,基于这两类方法的预测技术已逐渐被应用在生物医学研究领域,但对其预测性能(即泛化能力的大小)进行比较的研究却很少,因此将数据挖掘方法与统计学方法的泛化能力进行比较是一个非常值得研究的方向。本研究以 2 型糖尿病并发末梢神经病变(Diabetic Peripheral Neuropathy, DPN)的病例对照研究数据(数据来源情况详见本文第 2 章)为例,采用 Logistic 回归(Logistic Regression, LR)、决策树(Decision Trees, DT)和神经网络(Neural Networks, NN)对 DPN 发生的概率进行预测,并就建模和预测性能比较研究中的几个难点,提出了较为理想的解决方案。

本研究的难点及相应的解决方案如下:

(1) 科学地实现连续变量离散化。在一些科学研究中,人们通常对一些连续变量的一个单位值的变化不感兴趣,或根据专业知识需将连续变量进行离散化,因此如何科学的实现连续变量离散化是一个值得研究的问题。

本文采用 χ^2 分割法对连续变量进行离散化,不仅使离散化后的变量各个等级之间划分得有意义,而且使等级之间的区分度尽可能地大,很好地实现了连续变量离散化的目的。

(2) 在建模过程中充分利用数据信息、防止过拟合。在数据量有限的情况下,能尽量多地利用数据信息是很重要的。在决策树和神经网络构建过程中,如何在小样本时既能达到充分利用数据信息,又能防止过拟合现象的发生是一个重要的问题。

本研究采用 100 次 5~7 折分层交叉验证方法,将分类和回归树(CART)与卡方自动交互式检测树(CHAID)相结合,建立起决策树模型,既充分利用了数据信息,又避免了过拟合现象的发生。此外,在选取神经网络模型隐含层数和隐含层节点数目时,以 SBC 准则作为选择的标准,在建模过程中利用 L-M 优化技术,采用权重衰减和预训练的方法,也可充分利用数据信息,有效避免过拟合现象和局部最优现象的发生,从而建立起较为准确可靠的模型。

(3) 快速有效地构建 Logistic 回归模型。常规的 Logistic 回归建模筛选变量

的方法有向前选择法、向后剔除法、逐步法、最优子集法，前三种筛选变量方法均涉及到变量进入和（或）剔除的 P 值大小的选择问题，显然 P 值的选取存在一定的主观性。例如，有些研究认为变量进入方程的显著性水平（SLE）0.05 过于严厉，经常将重要的变量排除在外。针对所有原因变量的组合情况，最优子集法均可以给出其对应的 χ^2 值，但却无法指出哪种组合最佳。因此，如何快速有效地进行变量筛选，构建准确可靠的模型是很重要的。

本研究中采用最优子集法与 AIC 信息准则相结合对变量进行快速方便的筛选。此法既考虑了模型的泛化能力又避免了人为选取 P 界值点带来的“烦恼”，建立的模型也优于用常规筛选变量方法建立的模型。

（4）小样本情况下的模型泛化能力比较。大量文献资料显示，迄今为止，在生物医学领域中，关于多种不同模型预测、分类技术的比较研究，或针对于较大的数据量（如从几百例观测至几十万例观测），或对模型泛化能力比较时采用保持法（将数据集随机分成两部分，一部分建模一部分测试），并没有涉及到小样本时如何有效利用数据信息以及基于小样本时如何对模型泛化能力进行比较。而在实际工作中，很多数据集较小（如 100 例左右），且变量较多，此时采用保持法进行模型泛化能力的比较就会损失数据信息，导致比较结果的可靠性降低甚至不可靠（本研究中也证实了这一点，详见本文第 5 章）。因此，如何针对小样本的特性，有效地构建模型并对模型的泛化能力进行客观评价，是一个很值得研究的问题，也是本次研究的重点。

在本研究中针对小样本的特性，采用 Monte Carlo 模拟抽样（10~100 次的 2~10 折分层交叉验证法、刀切法、100~1000 次自引导法（具体为 0.632 自引导法））的校正技术，对模型的泛化误差作出可靠的评价，进而对三种预测方法（LR、DT、NN）的泛化能力进行比较，并客观地评价三种模型的泛化能力，有效弥补了应用保持法对模型泛化能力进行比较时存在的上述不足。就本资料而言，结果表明，总体来说 NN 泛化能力最好，LR 次之，DT 最差。

（5）调整过抽样。当样本的获取方式是来源于过抽样（即分离抽样）时，模型估计的概率值是基于样本而不是基于总体的，此时对总体人群疾病发生的概率进行预测可能会存在较大的偏差。

本文针对过抽样的特点，利用先验概率对后验概率进行调整，从而使调整后的结果能够更客观准确地预测疾病发生的可能性。

综上所述，本研究采用三种方法（LR、DT、NN）对 DPN 发生的概率进行预测，在基于小样本条件下，从五个方面（即①科学地实现连续变量离散化、②充分利用数据且又防止过拟合、③快速有效地构建模型、④有效利用数据信息提

高模型泛化能力、⑤有效调整过抽样获得更客观准确的预测结果) 进行比较研究和改进, 均取得了比较理想的结果, 其建模思想和技术方法可方便成功地移植到生物医学甚至其它研究领域中去。

关键词: Logistic 回归; 决策树; 神经网络; 保持法; 交叉验证法; 刀切法; 自引导法; 过抽样; 糖尿病并发末梢神经病变

Abstract

A Performance Comparison between Logistic Regression, Decision Trees, and Neural Networks in Predicting Peripheral Neuropathy in Type 2 Diabetes Mellitus

The development of mathematical methods and computer technology has made it possible to use complex models for prediction in recent years. There are two primary methods employed—statistical methods and data mining methods. The predicting technology based on the two methods has been applied to the field of biomedical studies, but there are quite a few studies on comparing performance of prediction, that is, the generalization ability. It is worth comparing the generalization ability of data mining methods with that of statistical methods. In this study, by taking the case control study data of Diabetic Peripheral Neuropathy(DPN) in type 2 Diabetes Mellitus(It is introduced in chapter 2 of this thesis.) for example, some desirable solutions are proposed to several difficulties in building models and in comparing the performance of the logistic regression, decision tree, and neural network for predicting the probability of DPN.

The difficulties and the corresponding solutions in predicting the probability of DPN are as follows:

(1) Discretization of continuous variables. In some scientific studies, there is no interest in change of specific value of a unit of continuous variables, or discretization of continuous variables is required according to professional knowledge. However, how to scientifically discretize the continuous variables is a problem worthy of study.

In this thesis, we use the chi-square partitioning method to discretize the continuous variables. The distinction between classes is maximized after the variables are discretized.

(2) Utilization of data information and avoiding overfitting in the process of establishing a model. When the amount of data is limited, it is particularly important to use as much data information as possible and avoiding overfitting. This is very important for the decision tree and neural network.

In this research, we combine the classification and regression tree with the chi-squared automatic interaction detector tree by means of the 100 times 5~7 fold

stratified cross-validation method to establish the decision tree model to make full use of data information and also to avoid overfitting. In addition, we use Schwarz Bayes Criterion to choose the number of hidden layers and hidden layer units, and use Levenberg-Marquardt optimization algorithm, weight decay, and preliminary training method to train the neural network. We also establish a reliable neural network model to make full use of the data information and also to avoid overfitting and inferior local minima.

(3) Quick and efficient establishment of a logistic regression. Conventional screening variable methods of the logistic regression include the forward-entry method, backward-elimination method, stepwise and best subset method. The first three methods are related to how to choose the P value, which is the cutoff point where the variables enter and (or) are removed from the model. It is obvious that P value is subjectively chosen and it is thought that 0.05 slentry is too stringent to include some important variables from the model in some cases. For all the combination of variables, The best subset method can give the corresponding chi-square value, but fails to decide which kind of combination is optimal. Therefore, it is very important to select variables quickly and effectively to establish an accurate and reliable model.

In this thesis, we combine the best subset method with the Akaike Information Criterion to screen variables quickly and easily. The method not only takes into account the generalization ability of the model but also saves the “trouble” of artificially choosing of P value. Thus we have built a logistic regression model which is superior to conventional screening methods.

(4) Comparison of the generalization ability in case of small sample. Large amounts of reference show that multiple different studies on model prediction and classification technique in the biomedical field have been either applied to a larger data volume(from several hundred to several hundred thousand observations) or use the holdout method(one part of set for training and the remainder for testing) to asses the generalization ability of the model. But these studies are not related to how to make full use of the data information or how to compare the generalization ability when the sample is small (as one hundred observations or so). But the data set is likely be small and the number of variables is large at work. Data information will be lost and low confidence or even unreliable results will ensue(It is proved in chapter 5 of this thesis.) if the holdout method is adopted to evaluate the generalization ability

of the model. Therefore it is worth studying how to establish an effective model and make an objective evaluation of the generalization ability when the sample is small, which is the most one of the primary focuses of the study.

We adopt Monte Carlo simulation of sampling (2~10 fold stratified cross-validation, jackknife method, 100~1000 times bootstrap method (to be more specific, 0.632bootstrap)) validation technology in the research to make a reliable assessment of generalization errors and make a comparison of the generalization ability in order to achieve an objective evaluation of the three models and avoid the drawback of the holdout method. On the whole, the result shows that the generalization ability of NN is the strongest, followed by LR's, DT's in terms of the data of DPN.

(5) Adjustment of oversampling. When the data is obtained by oversampling (that is, separate sampling), the probability of model estimation is not based on the population but on the sample. There may be larger deviation if we predict the probability of disease of the overall population.

Because the source of the data is from oversampling, we use prior probability to adjust the posterior probability so that the adjusted results can predict the possibility of outbreak of diseases more objectively and accurately.

In a word, we use three methods (LR, DT, NN) to predict the probability of DPN. In case of small sample, we have made comparative studies and improvement in terms of (①Discretization of continuous variables scientifically, ②Utilization of data information sufficiently and avoiding overfitting, ③Quick and efficient establishment of a model, ④Utilization of data information efficiently and improvement the generalization ability, ⑤Efficient adjustment of oversampling to acquire more objective and accurate results), and have achieved the desired results. The concept of modeling and techniques could be conveniently and successfully applied to the field of biomedical studies and other fields.

Key words: logistic regression; decision tree; neural network; holdout method; cross-validation method; jackknife method; bootstrap method; oversampling; Diabetic Peripheral Neuropathy

目 录

第一章 引言	1
1.1 引言	1
1.1.1 糖尿病并发末梢神经病变发病及研究现状	1
1.1.2 数据挖掘方法与统计学方法简介	1
1.1.3 数据挖掘方法与统计学方法在医学领域预测性能比较研究现状	2
1.2 本论文主要的研究内容	2
1.2.1 本论文研究中的难点	2
1.2.2 本论文的主要研究内容和结构安排	3
第二章 数据来源与数据库整理	5
2.1 本章引论	5
2.2 数据来源	5
2.3 数据整理	5
2.4 对变量进行描述	12
2.4.1 定量变量统计描述	12
2.4.2 定性变量统计描述	12
2.5 小结	15
第三章 三种预测模型及泛化能力评价方法等的简介	16
3.1 本章引论	16
3.2 预测模型简介	16
3.2.1 Logistic 回归	16
3.2.2 决策树	18
3.2.3 神经网络	22
3.3 过抽样简介	24
3.4 ROC曲线简介	25
3.5 模型泛化能力的评价及三种Monte Carlo模拟抽样方法的应用	28
3.6 软件实现	30
3.7 本章小结	30
第四章 三种预测模型建模过程及建模结果	31
4.1 本章引论	31
4.2 Logistic回归建模过程及结果	31
4.2.1 变量选择	31
4.2.2 模型建立	35
4.2.3 先验概率调整	40

4.3 决策树建模过程及结果.....	40
4.3.1 变量选择.....	40
4.3.2 交叉验证法建立模型.....	41
4.4 神经网络建模过程及结果.....	43
4.4.1 变量选择.....	43
4.4.2 确定隐含层数.....	44
4.4.3 隐含层节点数及跳跃层的确定.....	44
4.4.4 构造MLP模型.....	45
4.5 三个模型拟合原始数据后的ROC面积比较的结果.....	45
4.6 最佳分割点.....	46
4.7 小结.....	47
第五章 三种模型预测性能比较结果.....	48
5.1 本章引论.....	48
5.2 分层交叉验证的比较结果.....	48
5.2.1 分层交叉验证的流程.....	48
5.2.2 2 折分层交叉验证的结果.....	49
5.2.3 3 折分层交叉验证的结果.....	53
5.2.4 4 折分层交叉验证的结果.....	58
5.2.5 5 折分层交叉验证的结果.....	62
5.2.6 6 折分层交叉验证的结果.....	66
5.2.7 7 折分层交叉验证的结果.....	71
5.2.8 8 折分层交叉验证的结果.....	75
5.2.9 9 折分层交叉验证的结果.....	79
5.2.10 10 折分层交叉验证的结果.....	84
5.2.11 10 次~100 次 2 折~10 折分层交叉验证ROC面积大小变化示意图.....	88
5.3 刀切法比较结果.....	89
5.3.1 刀切法对模型泛化能力评价实现流程.....	89
5.3.2 刀切法验证后ROC面积大小比较结果.....	90
5.4 三种方法 100~1000 次自引导法ROC面积比较的结果.....	90
5.4.1 自引导法对模型泛化能力评价实现流程.....	91
5.4.2 自引导法ROC面积大小比较结果.....	91
5.4.3 100 次~1000 次自引导法ROC面积大小变化示意图.....	96
5.5 小结.....	96
第六章 讨论.....	98
6.1 三种Monte Carlo抽样方法进行泛化能力结果的比较.....	98

6.2 三种模型的优缺点.....	99
6.3 MLP优化算法比较	100
6.4 过抽样的影响.....	100
6.5 Logistic回归分析中变量筛选方法.....	101
6.6 各种方法相互借鉴.....	101
第七章 总结和展望	103
7.1 本论文的主要工作和贡献.....	103
7.2 进一步工作的展望.....	104
参考文献	105
附录 1 变量的定义及赋值方法.....	110
附录 2 主要程序代码	112
致 谢	120
个人学习经历、工作情况、发表文章及参编著作.....	121
综 述	124

第一章 引言

1.1 引言

1.1.1 糖尿病并发末梢神经病变发病及研究现状

随着发展中国家人口老龄化以及生活方式的改变,糖尿病的发病人数急剧增加,至 2003 年全球糖尿病发病人数为 1.94 亿^[1],2006 年将近 2 亿,而到 2030 年发病人数可能会翻倍^[2]。在糖尿病易发生的并发症中,糖尿病神经病变具有高致死率和高致残率,是全身性并发症。该病变又以末梢神经病变(Diabetic Peripheral Neuropathy, DPN)发病最多、出现最早,它是肢体保护性的机械性感觉丧失、创伤性溃疡损伤并因此截肢的主要原因,严重影响患者的生活质量。但 DPN 病因学尚不清楚,对其症状进展与治疗的了解也很有限。

目前关于 DPN 的研究主要集中在发病机理、治疗方法的研究上^[3-4],此外也有一些涉及相关危险因素的研究^[5-6],如通过 DPN 发病的流行病学调查分析发现:DPN 的发病与性别、病情等无明显相关性而与血糖控制水平相关等特点。但总体来说对 DPN 发生相关因素的研究还不是很明确,尚待进一步研究。

由此可见,将统计学方法与数据挖掘方法应用于 DPN 发生相关因素的研究中,建立起准确可靠的模型来进行疾病的预测,从而为疾病的诊断和预防提供参考是一项很有意义也很重要的工作。然而,目前在 DPN 的相关研究中,尚未发现将数据挖掘方法与统计学方法结合起来,进行预测及其性能的比较。

1.1.2 数据挖掘方法与统计学方法简介

数据挖掘是找出数据中模式的过程。很多其它领域的思想、工具和方法都被应用于数据挖掘过程中,如计算机科学(包括机器学习、数据库技术)、统计学、数学等。其中统计学是数据挖掘领域的一个支柱。

传统的统计学所研究的主要是渐近理论,即当样本趋于无穷多时的统计性质。其主要考虑测试预想的假设是否与数据模型相吻合,即着眼于最适合的模型,建立一个推荐模型^[7],大部分统计分析是确定性的分析。

与传统的统计分析不同,数据挖掘过程是实验性的,其发展方向主要集中在方法改进及应用方面。与确定性分析不同,几乎所有的数据挖掘方法都集中于计算。很多学者进行了如何提高数据挖掘方法的效率、准确率等方面的研究^[8-9],如挖掘关联规则中 Apriori 算法的改进、结合贝叶斯推理技术改进决策树研究、基于分层神经网络的分类算法等。另外,数据挖掘的主要目的是发现,它不关心统计学领域中在回答一个特定的问题之前如何很好的收集数据,例如实验设计和调查设计,关心的只是如何发现其中的秘密。这种实验性的数据分析可以为统计

学发展提供重要的参考。

统计学与数据挖掘有着很多联系,数据挖掘中很多方法运用了统计学方法,如聚类分析、回归分析、贝叶斯方法等等,统计学方法是其核心。统计学与数据挖掘交叉的一部分是在现代统计学中起核心作用的“模型”。如今,数据挖掘方法和统计学方法已经结合起来,如大部分数据挖掘学习算法在创建规则以及修正“过度拟合”的模型时,使用了统计测试用来验证数据挖掘学习的模型和评估数据挖掘学习算法。

1.1.3 数据挖掘方法与统计学方法在医学领域预测性能比较研究现状

预测发生某种疾病的可能性是一项非常重要且具有挑战性的工作。数学方法和计算机技术的发展使复杂的模型预测成为可能。将数据挖掘方法与统计学方法应用于生物医学领域来进行疾病预测性能的比较,从而建立起更为准确可靠的模型是一个非常值得研究的方向。

一些基于数学、统计学和计算机的预测技术已逐渐应用在生物医学研究领域,但关于多种预测技术的预测性能比较的研究仍然很少,目前仅有少量类似的研究^[10-16]:如 Delen^[14]等人于 2004 年运用 Logistic 回归、决策树和神经网络对 20 多万乳腺癌病人的生存状况的预测性能比较研究;Ture^[15]等人 2005 年运用多种分类技术(Logistic 回归、判别分析、径向基函数等)对 694 例观测进行原发性高血压发生危险性的预测性能比较研究;2008 年陈建新^[16]等人采用四种方法(贝叶斯方法、RBF、SVM、Logistic 回归)对冠心病病人(共 1069 例)在中医诊断分类的准确性进行比较研究等。

然而这些研究在评价模型预测或分类技术时,或针对于较大的数据量(从几百例观测至几十万例观测),或对模型泛化能力比较时采用保持法(将数据集随机分成两部分一部分建模,一部分测试),并没有涉及到小样本时如何有效利用数据信息,并对模型泛化能力进行比较等问题。然而在实际工作中,很多时候数据集较小(例如 100 例左右),此时如果采用保持法进行模型泛化能力的比较时就会损失数据信息,导致比较结果的可靠性降低甚至不可靠^[17-20]。因此如何在数据量很有限的情况下,有效利用数据信息,建立起可靠的模型,并对模型泛化能力做出客观的评价,是一个实际工作中不可忽略并亟待解决的问题。

1.2 本论文主要的研究内容

1.2.1 本论文研究中的难点

本研究采用 Logistic 回归、决策树和神经网络对 DPN 发生的概率进行预测,在建模和预测性能比较研究中,主要存在以下五个难点:

(1) 科学地实现连续变量离散化方面。在一些科学研究中,人们通常对一

些连续变量的一个单位值的变化不感兴趣,或根据专业知识需将连续变量进行离散化,因此如何科学的实现连续变量离散化是一个值得研究的问题。

(2) 充分利用数据信息又防止过拟合方面。对于很灵活的建模方法,如在决策树和神经网络模型的构建中,当决策树叶子足够大或神经网络节点、训练次数足够多时,会对训练集数据产生过拟合,如何在防止过拟合的同时,又要保证充分利用数据信息(这在小样本时很关键),是一个关键点。

(3) 快速有效地构建 Logistic 回归模型方面。在采用 Logistic 回归方法建模时,变量选择的方法有很多,常用的有向前选择法、向后剔除法、逐步法、最优子集法,而前三种方法都要涉及到变量进入和(或)剔除的 P 值大小的选择问题^[21-22],显然 P 值的选取存在主观性,例如有些研究认为 $SLE=0.05$ 过于严厉^[21]。针对所有原因变量的组合情况,最优子集法均可以给出其对应的 χ^2 值,但却无法给出哪种组合最佳。如何快速有效地进行变量的筛选,构建准确可靠的 Logistic 回归模型是一个值得关注的问题^[23-26]。

(4) 有效利用数据信息提高模型泛化能力方面。如前所述,将不同领域的预测技术用于 DPN 的发生并对模型的泛化能力进行比较是一项具有实际意义的重要工作。本研究所采用的 DPN 数据集是一个以医院为基础的非匹配的病例对照研究资料,样本量小(病例组、对照组观测均为 137 例),观测指标多(候选指标 30 个),是医学科研工作中非常典型的一个实例。在这样数据量很有限的情况下,采用保持法对模型的泛化能力进行比较可靠性会降低,甚至不可靠。因此既能有效地利用数据信息,建立起更为可靠的预测模型,又能对模型泛化能力做出客观的评价,是本研究的难点,也是一个很值得研究的问题。

(5) 有效调整过抽样方面。本研究中样本的获取方式是来源于过抽样,因此用模型预测出的事件发生的概率是基于样本而不是基于总体的,此时对总体人群疾病发生的概率进行预测可能会存在较大的偏差。所以需要调整后验概率进行调整,从而使调整后的结果更能客观准确地预测疾病发生的可能性。

1.2.2 本论文的主要研究内容和结构安排

本论文针对 Logistic 回归、决策树和神经网络在 DPN 发生的预测性能比较研究中的难点,研究了相应的解决方案,提出了相应的解决方法,主要如下:

(1) 采用 χ^2 分割法对连续变量进行离散化,不仅使离散化后的变量各个等级之间划分得有意义,并且尽量使等级之间区分度最大,较好地实现了连续变量离散化。

(2) 采用 100 次 5~7 折分层交叉验证的方法, 将 CART 与 CHAID 法相结合, 建立起了决策树模型, 既充分利用数据信息又避免了过拟合现象的发生。此外, 在神经网络模型隐含层数和隐含层节点数目选取中, 采用 SBC 准则作为选择的标准, 在建模过程中利用 L-M 优化技术, 采用权重衰减和预训练的方法, 也达到了充分利用数据信息有效避免过拟合现象和局部最优现象的发生, 从而建立起了较为准确、可靠的模型。

(3) 在 Logistic 回归建模过程中, 采用最优子集法与 AIC 信息准则相结合, 对变量进行快速方便地筛选, 此法既考虑了模型的泛化能力又避免了 P 界值点选取的“烦恼”, 建立的模型也优于常规变量筛选法(如向前选择法、向后剔除法、逐步回归法、最优子集法)构建的 LR 模型。

(4) 针对 DPN 发病数据集的小样本特性, 采用 Monte Carlo 模拟抽样(分层交叉验证、刀切法、自引导法)的校正技术, 对模型的泛化误差作出可靠的评价, 进而对三种方法(LR、DT、NN)泛化能力进行比较, 有效地弥补了保持法的不足, 达到了客观评价模型泛化能力的目的。

(5) 本研究中, 样本的获取方式是来源于分离抽样, 因此用先验概率对后验概率进行调整, 使调整后的结果适用于人群预测疾病发生的可能性。

本论文以后的章节安排如下:

第二章 介绍数据来源与数据库整理; 第三章是 LR、DT、NN 三种方法及模型泛化能力评价等的简介; 第四章阐述三种预测模型的建模过程及建模结果; 第五章对各种预测模型结果的泛化能力进行比较; 第六章对结果进行讨论; 第七章是总结和展望。

第二章 数据来源与数据库整理

2.1 本章引论

本章主要介绍数据集的来源以及数据集的整理工作。数据整理工作很关键，对后续的数据分析过程以及分析结果都具有重要影响。数据整理后给出数据集中相关变量的统计描述结果。在一些科学研究中，人们对一些连续变量中的一个单位值的变化通常不感兴趣，或有时根据数据分析的需要将连续变量离散化，使得分段之后的结果变量在各段之间的差异最大。因此，连续变量离散化也是一个比较关键的环节。本研究采用 χ^2 分割法对连续变量进行离散化，使离散化后的变量各个等级之间划分得有意义，并尽量使等级之间区分度最大，很好地实现了连续变量离散化。

2.2 数据来源

数据来源于 2002 年 12 月至 2003 年 11 月以某专科医院为基础的非匹配的病例对照研究的观察结果。病例组为 2 型糖尿病合并末梢神经病变的患者（本文简称为 DPN，后同），对照组为同期就诊的无末梢神经病变的 2 型糖尿病患者，病例组与对照组均为 137 例。病例组和对照组均符合入排标准。各种变量的定义及赋值方法见附录 1。

2.3 数据整理

根据数据库的实际情况，本研究主要进行了包括异常值、数据信息错误、缺失值填充、新变量生成等方面的整理工作。

1. 定量变量

在该数据集中定量变量并不多，主要有：年龄（age）、糖尿病病程（dmbc）、吸烟量（smoke3）、身高体重指数（BMI）、吸烟年限（smokenx）、糖化血红蛋白含量（HbA1c1，HbA1c%）6 个。

（1）异常值和数据错误

主要包括数据输入错误和逻辑错误：例如数据录入过程中某个指标是否被正确录入（如是否吸烟实际录入只能取 1、2、3 而不可能为 0 或 26）；数据若是缺失是否为 0（如吸烟量缺失经过核查为 0 即不吸）；不是 DPN 患者却出现了 DPN 病程的数值；糖尿病病程反而小于 DPN 病程；是否吸烟和开始吸烟年龄存在矛盾；是否戒烟和戒烟年限之间存在矛盾。

对于异常值的检查如年龄低于 18 岁则诊断为异常数据，进一步确认后方可进行变量的确认。

类似的问题较多，对在数据核查过程中存在的问题，不能简单的主观臆断、凭想象进行修改或一删了之，均应在核查原始资料并与研究者确认后将相关错误改正过来。

（2）缺失值填充

缺失值填充的方法主要包括单值替换、类均值替换、回归替换。单值替换主要包括应用均值、中位数、众数对缺失值进行填充；类均值替换是使用其它变量或变量组的子组中的均值进行缺失值的填补；回归替换是利用变量和其它变量之间的线性关系或其它关系进行缺失值的填补。总之，对部分缺失值的填补应尽可能保持原变量的原始分布且接近于真实值。

本研究涉及到需要填充的变量主要有：BMI（缺失值共 9 个）、糖尿病病程 dmbc（缺失值共 2 个）。对 BMI、dmbc 采用中位数进行填充。

（3）根据专业知识生成新的变量

①生成吸烟指数（smokeindex）

吸烟指数=每天吸烟支数×吸烟年限

（4）连续变量离散化

①根据公认的标准进行划分

（a）吸烟指数分级

WHO（1984）建议采用吸烟指数做为评价吸烟危害指标。在本研究中生成吸烟指数（smokeindex）做为吸烟危害的衡量指标。吸烟指数 ≤ 200 为轻度吸烟，200~400 为中度吸烟， ≥ 400 为重度吸烟。因此在本研究中将吸烟指数（smokeindex）分级生成新的变量名为吸烟指数分级（smokeindexf）。

（b）BMI 分级：按以下标准将 BMI 分级

0 正常 BMI <25 1 超重 $25 \leq \text{BMI} < 28$ 2 肥胖 BMI ≥ 28

（c）试验室指标分级

将试验室指标按照其相应的诊断标准分为正常、异常等。指标如尿素氮（BUN）、ALT（丙氨酸转氨酶）、AST（丙草酸转氨酶）等。但在数据收集过程中，部分试验室指标缺失较多（如肌酐（Cr 缺失 44 个）、低密度脂蛋白（LDL 缺失 39 个）、高密度脂蛋白（HDL 缺失 41 个）等），影响研究结果的可信度，故根据实际情况不纳入。具体试验室指标见附表 1。

②连续变量离散化

在一些科学研究中，人们对一些连续变量中的一个单位值的变化通常不感兴趣，如年龄增加 1 岁对发病的影响并不重要。或有时根据数据分析需要（如原因变量与结果变量之间存在复杂的非线性关系，不能很好地发现两者之间的关系）将连续变量离散化，使得分段之后结果变量在各段之间的差异最大。但值得注意

的是：对变量离散化后如果该连续变量与结果变量之间非线性倾向很大，此时效果可能会不错，但可能会忽略一些重要的点的影响（如极值点或驻点）^[27-28]。因此，应尽量要找出变量之间存在的关系（除非是研究需要，要将连续变量进行离散），若发现变量之间是非线性的关系，那么可以通过变量变换找到变量间的线性关系的表达式。

将连续变量离散化有很多种方法^[29]：主要有非监督离散化法和监督离散化法。非监督离散化方法不使用结果变量的信息，仅对连续变量进行分割。主要方法有：

（a）等宽方法：将连续变量划分成具有相同宽度的区间，区间的多少由研究者自己定，这种方法可能受到离群点的影响。

（b）等频率法：将相同数量的对象放进每个区间。

监督离散化的方法有：

（a）十分位数法：按频数分布法将连续变量在结果发生中的构成情况列出，找出构成波动点，把分割点找出。

（b）基于熵的划分方法：开始将初始值切分成两部分，使得两个结果区间产生最小熵。该技术因为假定区间包含有序值的集合，所以只需要把每个值看作可能的分割点。然后，取一个区间，通常选取具有最大熵的区间，重复分割过程，直到区间的个数达到用户指定的个数，或者满足终止条件。

首先，定义熵。设 k 是不同的类标号数， m_i 是某划分的第 i 个区间中观测的个数，而 m_{ij} 是区间 i 中类 j 的观测的个数。第 i 个区间的熵 e_i 由式（2-1）计算：

$$e_i = \sum_{j=1}^k p_{ij} \log_2 p_{ij} \quad (2-1)$$

其中， $p_{ij} = \frac{m_{ij}}{m_i}$ 是第 i 个区间中类 j 的概率。

划分的总熵 e 是每个区间的熵的加权平均：

$$e = \sum_{i=1}^n w_i e_i \quad (2-2)$$

其中， m 是观测的总个数， $w_i = \frac{m_i}{m}$ 是第 i 个区间的观测的比例，而 n 是区间个数。可见区间的熵是区间纯度的度量。如果一个区间只包含一个类的值（该区间非常纯），则熵值为 0。如果一个区间中的各类出现的频率相等（该区间尽可能不纯），则熵值最大。

连续变量离散化是实际工作中常常遇到的问题。虽然在本研究中，连续变量

均以原连续变量的形式进入，但仍以连续变量年龄（age）为例，尝试多种方法对年龄进行划段，用以说明在实际工作中若需要进行连续变量离散化时，应试着采用不同的离散化方法，结合专业知识和统计学知识，对连续变量进行合理划分。

（a）首先，年龄的频数分布如图 2.1 所示。现以将年龄分割为 5 段为例，应用常见的连续变量的划分方法进行划分。




图2.1 年龄频数分布图

（b）等宽分割法。该法将年龄（在该数据集中年龄最小为 20 岁，最大为 84 岁）分成 5 段，即 20~33，33~46，46~59，59~72，72~，其频数分布如图 2.2 所示。

DNF（是否 DPN）

年龄等宽法分 5 段

Frequency Percent Row Pct Col Pct	1	2	3	4	5	Total
0	2 0.73 1.46 50.00	18 6.57 13.14 50.00	42 15.33 30.66 48.28	63 22.99 45.99 52.94	12 4.38 8.76 42.86	137 50.00
1	2 0.73 1.46 50.00	18 6.57 13.14 50.00	45 16.42 32.85 51.72	56 20.44 40.88 47.06	16 5.84 11.68 57.14	137 50.00
Total	4 1.46	36 13.14	87 31.75	119 43.43	28 10.22	274 100.00

图 2.2 年龄等分 5 段后的频数分布情况

注：DNF=0 对照组，指无末梢神经病变的 2 型糖尿病患者

DNF=1 病例组，指 DPN 患者组，以下同。

由频数分布图可见划分得不太合理，病例组和对照组在各年龄段的构成比几乎相同（如第 1 个年龄段 20~33 岁中，对照组与病例组均为 0.73%，第 2 个年龄

段病例组和对照组均为 6.57%等), 并且病例组和对照组的构成比在 1~4 年龄段一致成上升趋势, 这样将年龄分段后不能使得病例组和对照组的构成在各段之间差别尽可能地大, 也就是说, 不能找到使纯度 (或构成差异) 尽可能大的分割点 (具体见 Percent 行)。

(c) 等频率分割法。该法将年龄划分为 5 段, 即 <48, 48~56, 56~62, 62~69, 69~。

DNF (是否 DPN)

年龄等频率法分 5 段

Frequency Percent Row Pct Col Pct	1	2	3	4	5	Total
0	23 8.39 16.79 46.94	30 10.95 21.90 51.72	27 9.85 19.71 51.92	29 10.58 21.17 50.88	28 10.22 20.44 48.28	137 50.00
1	26 9.49 18.98 53.06	28 10.22 20.44 48.28	25 9.12 18.25 48.08	28 10.22 20.44 49.12	30 10.95 21.90 51.72	137 50.00
Total	49 17.88	58 21.17	52 18.98	57 20.80	58 21.17	274 100.00

图 2.3 年龄等频率划分 5 段后的频数分布情况

由频数分布表可见划分的也不太合理, 具体分析同上 (注意: 因为相同年龄的观测较多, 只能近似等频率)。

(d) 十分位数间距法。将年龄划分为如下十段: 41~、48~、52~、56~、60~、62~、65~、69~、72~、74~。现欲根据年龄的十分位数将年龄分成 5 段。十分位数划分后的频数分布如图 2.4 所示。由 Percent 行可以看出, 病例组 (DNF=1) 的构成比从第 1 十分位数年龄段开始到第 4 十分位数呈平稳上升趋势至 5.11%, 从第 5 十分位数开始构成比均有波动。比如可将第 4、5、6、7 十分位数作为分割点 (当然还可根据情况将其它分位数点做为分割点) 划分如下: <56, 56~、62~、65~、69~。应指出的是用十分位数法进行划分只是一个大致的划分, 划分方法不是唯一的。

DNF (是否 DPN)

年龄十分位数分段

Frequency Percent Row Pct Col Pct	1	2	3	4	5	6	7	8	9	10	Total
0	14 5.11 10.22 53.85	9 3.28 6.57 39.13	17 6.20 12.41 54.84	13 4.74 9.49 48.15	13 4.74 9.49 52.00	14 5.11 10.22 51.85	13 4.74 9.49 54.17	16 5.84 11.68 48.48	16 5.84 11.68 53.33	12 4.38 8.76 42.86	137 50.00
1	12 4.38 8.76 46.15	14 5.11 10.22 60.87	14 5.11 10.22 45.16	14 5.11 10.22 51.85	12 4.38 8.76 48.00	13 4.74 9.49 48.15	11 4.01 8.03 45.83	17 6.20 12.41 51.52	14 5.11 10.22 46.67	16 5.84 11.68 57.14	137 50.00
Total	26 9.49	23 8.39	31 11.31	27 9.85	25 9.12	27 9.85	24 8.76	33 12.04	30 10.95	28 10.22	274 100.00

图 2.4 年龄十分位数划分后的频数分布情况

十分位数法将年龄分成 5 段后的频数分布如图 2.5 所示：

DNF (是否 DPN)

年龄十分位数法分 5 段

Frequency Percent Row Pct Col Pct	1	2	3	4	5	Total
0	53 19.34 38.69 49.53	27 9.85 19.71 51.92	13 4.74 9.49 54.17	16 5.84 11.68 48.48	28 10.22 20.44 48.28	137 50.00
1	54 19.71 39.42 50.47	25 9.12 18.25 48.08	11 4.01 8.03 45.83	17 6.20 12.41 51.52	30 10.95 21.90 51.72	137 50.00
Total	107 39.05	52 18.98	24 8.76	33 12.04	58 21.17	274 100.00

图 2.5 年龄十分位数划分 5 段后的频数分布情况

可见十分位数法划将年龄分成 5 段后，由图 2.5 可见，划分得也不太合理，病例组和对照组的构成比在 1~3 年龄段一致成下降趋势（如病例组构成比从 19.71%下降至 4.01%），具体见 **Percent** 行）。仍然不能较好地将发病在各年龄段之间的差异区分开来。

(e)熵值法。该法将变量分为 5 段，即<47.5, 47.5~50.5, 50.5~58.5, 58.5~62.5, 62.5~（注：在实际分段时可取整））。

由划分后的频数分布图 2.6 可见，病例组和对照组在各年龄段的构成比不相同，例如从病例组的构成比可以看出，在 1~5 年龄段构成比呈下降-上升-下降-上升的波动，这样将年龄分段后可使病例组和对照组的构成在各段之间差别尽可能地大，达到较好的连续变量离散化的目的。

DNF (是否 DPN)

年龄熵值法分 5 段

Frequency Percent Row Pct Col Pct	1	2	3	4	5	Total
0	23 8.39 16.79 46.94	17 6.20 12.41 60.71	22 8.03 16.06 44.00	28 10.22 20.44 62.22	47 17.15 34.31 46.08	137 50.00
1	26 9.49 18.98 53.06	11 4.01 8.03 39.29	28 10.22 20.44 56.00	17 6.20 12.41 37.78	55 20.07 40.15 53.92	137 50.00
Total	49 17.88	28 10.22	50 18.25	45 16.42	102 37.23	274 100.00

图 2.6 采用熵值法将年龄划分 5 段后的频数分布情况

(f) χ^2 分割法。具体步骤如下：开始将初始值切分成两部分，使得两个结果区间产生的 χ^2 值最大。采用穷尽搜索的过程，重复分割过程，计算 χ^2 值，直到区间的个数达到用户指定的个数，或者满足终止条件。采用 χ^2 分割法将变量分为 5 段 (<47.5 , $47.5\sim50.5$, $50.5\sim58.5$, $58.5\sim62.5$, $62.5\sim$ (注：在实际分段时可取整))，其频数分布如图 2.7 所示：

DNF (是否 DPN)

年龄 χ^2 分割法分 5 段

Frequency Percent Row Pct Col Pct	1	2	3	4	5	Total
0	23 8.39 16.79 46.94	17 6.20 12.41 60.71	22 8.03 16.06 44.00	28 10.22 20.44 62.22	47 17.15 34.31 46.08	137 50.00
1	26 9.49 18.98 53.06	11 4.01 8.03 39.29	28 10.22 20.44 56.00	17 6.20 12.41 37.78	55 20.07 40.15 53.92	137 50.00
Total	49 17.88	28 10.22	50 18.25	45 16.42	102 37.23	274 100.00

图 2.7 采用 χ^2 分割法将年龄划分 5 段后的频数分布情况

可见 χ^2 分割的结果与熵值分割的结果相同。

由此可见，有监督的分段要好于等宽和等频率的无监督分段方法，它能把结果变量在该段中分布最有差异的连续变量（原因变量）的分割点找出来。一般不存在适合于所有连续变量离散化的通用方法。在本研究中，采用 χ^2 分割法，分

割的效果与熵值分割结果相同，且 χ^2 检验的思想易于理解，可作为连续变量离散化时的一种候选方法，研究者可结合专业知识和分割变量的各种方法进行综合考虑，在需要时对连续变量做出合理的离散化。

2. 定性变量

(1) 数据核查

在本研究中，定性变量有很多，对数据进行核查（如若饮茶则饮茶口味不应缺失）的步骤基本同定量变量。

(2) 研究中涉及到的定性变量

通过专业知识、数据可靠性及数据缺失情况进行综合分析后，本研究主要涉及到的定性变量有 28 个：性别 (sex)、职业 (occup1)、婚姻 (hunyin1)、民族 (mz)、是否有 AD (chd)、胰岛素否 (pgif)、血控方法 (bpkzff)、吸烟指数分级 (smokeindexf)、DM 后吸烟否 (smokedmf)、是否有 DM 视网膜病变 (drf)、是否有 DM 性肾病 (dnrf)、主食过量否 (zsglf)、副食过量否 (fsglf)、饮咖啡情况 (coffeef)、中风史 (zfs)、chd 史 (chds)、手术创伤否 (csf)、肾病史 (sbs)、饮酒情况 (drinkf)、饮茶情况 (teaf)、是否有缺血性心脏病 (ischemia)、bmi 分级 (bmif)、肥胖史 (fps)、是否发生高尿酸血症 (huf)、dm 家族史 (dms)、体力活动水平 (zlsjf)、锻炼情况 (sfdl)、高血压否 (hbpf)。

2.4 对变量进行描述

2.4.1 定量变量统计描述

表 2.1 两组定量变量统计描述

定量变量	对照组	病例组
	M (Q1~Q3)	M (Q1~Q3)
age (年龄)	60 (49~67)	60 (49~67)
dmhc (DM 病程)	3 (1~8)	9 (3~14)
bmi (BMI)	24.68 (22.67~27.60)	25.28 (23.32~28.00)
hba1c1 (HbA1c%)	6.7 (5.8~7.6)	7.7 (7.0~8.7)

2.4.2 定性变量统计描述

表 2.2 两组定性变量分布情况

变 量	对照组	病例组	统计量	P
性别 (sex)			0.0146	0.9038
女	70 (51.09)	71 (51.82)		
男	67 (48.91)	66 (48.18)		
合计	137	137		
民族 (mz)				

变 量	对照组	病例组	统计量	P
汉	137	137		
合计	137	137		
职业(occup1)			2.1434	0.1432
脑力	84(61.31)	72(52.55)		
体力	53(38.69)	65(47.45)		
合计	137	137		
婚姻(hunyin1)			0.0566	0.8120
正常	127(92.70)	128(93.43)		
异常	10(7.30)	9(6.57)		
合计	137	137		
是否有 AD(chd)			7.4273	0.0064
是	33(24.09)	54(39.42)		
否	104(75.91)	83(60.58)		
合计	137	137		
胰岛素否(pgif)			1.1849	0.2764
是	33(24.09)	41(29.93)		
否	104(75.91)	96(70.07)		
合计	137	137		
血控方法(bpkzff)			*	0.8537
单纯饮食控制(1)	6(4.38)	4(2.92)		
运动疗法(2)	1(0.73)	2(1.46)		
口服降糖药(3)	92(67.15)	87(63.50)		
胰岛素注射(4)	1(0.73)	1(0.73)		
口服降糖药与胰岛素注射联合(5)	37(27.01)	43(31.39)		
合计	137	137		
吸烟指数分级(smokeindexf)			0.8820	0.8298
不吸	105(76.64)	100(72.99)		
轻	11(8.03)	14(10.22)		
中	4(2.92)	6(4.38)		
重	17(12.41)	17(12.41)		
合计	137	137		
DM 后吸烟否(smokedmf)			0.5400	0.4624
否	27(19.71)	32(23.36)		
是	110(80.29)	105(76.64)		
合计	137	137		
是否有 DM 视网膜病变(drf)			55.1262	0.0000
否	131(95.62)	79(57.66)		
是	6(4.38)	58(42.34)		
合计	137	137		
是否有 DM 性肾病(dnrf)			46.2791	0.0000
否	131(95.62)	85(62.04)		
是	6(4.38)	52(37.96)		
合计	137	137		

变 量	对照组	病例组	统计量	P
DM 后主食过量否(zsglf)			3.8056	0.0511
否	13(9.49)	5(3.65)		
是	124(90.51)	132(96.35)		
合计	137	137		
副食过量否(fsglf)			12.8885	0.0003
否	23(16.79)	5(3.65)		
是	114(83.21)	132(96.35)		
合计	137	137		
饮咖啡情况(coffeef)			*	0.4158
经常(多于3次/周,连续1年以上)(1)	5(3.65)	3(2.19)		
偶尔(2)	52(37.96)	44(32.12)		
否(3)	80(58.39)	90(65.69)		
合计	137	137		
中风史(zfs)			0.3475	0.2457
是	18(13.14)	12(8.76)		
否	119(86.86)	125(91.24)		
合计	137	137		
chd 史(chds)			6.8429	0.0089
是	15(10.95)	4(2.92)		
否	122(89.05)	133(97.08)		
合计	137	137		
手术创伤(csf)			7.9837	0.0047
否	94(68.61)	114(83.21)		
是	43(31.39)	23(16.79)		
合计	137	137		
肾病史(sbs)			*	1.0000
是	2(1.46)	2(1.46)		
否	135(98.54)	135(98.54)		
合计	137	137		
饮酒情况(drinkf)			2.3476	0.3092
否(0)	112(81.75)	121(88.32)		
偶尔(1)	10(7.30)	6(4.38)		
经常(2)(多于1次/周,连续1年以上)	15(10.95)	10(7.30)		
合计	137	137		
饮茶情况(teaf)			5.0543	0.0799
否(0)	26(18.98)	33(24.09)		
偶尔(1)	74(54.01)	82(59.85)		
经常(2)(多于3次/周,连续1年以上)	37(27.01)	22(16.06)		
合计	137	137		
是否有 ischemia(ischemia)			2.7906	0.0948

变 量	对照组	病例组	统计量	P
是	21 (15. 33)	12 (8. 76)		
否	116 (84. 67)	125 (91. 24)		
合计	137	137		
bmi 分级(bmif)			1. 9729	0. 3729
正常 (0)	78 (56. 93)	67 (48. 91)		
超重 (1)	28 (20. 44)	36 (26. 28)		
肥胖 (2)	31 (22. 63)	34 (24. 82)		
合计	137	137		
肥胖史 (fps)			0. 7682	0. 3808
是	33 (24. 09)	27 (19. 71)		
否	104 (75. 91)	110 (80. 29)		
合计	137	137		
是否发生高尿酸血症 (huf)			2. 7711	0. 0960
否	131 (95. 62)	124 (90. 51)		
是	6 (4. 38)	13 (9. 49)		
合计	137	137		
dm 家族史 (dmf)			0. 0595	0. 8072
是	60 (43. 80)	58 (42. 34)		
否	77 (56. 20)	79 (57. 66)		
合计	137	137		
体力活动水平 (zlsjf)			13. 0262	0. 0015
轻度 (0)	4 (2. 92)	6 (4. 38)		
中度 (1)	85 (62. 04)	109 (79. 56)		
重度 (2)	48 (35. 04)	22 (16. 06)		
合计	137	137		
锻炼情况 (sfdl)			3. 5261	0. 1715
经常 (0)	20 (14. 60)	12 (8. 76)		
偶尔 (1)	72 (52. 55)	68 (49. 64)		
几乎不 (2)	45 (32. 85)	57 (41. 61)		
合计	137	137		
高血压否 (hbpj)			9. 1503	0. 0025
否	61 (44. 53)	37 (27. 01)		
是	76 (55. 47)	100 (72. 99)		
合计	137	137		

注：*表示采用 Fisher 确切概率法 对照组指 2 型 DM 病人，病例组指 2 型 DM 合并末梢神经病变组

2.5 小结

在本章中介绍了数据库整理的大致步骤及其结果，给出了相关变量的统计描述情况。并以连续变量年龄为例，给出了连续变量离散化的几种方法，且采用 χ^2 分割法也达到了比较理想的效果。

第三章 三种预测模型及泛化能力评价方法等的简介

3.1 本章引论

在本章中对 Logistic 回归、决策树、神经网络这三种预测模型的建模方法进行简要介绍。由于在本研究中涉及到了 ROC 面积、过抽样及模型泛化能力评价方法的相关内容，故一并做一简要介绍。

3.2 预测模型简介

3.2.1 Logistic 回归

3.2.1.1 模型简介^[28]

Logistic 回归分析中的结果变量与自变量之间的关系是非线性的，非线性关系可以通过 logit 变换使其被转换为线性关系。Logistic 回归模型如下所示：

$$\ln\left(\frac{p_i}{1-p_i}\right) = \alpha + \sum_{k=1}^K \beta_k x_{ki} \quad (3-1)$$

其中， $p_i = P(y_i = 1 | x_{1i}, x_{2i}, \dots, x_{ki})$ 为在给定系列原因变量 $x_{1i}, x_{2i}, \dots, x_{ki}$ 的值时的事件发生概率， K 为总的原因变量个数。

3.2.1.2 Logistic 回归系数分析及检验

Logistic 回归系数的最大似然估计（MLE）是总体参数的渐近无偏和有效的点估计。Logistic 回归系数的 MLE 估计近似服从正态分布，所以可以直接对回归系数进行假设检验，主要采用 χ^2 检验和似然比检验。

3.2.1.3 拟合优度检验

主要有 Pearson χ^2 、偏差、Hosmer-Lemeshow 检验、信息度量指标（如 AIC、SBC）等。

3.2.1.4 变量间非线性检测

在 Logistic 回归中，链接函数是 logistic 函数，要求原因变量与 $\log it P$ 之间是线性的，否则系数的估计会有偏差。因此，观察各连续变量与 $\log it P$ 之间是否是线性关系也是很重要的一个步骤。在本文中通过绘制各连续变量与 $\log it P$ 值之间的散点图，来探索变量之间是否存在线性关系。具体的做法是^[28,30]：计算变量的分位数（如四分位数或五分位数等），将变量分成相应的几个段，计算每段的

$\log itP$ 值, 将各段的均值与 $\log itP$ 绘制散点图, 观察变量间是否存在线性趋势。

$\log itP$ 值可通过以下公式计算^[30]:

$$\ln \left(\frac{m_i + \frac{\sqrt{M_i}}{2}}{M_i - m_i + \frac{\sqrt{M_i}}{2}} \right) \quad (3-2)$$

其中, m_i 是指阳性事件发生数, M_i 指总观测例数, i 指划分的段数。

3.2.1.5 建模方法简介

(1) 向前选择法: 逐个将有统计学意义 ($\text{slentry}=p$) 的变量引入进入模型直至不再有统计学意义的变量进入模型为止。

(2) 向后剔除法: 从所有变量全部进入模型开始, 依次将无统计学意义的变量剔除 ($\text{slstay}=p$) 模型, 直至不再有无统计学意义的变量在模型中为止。

(3) 逐步法: 与向前选择法相似, 只不过每次向前选择后又加入了向后剔除的过程, 在 SAS 软件中可通过设定进入和剔除的标准 ($\text{slentry}=p_1$ 、 $\text{slstay}=p_2$) 来实现。

(4) 最优子集法^[31]: 最优子集选择基于似然得分统计量, 这种方法分别对包含一个、两个、三个变量等等, 直至包含所有原因变量的模型, 输出各种原因变量组合时的得分。

(5) 最优子集法+AIC:

(1)~(3)方法都涉及到了变量进入和剔除模型的 P 界值点的选择问题^[21-22], 因为 P 值的选取存在主观性, 例如有些研究认为 $\text{SLE}=0.05$ 过于严厉^[21]。针对所有原因变量的组合情况, 最优子集法均可以给出其对应的 χ^2 值, 但却无法给出哪种组合最佳。因此, 还需要在最优子集法选出候选变量组合的情况下找出哪种组合较优。此时, AIC 信息准则 (Akaike Information Criterion, 简记为 AIC)^[32] 就能发挥其作用了。极大似然原理是统计学中估计参数的一种方法, Akaike 把这个方法加以修正, 提出了一种较为一般的模型选择标准, 称为 Akaike 信息准则。AIC 统计量是在对数似然函数最大值上添加了变量数的惩罚项。

对变量的选择可利用信息准则指标, 其根据原因变量的复杂性对似然值进行惩罚。因此在本研究中将最优子集法结合 AIC 值, 找出 AIC 最小值对应的组合, 既能压缩变量、提高泛化能力, 又可避免前三种方法设定入选或剔除的 P 值大小的“痛苦”。

3.2.2 决策树

3.2.2.1 决策树模型简介^[33-35]

1. 决策树的基本原理

决策树是一种非线性的判别分析的方法，它通过原因变量竞争分裂，分裂成一系列更小的子群。在树的每个分支中重复迭代此过程，在某种标准下，选择与结果变量有最强关联的原因变量进行分裂^[35-36]。它首先对数据进行处理，利用归纳法生成可读的规则，然后使用该规则对新数据进行分析。本质上决策树是通过一系列规则对数据进行分类的过程。决策树技术发现数据模式和规则的核心是采用递归分割（recursive partitioning）的贪婪算法（greedy algorithm）。决策树主要有二元分支（二元分裂，binary split）树和多分支（多元分裂，multiway split）树。一般采用二元分裂，因为二元分裂在穷举搜索中更加灵活。




图 3.1 常见的决策树形式

2. 构造决策树思路


构造一个决策树分类器，它的输入是一组带有类别标记的例子，构造的结果是一棵二叉或多叉树。构造决策树的方法是采用自上而下的递归分割，采用贪婪算法，从根节点开始，如果训练集中的所有观测是同类的，则将其作为叶子节点，节点内容即是该类别标记。否则，根据某种策略选择一个属性，按照属性的各个取值，把训练集划分为若干个子集合，使得每个子集上的所有例子在该属性上具有同样的属性值。然后再依次递归处理各个子集，直到符合某种停止条件。

3. 递归分割的分裂标准

决策树的建立从根节点开始进行分割（对于连续变量将其分段），穷尽搜索各种可能的分割方式，通过分裂标准（通常用结果变量在子节点中变异的减少的多少来作为标准）来决定哪个原因变量做为候选分割变量。根节点分割后，子节点会象根节点一样重复分割过程，分割在该子节点下的观测一直到符合某种条件停止分割。分裂标准主要有以下几个指标，按照结果变量的分类如下：

（1）结果变量是分类变量。当结果变量是分类变量时生成的树称之为分类树。其分裂的标准主要有以下 3 个：

①纯度的减少指标：如图 3.2 所示。



$$\text{纯度减少: } \Delta i = i(0) - \left(\frac{n_1}{n_0} i(1) + \frac{n_2}{n_0} i(2) + \frac{n_3}{n_0} i(3) + \frac{n_4}{n_0} i(4) \right)$$

图 3.2 决策树分裂纯度减少标准示意图

其中 $i(\cdot)$ 是指节点纯度的计算值。Gini 系数变化和 entropy 变化都基于纯度减少原理：

(a) Gini 系数变化 (ΔGini) [17]

该指标是用来测量节点纯度的指标, 其中 Gini 系数定义为：

$$1 - \sum_{j=1}^r p_j^2 = 2 \sum_{j < k} p_j p_k \quad (3-3)$$

其中 $p_1, p_2, \dots, p_r$ 是指第 r 类在某节点中的概率。 r 指分类变量的类别。一个完全纯的节点 Gini 系数为 0, 随着节点内部种类的增加, Gini 系数趋近于 1, Gini 系数越大说明节点越不纯。

(b) 熵值变化 ($\Delta \text{entropy}$) [37-38]

该指标用来对分类资料变异性进行度量, 其中熵值定义为：

$$H(p_1, p_2, \dots, p_r) = - \sum_{i=1}^r p_i \log_2(p_i) \quad (3-4)$$

② χ^2 检验 [39]

分类树的分裂能整理成列联表的形式, 行代表子节点, 列代表结果变量的类别, 单元格里是相应类别的频数。采用 Pearson χ^2 检验用来判断分裂的价值。

$$\chi_v^2 = \sum \frac{(O - E)^2}{E} \quad (3-5)$$

其中 $v = (r - 1)(B - 1)$, r 指结果变量的水平数, B 指原因变量的分类数 (即树的分支)。由此可见, 列联表越大, 即分支越多, χ^2 值越大。 χ^2 分割标准是用 χ^2

检验的 P 值做为分裂的标准。为计算方便起见，一般把求得的 P 值进行对数变换，即： $\log worth = -\log_{10}(P)$ ， $\log worth$ 随 P 值的减少而增大。

(2) 结果变量是连续变量。当结果变量是连续变量时生成的树称之为回归树。其分裂的标准主要有以下 3 个：

①纯度的减少指标^[40]：与 Gini 系数和 Entropy 值不同，由于原因变量是连续的，所以纯度的衡量标准是样本的方差，如公式 (3-6) 所示。

$$i(t) = \frac{1}{n_t} \sum_{j=1}^{n_t} (y_{jt} - \bar{y}_t)^2 \quad (3-6)$$

其中， $i(t)$ 指第 t 个节点的纯度， n_t 指第 t 个节点的观测数。 y_{jt} 指第 t 个节点的第 j 个结果变量的观测值， $\bar{y}_t$ 指第 t 个节点的结果变量的均值。

② F 检验

$$F = \left(\frac{SS_{\text{组间}}}{SS_{\text{组内}}} \right) \left(\frac{n-B}{B-1} \right) \sim F_{B-1, n-B} \quad (3-7)$$

其中 B 指分裂的分支数， n 指总观测例数。通过 F 值计算 P 值。 P 值用来做为分裂标准同分类树中的 χ^2 检验的 P 值作用。

4. 剪枝

最大的决策树对训练集的准确率能达到 100%，但其结果往往会导致过拟合（对信号和噪声都适应）。因此建立的树模型不能很好地推广到总体中的其他样本中去。同样，太小的决策树仅含有很少的分支，会导致欠拟合。一个好的树模型有低的偏倚（适应信号）和低的方差（不适应噪声），模型的复杂性往往在偏倚和方差之间做一个折中，因此要对树进行剪枝。剪枝方法主要有前剪枝和后剪枝。

(1) 前剪枝（上-下停止规则）。类似于回归分析中向前选择法选择变量。

向前停止的规则主要包括：限制树的深度、限制断裂的数量（每个节点中的观测例数）、依据假设检验的 P 值（如 χ^2 检验或 F 检验的 P 值，若不满足统计学意义则停止生长）。

(2) 后剪枝（下-上停止规则）。类似于回归分析中向后剔除法选择变量。

通过长成一个大的树后，然后从下向上进行剪枝。后剪枝需要有两个条件：

一个条件是要有一个分类或预测性能的评价方法，最简单的是将数据集分成训练集和测试集。测试集用来进行模型的比较。但是存在一个问题是：当数据集小时，数据集拆分会降低拟合度；另一个条件是要有一个选择模型的标准，如准确度、利润、误差均方等。

有一些研究者利用仿真数据进行了许多次试验,研究发现:前剪枝通常比后剪枝快,但不如后剪枝效果好^[17,41]。在 SAS 的 EM 模块采用的是混合剪枝的方法,决策树的基本原理比较简单,其目的是:找出在子节点中能达到最大同质性的变量及其分割点。很多的研究者针对决策树改进的不同方面提出了不同的算法如 ID3、CHAID、CART 等方法。它们的基本原理是相通的,不同之处在于树的每一层允许的拆分点的数目(如 CART 是二分支树)、建树时拆分点的选择原则(集中在递归分割的分裂标准的选择、分裂搜索捷径的选择、加快搜索速度及防止穷举搜索造成“组合爆炸”等)、为防止过度拟合该怎样限制树的成长、如何对算法进行优化等方面。

5. 分类和回归树^[17] (CART:Classification and Regression Tree)

其特点是二分支树的结构,即根节点包含所有样本,在一定的分裂规则下,根节点被分裂为两个子节点,这个过程又在子节点上重复进行,直至不可再分,成为叶节点为止。分裂的标准一般采用纯度减少(如 Gini 系数)的标准。

6. 卡方自动交互式检测树 (CHAID:Chi-squared Automatic Interaction Detector Tree)

其特点是基于 χ^2 检验基础之上。根节点包含所有样本,在一定的分裂规则下,根节点被分裂为两个或多个子节点,这个过程又在子节点上重复进行,直至不可再分,成为叶节点为止。分裂的标准一般采用 χ^2 检验。

3.2.2.2 变量重要性检测

BFOS^[17]于 1984 年提出在决策树中对变量重要性进行检测的一种方法。




图 3.3 变量重要性示意图

$$\text{Importance}(x_j) = \sum_{t=1}^T \frac{n_t}{n} \Delta \text{Gini}(s(x_j), t) \quad (3-8)$$

其中 $s(x_j, t)$ 代表在第 t ($t=1, 2, \dots$) 个内部节点(包括最初分裂)的第 j 个输入变量。重要性是第 j 个输入变量在所有节点基尼系数的平均减少。 n 指总观

测数, n_t 是指第 t 个节点的观测数。具体如图 3.3 所示。

3.2.3 神经网络

3.2.3.1 神经网络简介

神经网络是一种模拟生物神经元工作方式的数学模型,被广泛应用于模式识别、预报预测等^[42-44]。最常用于预测的神经网络模型是多层感知器模型(Multilayer Perceptron, 简称 MLP)^[45-46]。MLP 是一种前馈型神经网络(如下图 3.4 所示),它的结构一般分为三层:输入层、输出层、隐含层(可有多层隐含层),每一层可包含一个或多个神经元,其中每一层的每个神经元和前一层相连接,同一层之间没有连接,其表达式如公式(3-9)~公式(3-11)所示。

$$g_0^{-1}(E(y)) = w_0 + w_1 H_1 + w_2 H_2 \quad (3-9)$$

$$H_1 = \tanh(w_{01} + w_{11}x_1 + w_{21}x_2 + w_{31}x_3) \quad (3-10)$$

$$H_2 = \tanh(w_{02} + w_{12}x_1 + w_{22}x_2 + w_{32}x_3) \quad (3-11)$$




图 3.4 前馈型神经网络示意图

其中 $g_0^{-1}(E(y))$ 是指目标变量(结果变量)的期望变换,即为输出激活函数的反函数,为非线性激活函数的线性合并。 $g_0(\cdot)$ 指输出激活函数。MLP 用的是 S 型激活函数(如双曲正切函数)。其中, w 指权重。 H 分别代表隐单元。 x 指原因变量。

3.2.3.2 多层感知器的学习

多层感知器的学习主要包含两个方面,即学习连接权值和学习网络结构。

1. 学习连接权值

MLP 网络权值的调整早期采用后向传播(Backpropagation)算法,训练一个后向传播神经网络有三个步骤^[34]: (1) 得到一个训练实例,在网络中使用现有的权重来计算实例的输出; (2) 向后传播然后计算误差——计算结果和期望(实际)

结果的差；(3) 该误差用来调整权重。此过程可看作是把误差通过神经网络反馈的过程。

由于标准的后向传播算法存在着收敛速度慢, 易陷入局部最小及网络泛化能力差等缺点, 近些年各种对后向传播算法的改进算法相继被提出, 并广泛用于解决各种实际问题。这类算法主要分为两类。一类是启发式方法: 如带动量、学习率的后向传播算法、标准批处理后向传播算法 (Standard batch backprop)、Quickprop 算法、RPROP 算法等; 另一类是使用数字最优化技术: 如共轭梯度下降法 (Conjugate Gradient Descent)、准牛顿法 (Quasi-Newton Method)、L-M 算法 (Levenberg-Marquardt) [47-48] 等。

2. 学习网络结构

一般来说, 网络层数 (即隐含层数) 和隐藏层神经元数 (即隐层节点数) 越多, 网络规模越大, 其逼近能力越强, 误差越小。但是网络的参数是通过样本学习的, 其可能由于样本含量不足或学习时间不够带来误差, 同时, 过大的网络训练时容易发生过拟合, 导致网络泛化能力下降, 因此对网络结构的选择很关键。

(1) 网络层数的确定^[48]: 由映射存在定理可知: 给定任一连续函数 $f: u^n \rightarrow r^m, f(x) = y$ 。这里 u 是闭单位区间 $[0, 1]$, f 可以精确地用一个三层感知器网络实现。因此, 在实际问题中, 隐含层数一般取 1-2 层即可, 增多层数会增加网络的复杂性, 可能会影响到网络收敛的速度。

(2) 单隐藏层神经元数的确定: 隐层节点数的大小依靠训练的样本数、噪声的数量和函数的复杂性而定。目前并没有公认的计算隐层节点数的公式, 以下是几种单隐层网络中隐层节点数的估计方法:

$$\textcircled{1} h = 2n + 1 \quad (3-12)$$

式中, n 为输入神经元个数, h 为隐层节点个数。

$$\textcircled{2} k < \sum_{i=1}^n C_i^h \quad (3-13)$$

式中, k 为样本数, 其它符号含义同公式 (3-12)。

$$\textcircled{3} h = \sqrt{n+m} + a \quad (3-14)$$

式中, m 为输出神经元个数, a 的取值在 1~10 之间, 其它符号含义同公式 (3-12)。

$$\textcircled{4} h = \log_2 n \quad (3-15)$$

式中符号含义同公式 (3-12)。

在实际的问题中, 往往采用“试错法”, 不断的增加神经元数目到模型泛化

能力不再明显增加为止。

3.2.3.3 模型过拟合

在 MLP 构建中要防止模型出现过拟合现象的发生^[49]，主要有权重衰减和早停止两种方法。

1. 权重衰减^[50]：其基本思想是惩罚大的权重，它通过构造一个目标函数（objective function），即在误差函数的基础上加一个惩罚函数，目标函数如公式（3-16）所示。

$$\bar{O} = \frac{L_+ + P_+}{\sum_i \sum_k f_i} \quad (3-16)$$

$$P_+ = d \sum_l w_{(l)}^2 \quad (3-17)$$

其中， $\bar{O}$ 是指目标函数， L_+ 是指误差函数， P_+ 是指惩罚函数，其中 d 是权重衰减常数， $w_{(l)}$ 是第 l 个权重（不包含输出偏倚项）， f 指观测频数。模型的训练就是通过对目标函数进行训练，使目标函数最小化。

2. 早停止^[51-52]：主要是通过将数据集分成训练集和校正集进行，通过监控训练集和校正集的性能变化（如准确率）来发现模型训练何时结束。

3.3 过抽样简介

在抽样设计中通常有两种：（1）联合抽样（joint sampling）也称为混合抽样（mixture sampling），是指随机的从总体中抽取受试对象。（2）分离抽样（separate sampling），是指分别从各自的总体中抽取受试对象。联合抽样和分离抽样可用图 3.5 形象地表示：




图 3.5 不同抽样设计形式的示意图

假设 π_0 和 π_1 分别代表人群中某类别是 0 ($y=0$) 和类别是 1 ($y=1$) 的概率, 样本中该类别是 0 和 1 的概率分别用 ρ_0 和 ρ_1 表示。在分离抽样中 $\pi_0 \neq \rho_0$ 、 $\pi_1 \neq \rho_1$ 。对于过抽样的调整需要知道事件的先验概率 (priori)。

分离抽样经常用于病例对照研究, 尤其对罕见疾病进行预测的研究中, 经常会用到该技术。

Logistic 回归采用最大似然法对参数进行估计时, 要求 y_i 服从独立的贝努力分布。该假设适合联合抽样而不适合分离抽样的试验设计类型。然而, 当该假设违背时, 即采用分离抽样时可以很容易地得到校正。在 Logistic 回归里, 分离抽样仅仅影响模型的截距大小的估计。如果标准的模型是:

$$\text{logit}(p_i) = \beta_0 + \beta_1 x_1 + \cdots + \beta_k x_k \quad (3-18)$$

该模型适合于联合抽样。

最大似然法估计分离抽样模型如式 (3-19) 所示:

$$\text{logit}(p_i^*) = \ln \left(\frac{\rho_1 \pi_0}{\rho_0 \pi_1} \right) + \beta_0 + \beta_1 x_1 + \cdots + \beta_k x_k \quad (3-19)$$

p^* 是指有偏抽样的后验概率。

可以看出, 过抽样的影响是改变了 $\log itP$ 值的截距项 (称 $\ln \left(\frac{\rho_1 \pi_0}{\rho_0 \pi_1} \right)$ 为偏移 (offset))。可见, 当对罕见事件进行研究中, 采用过抽样技术时, 可以得知: $\pi_0 > \rho_0$ 且 $\pi_1 < \rho_1$, offset 值是正值, $\log itP$ 值会变大。

也可通过以下公式 (3-20) 直接对后验概率进行调整 (这种方法也可用在决策树和神经网络建模预测后, 对其后验概率进行调整):

$$\hat{p}_i = \frac{\hat{p}_i^* \rho_0 \pi_1}{(1 - \hat{p}_i^*) \rho_1 \pi_0 + \hat{p}_i^* \rho_0 \pi_1} \quad (3-20)$$

其中, $\hat{p}_i$ 是调整的后验概率值, 其他符号含义同公式 (3-19)。

3.4 ROC 曲线简介

接受者工作特征曲线 (receiver operating characteristic): 简称 ROC 曲线。

评价一种诊断技术的传统方法是使用灵敏度、特异度、准确率等指标。但这些指标受到诊断界点的影响, 难以反映诊断方法的优劣。为了更全面地评价诊断方法的诊断价值, 必须考虑各种可能的诊断界点。而 ROC 曲线可通过改变诊断

界点，将灵敏度和特异度结合起来，通过计算 ROC 曲线下面积（AUC），根据曲线的形状和面积对诊断技术做出定量分析，总体评价诊断的准确性。因此在本研究中评价模型泛化的性能时采用 ROC 面积作为评价三种模型预测性能的指标。

美国生物统计百科全书中关于 ROC 的定义是^[53]：“对于可能或将会存在混淆的 2 种条件或自然状态，需要试验者、专业诊断学工作者以及预测工作者做出精细判别，或者准确决策的一种定量方法”。目前 ROC 分析已经成为广泛应用于临床诊断和人群筛检研究的一种统计方法^[54-55]。

ROC 曲线绘制方法如下：ROC 曲线以每一个检测结果作为可能的诊断界值，以 1-特异度（即假阳性率，FPR）为横轴，灵敏度为纵轴（即真阳性率，TPR），横轴和纵轴长度相等，形成正方形，在图中将 ROC 曲线工作点标出，用直线连接各相邻两点构建 ROC 曲线，如图 3.6 所示。

目前对 ROC 曲线下面积解释主要有两种^[56]：一种是 ROC 面积反映了识别算法正确区分真假目标能力的大小；另一种是 ROC 面积等于任意选取的目标样本特征值大于任意选取的非目标样本特征值的概率。




图 3.6 ROC 曲线示意图

ROC 面积大小估计主要有参数法和非参数法。在本文中采用的较为常用的非参数方法计算 ROC 面积大小。假设对照组有 n_c 个观察值，记为

$X_j (j=1, 2, \dots, n_c)$ ，病例组有 n_a 个观察值，记为 $X_i (i=1, 2, \dots, n_a)$ 。如果观察值大判归为病例，根据 Wilcoxon-Mann-Whitney 检验统计量，ROC 面积（用 A_z 表示）就是病例组每个观察值大于对照组每个观察值的概率，用公式（3-21）、公式（3-22）表示。

$$A_z = \frac{1}{n_a n_c} \sum_{j=1}^{n_c} \sum_{i=1}^{n_a} \Psi(X_i, X_j) \quad (3-21)$$

$$\Psi(X_i, X_j) = \begin{cases} 1 & X_i > X_j \\ 0.5 & X_i = X_j \\ 0 & X_i < X_j \end{cases} \quad (3-22)$$

该公式为病例组 n_a 个 X_i 与对照组的 n_c 个 X_j 比较, 如果前者大于后者则比较结果为 1, 相等为 0.5, 否则为 0, 将 $n_a \times n_c$ 个比较结果相加取平均即得 A_z 。

A_z 的标准误的计算公式为:

$$SE(A_z) = \sqrt{\frac{A_z(1-A_z) + (n_a-1)(Q_1-A_z^2) + (n_c-1)(Q_2-A_z^2)}{n_a n_c}} \quad (3-23)$$

其中 $SE(A_z)$ 为 A_z 的标准误, Q_1 是两个随机选择的病例组观察值比一个随机选择的对照组观察值都将有更大可能划归为病例的概率。 Q_2 是一个随机选择的病例组观察值比两个随机选择的对照组将有更大可能划归为病例的概率。根据 $A_z \pm u_\alpha SE(A_z)$ 可计算 A_z 的 $100(1-\alpha)\%$ 置信区间。

设两个诊断试验 ROC 面积分别为 A_{z1} 和 A_{z2} , 对应的标准误分别为 SE_1 和 SE_2 , 比较 ROC 面积对应的公式为^[58]:

$$Z = \frac{|A_{z1} - A_{z2}|}{\sqrt{SE_1^2 + SE_2^2 - 2rSE_1SE_2}} \quad (3-24)$$

其中 z 是标准正态离差值。 A_{z1} 和 A_{z2} 是两诊断试验的曲线下面积。 SE_1 和 SE_2 是其对应的标准误。 r 是两个 ROC 曲线下面积间的相关系数。

两个 ROC 面积的比较也可采用文献[58]中介绍的非参数检验方法处理, 在此不再赘述。

完全无价值的诊断试验 ROC 面积为 0.5, 在 ROC 面积与 0.5 之间的差别有统计学意义的前提下, 一般认为对于一个诊断试验, ROC 面积在 0.5~0.7 之间时诊断价值较低, 在 0.7~0.9 之间时诊断价值中等, 在 0.9 以上时诊断价值较高。

ROC 曲线最佳工作点的确定: 一个诊断系统中, 同时使用误诊率和漏诊率较小, 特异度和灵敏度同时最大的临界点即为最佳工作点。本研究采用较常用的做法, 选取使 Youden 指数最大的那一点^[59]作为最佳工作点。

3.5 模型泛化能力的评价及三种 Monte Carlo 模拟抽样方法的应用

评估模型泛化能力的大小时，当样本量足够大的情况下，只要在一个大的训练集上建模，然后在另一个大的测试集上验证就能得出比较客观的评价结果。然而在数据量有限时，泛化能力的评估将是一个具有挑战性的工作。

1. 训练和测试

用训练集 (train set) 数据进行测试所产生的误差为重新代入误差，它是将训练实例重新代入由这些训练实例而产生的模型进行计算的，虽然它不可能可靠地反映模型在新数据上的真实的误差，但依然有一定的参考价值。为了能测试一个模型在新数据上的性能表现，需要一组没有参与建模的数据集，并在此数据集上评估预测性能，如误分率等。这组独立的数据集称为测试集 (test set)。此外，还有可能需要一组用于优化或选择模型参数的数据集，即验证集 (validation data)。这里需要强调的是，训练集、校正集和测试集必须保持独立性。

一旦误差率已定，可以将测试数据合并到训练数据中，由此产生新的模型应用于实践中，这样是可行的。重要的是误差率不能源于这些数据。同样，一旦验证数据已被使用，那么也可以将验证数据合并到训练数据中，使用尽可能多的数据重新训练学习方案^[60]。

2. 评价泛化能力问题的关键点

评价模型泛化能力大小有很多的方法：有适合于线性最小二乘回归的方法如误差均方 ($MSE = SSE/(N - P)$ ， SSE 为训练集的离均差平方和， N 为训练集的样本量， P 为模型包含截距项在内的参数个数)、最终预测误差 ($FPE = \frac{SSE(N + P)}{N(N - P)}$ ，其中 N 为训练集的样本量， P 为模型包含截距项的参数个数， SSE 指误差平方和) 等；还有适用于线性和非线性模型的指标^[61]如：SBC (对于最小二乘法， $SBC = N \ln(SSE / N) + P \ln(N)$ ；对于最大似然法估计， $SBC = 2NLL + P \ln(N)$ ，其中 NLL 是负对数似然函数， N 为训练集的样本量， P 为模型包含截距项的参数个数)、AIC (对于最小二乘法， $AIC = N \ln(SSE / N) + 2 * P$ ；对于最大似然法估计， $AIC = 2NLL + 2 * P$ ，其中各符号含义同 SBC) 等。然而，因为决策树模型没有很好定义模型包含截距项在内的参数个数，所以 AIC、SBC 不能直接应用于树模型。

保持法、交叉验证法、自引导法可以应用于任何模型的泛化能力的评价。如果是一个大的数据集，可以将该数据集分成训练集和测试集两个部分，即取一个

大的样本进行训练, 取一个不同的有代表性的大样本进行测试, 从而得到反映模型真实性能的估计。一般来说, 训练样本量越大, 所建的模型预测性能越好 (虽然样本量超过一定的限度, 性能提高会有所减缓)。测试样本量越大, 误差估计越准确。问题关键点在于: 小样本时, 用于训练、验证和测试的数据量非常有限, 怎么才能最好地利用一个小样本数据集? 即既要用尽可能多的数据用于训练, 同时又有尽可能多的数据用于测试, 得到一个准确的误差估计。

3. 解决问题的方法^[29,61]

(1) 交叉验证法 (cross-validation method)

采用保持法 (即一部分用于训练, 剩余部分用于测试 (如有必要可再留一部分用于验证)) 进行建模和泛化能力的评价, 有一些众所周知的局限性^[17-20,29]: 第一, 因为要保留一部分数据用于测试, 所以用于训练的被标记样本较少, 因此建立的模型不如使用所有样本建立的模型好。第二, 模型可能高度依赖于训练集和测试集的构成。一方面, 训练集越小, 模型的方差越大, 另一方面, 如果训练集太大, 用较小的测试集估计的准确率又不太可靠。这样的估计具有很宽的置信区间。第三, 因为训练集和测试集来源于同一个数据集, 在一个子集中超出比例的类在另一个子集就低于原先的比例, 反之亦然。

为了减少由于保持法抽样引起的对预测性能估计的偏差, 可以重复整个过程, 即采用多次重复保持法, 称为随机二次抽样。此方法也会遇到一些与保持法同样的问题, 因为在训练阶段也没有利用尽可能多的数据, 并且由于它没有控制每个记录用于训练和测试的次数, 因此有些记录用于训练可能比其他记录更频繁。

一种简单的替代随机二次抽样的方法是交叉验证法。即先决定一个固定的折数, 也就是说将数据分成大致相同的 k 份, 每份被轮流用于测试而其他数据用于训练。此过程重复 k 次, 从而每个观测恰好有一次用于测试。由于学习过程共进行 k 次, 因此可以得到 k 个误差率或总误差 (k 次学习过程测试集误差之和), 最后可将 k 个误差率平均得出一个综合误差估计等等。对于小数据集来说, 交叉验证法显著地优于保持法^[17-20,62]。交叉验证能有效地利用数据, 因为每一个观测既用于训练也用于测试。但交叉验证比保持法需要更多的计算机时间来计算。

(2) 刀切法 (jackknife method): 也称为留一法交叉验证。

刀切法其实就是 n (n 为数据集所含观测的个数) 折交叉验证。每个观测依次被保留在外, 剩余的观测用于模型的训练。该方法的评估是看那个保留在外的观测分类的正确性。所有的 n 个测试结果被平均, 得到的平均值便是最终的误差估计。

刀切法的优点是利用尽可能多的训练数据, 从而增加了获得正确预测的机

会。另外该方法无需随机抽样，具有确定性。不足之处是计算成本高，不能对样本进行分层，因为每个测试集中只有一个观测，性能估计的方差偏高。

(3) 自引导法 (bootstrap method)

该方法是基于有放回抽样理论。它是采取有放回抽样形成训练集，即已经选做的观测将放回原来的数据集中，使得它与数据集中其它的观测有相同的概率被重新抽取。本文采用最常用的 0.632 自引导法，即一个拥有 n 个观测的数据集（原始数据集）进行了 n 次有放回抽样，形成另一个含有 n 例的数据集，在该数据集中，会有（几乎肯定会）一些重复观测，那么在原始数据集中必有部分观测未被抽取，因此可选取这些未被抽取的观测作为测试集。因为观测被抽中的概率是 $1-(1-1/N)^N$ ，当 N 足够大，该概率逐渐逼近 $1-e^{-1}=0.632$ 。因为训练集只用了 63.2% 的观测，用测试集进行泛化能力的估计，得到的将是一个对真实误差较为悲观的估计。为了补偿这一点，通常采用 0.632 自引导法评估模型的性能。如计算指标是准确率，则通过计算每个 bootstrap 样本的准确率 (ε_i) 和由包含所有标记样本的训练集的准确率 (acc_s)，从而计算最终准确率的估计值，如公式 (3-25) 所示。

$$acc_{boot} = \frac{1}{b} \sum_{i=1}^b (0.632 \times \varepsilon_i + 0.368 \times acc_s) \quad (3-25)$$

其中 b 是指生成的 bootstrap 样本的个数。

在本文中，采用 Monte-Carlo 模拟的思想，运用三种抽样技术（刀切法、10~100 次的 2~10 折的分层交叉验证法、100~1000 次自引导法（具体为 0.632 自引导法，后同）），计算每种情况下的 ROC 面积，并对三种模型的预测性能进行较为客观的评价，并通过统计学检验来确定差异是否有统计学意义。

3.6 软件实现

数据分析采用 SAS8.2 软件实现，线图的绘制是通过 EXCEL2003 完成，ROC 曲线的绘制是通过 SPSS16.0 完成。

3.7 本章小结

在本章中对三种预测模型的建模方法、ROC 面积、过抽样调整及模型泛化能力评价方法进行了简要介绍。有效利用数据信息在小样本时是很关键的，它关系到模型构建的成败也是模型之间进行比较得出正确和可靠结论的关键，具体论证见本章 3.5 部分。

第四章 三种预测模型建模过程及建模结果

4.1 本章引论

本章结合数据集（样本量小）和三种方法（LR、DT、NN）的特点，对模型的构建采取了相应的措施。首先在 Logistic 回归建模的过程中，采用最优子集法结合 AIC 信息准则法，快速有效地筛选出变量，建立起了可靠的 Logistic 回归模型，结果显示：预测性能优于一般筛选变量的方法（如向前选择法、向后剔除法、逐步回归法、最优子集法）建立的 Logistic 回归模型。

本文第 1、2 章中已提到，在模型构建的过程中，决策树和神经网络模型易造成过拟合，而又不宜采用保持法建模（样本量小）。针对这些问题，本文采用 5~7 折分层交叉验证的法将 CART 与 CHAID 法相结合，建立起了决策树模型，达到了既能充分的利用数据信息，又可避免过拟合现象发生的目的；在神经网络模型隐含层数和隐含层节点数选取中，采用 SBC 准则作为选择的标准，在建模过程中利用 L-M 优化技术、预训练法、权重衰减法等，也达到了充分利用数据信息并有效避免过拟合现象发生的效果，建立起了较为准确、可靠的模型，并对建立起的 3 个模型进行 ROC 面积大小的比较。通过对过抽样进行调整，得到相应的后验概率，然后以此来计算预测的最佳分割点。

4.2 Logistic 回归建模过程及结果

4.2.1 变量选择

将变量初筛（去掉可信度较低、缺失值过多的变量）后，得到候选的变量有 30（民族不纳入，所有观测均为汉族）个。将 30 个变量先进行两变量相关性分析，初步观察变量间的相关性及变量间的关系是否存在非线性。

1. 两变量相关性分析结果

进行两变量分析可大致了解一下单个原因变量与结果变量之间的关系。采用 Spearman 秩相关是因为其对非单调性和异常值不敏感。然而当变量间不具有单调趋势时，其容易将重要的变量遗漏掉。因此，可采用一种普遍且稳健的方法即 Hoeffding's D 统计量^[63-64]，来检测两个变量间的关系。Hoeffding's D 统计量介于 -0.5 和 1 之间，其值越大相关性越高。如果 Spearman 秩次低而 Hoeffding's D 高，提示变量间的关系可能不是单调的。由表 4.1 可以看出，Spearman 秩次低而 Hoeffding's D 统计量秩次高的变量主要是年龄，因此在进行分析时要注意考察它与结果变量之间是否存在非单调的关系。

表 4.1 两变量相关性分析结果

<i>n</i>	变量	Spearman 秩	Hoeffding 秩	Spearman 相关系数	Spearman p-值	Hoeffding 相关系数	Hoeffding p-值
1	是否有 DM 视网膜病变(drf)	1	2	-0.449	0.000	0.013	0.001
2	是否有 DM 性肾病(dnrf)	2	4	-0.411	0.000	0.009	0.003
3	HbA1c%(hbalc1)	3	1	-0.369	0.000	0.022	0.000
4	糖尿病病程(dmbc)	4	3	-0.260	0.000	0.010	0.002
5	DM 后副食过量否(fsglf)	5	11	-0.217	0.000	-0.003	1.000
6	体力活动水平(zlsjf)	6	5	0.212	0.000	0.000	0.275
7	高血压否(hbpf)	7	6	-0.183	0.002	0.000	0.480
8	创伤否(csf)	8	9	0.171	0.005	-0.002	0.961
9	是否有 AD(chd)	9	7	0.165	0.006	-0.001	0.828
10	chd 史(chds)	10	23	-0.158	0.009	-0.004	1.000
11	饮茶情况(teaf)	11	8	0.122	0.043	-0.002	0.952
12	DM 后主食过量否(zsglf)	12	27	-0.118	0.051	-0.005	1.000
13	是否锻炼(sfdl)	13	10	-0.110	0.070	-0.002	0.999
14	是否有缺血性心脏病(ischemia)	14	24	-0.101	0.096	-0.004	1.000
15	是否发生高尿酸血症(huf)	15	28	-0.101	0.097	-0.005	1.000
16	饮酒情况(drinkf)	16	20	0.091	0.133	-0.004	1.000
17	职业(occup1)	17	12	-0.089	0.144	-0.003	1.000
18	喝咖啡情况(coffeef)	18	14	-0.078	0.198	-0.003	1.000
19	中风史(zfs)	19	26	-0.070	0.247	-0.005	1.000
20	bmi 分级(bmif)	20	13	-0.068	0.261	-0.003	1.000
21	胰岛素否(pgif)	21	17	0.066	0.278	-0.004	1.000
22	肥胖史(fps)	22	22	-0.053	0.383	-0.004	1.000
23	血糖控制方法(bpkzff)	23	16	-0.049	0.416	-0.004	1.000
24	DM 后吸烟否(smokedmf)	24	25	0.044	0.464	-0.004	1.000
25	吸烟指数分级(smokeindexf)	25	21	-0.037	0.542	-0.004	1.000
26	DM 家族史(dms)	26	19	-0.015	0.808	-0.004	1.000
27	婚姻(hunyin1)	27	29	0.014	0.813	-0.005	1.000
28	年龄(age)	28	15	0.012	0.847	-0.003	1.000
29	性别(sex)	29	18	0.007	0.904	-0.004	1.000
30	肾病史(sbs)	30	30	0.000	1.000	-0.005	1.000

2. 共线性诊断

将初步筛选出来的 30 个变量进行共线性诊断：得出条件指数（条件指数为 83.43226），说明变量间存在较严重的共线性。诊断发现：PGI 和 bpkzff 存在严重的共线性。对 30 个变量进行变量聚类，发现 PGI 和 bpkzff 聚在了同一类，通过聚类结果选出代表性好的 PGI（OwnCluster=0.8983，NextClosest=0.0601）进入，将 bpkzff（OwnCluster=0.8983，NextClosest=0.0396）剔除，以下是变量聚类的示意图。




图 4.1 变量聚类图

3. 连续变量logitP 变换后与结果变量之间的关系

在候选的30个变量中，等级或名义的定性变量（体力活动水平（zlsjf）、吸烟指数分级（smokeindexf）、bmi分级（bmif）、饮酒情况（drinkf）、饮茶情况（teaf）、是否锻炼（sfdl）、饮咖啡情况(coffee)、血糖控制方法(bpkzff)）在建模过程中均以哑变量的形式进入，生成的哑变量如表4.2所示。

表 4.2 定性变量（等级或名义）生成哑变量赋值情况

变量	变量赋值	生成的哑变量
体力活动水平 (zlsjf)	0 ≤2h 1 (2,4]h 2 >4	zlsjf1=(zlsjf=0) zlsjf2=(zlsjf=1)
吸烟指数分级 (smokeindexf)	0 不吸 1 ≤200 轻度 2 200~400 中度 3 ≥400 重度	smokeindexf1=(smokeindexf=0) smokeindexf2=(smokeindexf=1)
bmi 分级(bmif)	0 正常 1 超重 2 肥胖	bmif1=(bmif=0) bmif2=(bmif=1)
饮酒情况 (drinkf)	0 无 1 偶尔 2 经常（是（多于1次/周，连续1年以上）	drinkf1=(drinkf=0) drinkf2=(drinkf=1)
饮茶情况(teaf)	0 无 1 偶尔 2 经常（是（多于3次/周，连续1年以上）	teaf1=(teaf=0) teaf2=(teaf=1)
锻炼情况(sfdl)	0 经常 1 偶尔 2 几乎不	sfdl1=(sfdl=0) sfdl2=(sfdl=1)

变量	变量赋值	生成的哑变量
饮咖啡情况 (coffeef)	0 经常 (多于 3 次/周, 连续 1 年以 上) 1 偶尔 2 否	coffeef1=(coffeef=0) coffeef2=(coffeef=1)
血糖情况 (bpkzff)	1 单纯饮食控制 2 运动疗法 3 口服降糖药 4 胰岛素注射 5 口服 降糖药与胰岛素注射联合	bpkzff1=(bpkzff=1)bpkzff2=(b pkzff=2)bpkzff3=(bpkzff=3) bpkzff4=(bpkzff=4)

对连续变量年龄、病程、糖化血红蛋白含量 HbA1c% 绘制经验 $\log itP$ 图, 如图 4.2-图 4.4 所示。




图 4.2 对年龄绘制经验 $\log itP$ 图




图 4.3 对病程绘制经验 $\log itP$ 图




图 4.4 对 HbA1c% 绘制经验 $\log itP$ 图

绘制连续变量 DM 病程、糖化血红蛋白含量的 $\log itP$ 图, 可见各变量与 $\log itP$ 之间基本上是线性关系, 故不需要对变量进行变换。对年龄绘制经验 $\log itP$ 图, 可以发现年龄与 $\log itP$ 之间基本无相关性。

4. 采用各种方法挑选变量的结果

由于变量数较多,而每组只有 137 例观测,因此在建模的过程中既要将有意义的变量纳入,提高模型的预测精度,又要根据实际情况,尽量压缩变量个数,提高模型泛化能力。

一个模型的建立不是一个简单的过程,而是一个反复实践不断探索的过程。由于变量的筛选有很多的方法,因此我们尝试用常见的几种变量筛选法(向前选择法、向后剔除法、逐步回归法)进行变量筛选(注意在 SAS 过程中,针对所有原因变量的组合情况,最优子集法均可以给出其对应的 χ^2 值,但却无法给出哪种组合最佳),并给出本研究中采用最优子集法与 AIC 信息准则相结合的方法(BEST+AIC)的结果。

4.2.2 模型建立

(1) 向前法

以下 8 个变量最后进入模型: 体力活动水平(zlsjf(zlsjf0 zlsjf1))、DM 视网膜病变否(drf)、DM 性肾病否(dnrf)、HbA1c%(hba1c1)、高尿酸血症否(huf)、DM 后副食过量否(fsglf)、drf*dnrf。

表 4.3 Logistic 回归(向前法)对进入模型的变量假设检验的结果

变 量	自由度	χ^2	<i>P</i>
体力活动水平(zlsjf)	2	8.9721	0.0113
DM 视网膜病变否(drf)	1	15.2705	<.0001
DM 性肾病否(dnrf)	1	14.6056	0.0001
HbA1c%(hba1c1)	1	12.5771	0.0004
高尿酸血症否(huf)	1	5.3735	0.0204
DM 后副食过量否(fsglf)	1	9.184	0.0024
drf*dnrf	1	7.3869	0.0066

表 4.4 向前选择法对变量系数估计的结果

变量		自由度	β	SE	χ^2	P
Intercept		1	-5.5325	1.1065	24.9995	<.0001
zlsjf	0	1	0.798	0.544	2.1519	0.1424
zlsjf	1	1	0.1575	0.3148	0.2504	0.6168
drf		1	3.0183	0.7724	15.2705	<.0001
dnrf		1	3.1429	0.8224	14.6056	0.0001
hba1c1		1	0.3594	0.1013	12.5771	0.0004
huf		1	1.6542	0.7136	5.3735	0.0204
fsglf		1	2.2717	0.7496	9.184	0.0024
drf*dnrf		1	-3.3904	1.2474	7.3869	0.0066

H-L 拟合优度检验: $\chi^2 = 7.3927$ $P=0.4949$

该模型拟合结果: 准确率: 78.8%, 敏感度 (S_e): 70.8%, 特异度 (S_p) 86.9%, ROC 面积: 0.8677。

(2) 向后剔除法及逐步回归法

筛选变量及拟合模型的结果均与向前选择法相同。

(3) 最优子集+AIC 法 (BEST+AIC)

①筛选变量的结果

表 4.5 最优子集法结合 AIC 信息准则挑选变量的结果

变量数	AIC	进入模型的变量
1	-51.1262	drf
2	-65.0252	drf dnrf
3	-78.9533	drf dnrf drfdnrf
4	-87.9180	drf dnrf hba1c1 drfdnrf
5	-92.3223	drf dnrf hba1c1 fsglf drfdnrf
6	-94.7014	drf dnrf hba1c1 zlsjf2 fsglf drfdnrf
7	-95.7810	drf dnrf hba1c1 huf zlsjf2 fsglf drfdnrf
8	-96.6181	drf dnrf hba1c1 huf zlsjf1 zlsjf2 fsglf drfdnrf
9	-97.0700	dmbsc csf drf dnrf hba1c1 huf zlsjf2 fsglf drfdnrf
10	-97.9941	dmbsc csf drf dnrf hba1c1 huf zlsjf2 teaf1 fsglf drfdnrf
11	-97.9428	dmbsc csf drf dnrf hba1c1 huf zlsjf1 zlsjf2 teaf1 fsglf drfdnrf
...	...	...
32	-61.5362	dmbsc csf drf dnrf hba1c1 huf zlsjf1 zlsjf2 bmif1 bmif2 smokeindexf1 smokeindexf2 drinkf1 drinkf2 teaf1 teaf2 pgif fps sbs zfs chds dms chd ischemia fsglf smokedmf sfdl2 coffeef2 zsglf drfdnrf hbpf age sex hunyin1 occup1

选出最小 AIC 对应的进入模型的变量数为 10 个, 为 dmbc、csf、drf、dnrf、hba1c1、huf、zlsjf2、teaf1、fsglf、drfdnrf。

②进入模型的变量假设检验的结果

表 4.6 BEST+AIC 法对变量系数估计的结果

变 量	自由度	β	SE	χ^2	P
DM 病程 (dmbc)	1	0.0566	0.0252	5.0425	0.0247
创伤否 (csf)	1	-1.0319	0.4457	5.3596	0.0206
DM 视网膜病变否 (drf)	1	2.5484	0.7771	10.7551	0.001
DM 性肾病否 (dnrf)	1	2.85	0.8231	11.9899	0.0005
HbA1c% (hba1c1)	1	0.3461	0.1033	11.2381	0.0008
高尿酸血症否 (huf)	1	1.7857	0.7269	6.0338	0.014
体力活动中等否 (zlsjf2)	1	0.9219	0.3801	5.8838	0.0153
经常饮茶否 (teaf1)	1	0.9191	0.4305	4.5582	0.0328
DM 后副食过量否 (fsglf)	1	2.2816	0.7439	9.4058	0.0022
drf*dnrf	1	-2.6905	1.2632	4.5368	0.0332

H-L 拟合优度检验: $\chi^2 = 5.7824$ $P=0.6716$ 。

表 4.7 BEST+AIC 法变量的 OR 值及其 95%CI

变 量	OR 值	95%CI
dmbc (DM 病程)	1.058	1.007~1.112
csf (创伤否)	0.356	0.149~0.854
hba1c1 (HbA1c%)	1.414	1.155~1.731
huf (高尿酸血症否)	5.963	1.435~24.79
zlsjf2 (体力活动中等否)	2.514	1.194~5.295
teaf1 (经常饮茶否)	2.507	1.078~5.829
fsglf (DM 后副食过量否)	9.792	2.278~42.083

拟合模型的结果: 准确率: 79.6%, 敏感度 (S_e): 73%, 特异度 (S_p): 86.1%, ROC 面积: 0.8802。

③与其它三种方法 (向前选择法、向后剔除法、逐步回归法) 进行比较结果把最优子集结合 AIC 建立的模型与其它三种方法 (本文中为简便起见, 称向前选择法、向后剔除法、逐步回归法三种筛选变量建模的方法为一般方法, 以下同) 相比, 进入模型的变量数多了 2 个, 并且准确度、ROC 面积均高于后者, 那么会不会因为变量数的增多使模型的泛化能力变差呢? 虽然理论上已经用 AIC 对变量数进行了“惩罚”, 应该泛化能力不会比后者差, 但为了进一步看一下方法间泛化能力的优劣, 采用三种 Monte Carlo 模拟方法, 对最优子集结合 AIC

的方法与其它三种方法进行比较。

(a) 采用刀切法计算 ROC 面积:

表 4.8 两种 LR 方法刀切法 ROC 面积大小

方法	AUC	SE	95%LCL	95%UCL
一般	0.8390	0.0242	0.7916	0.8865
本文	0.8501	0.0236	0.8040	0.8962

由刀切法可见, BEST+AIC 方法 (简称本文方法) 的用刀切法抽样后 ROC 面积高于一般方法。

(b) 采用 100~1000 次 bootstrap 法抽样 ROC 面积大小比较结果

为了简便起见, 给出 100~1000 次 bootstrap 法抽样后 (具体为 0.632 自引导法) 两种方法 ROC 面积变化的线图。




图 4.5 不同 LR 挑选变量方法不同次数自引导法抽样后 ROC 面积大小

由上图 4.5 可以看出, BEST+AIC 法与一般筛选变量建模进行 LR 回归相比, ROC 面积大小均大于后者。

(c) 10 次~100 次 3 折~10 折交叉验证 ROC 面积大小比较结果

为了方便起见, 以图 4.6 表示, 可见, BEST+AIC 方法在不同次数不同折数 (3~10 折、10~100 次) 交叉验证后的 ROC 面积均略大于一般方法。




图 4.6.2 不同 LR 挑选变量方法 3~10 折分层交叉验证后 ROC 面积大小

对于本文数据集来说，由以上三种 Monte Carlo 模拟结果可以看出，BEST+AIC 方法 ROC 面积均高于一般方法。由此可见，将最优子集法结合 AIC 方法建立的 LR 模型较优。

4.2.3 先验概率调整

糖尿病合并末梢神经病变在糖尿病病人中的比例大约为 60%，而该研究是采用分离抽样的病例对照研究，病例组和对照组的比例各为 50%。故应对模型进行过抽样调整。

在本次建模过程中，在拟合 Logistic 回归模型时未对过抽样进行校正的模型：

$$\text{logit}(p_i^*) = \ln\left(\frac{\rho_1\pi_0}{\rho_0\pi_1}\right) + \beta_0 + \beta_1x_1 + \cdots + \beta_kx_k$$

在本研究中首先构造出未对过抽样进行调整的模型如下：

$$\begin{aligned} \log it(\hat{p}_i^*) = & -6.5039 + 0.0566dmbc - 1.0319csf + 2.5484drf + 2.8500dnrf + 0.3461hba1c1 \\ & + 1.7857huf + 0.9219zlsjf2 + 0.9191teaf1 + 2.2816fsglf - 2.6905drf * dnrf \end{aligned}$$

可以知道 $\pi_0 = 0.4$ ， $\rho_0 = 0.5$ ， $\pi_1 = 0.6$ ， $\rho_1 = 0.5$ ，故可计算

$$offset = \log(\rho_1\pi_0 / \rho_0\pi_1) = \log((1-0.6)*0.5/0.6*(1-0.5)) = -0.405465108$$

对过抽样调整后最终模型为：

$$\begin{aligned} \log it(\hat{p}_i) = & -6.0984 + 0.0566dmbc - 1.0319csf + 2.5484drf + 2.8500dnrf + 0.3461hba1c1 \\ & + 1.7857huf + 0.9219zlsjf2 + 0.9191teaf1 + 2.2816fsglf - 2.6905drf * dnrf \end{aligned}$$

4.3 决策树建模过程及结果

4.3.1 变量选择

表 4.9 决策树变量重要性列表

变量名	变量标签	Importance 值
DRF	是否有 DM 视网膜病变	1.0000
DNRF	是否有 DM 性肾病	0.6908
HBA1C1	HbA1c%	0.6428
ZLSJF	体力活动水平	0.6399
CSF	手术创伤	0.5586
DMBC	DM 病程	0.5270
ZSGLF	主食过量否	0.0000
HUF	是否发生高尿酸血症	0.0000
HUNYIN1	婚姻状况	0.0000
...	...	...
ZFS	中风史	0.0000
AGE	年龄	0.0000

将 30 个变量进行重要性检测（具体方法见本文第 3 章 3.2.2 节），如表 4.9 所示。按变量重要性从大到小排序依次为：是否有 DM 视网膜病变（drf）、是否

有 DM 性肾病 (dnrf)、HbA1c% (hbalc1)、体力活动水平 (zlsjf)、手术创伤 (csf)、DM 病程 (dmbc)。

4.3.2 交叉验证法建立模型

在前一章中已经指出,决策树是一种非常灵活的建模方法,当树长成无限大的时候,就会造成树的过拟合,而对于新的有噪声的数据不能很好的适应。当树模型太小时,训练和检验的误差都很大,此时树模型欠拟合,因此,找到一个“适合”的树,即既不过拟合也不欠拟合(即过拟合和欠拟合的折中)的树很关键。数据量大的时候建立起一个决策树模型比较简单,常用的方法是保持法。即将数据分成两个部分,一部分用于训练一部分用于校正。已有研究证明,当数据集小的时候,采用保持法对模型性能的测量很多时候是不可靠的^[17-20]。针对本研究中数据量小的特点,采用 100 次 5~7 折分层交叉验证的方法,将 CHAID 方法与 CART 方法相结合,建立起决策树模型,既达到能充分利用数据,又能建立起较可靠的决策树模型的目的。主要流程如下:

1. 分层交叉验证流程

在本研究中,病例组和对照组的观测各 137 例,样本量小。为了充分利用数据信息,多方面综合考虑,结合 CHAID 方法与 CART 方法(用交叉验证思想来建立决策树首先在该方法中提出,可通过 CHAID 法简单实现)采用交叉验证的思想进行建模,尝试通过 100 次 5-7 折分层交叉验证,确定 χ^2 分割的 P 界值点。

以 100 次 5 折分层交叉验证为例,介绍如何确定 χ^2 分割的 P 界值点。具体步骤如下:

改变 CHAID 建模中分裂标准即 P 值大小(从 0.01~0.2),将样本随机分层的方法大致等分成 5 个部分,每一部分被轮流用于测试而其他数据用于训练。此过程重复 5 次,从而每个观测恰好有一次用于训练,一次用于测试。由于学习过程共进行 5 次,因此可以得到 5 个准确率,最后可将 5 个准确率平均得出一个准确率的平均值。在每个 P 值下对应一个平均的准确率。最后选择平均准确率最高的 P 值做为分裂标准。重复以上过程 100 次,每次选出一个 P 值,共选出 100 个 P 值,最后将 100 个 P 值平均得出最后用于 CHAID 分裂标准的 P 值。具体流程如图 4.7 所示:




图 4.7 100 次 5 折交叉验证建立 CHAID 树过程

2. CHAID 树的建立

通过 100 次 5 折、6 折、7 折交叉验证后得到的 P 值分别为 0.050、0.0469、0.054（平均值为 0.0503）。最后选定 χ^2 分裂标准为 $P=0.05$ ，建立起的决策树模型最后的结果如图 4.8、4.9 所示。




图 4.8 决策树模型拟合后生成的混淆矩阵、年轮图、叶子数




图 4.9 决策树模型生成的树形图

其中 ROC 面积: 0.8536, 准确率: 81%, 灵敏度 (S_e): 78.8%, 特异度 (S_p): 83.2%。

4.4 神经网络建模过程及结果

4.4.1 变量选择

目前尚缺乏与神经网络分析相配套、较成熟的变量选择方法, 由于在结构上, Logistic 回归又等同于以 logistic 链接函数为激活函数的单层前馈网络^[65-66]。因此, 本研究将 Logistic 回归方法和神经网络权重挑选变量方法相结合, 挑选出进入模型的变量。故最后选择进入模型的变量比 Logistic 回归选择的 10 个变量多了 1 个变量即肥胖史。

4.4.2 确定隐含层数

Hecht-Nielsen 曾证明当节点具有不同阈值时,对于在任意闭区间的一个连续函数都可以用一个隐含层的网络来逼近,因此,一个两层的 BP 网络可以完成任意的 n 维到 m 维的映射^[67]。本研究综合以上看法,尝试采用隐含层 1~5 个看一下本文数据适合的隐含层数。不同隐含层数拟合模型所得的统计量结果如表 4.10 所示。

表 4.10 不同隐含层数拟合 MLP 的结果

隐含层数	模型自由度 (DFM)	SBC	均方根误差 (RMSE)	离差	误分率 (MISC)
1	14	307.3809	0.3689	228.7971	0.1752
2	16	321.6077	0.3725	231.7977	0.1715
3	18	330.1682	0.3703	229.1319	0.1569
4	20	343.6268	0.3748	231.3643	0.1642
5	22	503.3335	0.5214	379.8447	0.5000

由表 4.10 可见,随着隐含层数增加模型自由度在增加,且离差降低的单位数还没有 SBC 增加的多,故选择隐层数为 1 较为适合。

4.4.3 隐含层节点数及跳跃层的确定

对于模型选择几个隐层数,每个隐层含有几个神经元(即隐含层节点数),是一个进行对比和调试的过程。在确定选择隐含层数为 1 后,对隐含层节点数进行调试。

表 4.11 1 个隐含层不同节点数调试结果

隐含层节点数	模型自由度 (DFM)	SBC	均方根误差 (RMSE)	离差	误分率 (MISC)
1	14	307.3809	0.3689	228.7971	0.1752
1+skip	25	352.8690	0.3666	212.5408	0.1715
2	27	342.6937	0.3526	191.1392	0.1496
2+skip	38	391.3770	0.3495	178.0782	0.1423
3	40	381.7758	0.3292	157.2506	0.1350
3+skip	51	420.5136	0.3125	134.2440	0.1095
4	53	448.2993	0.3281	150.8035	0.1168
4+skip	64	469.6004	0.2935	110.3602	0.0949
5	66	466.1276	0.2738	95.6611	0.0693
5+skip	77	525.5509	0.2773	93.3400	0.0766

由表 4.11 可见,虽然随着隐含层节点数的增加离差在下降,但可以发现模型的自由度在增加,且 SBC 增长的幅度大于误差函数减少的幅度。并从尽量减少

变量的维度、防止过拟合和提高泛化能力的角度出发,综合考虑各种情况,选择1个隐含节点。

在选定含有1个隐含层和1个隐含节点后,发现去掉偏倚项(bias)会使模型性能更好,故最后选择去掉bias项的网络结构进行建模,具体如表4.12所示。

表 4.12 1 个隐含层、1 个隐含节点时加与不加偏倚项后调试结果

bias 加否	模型自由度 (DFM)	SBC	均方根误差 (RMSE)	离差	误分率 (MISC)
加	14	307.3809	0.3689	228.7971	0.1752
不加	12	297.7802	0.3732	230.4226	0.1715

4.4.4 构造 MLP 模型

在本文中,由于样本量小,在模型拟合过程中为了尽可能地充分利用数据,故在防止过拟合过程中采用权重衰减技术,采用 Levenberg-Marquardt 优化算法,为避免局部最优,采用预训练(prelim=20)的方法。采用 11-1-1 网络结构,对模型进行拟合,并对结果变量进行样本内预测,结果如下:

其中 ROC 面积: 0.8863, 准确率: 83%, 灵敏度 (S_e): 76.6%, 特异度 (S_p): 89.1%。

4.5 三个模型拟合原始数据后的 ROC 面积比较的结果

LR、DT、NN3 个模型拟合后,计算 ROC 面积的大小,并对 ROC 面积进行统计学差异的检验,如表 4.13、表 4.14、图 4.11 所示。

表 4.13 三个模型拟合原始数据后的 ROC 面积大小

方法	AUC	SE	95%LCL	95%UCL
LR	0.8802	0.0202	0.8406	0.9199
DT	0.8536	0.0233	0.8080	0.8992
NN	0.8863	0.0200	0.8470	0.9256

表 4.14 三个模型拟合原始数据后的 ROC 面积($AUC_d=AUC_{column1}-AUC_{column2}$)比较结果

方法 1	方法 2	AUC_d	SE	95%LCL	95%UCL	χ^2	P
LR	DT	0.0266	0.014	-0.0008	0.0541	3.6077	0.0575
LR	NN	-0.0061	0.0069	-0.0196	0.0074	0.777	0.3781
NN	DT	-0.0327	0.0149	-0.0618	-0.0036	4.8453	0.0277




图 4.11 三个模型拟合原始数据后的 ROC 面积图

由表 4.13、表 4.14 可知，建立的 3 个模型的 ROC 面积由大到小依次为 $NN > LR > DT$ 。两两比较的结果发现，3 个模型间 ROC 面积差别均无统计学意义。由于 3 个模型要分别进行两两比较，故对 I 类错误的概率进行调整，调整后 $\alpha' = \frac{\alpha}{3} = \frac{0.05}{3} = 0.017$ 。因此，NN 与 DT 的 ROC 面积比较 ($\chi^2 = 4.8453$, $P = 0.0277$) 差别仍无统计学意义。

以上是对模型的泛化能力进行的样本内比较，虽然样本内比较也能体现一部分模型预测性能的优劣，但真正比较模型的泛化能力还要通过对三种方法样本外比较来发现模型间预测能力的差异，关于模型泛化能力的比较见第五章。

4.6 最佳分割点

不能简单地以 0.5 作为预测事件发生不发生的概率分割点^[59]。简单的做法是：对 LR、DT、NN 的后验概率进行过抽样调整后，找出 Youden 指数最大的点做为最佳概率分割点。各种模型对应的最佳概率分割点如表 4.15 所示。

表 4.15 三种模型最佳概率分割点列表

模型	分割点	S_e	S_p
LR	0.66	0.723	0.912
DT	0.54	0.788	0.832
NN	0.54	0.818	0.854

由表 4.15 可以看出，在实际工作中，若选用 NN 作为预测模型，则可选择

概率的分割点为 0.54, 此时 Youden 指数最大 (即灵敏度与特异度之和最大), 以此类推。并且可以看出, DT 和 NN 最佳概率分割点相同, 而 LR 的较高, 为 0.66。

4.7 小结

本文采用最优子集与 AIC 信息准则相结合的方法, 筛选变量后构造的 Logistic 回归模型, 既考虑了模型的泛化能力又避免了 P 界值点选取的“烦恼”, 建立起了优于常规筛选变量方法建立的模型。

在数据量有限的情况下, 能尽量多的利用数据信息非常重要。针对决策树和神经网络模型在建模的过程中易造成过拟合的特点, 而在建模的过程中又不宜采用保持法建模 (样本量小), 故采用 100 次 5~7 折分层交叉验证方法将 CHAID 法与 CART 法相结合, 建立起决策树模型, 既充分利用了样本信息, 又建立起可靠的模型。

采用 SBC 准则作为 MLP 隐含层数和隐含层节点数的选择标准, 结合 L-M 优化技术, 采用预训练方法避免局部最优, 采用权重衰减法避免过拟合等, 建立起 MLP 模型, 也达到既能充分利用样本信息, 又能建立起可靠模型的目的。

针对本研究数据集获得的方式为分离抽样的特点, 采用先验概率对后验概率进行调整, 从调整后的结果中找出预测的最佳概率分割点, 用于客观地预测疾病发生的可能性, 用以指导实际决策, 具体如表 4.15 所示。

第五章 三种模型预测性能比较结果

5.1 本章引论

在本文第一章 1.1、1.2 节中已提到, 如何针对小样本的特性, 有效地建立起模型并对模型的泛化能力进行客观评价, 是一个至关重要的问题。因此在本研究中针对小样本的特性, 尽量弥补保持法评价模型泛化能力(即预测性能)的不足, 提出了相应的解决方案: 采用 Monte Carlo 模拟抽样的校正技术, 对模型的泛化误差做出可靠地评价, 从而对 LR、DT、NN 三种模型的泛化能力进行比较, 达到客观评价其泛化能力的目的, 有效地弥补了保持法对模型泛化能力比较时的不足。

由本文第三章 3.4 节介绍可知, 为了更全面的评价模型的泛化能力, 必须考虑各种可能的诊断界点。而 ROC 曲线可通过改变诊断界点, 将灵敏度和特异度结合起来, 通过计算 ROC 曲线下面积, 根据曲线的形状和面积对诊断技术做出定量分析, 从而对模型做出总体预测能力的评价。因此在本研究中评价模型泛化能力时采用 ROC 面积作为评价三种模型预测性能的指标, 使结果更加准确可靠。

5.2 分层交叉验证的比较结果

5.2.1 分层交叉验证的流程

以 100 次 5 折分层交叉验证为例, 实现模型的泛化能力的评价。即先将数据随机分层抽样, 分成大致相同的 5 份(保证每份中病例组和对照组的观测数大致相同), 每份被轮流用于测试而其他数据用于训练。此过程重复 5 次, 从而每个观测恰好有一次用于训练, 有一次用于测试, 每一个个体均可得到用于测试后的一个预测概率值。反复重复 5 折分层交叉验证 100 次, 最后每个观测会得 100 个用于测试的概率估计值, 取每个观测的概率估计值的平均值用于最后计算 ROC 面积的大小。由于每次抽样是随机的, 为了得到可靠的估计, 单次的 n 折交叉验证有可能是不够。而且目前尚无明确的结论采用几折交叉验证是标准的评估方法。因此, 在本研究中采用了 2 折~10 折分层交叉验证的方法, 每次交叉验证方法重复进行 10 次~100 次, 通过 ROC 面积大小的变化趋势, 对 3 个模型泛化能力进行客观评价。整个分层交叉验证的过程如图 5.1 所示(以 100 次 5 折分层交叉验证为例)。




图 5.1 5 折交叉验证数据集分割（左）及 100 次 5 折交叉验证程序（右）示意图

5.2.2.2 折分层交叉验证的结果

1. 10 次~100 次 2 折分层交叉验证 ROC 面积大小及两两比较结果

表 5.1 给出 10 次~100 次 2 折分层交叉验证后 3 个模型 ROC 面积的大小、标准误、95%置信区间。表 5.2 给出 10 次~100 次 2 折分层交叉验证后三种方法 ROC 面积大小两两比较的结果。

表 5.1 三种方法 10~100 次 2 折分层交叉验证的 ROC 面积大小

次数	方法	AUC	SE	95%LCL	95%UCL
10	LR	0.8428	0.0244	0.7951	0.8906
	DT	0.8108	0.0275	0.7569	0.8646
	NN	0.8595	0.0230	0.8145	0.9046
20	LR	0.8559	0.0231	0.8107	0.9011
	DT	0.8155	0.0275	0.7617	0.8694
	NN	0.8557	0.0236	0.8095	0.9020
30	LR	0.8555	0.0229	0.8105	0.9004
	DT	0.8179	0.0272	0.7646	0.8712
	NN	0.8588	0.0229	0.8139	0.9037
40	LR	0.8531	0.0233	0.8073	0.8988
	DT	0.8182	0.0274	0.7645	0.8720
	NN	0.8568	0.0233	0.8111	0.9026
50	LR	0.8534	0.0232	0.8080	0.8989
	DT	0.8116	0.0277	0.7573	0.8659
	NN	0.8572	0.0232	0.8118	0.9026

次数	方法	AUC	SE	95%LCL	95%UCL
60	LR	0.8510	0.0235	0.8050	0.8971
	DT	0.8172	0.0272	0.7639	0.8705
	NN	0.8555	0.0233	0.8098	0.9011
70	LR	0.8529	0.0233	0.8073	0.8986
	DT	0.8179	0.0274	0.7641	0.8716
	NN	0.8576	0.0233	0.8119	0.9033
80	LR	0.8529	0.0232	0.8075	0.8984
	DT	0.8154	0.0275	0.7615	0.8693
	NN	0.8556	0.0235	0.8096	0.9015
90	LR	0.8514	0.0234	0.8055	0.8973
	DT	0.8168	0.0274	0.7631	0.8706
	NN	0.8564	0.0232	0.8108	0.9019
100	LR	0.8513	0.0234	0.8054	0.8972
	DT	0.8154	0.0275	0.7615	0.8693
	NN	0.8551	0.0234	0.8092	0.901

表 5.2 三种方法 10~100 次 2 折交叉验证后 ROC 面积($AUC_d = AUC_{column1} - AUC_{column2}$)比较结果

方法 1	方法 2	n	AUC_d	SE	95%LCL	95%UCL	χ^2	P
LR	NN	10	-0.0167	0.0093	-0.0349	0.0016	3.2044	0.0734
LR	DT	10	0.0321	0.0145	0.0037	0.0604	4.9094	0.0267
DT	NN	10	-0.0488	0.0155	-0.0790	-0.0185	9.9478	0.0016
LR	NN	20	0.0002	0.0089	-0.0171	0.0176	0.0006	0.9808
LR	DT	20	0.0404	0.0140	0.0130	0.0678	8.3541	0.0038
DT	NN	20	-0.0402	0.0144	-0.0685	-0.0119	7.7471	0.0054
LR	NN	30	-0.0033	0.0078	-0.0186	0.0120	0.1792	0.6721
LR	DT	30	0.0376	0.0149	0.0083	0.0668	6.3368	0.0118
DT	NN	30	-0.0409	0.0146	-0.0696	-0.0122	7.7951	0.0052
LR	NN	40	-0.0038	0.0074	-0.0184	0.0108	0.2587	0.6110
LR	DT	40	0.0348	0.0146	0.0062	0.0650	5.6931	0.0170
DT	NN	40	-0.0386	0.0150	-0.0680	-0.0093	6.6653	0.0098
LR	NN	50	-0.0038	0.0077	-0.0189	0.0113	0.2407	0.6237

方法 1	方法 2	<i>n</i>	AUC _d	SE	95%LCL	95%UCL	χ^2	<i>P</i>
LR	DT	50	0.0418	0.0145	0.0134	0.0703	8.2984	0.0040
DT	NN	50	-0.0456	0.0145	-0.0740	-0.0172	9.9341	0.0016
LR	NN	60	-0.0044	0.0082	-0.0204	0.0116	0.2938	0.5878
LR	DT	60	0.0338	0.0137	0.0070	0.0607	6.0922	0.0136
DT	NN	60	-0.0383	0.0135	-0.0648	-0.0117	7.9771	0.0047
LR	NN	70	-0.0046	0.0081	-0.0205	0.0112	0.3282	0.5667
LR	DT	70	0.0351	0.0133	0.0089	0.0612	6.9125	0.0086
DT	NN	70	-0.0397	0.0135	-0.0662	-0.0132	8.6053	0.0034
LR	NN	80	-0.0026	0.0081	-0.0184	0.0132	0.1046	0.7464
LR	DT	80	0.0375	0.0147	0.0086	0.0664	6.4755	0.0109
DT	NN	80	-0.0401	0.0149	-0.0693	-0.0109	7.2514	0.0071
LR	NN	90	-0.0050	0.0079	-0.0204	0.0105	0.3973	0.5285
LR	DT	90	0.0346	0.0137	0.0078	0.0614	6.4048	0.0114
DT	NN	90	-0.0395	0.0135	-0.0660	-0.0131	8.5638	0.0034
LR	NN	100	-0.0038	0.0083	-0.0200	0.0124	0.2154	0.6425
LR	DT	100	0.0359	0.0139	0.0087	0.0631	6.7001	0.0096
DT	NN	100	-0.0397	0.0138	-0.0668	-0.0127	8.3114	0.0039

由表 5.1、表 5.2 可以看出, 除个别次数 ($n=20$) LR 的 ROC 面积大于 NN 的 ROC 面积外, 其它次数的 2 折分层交叉验证后 ROC 面积由大到小依次为 $NN > LR > DT$ 。其中 LR 与 NN 差别均无统计学意义。NN 与 DT 的 ROC 面积的差别均有统计学意义。LR 与 DT 的 ROC 面积的差别除个别次数 ($n=10$, $\chi^2=4.9094$, $P=0.0267$) 无统计学意义外, 其它点的比较差别均有统计学意义。

2. 10 次~100 次 2 折分层交叉验证 ROC 面积示意图

分别绘制 10 次~100 次 2 折分层交叉验证后的 ROC 曲线, 如图 5.2 所示。




图 5.2 三种方法 10 次~100 次 2 折分层交叉验证 ROC 面积示意图




图 5.2 三种方法 10 次~100 次 2 折分层交叉验证 ROC 面积示意图

由图 5.2 可以看出，总体来说，2 折 10~100 次分层交叉验证得到 ROC 面积以 NN 最大，而 DT 的 ROC 面积最小。但从图 5.1 可以看出 NN 与 LR 的 ROC 面积差别不大。

5.2.3 3 折分层交叉验证的结果

1. 10 次~100 次 3 折分层交叉验证 ROC 面积大小及两两比较结果

表 5.3 给出 10 次~100 次 3 折分层交叉验证后 3 个模型 ROC 面积的大小、标准误、95%置信区间。表 5.4 给出 10 次~100 次 3 折分层交叉验证后三种方法 ROC 面积大小两两比较的结果。

表 5.3 三种方法 3 折分层交叉验证不同次数的 ROC 面积大小

次数	方法	AUC	SE	95%LCL	95%UCL
10	LR	0.8518	0.0236	0.8056	0.8980
	DT	0.7809	0.0303	0.7216	0.8402
	NN	0.8531	0.0234	0.8071	0.8990
20	LR	0.8501	0.0236	0.8038	0.8964
	DT	0.7904	0.0296	0.7324	0.8484
	NN	0.8597	0.0230	0.8146	0.9047
30	LR	0.8541	0.0232	0.8085	0.8996
	DT	0.7968	0.0294	0.7392	0.8544
	NN	0.8529	0.0237	0.8065	0.8993
40	LR	0.8534	0.0232	0.8078	0.8989
	DT	0.7941	0.0293	0.7366	0.8516
	NN	0.8560	0.0235	0.8100	0.9020
50	LR	0.8525	0.0233	0.8068	0.8983
	DT	0.7981	0.0293	0.7406	0.8555
	NN	0.8555	0.0234	0.8096	0.9014
60	LR	0.8518	0.0235	0.8059	0.8978
	DT	0.7953	0.0294	0.7376	0.8530
	NN	0.8550	0.0234	0.8091	0.9009
70	LR	0.8508	0.0235	0.8046	0.8969
	DT	0.7956	0.0296	0.7376	0.8535
	NN	0.8560	0.0234	0.8100	0.9019
80	LR	0.8529	0.0232	0.8074	0.8984
	DT	0.7995	0.0292	0.7422	0.8568
	NN	0.8569	0.0233	0.8112	0.9027
90	LR	0.8515	0.0234	0.8056	0.8973
	DT	0.7963	0.0294	0.7387	0.8539
	NN	0.8565	0.0234	0.8106	0.9024
100	LR	0.8525	0.0233	0.8068	0.8981
	DT	0.7946	0.0298	0.7363	0.8529
	NN	0.8552	0.0235	0.8093	0.9012

表 5.4 三种方法 3 折分层交叉验证后 ROC 面积($AUC_d = AUC_{column1} - AUC_{column2}$)比较结果

方法 1	方法 2	n	AUC_d	SE	95%LCL	95%UCL	χ^2	P
LR	NN	10	-0.0013	0.0075	-0.0159	0.0133	0.0294	0.8638
LR	DT	10	0.0709	0.0150	0.0414	0.1003	22.1876	<0.0001
DT	NN	10	-0.0721	0.0149	-0.1014	-0.0429	23.4159	<0.0001
LR	NN	20	-0.0095	0.0084	-0.0260	0.0070	1.2819	0.2575
LR	DT	20	0.0597	0.0150	0.0303	0.0892	15.8174	<0.0001
DT	NN	20	-0.0693	0.0151	-0.0989	-0.0396	20.9906	<0.0001
LR	NN	30	0.0011	0.0082	-0.0149	0.0171	0.0188	0.8910
LR	DT	30	0.0573	0.0143	0.0292	0.0853	15.9919	<0.0001
DT	NN	30	-0.0562	0.0150	-0.0856	-0.0268	14.0092	0.0002
LR	NN	40	-0.0026	0.0084	-0.0191	0.0138	0.0967	0.7558
LR	DT	40	0.0592	0.0143	0.0312	0.0873	17.0958	<0.0001
DT	NN	40	-0.0619	0.0146	-0.0904	-0.0333	18.0562	<0.0001
LR	NN	50	-0.0030	0.0080	-0.0187	0.0127	0.1383	0.7100
LR	DT	50	0.0545	0.0140	0.0270	0.0820	15.0619	0.0001
DT	NN	50	-0.0574	0.0149	-0.0866	-0.0283	14.8811	0.0001
LR	NN	60	-0.0031	0.0081	-0.0190	0.0127	0.1512	0.6974
LR	DT	60	0.0565	0.0147	0.0278	0.0853	14.8814	0.0001
DT	NN	60	-0.0597	0.0151	-0.0893	-0.0300	15.5439	<0.0001
LR	NN	70	-0.0052	0.0079	-0.0206	0.0102	0.4400	0.0571
LR	DT	70	0.0552	0.0143	0.0272	0.0832	14.9569	0.0001
DT	NN	70	-0.0604	0.0149	-0.0897	-0.0311	16.3594	<0.0001
LR	NN	80	-0.0040	0.0078	-0.0193	0.0113	0.2690	0.6040
LR	DT	80	0.0534	0.0146	0.0248	0.0819	13.4433	0.0002
DT	NN	80	-0.0574	0.0150	-0.0867	-0.0281	14.7592	0.0001
LR	NN	90	-0.0051	0.0083	-0.0214	0.0112	0.3700	0.5430
LR	DT	90	0.0551	0.0148	0.0262	0.0841	13.9753	0.0002

方法 1	方法 2	n	AUC _d	SE	95%LCL	95%UCL	χ^2	P
DT	NN	90	-0.0602	0.0146	-0.0889	-0.0315	16.8913	<0.0001
LR	NN	100	-0.0028	0.0082	-0.0188	0.0133	0.1141	0.7356
LR	DT	100	0.0579	0.0146	0.0293	0.0864	15.7893	<0.0001
DT	NN	100	-0.0606	0.0151	-0.0902	-0.0310	16.1303	<0.0001

由表 5.3、表 5.4 可以看出, 除个别次数 ($n=30$) LR 的 ROC 面积大于 NN 的 ROC 面积外, 其他次数的 3 折分层交叉验证后 ROC 面积由大到小依次为 NN>LR>DT。其中 LR 与 NN 差别均无统计学意义。NN、LR 与 DT 的 ROC 面积的差别均有统计学意义。

2. 以下是三种方法 10 次~100 次 3 折分层交叉验证后分别绘制 ROC 曲线, 如图 5.3 所示:




图 5.3 三种方法 10 次~100 次 3 折分层交叉验证 ROC 面积示意图




图 5.3 三种方法 10 次~100 次 3 折分层交叉验证 ROC 面积示意图

由图 5.3 可以看出, 总体来说, 3 折 10~100 次分层交叉验证得到 ROC 面积以 NN 最大, 而 DT 的 ROC 面积最小, 而 NN 与 LR 差别不大。

5.2.4.4 折分层交叉验证的结果

1. 10 次~100 次 4 折分层交叉验证 ROC 面积大小及两两比较结果

表 5.5 给出 10 次~100 次 4 折分层交叉验证后 3 个模型 ROC 面积的大小、标准误、95%置信区间。表 5.6 给出 10 次~100 次 4 折分层交叉验证后三种方法 ROC 面积大小两两比较的结果。

表 5.5 三种方法分层 4 折交叉验证不同次数的 ROC 面积大小

次数	方法	AUC	SE	95%LCL	95%UCL
10	LR	0.8500	0.0235	0.8041	0.8960
	DT	0.7871	0.0298	0.7287	0.8455
	NN	0.8586	0.0231	0.8133	0.9039
20	LR	0.8506	0.0235	0.8046	0.8967
	DT	0.7922	0.0297	0.7341	0.8503
	NN	0.8571	0.0232	0.8116	0.9026
30	LR	0.8527	0.0233	0.8070	0.8984
	DT	0.7902	0.0300	0.7314	0.8490
	NN	0.8566	0.0233	0.8110	0.9022
40	LR	0.8522	0.0234	0.8063	0.8981
	DT	0.7908	0.0300	0.7320	0.8495
	NN	0.8565	0.0235	0.8104	0.9026
50	LR	0.8506	0.0235	0.8045	0.8966
	DT	0.7892	0.0302	0.7301	0.8483
	NN	0.8562	0.0234	0.8104	0.9020
60	LR	0.8527	0.0233	0.8071	0.8983
	DT	0.7893	0.0304	0.7298	0.8489
	NN	0.8581	0.0233	0.8124	0.9038
70	LR	0.8500	0.0236	0.8037	0.8962
	DT	0.7877	0.0303	0.7284	0.8471
	NN	0.8584	0.0232	0.8130	0.9038
80	LR	0.8526	0.0232	0.8071	0.8981
	DT	0.7906	0.0301	0.7315	0.8497
	NN	0.8569	0.0234	0.8110	0.9028
90	LR	0.8531	0.0233	0.8074	0.8987

次数	方法	AUC	SE	95%LCL	95%UCL
100	DT	0.7908	0.0302	0.7315	0.8501
	NN	0.8574	0.0233	0.8116	0.9031
	LR	0.8529	0.0233	0.8073	0.8985
	DT	0.7899	0.0301	0.7310	0.8488
	NN	0.8577	0.0233	0.812	0.9034

表 5.6 三种方法 4 折交叉验证后 ROC 面积($AUC_d = AUC_{column1} - AUC_{column2}$)比较结果

方法 1	方法 2	n	AUC_d	SE	95%LCL	95%UCL	χ^2	P
LR	NN	10	-0.0086	0.0087	-0.0256	0.0084	0.9797	0.3223
LR	DT	10	0.0629	0.0158	0.0319	0.0940	15.7714	<0.0001
DT	NN	10	-0.0715	0.0160	-0.1029	-0.0401	19.8566	<0.0001
LR	NN	20	-0.0065	0.0081	-0.0224	0.0094	0.6430	0.4226
LR	DT	20	0.0584	0.0150	0.0291	0.0877	15.2207	<0.0001
DT	NN	20	-0.0649	0.0157	-0.0957	-0.0341	17.0182	<0.0001
LR	NN	30	-0.0039	0.0082	-0.0201	0.0122	0.2299	0.6316
LR	DT	30	0.0625	0.0159	0.0314	0.0936	15.5113	<0.0001
DT	NN	30	-0.0664	0.0163	-0.0984	-0.0345	16.5726	<0.0001
LR	NN	40	-0.0043	0.0084	-0.0208	0.0121	0.2644	0.6071
LR	DT	40	0.0614	0.0152	0.0316	0.0913	16.2536	<0.0001
DT	NN	40	-0.0657	0.0160	-0.0971	-0.0344	16.8466	<0.0001
LR	NN	50	-0.0056	0.0084	-0.0221	0.0108	0.4539	0.5005
LR	DT	50	0.0614	0.0151	0.0317	0.0910	16.4759	<0.0001
DT	NN	50	-0.0670	0.0161	-0.0985	-0.0356	17.4215	<0.0001
LR	NN	60	-0.0054	0.0082	-0.0214	0.0106	0.4349	0.5096
LR	DT	60	0.0633	0.0157	0.0325	0.0942	16.2097	<0.0001
DT	NN	60	-0.0687	0.0162	-0.1005	-0.0370	18.0162	<0.0001
LR	NN	70	-0.0084	0.0084	-0.0248	0.0080	1.0096	0.3150
LR	DT	70	0.0622	0.0158	0.0312	0.0933	15.4160	<0.0001

方法 1	方法 2	n	AUC _d	SE	95%LCL	95%UCL	χ^2	P
DT	NN	70	-0.0706	0.0166	-0.1033	-0.0380	18.0181	<0.0001
LR	NN	80	-0.0043	0.0082	-0.0204	0.0118	0.2696	0.6036
LR	DT	80	0.0620	0.0152	0.0323	0.0917	16.7322	<0.0001
DT	NN	80	-0.0663	0.0157	-0.0971	-0.0354	17.7104	<0.0001
LR	NN	90	-0.0043	0.0081	-0.0203	0.0116	0.2811	0.5960
LR	DT	90	0.0622	0.0152	0.0325	0.0920	16.8206	<0.0001
DT	NN	90	-0.0665	0.0160	-0.0978	-0.0353	17.3950	<0.0001
LR	NN	100	-0.0048	0.0080	-0.0205	0.0109	0.3577	0.5498
LR	DT	100	0.0630	0.0155	0.0325	0.0934	16.4090	<0.0001
DT	NN	100	-0.0678	0.0158	-0.0988	-0.0368	18.3597	<0.0001

由表 5.5、表 5.6 可以看出, 10~100 次 4 折分层交叉验证后 ROC 面积由大到小依次为 NN>LR>DT。其中 LR 与 NN 差别均无统计学意义。NN、LR 与 DT 的 ROC 面积的差别均有统计学意义。

2. 以下是三种方法 10 次~100 次 4 折交叉验证后分别绘制 ROC 曲线, 如图 5.4 所示:




图 5.4 三种方法 10 次~100 次 4 折分层交叉验证 ROC 面积示意图




图 5.4 三种方法 10 次~100 次 4 折分层交叉验证 ROC 面积示意图




图 5.4 10 次~100 次 4 折分层交叉验证 ROC 面积示意图

由图 5.4 可以看出,4 折 10~100 次分层交叉验证得到 ROC 面积以 NN 最大,而 DT 的 ROC 面积最小,而 NN 与 LR 的 ROC 面积差别不大。

5.2.5 5 折分层交叉验证的结果

1. 10 次~100 次 5 折分层交叉验证 ROC 面积大小及两两比较结果

表 5.7 给出 10 次~100 次 5 折分层交叉验证后 3 个模型 ROC 面积的大小、标准误、95%置信区间。表 5.8 给出 10 次~100 次 5 折分层交叉验证后三种方法 ROC 面积大小两两比较的结果。

表 5.7 三种方法 5 折交叉验证不同次数的 ROC 面积大小

次数	方法	AUC	SE	95%LCL	95%UCL
10	LR	0.8484	0.0236	0.8021	0.8948
	DT	0.7890	0.0301	0.7300	0.8480
	NN	0.8580	0.0232	0.8126	0.9034
20	LR	0.8501	0.0236	0.8039	0.8964
	DT	0.7852	0.0304	0.7257	0.8448
	NN	0.8569	0.0233	0.8112	0.9026
30	LR	0.8516	0.0234	0.8058	0.8974
	DT	0.7861	0.0305	0.7264	0.8458
	NN	0.8566	0.0234	0.8108	0.9025
40	LR	0.8533	0.0232	0.8077	0.8988
	DT	0.7867	0.0305	0.7269	0.8465

次数	方法	AUC	SE	95%LCL	95%UCL
50	NN	0.8581	0.0232	0.8127	0.9036
	LR	0.8525	0.0233	0.8069	0.8981
	DT	0.7923	0.0301	0.7334	0.8512
60	NN	0.8557	0.0235	0.8095	0.9018
	LR	0.8512	0.0234	0.8053	0.8971
	DT	0.7825	0.0309	0.7219	0.8430
70	NN	0.8571	0.0233	0.8114	0.9028
	LR	0.8532	0.0233	0.8076	0.8988
	DT	0.7858	0.0307	0.7257	0.8459
80	NN	0.8586	0.0232	0.8133	0.9040
	LR	0.8524	0.0234	0.8066	0.8982
	DT	0.7833	0.0308	0.7230	0.8437
90	NN	0.8577	0.0232	0.8123	0.9032
	LR	0.8521	0.0233	0.8064	0.8978
	DT	0.7811	0.0312	0.7200	0.8422
100	NN	0.8565	0.0234	0.8106	0.9023
	LR	0.8523	0.0233	0.8066	0.8979
	DT	0.7848	0.0307	0.7246	0.8450
	NN	0.8564	0.0234	0.8106	0.9023

表 5.8 三种方法 5 折交叉验证后 ROC 面积($AUC_d = AUC_{column1} - AUC_{column2}$)比较结果

方法 1	方法 2	n	AUC_d	SE	95%LCL	95%UCL	χ^2	P
LR	NN	10	-0.0096	0.0083	-0.0259	0.0067	1.3242	0.2498
LR	DT	10	0.0594	0.0163	0.0274	0.0914	13.2285	0.0003
DT	NN	10	-0.0690	0.0169	-0.0120	-0.0360	16.7537	<0.0001
LR	NN	20	-0.0068	0.0079	-0.0222	0.0087	0.7344	0.3914
LR	DT	20	0.0649	0.0162	0.0331	0.0967	16.0161	<0.0001
DT	NN	20	-0.0717	0.0167	-0.1044	-0.0389	18.3609	<0.0001
LR	NN	30	-0.0050	0.0081	-0.0208	0.0108	0.3862	0.5343
LR	DT	30	0.0655	0.0160	0.0342	0.0969	16.7809	<0.0001
DT	NN	30	-0.0705	0.0167	-0.1033	-0.0378	17.8621	<0.0001

方法 1	方法 2	n	AUC _d	SE	95%LCL	95%UCL	χ^2	P
LR	NN	40	-0.0048	0.0079	-0.0204	0.0107	0.3723	0.5418
LR	DT	40	0.0665	0.0159	0.0354	0.0977	17.5146	<0.0001
DT	NN	40	-0.0714	0.0164	-0.1035	-0.0393	18.9609	<0.0001
LR	NN	50	-0.0032	0.0083	-0.0195	0.0131	0.1478	0.7007
LR	DT	50	0.0602	0.0148	0.0313	0.0892	16.6098	<0.0001
DT	NN	50	-0.0634	0.0155	-0.0937	-0.0331	16.8135	<0.0001
LR	NN	60	-0.0059	0.0082	-0.0220	0.0102	0.5199	0.4709
LR	DT	60	0.0687	0.0163	0.0368	0.1006	17.8299	<0.0001
DT	NN	60	-0.0746	0.0168	-0.1076	-0.0417	19.7098	<0.0001
LR	NN	70	-0.0054	0.0081	-0.0231	0.0105	0.4481	0.5032
LR	DT	70	0.0674	0.0160	0.0360	0.0988	17.6778	<0.0001
DT	NN	70	-0.0728	0.0169	-0.1060	-0.0397	18.5475	<0.0001
LR	NN	80	-0.0053	0.0078	-0.0207	0.0100	0.4612	0.4971
LR	DT	80	0.0691	0.0160	0.0377	0.1005	18.5506	<0.0001
DT	NN	80	-0.0744	0.0167	-0.1072	-0.0417	19.8157	<0.0001
LR	NN	90	-0.0044	0.0081	-0.0203	0.0116	0.2879	0.5916
LR	DT	90	0.0710	0.0165	0.0386	0.1034	18.4688	<0.0001
DT	NN	90	-0.0754	0.0171	-0.1090	-0.0418	19.3403	<0.0001
LR	NN	100	-0.0042	0.0082	-0.0203	0.0120	0.2554	0.6133
LR	DT	100	0.0675	0.0160	0.0361	0.0988	17.7962	<0.0001
DT	NN	100	-0.0716	0.0165	-0.1040	-0.0392	18.8068	<0.0001

由表 5.7、表 5.8 可以看出, 10~100 次 5 折分层交叉验证后 ROC 面积大小两两比较的结果同 4 折分层交叉验证验证 ROC 面积两两比较的结果。

2. 以下是三种方法 10 次~100 次 5 折交叉验证后分别绘制 ROC 曲线, 如图 5.5 所示:




图 5.5 三种方法 10 次~100 次 5 折分层交叉验证 ROC 面积示意图




图 5.5 三种方法 10 次~100 次 5 折分层交叉验证 ROC 面积示意图

由图 5.5 可以看出，5 折 10~100 次分层交叉验证得到 ROC 曲线下面积图来看，同 4 折分层交叉验证 ROC 曲线下面积图比较的结果。

5.2.6 6 折分层交叉验证的结果

1. 10 次~100 次 6 折分层交叉验证 ROC 面积大小及两两比较结果

表 5.9 给出 10 次~100 次 6 折分层交叉验证后 3 个模型 ROC 面积的大小、标准误、95%置信区间。表 5.10 给出 10 次~100 次 6 折分层交叉验证后三种方法 ROC 面积大小两两比较的结果。

表 5.9 三种方法 6 折交叉验证不同次数的 ROC 面积大小

次数	方法	AUC	SE	95%LCL	95%UCL
10	LR	0.8516	0.0234	0.8056	0.8975
	DT	0.7841	0.0304	0.7244	0.8437
	NN	0.8554	0.0236	0.8092	0.9016
20	LR	0.8499	0.0236	0.8036	0.8963
	DT	0.7817	0.0311	0.7209	0.8426
	NN	0.8564	0.0234	0.8106	0.9022
30	LR	0.8510	0.0235	0.8049	0.8971
	DT	0.7822	0.0310	0.7214	0.8430
	NN	0.8565	0.0234	0.8106	0.9024
40	LR	0.8510	0.0234	0.8051	0.8970
	DT	0.7841	0.0305	0.7242	0.8439
	NN	0.8576	0.0233	0.8119	0.9034
50	LR	0.8511	0.0234	0.8053	0.8970
	DT	0.7796	0.0311	0.7187	0.8405
	NN	0.8571	0.0233	0.8114	0.9028
60	LR	0.8505	0.0236	0.8042	0.8968
	DT	0.7840	0.0309	0.7235	0.8445
	NN	0.8564	0.0233	0.8107	0.9021
70	LR	0.8521	0.0234	0.8064	0.8979
	DT	0.7835	0.0307	0.7234	0.8437
	NN	0.8566	0.0234	0.8108	0.9025
80	LR	0.8512	0.0235	0.8053	0.8972
	DT	0.7816	0.0311	0.7207	0.8425
	NN	0.8579	0.0233	0.8123	0.9035
90	LR	0.8517	0.0234	0.8058	0.8975
	DT	0.7821	0.0310	0.7214	0.8428
	NN	0.8573	0.0233	0.8116	0.9030
100	LR	0.8503	0.0235	0.8043	0.8964
	DT	0.7800	0.0312	0.7188	0.8412
	NN	0.8571	0.0233	0.8114	0.9028

表 5.10 三种方法 6 折交叉验证后 ROC 面积(AUC_d=AUC_{column1}-AUC_{column2})比较结果

方法 1	方法 2	<i>n</i>	AUC _d	SE	95%LCL	95%UCL	χ^2	<i>P</i>
LR	NN	10	-0.0038	0.0082	-0.0199	0.0122	0.2191	0.6397
LR	DT	10	0.0675	0.0162	0.0357	0.0993	17.3348	<0.0001
DT	NN	10	-0.0713	0.0174	-0.1054	-0.0373	16.8500	<0.0001
LR	NN	20	-0.0064	0.0081	-0.0224	0.0095	0.6265	0.4286
LR	DT	20	0.0682	0.0164	0.0360	0.1004	17.2516	<0.0001
DT	NN	20	-0.0746	0.0175	-0.1089	-0.0404	18.2288	<0.0001
LR	NN	30	-0.0055	0.0081	-0.0213	0.0104	0.4609	0.4972
LR	DT	30	0.0688	0.0160	0.0375	0.1001	18.5133	<0.0001
DT	NN	30	-0.0743	0.0170	-0.1076	-0.0409	19.0491	<0.0001
LR	NN	40	-0.0066	0.0084	-0.0231	0.0099	0.6150	0.4329
LR	DT	40	0.0670	0.0161	0.0355	0.0985	17.3651	<0.0001
DT	NN	40	-0.0736	0.0171	-0.1071	-0.0401	18.5484	<0.0001
LR	NN	50	-0.0060	0.0082	-0.0221	0.0102	0.5247	0.4688
LR	DT	50	0.0716	0.0167	0.0388	0.1043	18.2954	<0.0001
DT	NN	50	-0.0775	0.0176	-0.1120	-0.0430	19.3953	<0.0001
LR	NN	60	-0.0059	0.0083	-0.0222	0.0104	0.4969	0.4809
LR	DT	60	0.0665	0.0159	0.0352	0.0977	17.3890	<0.0001
DT	NN	60	-0.0724	0.0169	-0.1055	-0.0392	18.2552	<0.0001
LR	NN	70	-0.0045	0.0082	-0.0206	0.0116	0.2975	0.5854
LR	DT	70	0.0686	0.0159	0.0375	0.0997	18.7256	<0.0001
DT	NN	70	-0.0731	0.0165	-0.1054	-0.0408	19.7044	<0.0001
LR	NN	80	-0.0067	0.0082	-0.0227	0.0094	0.6604	0.4164
LR	DT	80	0.0696	0.0163	0.0378	0.1015	18.3625	<0.0001
DT	NN	80	-0.0763	0.0172	-0.1099	-0.0427	19.7714	<0.0001
LR	NN	90	-0.0056	0.0081	-0.0215	0.0102	0.4894	0.4842

方法 1	方法 2	n	AUC _d	SE	95%LCL	95%UCL	χ^2	P
LR	DT	90	0.0696	0.0165	0.0372	0.1019	17.7717	<0.0001
DT	NN	90	-0.0752	0.0169	-0.1084	-0.0421	19.7524	<0.0001
LR	NN	100	-0.0068	0.0082	-0.0229	0.0094	0.6741	0.4116
LR	DT	100	0.0703	0.0168	0.0374	0.1033	17.4790	<0.0001
DT	NN	100	-0.0771	0.0175	-0.1114	-0.0428	19.3734	<0.0001

由表 5.9、表 5.10 可以看出, 10~100 次 6 折分层交叉验证后 ROC 面积比较的结果与 4 折分层交叉验证 ROC 面积两两比较的结果同。

2. 以下是三种方法 10 次~100 次 6 折交叉验证后分别绘制 ROC 曲线, 如图 5.6 所示:




图 5.6 三种方法 10 次~100 次 6 折分层交叉验证 ROC 面积示意图




图 5.6 三种方法 10 次~100 次 6 折分层交叉验证 ROC 面积示意图

由图 5.6 可以看出, 6 折 10~100 次分层交叉验证得到 ROC 曲线下面积图来看, 同 4 折分层交叉验证 ROC 曲线下面积图比较的结果。

5.2.7 7 折分层交叉验证的结果

1. 10 次~100 次 7 折分层交叉验证 ROC 面积大小及两两比较结果

表 5.11 给出 10 次~100 次 7 折分层交叉验证后 3 个模型 ROC 面积的大小、标准误、95%置信区间。表 5.12 给出 10 次~100 次 7 折分层交叉验证后三种方法 ROC 面积的大小两两比较的结果。

表 5.11 三种方法 7 折交叉验证不同次数的 ROC 面积大小

次数	方法	AUC	SE	95%LCL	95%UCL
10	LR	0.8518	0.0234	0.8058	0.8977
	DT	0.7778	0.0310	0.7169	0.8386
	NN	0.8566	0.0234	0.8108	0.9025
20	LR	0.8508	0.0235	0.8047	0.8969
	DT	0.7858	0.0305	0.7260	0.8456
	NN	0.8598	0.0230	0.8147	0.9049
30	LR	0.8506	0.0235	0.8045	0.8966
	DT	0.7806	0.0310	0.7199	0.8413
	NN	0.8572	0.0233	0.8115	0.9028
40	LR	0.8516	0.0234	0.8057	0.8975
	DT	0.7772	0.0312	0.7160	0.8384
	NN	0.8575	0.0234	0.8117	0.9032
50	LR	0.8514	0.0234	0.8055	0.8972
	DT	0.7821	0.0310	0.7214	0.8429
	NN	0.8578	0.0232	0.8123	0.9033
60	LR	0.8521	0.0234	0.8064	0.8979
	DT	0.7794	0.0313	0.7182	0.8407
	NN	0.8574	0.0233	0.8118	0.9031
70	LR	0.8512	0.0235	0.8053	0.8972
	DT	0.7794	0.0312	0.7182	0.8406
	NN	0.8576	0.0233	0.8120	0.9033
80	LR	0.8525	0.0233	0.8068	0.8982
	DT	0.7770	0.0315	0.7151	0.8388
	NN	0.8577	0.0233	0.8121	0.9034
90	LR	0.8519	0.0234	0.8060	0.8977

次数	方法	AUC	SE	95%LCL	95%UCL
100	DT	0.7788	0.0313	0.7174	0.8403
	NN	0.8566	0.0234	0.8108	0.9024
	LR	0.8517	0.0234	0.8059	0.8975
	DT	0.7790	0.0313	0.7176	0.8404
	NN	0.8563	0.0234	0.8104	0.9022

表 5.12 三种方法 7 折交叉验证后 ROC 面积($AUC_d = AUC_{column1} - AUC_{column2}$)比较结果

方法 1	方法 2	n	AUC_d	SE	95%LCL	95%UCL	χ^2	P
LR	NN	10	-0.0048	0.0086	-0.0217	0.0120	0.3175	0.5731
LR	DT	10	0.0740	0.0170	0.0406	0.1074	18.8618	<0.0001
DT	NN	10	-0.0789	0.0176	-0.1133	-0.0444	20.1041	<0.0001
LR	NN	20	-0.0090	0.0084	-0.0255	0.0075	1.1470	0.2842
LR	DT	20	0.0651	0.0157	0.0342	0.0959	17.1165	<0.0001
DT	NN	20	-0.0741	0.0166	-0.1067	-0.0414	19.7862	<0.0001
LR	NN	30	-0.0066	0.0082	-0.0226	0.0094	0.6568	0.4177
LR	DT	30	0.0700	0.0163	0.0379	0.1020	18.3396	<0.0001
DT	NN	30	-0.0766	0.0169	-0.1098	-0.0434	20.4266	<0.0001
LR	NN	40	-0.0059	0.0082	-0.0219	0.0102	0.5102	0.4750
LR	DT	40	0.0744	0.0167	0.0416	0.1071	19.7884	<0.0001
DT	NN	40	-0.0802	0.0173	-0.1141	-0.0464	21.5767	<0.0001
LR	NN	50	-0.0064	0.0082	-0.0224	0.0095	0.6252	0.4291
LR	DT	50	0.0692	0.0161	0.0377	0.1007	18.4981	<0.0001
DT	NN	50	-0.0757	0.0170	-0.1089	-0.0424	19.8711	<0.0001
LR	NN	60	-0.0053	0.0081	-0.0211	0.0106	0.4244	0.5148
LR	DT	60	0.0727	0.0166	0.0401	0.1054	19.0884	<0.0001
DT	NN	60	-0.0780	0.0174	-0.1122	-0.0438	20.0056	<0.0001
LR	NN	70	-0.0064	0.0082	-0.0225	0.0097	0.6051	0.4366
LR	DT	70	0.0719	0.0165	0.0395	0.1042	18.9849	<0.0001
DT	NN	70	-0.0783	0.0173	-0.1121	-0.0444	20.5104	<0.0001

方法 1	方法 2	<i>n</i>	AUC _d	SE	95%LCL	95%UCL	χ^2	<i>P</i>
LR	NN	80	-0.0053	0.0082	-0.0213	0.0108	0.4145	0.5197
LR	DT	80	0.0755	0.0174	0.0414	0.1096	18.8671	<0.0001
DT	NN	80	-0.0808	0.0179	-0.1159	-0.0457	20.3354	<0.0001
LR	NN	90	-0.0047	0.0082	-0.0208	0.0114	0.3264	0.5678
LR	DT	90	0.0730	0.0167	0.0403	0.1058	19.0985	<0.0001
DT	NN	90	-0.0777	0.0176	-0.1121	-0.0433	19.6086	<0.0001
LR	NN	100	-0.0046	0.0082	-0.0206	0.0115	0.3126	0.5761
LR	DT	100	0.0727	0.0168	0.0398	0.1056	18.7826	<0.0001
DT	NN	100	-0.0773	0.0174	-0.1113	-0.0433	19.8145	<0.0001

由表 5.11、表 5.12 可以看出，10~100 次 6 折分层交叉验证后 ROC 面积比较的结果与 4 折分层交叉验证 ROC 面积两两比较的结果同。

2. 以下是三种方法 10 次~100 次 7 折交叉验证后分别绘制 ROC 曲线，如图 5.7 所示：




图 5.7 三种方法 10 次~100 次 7 折分层交叉验证 ROC 面积示意图




图 5.7 三种方法 10 次~100 次 7 折分层交叉验证 ROC 面积示意图




图 5.7 三种方法 10 次~100 次 7 折分层交叉验证 ROC 面积示意图

由图 5.7 可以看出，7 折 10~100 次分层交叉验证得到 ROC 曲线下面积图来看，同 4 折分层交叉验证 ROC 曲线下面积图比较的结果。

5.2.8 8 折分层交叉验证的结果

1. 10 次~100 次 8 折分层交叉验证 ROC 面积大小及两两比较结果

表 5.13 给出 10 次~100 次 8 折分层交叉验证后 3 个模型 ROC 面积的、标准误、95%置信区间。表 5.14 给出 10 次~100 次 8 折分层交叉验证后三种方法 AUC 大小两两比较的结果。

表 5.13 三种方法 8 折交叉验证不同次数的 ROC 面积大小

次数	方法	AUC	SE	95%LCL	95%UCL
10	LR	0.8496	0.0237	0.8032	0.8961
	DT	0.7787	0.0312	0.7176	0.8398
	NN	0.8581	0.0232	0.8126	0.9036
20	LR	0.8531	0.0232	0.8076	0.8985
	DT	0.7771	0.0311	0.7162	0.8381
	NN	0.8576	0.0232	0.8121	0.9032
30	LR	0.8514	0.0234	0.8056	0.8972
	DT	0.7789	0.0313	0.7175	0.8403
	NN	0.8563	0.0233	0.8106	0.9021
40	LR	0.8521	0.0234	0.8064	0.8979
	DT	0.7808	0.0310	0.7200	0.8416
	NN	0.8571	0.0233	0.8115	0.9027

次数	方法	AUC	SE	95%LCL	95%UCL
50	LR	0.8527	0.0233	0.8071	0.8983
	DT	0.7745	0.0317	0.7125	0.8366
	NN	0.8575	0.0232	0.8120	0.9030
60	LR	0.8516	0.0233	0.8058	0.8973
	DT	0.7792	0.0312	0.7180	0.8404
	NN	0.8579	0.0233	0.8123	0.9034
70	LR	0.8522	0.0233	0.8065	0.8979
	DT	0.7771	0.0314	0.7155	0.8387
	NN	0.8574	0.0233	0.8118	0.9031
80	LR	0.8524	0.0233	0.8067	0.8982
	DT	0.7771	0.0315	0.7154	0.8388
	NN	0.8567	0.0233	0.8110	0.9025
90	LR	0.8524	0.0233	0.8067	0.8981
	DT	0.7742	0.0318	0.7119	0.8365
	NN	0.8579	0.0232	0.8124	0.9034
100	LR	0.8516	0.0234	0.8057	0.8974
	DT	0.7745	0.0316	0.7126	0.8363
	NN	0.8565	0.0234	0.8107	0.9024

表 5.14 三种方法 8 折交叉验证后 ROC 面积($AUC_d = AUC_{column1} - AUC_{column2}$)比较结果

方法 1	方法 2	n	AUC_d	SE	95%LCL	95%UCL	χ^2	P
LR	NN	10	-0.0085	0.0085	-0.0251	0.0081	0.9979	0.3178
LR	DT	10	0.0710	0.0171	0.0374	0.1046	17.1385	<0.0001
DT	NN	10	-0.0794	0.0181	-0.1149	-0.0440	19.2947	<0.0001
LR	NN	20	-0.0046	0.0083	-0.0208	0.0117	0.3056	0.5804
LR	DT	20	0.0759	0.0172	0.0422	0.1096	19.5065	<0.0001
DT	NN	20	-0.0805	0.0181	-0.1160	-0.0450	19.7516	<0.0001
LR	NN	30	-0.0049	0.0081	-0.0208	0.0110	0.3646	0.5460
LR	DT	30	0.0725	0.0172	0.0388	0.1062	17.7987	<0.0001
DT	NN	30	-0.0774	0.0179	-0.1125	-0.0423	18.6782	<0.0001
LR	NN	40	-0.0050	0.0081	-0.0208	0.0108	0.3777	0.5389

方法 1	方法 2	<i>n</i>	AUC _d	SE	95%LCL	95%UCL	χ^2	<i>P</i>
LR	DT	40	0.0713	0.0162	0.0396	0.1031	19.3658	<0.0001
DT	NN	40	-0.0763	0.0171	-0.1099	-0.0427	19.8380	<0.0001
LR	NN	50	-0.0048	0.0080	-0.0205	0.0109	0.3592	0.5490
LR	DT	50	0.0782	0.0174	0.0441	0.1123	20.1700	<0.0001
DT	NN	50	-0.0830	0.0181	-0.1184	-0.0475	21.0747	<0.0001
LR	NN	60	-0.0063	0.0083	-0.0226	0.0100	0.5731	0.4490
LR	DT	60	0.0724	0.0168	0.0395	0.1053	18.6427	<0.0001
DT	NN	60	-0.0787	0.0175	-0.1131	-0.0443	20.1181	<0.0001
LR	NN	70	-0.0052	0.0080	-0.0209	0.0104	0.4275	0.5132
LR	DT	70	0.0751	0.1720	0.0413	0.1089	18.9745	<0.0001
DT	NN	70	-0.0803	0.0179	-0.1153	-0.0454	20.2554	<0.0001
LR	NN	80	-0.0043	0.0081	-0.0201	0.0115	0.2854	0.5932
LR	DT	80	0.0753	0.0170	0.0420	0.1086	19.6371	<0.0001
DT	NN	80	-0.0796	0.0176	-0.1141	-0.0451	20.4383	<0.0001
LR	NN	90	-0.0055	0.0081	-0.0214	0.0104	0.4580	0.4985
LR	DT	90	0.0782	0.0177	0.0436	0.1128	19.6108	<0.0001
DT	NN	90	-0.0837	0.0183	-0.1196	-0.0478	20.9171	<0.0001
LR	NN	100	-0.0050	0.0080	-0.0206	0.0107	0.3836	0.5357
LR	DT	100	0.0771	0.0173	0.0431	0.1111	19.7745	<0.0001
DT	NN	100	-0.0821	0.0179	-0.1172	-0.0469	20.9673	<0.0001

由表 5.13、表 5.14 可以看出, 10~100 次 7 折分层交叉验证后 ROC 面积比较的结果与 4 折分层交叉验证 ROC 面积两两比较的结果同。

2. 以下是三种方法 10 次~100 次 8 折交叉验证后分别绘制 ROC 曲线, 如图 5.8 所示:




图 5.8 三种方法 10 次~100 次 8 折分层交叉验证 ROC 面积示意图




图 5.8 三种方法 10 次~100 次 8 折分层交叉验证 ROC 面积示意图

由图 5.8 可以看出，8 折 10~100 次分层交叉验证得到 ROC 曲线下面积图来看，同 4 折分层交叉验证 ROC 曲线下面积图比较的结果。

5.2.9 9 折分层交叉验证的结果

1. 10 次~100 次 9 折分层交叉验证 ROC 面积大小及两两比较结果

表 5.15 给出 10 次~100 次 9 折分层交叉验证后 3 个模型 ROC 面积的大小、标准误、95%置信区间。表 5.16 给出 10 次~100 次 9 折分层交叉验证后三种方法 ROC 面积大小两两比较的结果。

表 5.15 三种方法 9 折交叉验证不同次数的 ROC 面积大小

次数	方法	AUC	SE	95%LCL	95%UCL
10	LR	0.8535	0.0233	0.8079	0.8991
	DT	0.7803	0.0309	0.7197	0.8409
	NN	0.8589	0.0231	0.8135	0.9042
20	LR	0.851	0.0236	0.8048	0.8971
	DT	0.777	0.0316	0.7151	0.8390
	NN	0.8572	0.0233	0.8115	0.9028
30	LR	0.8521	0.0234	0.8063	0.8980
	DT	0.7737	0.0317	0.7115	0.8359
	NN	0.8588	0.0231	0.8134	0.9041
40	LR	0.8523	0.0234	0.8065	0.8981
	DT	0.7761	0.0314	0.7146	0.8375
	NN	0.8574	0.0233	0.8117	0.9030
50	LR	0.8518	0.0234	0.8059	0.8977
	DT	0.7718	0.0318	0.7095	0.8340
	NN	0.8571	0.0233	0.8114	0.9028
60	LR	0.8516	0.0234	0.8057	0.8974
	DT	0.7757	0.0315	0.7139	0.8376
	NN	0.8571	0.0234	0.8113	0.9029
70	LR	0.8511	0.0235	0.8052	0.8971
	DT	0.7707	0.0319	0.7081	0.8333
	NN	0.8574	0.0233	0.8117	0.9030
80	LR	0.8521	0.0233	0.8064	0.8978
	DT	0.7723	0.0318	0.7100	0.8346
	NN	0.8568	0.0233	0.8111	0.9025
90	LR	0.8522	0.0234	0.8064	0.8980
	DT	0.7747	0.0317	0.7126	0.8369
	NN	0.8568	0.0234	0.8110	0.9026
100	LR	0.8509	0.0235	0.8049	0.8969
	DT	0.7728	0.0317	0.7106	0.8350
	NN	0.8565	0.0233	0.8107	0.9022

表 5.16 三种方法 9 折交叉验证后 ROC 面积($AUC_d = AUC_{column1} - AUC_{column2}$)比较结果

方法 1	方法 2	n	AUC_d	SE	95%LCL	95%UCL	χ^2	P
LR	NN	10	-0.0053	0.0082	-0.0215	0.0108	0.4173	0.5183
LR	DT	10	0.0733	0.0166	0.0407	0.1058	19.5068	<0.0001
DT	NN	10	-0.0786	0.0177	-0.1134	-0.0438	19.6146	<0.0001
LR	NN	20	-0.0062	0.0081	-0.0220	0.0096	0.5889	0.4429
LR	DT	20	0.0740	0.0175	0.0396	0.1083	17.7596	<0.0001
DT	NN	20	-0.0801	0.0181	-0.1156	-0.0447	19.6450	<0.0001
LR	NN	30	-0.0066	0.0083	-0.0229	0.0097	0.6290	0.4277
LR	DT	30	0.0785	0.0175	0.0442	0.1128	20.1089	<0.0001
DT	NN	30	-0.0851	0.0182	-0.1208	-0.0494	21.8469	<0.0001
LR	NN	40	-0.0051	0.0081	-0.0210	0.0108	0.3892	0.5327
LR	DT	40	0.0762	0.0170	0.0429	0.1096	20.0519	<0.0001
DT	NN	40	-0.0813	0.0178	-0.1161	-0.0465	20.9770	<0.0001
LR	NN	50	-0.0053	0.0080	-0.0209	0.0104	0.4364	0.5088
LR	DT	50	0.0801	0.0174	0.0460	0.1142	21.1507	<0.0001
DT	NN	50	-0.0854	0.0182	-0.1209	-0.0498	22.1144	<0.0001
LR	NN	60	-0.0055	0.0083	-0.0218	0.0107	0.4453	0.5046
LR	DT	60	0.0758	0.0172	0.0422	0.1095	19.4852	<0.0001
DT	NN	60	-0.0814	0.0180	-0.1166	-0.0461	20.4939	<0.0001
LR	NN	70	-0.0062	0.0080	-0.0219	0.0094	0.6075	0.4357
LR	DT	70	0.0804	0.0178	0.0455	0.1153	20.3829	<0.0001
DT	NN	70	-0.0866	0.0183	-0.1226	-0.0507	22.3134	<0.0001
LR	NN	80	-0.0047	0.0080	-0.0204	0.0110	0.3435	0.5578
LR	DT	80	0.0798	0.0175	0.0454	0.1141	20.7383	<0.0001
DT	NN	80	-0.0844	0.0182	-0.1201	-0.0488	21.5389	<0.0001
LR	NN	90	-0.0046	0.0081	-0.0204	0.0112	0.3230	0.5698

方法 1	方法 2	<i>n</i>	AUC _d	SE	95%LCL	95%UCL	χ^2	<i>P</i>
LR	DT	90	0.0775	0.0175	0.0431	0.1118	19.5279	<0.0001
DT	NN	90	-0.0821	0.0180	-0.1174	-0.0467	20.6894	<0.0001
LR	NN	100	-0.0056	0.0081	-0.0214	0.0102	0.4791	0.4888
LR	DT	100	0.0781	0.0174	0.0441	0.1121	20.2656	<0.0001
DT	NN	100	-0.0837	0.0180	-0.1189	-0.0485	21.6939	<0.0001

由表 5.15、表 5.16 可以看出，10~100 次 9 折分层交叉验证后 ROC 面积比较的结果与 4 折分层交叉验证 ROC 面积两两比较的结果同。

2. 以下是三种方法 10 次~100 次 9 折交叉验证后分别绘制 ROC 曲线，如图 5.9 所示：




图 5.9 三种方法 10 次~100 次 9 折分层交叉验证 ROC 面积示意图




图 5.9 三种方法 10 次~100 次 9 折分层交叉验证 ROC 面积示意图

由图 5.9 可以看出，9 折 10~100 次分层交叉验证得到 ROC 曲线下面积图来

看,同4折分层交叉验证 ROC 曲线下面积图比较的结果。

5.2.10 10 折分层交叉验证的结果

1. 10 次~100 次 10 折分层交叉验证 ROC 面积大小及两两比较结果

表 5.17 给出 10 次~100 次 10 折分层交叉验证后 3 个模型 ROC 面积的、标准误、95%置信区间。表 5.18 给出 10 次~100 次 10 折分层交叉验证后三种方法 ROC 面积大小两两比较的结果。

表 5.17 三种方法 10 折交叉验证不同次数的 ROC 面积大小

次数	方法	AUC	SE	95%LCL	95%UCL
10	LR	0.8531	0.0233	0.8075	0.8986
	DT	0.7759	0.0314	0.7144	0.8174
	NN	0.8582	0.0232	0.8128	0.9036
20	LR	0.8529	0.0232	0.8074	0.8984
	DT	0.7784	0.0312	0.7172	0.8395
	NN	0.8557	0.0235	0.8096	0.9018
30	LR	0.8520	0.0234	0.8061	0.8979
	DT	0.7740	0.0316	0.7120	0.8360
	NN	0.8561	0.0234	0.8104	0.9019
40	LR	0.8515	0.0234	0.8057	0.8973
	DT	0.7715	0.0319	0.7091	0.8340
	NN	0.8567	0.0234	0.8109	0.9026
50	LR	0.8514	0.0234	0.8056	0.8972
	DT	0.7724	0.0318	0.7101	0.8347
	NN	0.8580	0.0232	0.8125	0.9034
60	LR	0.8523	0.0233	0.8066	0.8980
	DT	0.7717	0.0317	0.7095	0.8339
	NN	0.8577	0.0233	0.8122	0.9033
70	LR	0.8516	0.0234	0.8057	0.8974
	DT	0.7748	0.0317	0.7126	0.8369
	NN	0.8569	0.0233	0.8112	0.9026
80	LR	0.8519	0.0234	0.8060	0.8977
	DT	0.7764	0.0315	0.7146	0.8381
	NN	0.8560	0.0234	0.8101	0.9019
90	LR	0.8521	0.0234	0.8063	0.8979
	DT	0.7733	0.0319	0.7108	0.8359
	NN	0.8572	0.0233	0.8116	0.9028

次数	方法	AUC	SE	95%LCL	95%UCL
100	LR	0.8517	0.0234	0.8058	0.8975
	DT	0.7715	0.0320	0.7089	0.8342
	NN	0.8572	0.0233	0.8115	0.9028

表 5.18 三种方法 10 折交叉验证后 ROC 面积($AUC_d = AUC_{column1} - AUC_{column2}$)比较结果

方法 1	方法 2	n	AUC_d	SE	95%LCL	95%UCL	χ^2	P
LR	NN	10	-0.0051	0.0082	-0.0213	0.0110	0.3859	0.5345
LR	DT	10	0.0771	0.0170	0.0439	0.1104	20.7110	<0.0001
DT	NN	10	-0.0823	0.0172	-0.1160	-0.0485	22.8263	<0.0001
LR	NN	20	-0.0028	0.0082	-0.0189	0.0134	0.1129	0.7369
LR	DT	20	0.0746	0.0161	0.0430	0.1062	21.3928	<0.0001
DT	NN	20	-0.0774	0.0171	-0.1108	-0.0439	20.5144	<0.0001
LR	NN	30	-0.0042	0.0081	-0.0201	0.0117	0.2626	0.6083
LR	DT	30	0.0780	0.0174	0.0439	0.1121	20.0459	<0.0001
DT	NN	30	-0.0822	0.0181	-0.1177	-0.0466	20.5413	<0.0001
LR	NN	40	-0.0052	0.0079	-0.0208	0.0104	0.4314	0.5113
LR	DT	40	0.0800	0.0178	0.0452	0.1148	20.2918	<0.0001
DT	NN	40	-0.0852	0.0183	-0.1211	-0.0492	21.5717	<0.0001
LR	NN	50	-0.0066	0.0081	-0.0224	0.0093	0.6556	0.4181
LR	DT	50	0.0790	0.0176	0.0446	0.1134	20.2437	<0.0001
DT	NN	50	-0.0856	0.0183	-0.1214	-0.0497	21.8825	<0.0001
LR	NN	60	-0.0054	0.0080	-0.0210	0.0102	0.4664	0.4946
LR	DT	60	0.0806	0.0173	0.0467	0.1145	21.7545	<0.0001
DT	NN	60	-0.0860	0.0182	-0.1216	-0.0505	22.4710	<0.0001
LR	NN	70	-0.0053	0.0080	-0.0209	0.0103	0.4489	0.5029
LR	DT	70	0.0768	0.0175	0.0425	0.1110	19.3271	<0.0001
DT	NN	70	-0.0821	0.0182	-0.1178	-0.0464	20.3015	<0.0001

方法 1	方法 2	<i>n</i>	AUC _d	SE	95%LCL	95%UCL	χ^2	<i>P</i>
LR	NN	80	-0.0041	0.0080	-0.0198	0.0116	0.2630	0.6081
LR	DT	80	0.0755	0.0173	0.0416	0.1094	19.0351	<0.0001
DT	NN	80	-0.0796	0.0178	-0.1145	-0.0447	19.9305	<0.0001
LR	NN	90	-0.0051	0.0080	-0.0207	0.0105	0.4125	0.5207
LR	DT	90	0.0787	0.0177	0.0440	0.1135	19.7770	<0.0001
DT	NN	90	-0.0839	0.0184	-0.1200	-0.0477	20.6730	<0.0001
LR	NN	100	-0.0055	0.0080	-0.0213	0.0103	0.4651	0.4952
LR	DT	100	0.0801	0.0180	0.0449	0.1153	19.8922	<0.0001
DT	NN	100	-0.0856	0.0186	-0.1220	-0.0492	21.2680	<0.0001

由表 5.17、表 5.18 可以看出，10~100 次 10 折分层交叉验证后 ROC 面积比较的结果与 4 折分层交叉验证 ROC 面积两两比较的结果同。

2. 以下是三种方法 10 次~100 次 10 折交叉验证后分别绘制 ROC 曲线，如图 5.10 所示：




图 5.10 三种方法 10 次~100 次 10 折分层交叉验证 ROC 面积示意图




图 5.10 三种方法 10 次~100 次 10 折分层交叉验证 ROC 面积示意图




图 5.10 三种方法 10 次~100 次 10 折分层交叉验证 ROC 面积示意图

由图 5.10 可以看出，10 折 10~100 次分层交叉验证得到 ROC 曲线下面积图来看，同 4 折分层交叉验证 ROC 曲线下面积图比较的结果。

5.2.11 10 次~100 次 2 折~10 折分层交叉验证 ROC 面积大小变化示意图




图 5.11 三种方法 10 次~100 次、2 折~10 折分层交叉验证 ROC 面积大小变化




图 5.11 三种方法 10 次~100 次、2 折~10 折分层交叉验证 ROC 面积大小变化

由图 5.11 可以看出，10 次~100 次、2 折~10 折分层交叉验证 ROC 面积，总体来说，以 NN 的 ROC 面积最大，LR 的 ROC 面积次之，DT 的 ROC 面积最小。并且可以看出，随着折数和次数的增加，每种模型的 ROC 面积的变化很小，基本稳定。

5.3 刀切法比较结果

5.3.1 刀切法对模型泛化能力评价实现流程

本文第三章 3.5 节中已经提到，刀切法其实就是 n (n 为数据集所含观测的个数，在本研究中 $n=274$) 折交叉验证。每个观测依次被保留在外，剩余的观测用于模型的训练。因此每个观测用于 273 次训练一次测试，故可得到 274 个测试结果。将 274 个测试结果（即每个观测的发生概率）用来计算 ROC 面积，用于模型间泛化能力的比较。

5.3.2 刀切法验证后 ROC 面积大小比较结果

表 5.19 三种模型刀切法拟合数据后 ROC 面积大小

方法	AUC	SE	95%LCL	95%UCL
LR	0.8501	0.0235	0.8040	0.8962
DT	0.7862	0.0299	0.7275	0.8448
NN	0.8559	0.0234	0.8101	0.9018

表 5.20 三种方法刀切法 ROC 面积($AUC_d=AUC_{column1}-AUC_{column2}$)比较结果

方法 1	方法 2	AUC_d	SE	95%LCL	95%UCL	χ^2	P
LR	DT	0.0639	0.0168	0.031	0.0969	14.4761	0.0001
LR	NN	-0.0058	0.0082	-0.0218	0.0102	0.5073	0.4763
NN	DT	0.0697	0.0178	0.0349	0.1046	15.3885	<0.0001




图 5.12 3 种模型刀切法后 ROC 面积比较结果

由表 5.19、表 5.20 可以看出，刀切法后 ROC 面积由大到小依次为 $NN>LR>DT$ 。其中 LR 与 NN 差别均无统计学意义。NN、LR 与 DT 的 ROC 面积的差别均有统计学意义。图 5.12 可以看出，刀切法得到 ROC 面积以 NN 最大，而 DT 的 ROC 面积最小，而 NN 与 LR 的 ROC 面积差别不大。

5.4 三种方法 100~1000 次自引导法 ROC 面积比较的结果

5.4.1 自引导法对模型泛化能力评价实现流程

在本研究中采用了 100~1000 次自引导法进行模型泛化能力的比较。现以 100 次 bootstrap 抽样为例, 阐述如何实现模型的泛化能力的评价。在本研究中, 数据集中共有 274 例观测。1 个 bootstrap 样本是指进行 274 次有放回抽样, 产生一个 bootstrap 样本。一个 bootstrap 样本生成后用于训练模型, 会有一部分观测没有被抽中, 这部分数据用于测试, 测试数据集中每个观测生成对应的预测概率。100 次 bootstrap 抽样的结果即是每次给予不同的随机种子数, 重复生成 100 个 bootstrap 样本和 100 个测试集, 在本研究中对 ROC 面积的评价采用本文第三章 3.5 节中介绍的 0.632 自引导法。即用于训练的所有标记样本的概率平均值 $\times 0.368$ +用于测试的所有样本的概率平均值 $\times 0.632$, 计算所得的每个观测的概率估计值用于最后计算 ROC 面积的大小。

并没有明确的结论认为采用多少次 bootstrap 抽样对模型泛化能力的评价是合理的, 因此在本研究中采用了 100 次~1000 次 bootstrap 抽样, 分别在相应次数的抽样情况下, 通过 ROC 面积大小的变化趋势, 对 3 个模型泛化能力进行客观评价。

5.4.2 自引导法 ROC 面积大小比较结果

1. 100 次~1000 次自引导法 ROC 面积大小及两两比较结果

表 5.21 三种方法 100~1000 次自引导法验证后的 ROC 面积大小

次数	方法	AUC	SE	95%LCL	95%UCL
100	LR	0.8637	0.0220	0.8206	0.9069
	DT	0.8304	0.0266	0.7782	0.8825
	NN	0.8672	0.0222	0.8237	0.9108
200	LR	0.8630	0.0221	0.8196	0.9063
	DT	0.8256	0.0271	0.7725	0.8787
	NN	0.8686	0.0220	0.8255	0.9117
300	LR	0.8622	0.0222	0.8186	0.9057
	DT	0.8272	0.0269	0.7746	0.8799
	NN	0.8676	0.0222	0.8241	0.9111
400	LR	0.8626	0.0221	0.8193	0.9060
	DT	0.8238	0.0273	0.7702	0.8774
	NN	0.8688	0.0220	0.8257	0.9119
500	LR	0.8621	0.0222	0.8186	0.9056
	DT	0.8218	0.0275	0.7678	0.8757

次数	方法	AUC	SE	95%LCL	95%UCL
600	NN	0.8676	0.0222	0.8242	0.9110
	LR	0.8628	0.0221	0.8195	0.9061
	DT	0.8224	0.0273	0.7688	0.8760
700	NN	0.8696	0.0219	0.8266	0.9125
	LR	0.8620	0.0222	0.8184	0.9055
	DT	0.8214	0.0276	0.7673	0.8754
800	NN	0.8683	0.0221	0.8250	0.9116
	LR	0.8630	0.0221	0.8197	0.9064
	DT	0.8235	0.0273	0.7699	0.8770
900	NN	0.8685	0.0221	0.8251	0.9118
	LR	0.8625	0.0222	0.8191	0.9059
	DT	0.8232	0.0272	0.7698	0.8766
1000	NN	0.8678	0.0221	0.8246	0.9111
	LR	0.8625	0.0221	0.8192	0.9058
	DT	0.8241	0.0273	0.7706	0.8775
	NN	0.8697	0.0220	0.8267	0.9128

表 5.22 三种方法 100~1000 次自引导法 ROC 面积($AUC_d = AUC_{column1} - AUC_{column2}$)比较结果

方法 1	方法 2	n	AUC_d	SE	95%LCL	95%UCL	χ^2	P
LR	NN	100	-0.0035	0.0077	-0.0186	0.0115	0.2094	0.6472
LR	DT	100	0.0334	0.0119	0.0101	0.0566	7.8909	0.0050
DT	NN	100	-0.0369	0.0122	-0.0608	-0.0130	9.1408	0.0025
LR	NN	200	-0.0056	0.0078	-0.0210	0.0097	0.5179	0.4717
LR	DT	200	0.0373	0.0127	0.0125	0.0622	8.6685	0.0032
DT	NN	200	-0.0430	0.0127	-0.0679	-0.0181	11.4874	0.0007
LR	NN	300	-0.0054	0.0076	-0.0203	0.0094	0.5140	0.4734
LR	DT	300	0.0350	0.0119	0.0116	0.0583	8.6101	0.0033
DT	NN	300	-0.0404	0.0121	-0.0640	-0.0167	11.2048	0.0008
LR	NN	400	-0.0061	0.0076	-0.0210	0.0088	0.6477	0.4209
LR	DT	400	0.0388	0.0125	0.0144	0.0632	9.7326	0.0018
DT	NN	400	-0.0450	0.0127	-0.0699	-0.0200	12.4996	0.0004

方法 1	方法 2	n	AUC _d	SE	95%LCL	95%UCL	χ^2	P
LR	NN	500	-0.0055	0.0076	-0.0204	0.0094	0.5199	0.4709
LR	DT	500	0.0403	0.0126	0.0156	0.0650	10.2420	0.0014
DT	NN	500	-0.0458	0.0131	-0.0715	-0.0201	12.2036	0.0005
LR	NN	600	-0.0068	0.0077	-0.0218	0.0083	0.7740	0.3790
LR	DT	600	0.0404	0.0122	0.0164	0.0644	10.9107	0.0010
DT	NN	600	-0.0472	0.0127	-0.0721	-0.0223	13.7606	0.0002
LR	NN	700	-0.0063	0.0078	-0.0216	0.0089	0.6664	0.4143
LR	DT	700	0.0406	0.0130	0.0152	0.0660	9.7966	0.0017
DT	NN	700	-0.0469	0.0134	-0.0732	-0.0207	12.2563	0.0005
LR	NN	800	-0.0054	0.0077	-0.0206	0.0097	0.4956	0.4814
LR	DT	800	0.0395	0.0118	0.0164	0.0627	11.2005	0.0008
DT	NN	800	-0.0450	0.0124	-0.0692	-0.0207	13.2123	0.0003
LR	NN	900	-0.0053	0.0076	-0.0203	0.0096	0.4889	0.4844
LR	DT	900	0.0393	0.0124	0.0150	0.0635	10.0800	0.0015
DT	NN	900	-0.0446	0.0128	-0.0698	-0.0194	12.0587	0.0005
LR	NN	1000	-0.0072	0.0078	-0.0226	0.0081	0.8537	0.3555
LR	DT	1000	0.0384	0.0126	0.0138	0.0631	9.3339	0.0022
DT	NN	1000	-0.0457	0.0129	-0.0710	-0.0203	12.4839	0.0004

2. 三种方法 100 次~1000 次自引导法分别绘制 ROC 面积




图 5.13 三种方法 100 次~1000 次自引导法 ROC 面积示意图




图 5.13 三种方法 100 次~1000 次自引导法 ROC 面积示意图

由表 5.21、表 5.22 可以看出, 100 次~1000 次自引导法 ROC 面积由大到小依次为 $NN > LR > DT$ 。其中 LR 与 NN 差别均无统计学意义。NN、LR 与 DT 的 ROC 面积的差别均有统计学意义。图 5.13 可以看出, ROC 面积以 NN 最大, 而 DT 的 ROC 面积最小, 而 NN 与 LR 的 ROC 面积差别不大。

5.4.3 100 次~1000 次自引导法 ROC 面积大小变化示意图




图 5.14 三种模型 100 次~1000 次自引导法 ROC 面积大小变化

由图 5.14 可以看出,100~1000 次自引导法 ROC 面积总体来说以 NN 的 ROC 面积最大, LR 的 ROC 面积次之, DT 的 ROC 面积最小。并且可以由图 5.14 看出,随着 bootstrap 抽样次数的增加,每种模型的 ROC 面积的变化很小,基本稳定。

5.5 小结

本章针对在小样本时,不能通过简单的保持法对模型的泛化能力进行比较的问题,采用了 10~100 次 2~10 折分层交叉验证法、刀切法、100~1000 次自引导法(具体为 0.632 自引导法)分别对 3 个模型进行泛化能力的比较。总体来说,ROC 面积从大到小依次为 $NN > LR > DT$ (除个别次数外);两两比较发现,NN、LR 与 DT 的 ROC 面积的比较差别(除个别次数外)均有统计学意义,但 NN、LR 比较差别无统计学意义(具体见本章第 5 节)。

由 10~100 次 2~10 折分层交叉验证和 100~1000 次自引导法进行 ROC 面积比较后可以发现:基本上每种模型在各种情况下 ROC 面积的变化很小,基本稳定。因此可以得出三种模型中以 NN 的 ROC 面积最大,预测性能最好,LR 次之,DT 最小。

可以看出,若仅凭一次保持法对 3 个模型的泛化能力进行比较,例如若采用保持法,数据分割正好如 20 次 2 折分层交叉验证或 30 次 3 折交叉验证($n=20$ 次时,2 折分层交叉验证后出现了 ROC 面积最大的为 LR 模型,而从总体趋势来说最大的 ROC 面积为 NN 模型; $n=30$ 次时,3 折分层交叉验证也出现了 ROC 面积最大的为 LR 模型,而从总体趋势来说最大的 ROC 面积为 NN 模型)的数据分割方法时,那么对 ROC 面积进行比较时很可能就不会正确客观地评价三种方法泛化能力的大小。

将 3 个模型应用于本文数据集进行泛化能力比较的结果来看,以 10 折 100 次分层交叉验证法为例,LR 法 ROC 面积为 0.8517 ± 0.0234 ,NN 法 ROC 面积为 0.8572 ± 0.0233 ,DT 法 ROC 面积为 0.7715 ± 0.0320 ;自引导法以 1000 次抽样为例,LR 法 ROC 面积为 0.8625 ± 0.0221 ,NN 法 ROC 面积为 0.8697 ± 0.0220 ,DT 法 ROC 面积为 0.8241 ± 0.0273 ;刀切法 LR 法 ROC 面积为 0.8501 ± 0.0235 ,NN 法 ROC 面积为 0.8559 ± 0.0234 ,DT 法 ROC 面积为 0.7862 ± 0.0299 。可以看出,三种方法 ROC 面积差别不大,以自引导法评价的 ROC 面积稍高一些,分层交叉验证法与刀切法很接近,这有可能由于抽样方法本身特点即自引导法是有放回抽样,而其它两种方法是无放回抽样造成的,但总体来说 ROC 面积比较的结果一致。

在本文中运用三种 Monte Carlo 模拟抽样方法,通过各种途径,尽量弥补保持法的不足,对建立的 LR、DT、NN3 个模型泛化能力进行综合的客观评价。由本文第三章 3.4 节介绍可知,更全面的评价模型的预测性能,必须考虑各种可能的诊断界点。而 ROC 曲线可通过改变诊断界点,将灵敏度和特异度结合起来,通过计算 ROC 曲线下面积,根据曲线的形状和面积对诊断技术做出定量分析,对模型做出总体预测能力的评价。结果表明,在本研究中评价模型泛化的性能时采用 ROC 面积作为评价三种模型预测性能的指标达到了准确客观评价的目的。

通过不同的 Monte Carlo 模拟抽样后对模型泛化能力进行比较的结果发现,DT 模型的泛化能力较 LR 和 NN 两种模型差,产生这种差别的原因主要可以从方法适用于数据类型的角度来看:决策树模型是以阶梯函数为基础,而回归方法和神经网络方法是以连续函数为基础的。具体分析见 6.1 部分。

并没有公认的看法认为在何种情况下应该选用何种抽样方法进行泛化能力的评价,在实际的研究中最好要根据数据特点,综合起来对模型的泛化能力做出客观的评价。

第六章 讨论

6.1 三种 Monte Carlo 抽样方法进行泛化能力结果的比较

本论文采用了分层交叉验证、刀切法及自引导法三种 Monte Carlo 抽样方法,应用这三种方法对模型进行泛化能力的评价时各有其特点^[68-70]。对于连续性误差函数如 MSE,在评价泛化能力时刀切法往往优于 k -折交叉验证^[71]。而对于非连续的误差函数例如误分类个数,一些方法如决策树法(使用阶梯函数而非连续性函数)、刀切法可能表现得很差,此时可使用其它的数据分割方法如保持法、 k -折交叉验证法^[72],其中交叉验证法在模型的建立和评价中是一个“强大”的方法。

对于非常小的数据集来说,自引导法也许是较好的误差估计法^[62]。自引导法与交叉验证法的基本不同点是:自引导法是进行有放回的随机抽样,而交叉验证法是无放回的随机抽样。交叉验证方法简单,且提供了泛化误差非常小的估计,而自引导法与交叉验证相比会有较大的误差估计,但在小数据集情况下会有较低的方差^[60,71]。

在本研究中,3个模型泛化能力的比较结果显示:除个别次数的交叉验证法后,LR 与 DT 的 ROC 面积比较差别无统计学意义外,LR 的 ROC 面积均高于 DT 且差别有统计学意义,NN 与 DT 比较,ROC 面积差别均有统计学意义,而 LR 与 NN 的 ROC 面积比较差别均无统计学意义。可以看到:DT 模型的泛化能力较其它两种方法差。产生这种差别的原因可以从方法适用于数据类型的角度来看:决策树模型是以阶梯函数的学习为基础,而回归方法和神经网络方法是以连续函数的学习为基础的。因此,在本研究中,回归方法和神经网络方法更适合于本研究的数据,即经过 logit 变换后,原因变量与结果变量间的关系基本上是线性的。由此可见:模型的预测性能与数据间错综复杂的关系有关,当原因变量与结果变量间存在复杂的非线性关系时,若不能通过 logit 变换使原因变量与结果变量间近似满足线性关系,此时神经网络预测性能往往优于 Logistic 回归;当变量间存在阶梯函数的关系且数据量较大时,此时采用决策树进行分类或预测时效果往往不错。

在本研究中应用三种方法(交叉验证法、刀切法、自引导法)对模型泛化能力进行比较,虽然参考文献[29,52]对以上三种抽样方法进行泛化能力评价的特点有一些研究,但并没有公认的看法认为在何种情况下应该选用何种抽样方法进行泛化能力的评价。因此在实际的工作中要根据各自研究的特点,综合起来对模型的泛化能力做出客观的评价。

6.2 三种模型的优缺点

(1) 对数据的要求

进行分析时, DT 对变量量纲的差异、离群值的存在以及有偏分布不太敏感,也就是说对数据准备要求不高。但有些情况下 DT 处理数值型输入变量的方式会造成一些有价值信息的损失,这是因为当拆分点只按照观察对象进入的顺序来选择时,有时这些取值的分布所携带的信息将会丢失。另外,一些决策树算法首先把所有的数值变量并类,然后把它们作为定性变量来看待,这个过程可能破坏信息。

LR 分析要求因变量满足独立性,且原因变量与 $\log itP$ 的关系是线性等。

而 NN 恰恰相反,它对变量不作出任何规定。

(2) 对数据量的要求

当每一类的训练样本数较小时, DT 容易出错,尤其对有好多分支的树或者每个节点有太多枝的树最有可能出错,且 DT 对输出结果的密度很敏感。

有的研究表明^[73], LR 模型样本量选择中,当各组样本含量大于原因变量数的 20 倍时,参数估计的偏差是可以接受的。

NN 则比较灵活,但为了有效训练,它对数据量的下限也有理论上的要求。NN 实质上包含了大量的权重,如在含有一个隐层和一个输出层的完全连通的神经网络中,权重的数目是 $h \times (n+2) + 1$, 这里 h 是隐层单元数, n 是输入变量数。其他类型的神经网络计算权重数目的公式会稍有不同。如果权重的数目大于训练网络的实例数目,那么该网络非常可能只能记住用于训练的数据集也就是发生过拟合现象。作为一个经验准则,确定网络中的一个权重至少需要 10 个训练数据。

(3) 模型的应用方面

因为 DT 方法能产生一些可以理解的规则,所以这种方法经常被选用。对于某一个已经分过类的记录来说,只要简单地沿着从根到叶的路径走就可以了。然而一个较复杂的决策树可能包含成千上万的叶,这样一棵树从整体上说跟神经网络一样,很难提供有关问题可以理解的信息;另外,DT 建立的模型是把最胜任的拆分变量放在树的根节点,因此在进行预测时,重要的变量会漂浮到树的顶端,这种方式使我们很容易发现哪些变量最胜任预测工作。因此决策树挑选出的变量也可为 NN 和 LR 模型进行变量筛选和决策时提供指导。

LR 模型的回归系数具有可解释性,在流行病学研究中,常采用一些危险度指标(如暴露优势比、相对危险度等)来衡量因素与发病(或死亡)的联系程度或对人群发病的致病作用的大小,这些危险度指标可通过 LR 模型的回归系数求得。如在本研究中发现:有 DM 视网膜病变、有 DM 性肾病、糖化血红蛋白过

高是 DPN 发生与否的危险因素等, 其危险程度的大小可以通过观察各相关因素的 OR 值的大小来发现, 具体见本文表 4.7。另外, Logistic 回归可以看作是一个简单类型的神经网络模型, 它可看作不含隐层、链接函数是 logistic 函数的单层感知器模型。

而 NN 一般不能对结果做出解释。NN 实际上是有很多综合记号、指数函数和很多参数的复杂数学函数, 这些函数揭示了神经网络的原理但却不易理解, 并且当有成千上万个输入时, 可能导致模型长时间的“训练”, 寻找模式更加困难且不会收敛于好的结果, 在医学研究或商业决策中, 这也是神经网络最大的缺陷。因此, 如果在预测中预测结果比了解模型的原理更重要时, NN 是一个很好的选择。

6.3 MLP 优化算法比较

MLP 的优化算法比较多^[50,74], 一类是启发式技术, 主要有标准批后向传播算法、Standard incremental backprop、quickprop、RPROP 法。另一类是使用数字最优化技术, 如 L-M 法、准牛顿法、共轭梯度法等。

在启发式技术中, L-M 法对于小网络可靠性强, 计算速度快, 但需要较大的内存; 准牛顿法对中等大小的网络训练较好, 该方法比 L-M 迭代的次数多, 但每次迭代需要的计算量小, 需要的内存一般仅为 L-M 法的一半; 共轭梯度法对于大的网络比较适合, 该方法比 L-M 法和准牛顿法迭代的次数多但每次迭代计算量要比以上两种方法小。

在函数逼近方面, 最常用到的是 L-M 法, 因为 L-M 不仅收敛速度快, 特别是对训练精度要求高的网络, L-M 方法可以获得更低的误差均方。当网络权值数目增加时, L-M 算法有时会略有下降, 但还是优于其他算法。

而启发式技术普遍的特点是训练速度快, 通过调整学习速率和学习动量, 对权重进行调整。但不足之处主要在于学习效率、学习动量的选择存在困难, 在函数逼近问题上性能不好。

6.4 过抽样的影响

过抽样仅仅影响 Logistic 回归模型估计的截距项, 因此如果研究的目的是分析原因变量对结果变量的影响或是仅仅对预测值进行排序, 那么可不对过抽样进行调整。

在建模的过程中先验概率不会影响以下几方面: (1) Logistic 回归中原因变量参数的估计; (2) 神经网络中权重的估计; (3) 决策树的生长; (4) 误差函数: 如离差或似然值等 (除了选择用先验概率进行分裂搜索); (5) 灵敏度和特异度等。

而先验概率可以影响以下几个方面：（1）后验概率；（2）分类；（3）决策；（4）误分率；（5）期望利润或损失；（6）阳性预测值和阴性预测值等。

6.5 Logistic 回归分析中变量筛选方法^[75]

在 Logistic 回归模型中，变量选择的方法有很多。当原因变量有 k 个时，可能的变量组合有 2^k 个。子集的选择通常有向前选择法、向后剔除法、逐步回归法、最优子集法，不同的变量选择方法有其不同的特点。

在逐步回归法挑选变量的过程中，每当一个新的变量进入模型时，就会重新计算不在模型中的剩余变量的显著性和已在模型中变量的显著性，直至不再有变量可以进入且变量要剔除模型为止，可见，逐步回归法提高了选择最佳原因变量的能力的同时降低了处理速度^[27]，逐步回归法与向前选择法比较相似。

后向剔除法与向前选择法、逐步回归法相比有一个明显的优势之处在于：它会考虑低显著性的变量，而这些低显著性的变量在向前选择法和逐步回归法中可能不会选入模型^[76-78]。

在本文第三章已经提到，向前选择法、向后剔除法、逐步回归法都要涉及到变量进入和剔除模型的 P 值大小的选取问题（ P 值的选取存在主观性），在 SAS 中默认的标准是 $P=0.05$ ，而有些研究认为该标准过于苛刻^[21]。针对所有原因变量的组合情况，最优子集法均可以给出其对应的 χ^2 值，但却无法给出哪种组合最佳。因此有人^[25]提出将采用后向剔除法与最优子集法相结合，通过后向剔除法找出最佳变量组合数然后通过最优子集找出对应组合数的变量组合，还有的研究^[26]将最优子集法与 SBC 相结合进行变量的挑选等等。

在本研究中采用最优子集法结合 AIC 值的方法，找出 AIC 最小值对应的组合。既达到压缩变量提高泛化能力的同时又可以避免前三种方法设定入选或剔除的 P 值大小的“痛苦”，达到了快速、有效地建立模型的目的。

需要指出的是，不同的数据集内部变量之间的关系错综复杂，建模的步骤不是唯一的。不同的思维方法、不同的统计方法所构建的模型可能不一样，因此，在建模过程中，应根据实际情况，尽量尝试多种建模策略，最后结合专业知识、经验积累与统计学方法从中选出较优模型，必要时可允许多个模型并存。

6.6 各种方法相互借鉴

目前普遍认为不存在某种方法能适合于任何特点的数据^[79]。由于数据内部变量间关系错综复杂，建立的模型之间存在不同的差异是肯定的，但这并不可怕。只要明确了试验设计类型、研究目的、各种建模方法特点等，将不同的建模方法的结果进行合理的比较，挑选出较优的模型是完全可能的。

当前很多研究都存在样本量偏小的问题,而且应用的资料很多为回顾性研究资料,因此模型的准确性还需要更多的证据来证实。在实际工作中,一方面可以增大样本量,另一方面尽可能的采用多种建模的方法,使得到的结果更具有可靠性。在本研究中,应用的数据集为回顾性研究所得到的,样本量偏小,涉及到的变量较多,因此在实际工作中若情况允许,可尽量增加样本、多方面考察相关因素,这样可以增加模型的准确性。

本文中通过对三种方法泛化能力的比较,旨在为研究人员提供一个参考:当对数据进行分析时,如想要建立起预测模型时,可选择的方法有很多种,应根据实际情况对数据尝试用不同的方法建立起模型,必要时可将不同的建模技术相结合,例如当遇到的数据量大、涉及到的变量多时,变量之间的关系有可能会错综复杂,那么可将不同的建模方法的优势发挥出来,比如可用 DT 模型进行变量的挑选,生成一些规则便于发现变量间的交互作用等,将变量挑选后的结果进行下一步 LR 或 NN 的建模。

在本研究中可以看到模型的预测准确率不高(约 80%),这是因为本研究为回顾性病例对照研究,一些关键性的变量如血糖长期控制情况以及遗传因素等由于研究所限并没有在调查中得到非常准确的结果或未进行调查,但这并不影响本研究的目的,在本研究中想通过一个小样本实例,探讨如何充分、有效地利用数据信息建立起可靠的 LR、DT、NN 模型,并将三个模型的泛化能力进行客观的评价,从而为研究者提供一个线索:即在实际工作中可根据不同的研究目的尝试不同的建模方案,在客观的比较模型的泛化能力后选出最佳方案用于指导实践。

第七章 总结和展望

7.1 本论文的主要工作和贡献

本研究以 DPN 的数据为例,采用 Logistic 回归、决策树和神经网络对 DPN 发生的概率进行预测,围绕建模和预测性能比较研究中的几个难点,主要进行了以下五个方面的工作,提出了较为理想的解决方案。

(1) 采用 χ^2 分割法进行连续变量离散化,结果证明该方法可行且易于理解,很好地实现了连续变量离散化的目的。

(2) 采用 100 次 5~7 折分层交叉验证法,将 CHAID 法与 CART 法相结合,既能充分利用数据又能有效地避免过拟合现象的发生。在神经网络建模的过程中,将 SBC 方法用于隐含层及隐含层节点数的选择上,采用预训练及 L-M 优化算法,既有效的避免了局部最优又防止过拟合现象的发生。从而建立起了准确可靠的决策树和神经网络模型。

(3) 采用最优子集法与 AIC 信息准则相结合建立的 LR 模型,此法既考虑了模型的泛化能力,又避免了选择 P 界值大小的“痛苦”,结果证明,该法建立的模型优于用常规筛选变量方法。

(4) 针对数据量小的特点,对模型泛化能力的比较采用了三种 Monte Carlo 模拟抽样的方法(10~100 次的 2~10 折分层交叉验证法、刀切法、100~1000 次自引导法),对模型的泛化能力进行了客观地评价,有效地弥补了保持法的不足。

(5) 由于本研究中的数据集获得的方式为分离抽样,因此用先验概率对后验概率进行了调整,从而使调整后的结果能够更客观准确地预测疾病发生的可能性。

综上所述,本研究采用三种方法(LR、DT、NN)对 DPN 发生的概率进行预测,在基于小样本条件下,从五个方面(即①科学地实现连续变量离散化、②充分利用数据且又防止过拟合、③快速有效地构建模型、④有效利用数据信息提高模型泛化能力、⑤有效调整过抽样获得更客观准确的预测结果)进行比较研究和改进,均取得了比较理想的结果,其建模思想和技术方法可方便成功地移植到生物医学甚至其它研究领域中去。

本论文的主要创新点是:

(1) 采用 χ^2 分割法有效地达到了连续变量离散化的目的;

(2) 在小样本情况下,应用不同领域的多种模型对疾病发生进行预测的比较研究中,采用三种 Monte Carlo 模拟抽样方法(分层交叉验证法、刀切法、自

引导法)对小样本情况下的模型泛化能力做出了客观评价,并针对实际情况对方进行了相应的改进,有效地弥补了保持法的不足;

(3)将三种方法(LR、DT、NN)对DPN发生的概率进行预测性能的比较研究,为实际工作者对DPN发生的概率进行预测研究提供方法的借鉴。

7.2 进一步工作的展望

目前我们对模型的选择还不是全自动的,如在SAS Enterprise Miner模块中在建模过程中仅能实现一次按比例抽样,不能实现循环模拟抽样(如 n 次自引导法抽样、刀切抽样、 n 折交叉验证抽样等)。而将模拟抽样思想应用到建模和模型评价过程中很重要,因此,将各种Monte Carlo模拟抽样的方法与各种建模方法集成实现模型选择和评价的自动化是下一步研究的方向。

在本研究中采用了交叉验证法、刀切法、自引导法三种Monte Carlo模拟抽样方法对模型进行泛化能力的比较,虽然对以上三种抽样方法的特点有一些研究(具体见本文第六章6.1部分),但并没有公认的看法认为在何种情况下应该选用何种抽样方法进行泛化能力的评价,因此尚待利用更多的仿真数据和电脑试验进行深入的研究。

参考文献

- [1] WHO. Developing world faces Mounting Diabetes Risk. 2003.
- [2] Wild S, Roglic G, Green A, et al. Global prevalence of diabetes: estimates for the year 2000 and projections for 2030. Diabetes Care, 2004, 27(5):1047-53.
- [3] Eyigor C, Uyar M, Pirildar S, et al. Combination therapy in treatment of peripheral diabetic neuropathy with severe pain in an adolescent patient. Paediatr Anaesth, 2009, 19(2):193-4.
- [4] Statsenko M E, Poletaeva L V, Turkina S V, et al. Mildronate effects on oxidant stress in type 2 diabetic patients with diabetic peripheral (sensomotor) neuropathy. Ter Arkh, 2008, 80(10):27-30.
- [5] 高琳, 王小英, 杨孟雪等. 2 型糖尿病末梢神经病变影响因素探讨. 贵州医学杂志, 2003, 27(8):692-693.
- [6] 职心乐, 王建华. 关于 2 型糖尿病并发末梢神经病变危险因素的病例对照研究. 实用预防医学, 2006, 13(1):27-29.
- [7] 熊朝松. 统计学和数据挖掘的异同. 科技广场, 2005:124-126.
- [8] 刘红岩, 陈剑, 陈国青. 数据挖掘中的数据分类算法综述. 清华大学学报, 2002, 42(6):727-730.
- [9] 郭景峰, 米浦波, 刘国华. 决策树算法的并行性研究. 计算机工程, 2002, 28(8):77-78.
- [10] 周利锋, 高尔生, 金丕焕. BP 神经网络与 logistic 回归对比初探. 中国卫生统计, 1998, 15(1):1-4.
- [11] El-Solh A A, Hsiao C B, Goodnough S. Predicting active pulmonary tuberculosis using an artificial neural network. Chest, 1999, 116(4):968-973.
- [12] Joannis G V, Dimitris A K, Manolis J H. Improved Medical Decision Making. Cambridge, 2000, 201:95.
- [13] Samanta B, Bird GL, Kuijpers M, et al. Prediction of periventricular leukomalacia. Part I. Selection of hemodynamic features using logistic regression and decision tree algorithms. Arti Intell Med. 2009, 45(1):300-320.
- [14] Delen D, Walker G, Kadam A. Predicting breast cancer survivability: a comparison of three data mining methods. Artificial Intelligence in Medicine, 2005, 34(2):113-127.
- [15] Ture M, Kurt I, Kurum A T, et al. Comparing classification techniques for predicting essential hypertension. Expert Systems with Applications, 2005, 29:583-588.
- [16] 陈建新, 西广成, 王伟. 数据挖掘分类算法在冠心病临床应用的比较. 北京生物医学工程, 2008, 27(3):249-252.
- [17] Breiman L, Friedman J H, Olshen R A, et al. Classification and Regression Trees,

- British:Chapman and Hall. 1984.
- [18]Ripley B D. Pattern Recognition and Neural Networks. Cambridge:Cambridge University Press, 1996.
- [19]Loh W Y, Shih Y S. Split Selection Methods for Classification Trees. *Statistica Sinica*, 1997, 7:815-840.
- [20]Kohavi R. A study of cross-validation and bootstrap for accuracy estimation and model selection. The Fourteenth International Joint Conference on Artificial Intelligence (IJCAI). San Fran-cisco, CA: Morgan Kaufman. 1995:1137-1145.
- [21]Hosmer D W, Lemeshow S. Applied Logistic Regression, New York:John Wiley & Sons,Inc, 1989.
- [22]SAS Institute Inc. Logistic Regression Examples Using the SAS System, Version 6, Cary, NC:SAS Institute Inc, 1995.
- [23]Akaike H. Information measures and model selection. *Bulletin of the International Statistical Institute*, 1983, 50:227-290.
- [24]Breiman L. The little bootstrap and other methods for dimensionality selection in regression:X-fixed prediction error. *Journal of the American Statistical Association*, 1992, 87(419):738-754.
- [25]Shtatland E S, Kleinman K, Cain E M. Stepwise methods in using SAS proc logistic and SAS enterprise miner for prediction. <http://www2.sas.com/proceedings/sugi28/258-28.pdf>.
- [26]Shtatland E S, Cain E, Barton M B. The perils of stepwise logistic regression and how to escape them using information criteria and the output delivery system. <http://www2.sas.com/proceedings/sugi26/p222-26.pdf>.
- [27]朱杨勇, 左子叶, 张忠平. 数据挖掘实践. 北京: 机械工业出版社. 2003.
- [28]王济川, 郭志刚 译. Logistic 回归模型-方法与应用. 北京: 高等教育出版社. 2001.
- [29]Tan P, Steibach M, Kumar V. Introduction to Data Mining. POST&TELECOM PRESS. 2008:135-137.
- [30]Santner D E, Duffy T J. The Statistical Analysis of Discrete Data, New York: Springer-Verlag, 1989.
- [31]Furnival G M, Wilson R W. Regression by Leaps and Bounds. *Technometrics*, 1974, 16(4): 499-511.
- [32]Akaike H. A new look at the statistical identification model. *IEEE Trans. Auto Control*, 1974, 19(6):716-723.
- [33]秦文. 分类技术中的决策树算法分析. *深圳信息职业技术学院学报*, 2004, 2(1):54-58.
- [34]张云涛, 龚玲. 数据挖掘:原理和技术. 北京: 电子工业出版社, 2004.

- [35]Michael J.A. Berry, Gordon S.Linoff. Data mining technique for marketing, sales and customer support. New York: Wiley, 1997.
- [36]Ture M, Kurt I, Kurum A T, Ozdamar K, et al. Comparing classification techniques for predicting essential hypertension. Expert Systems with Applications, 2005, 29(3):583–588.
- [37]Quinlan J R. C4.5:Programs for Machine Learning. San Mateo, Ca:Morgan Kaufmann, 1993.
- [38]Breiman L. Technical Note: Some Properties of Splitting Criteria. Machine Learning, 1996, 24:41-47.
- [39]Kass G V. An Exploratory Technique for Investigating Large Quantities of Categorical Data. Applied Statistics, 1980, 29:119-127.
- [40]Morgan J N, Sonquist J A. Problems in the Analysis of Survey Data, and a Proposal. Journal of the American Statistical Association, 1963, 58:415-434.
- [41]Loh W, Vanichsetakul N. Tree-Structured Classification Via Generalized Discriminant Analysis (with discussion). Journal of the American Statistical Association, 1988, 83:715-728.
- [42]İnan Güler, Hüseyin Polat, Uçman Ergün. Combining Neural Network and Genetic Algorithm for prediction of Lung Sounds. Journal of Medical System, 2005, 29(3):217-223.
- [43]Dieterle F, Müller-Hagedorn S, Liebich H M, et al. Urinary nucleosides as potential tumor markers evaluated by learning vector quantization. Artificial Intelligence in Medicine, 2003, 28(3):265-279.
- [44]Aleksander M, Renata J, Neural network as a decision support system in the development of pharmaceutical formulation–focus on solid dispersions. Expert System with Applications, 2005, 28(2):285-294.
- [45]Haykin S. Neural network:A comprehensive foundation. Upper Saddle River, NJ:Prentice Hall, 1999.
- [46]Principe J, Euliano N R, Lefebvre W C. Neural and adaptive systems: Fundamentals through simulations. New York:Wiley, 1999.
- [47]Pendharkar P C, Rodger J A, Yaverbaum G J,et al. Association,statistical,mathematical and neural approaches for mining breast cancer patters. Expert Systems Applications, 1999, 17:223-232.
- [48]Furundzic D, Djordjevic M, Bekic A J. Neural networks approach to early breast cancer detection. Syst Architect, 1998, 44:617-633.
- [49]Bartlett P L. For Valid Generalization, the Size of the Weights is More Important than the Size of the Network in: Advances in Neural Information Processing Systems Volume 9 (Mozier, Jordan, and Petsche eds.). Cambridge, Ma: The MIT Press, 1997.
- [50]Bishop C M. Neural Networks for Pattern Recognition. New York: Oxford University Press,

- 1995.
- [51]Hoerl A E, Kennard R W. Ridge Regression: Biased Estimation for Nonorthogonal Problems. *Technometrics*, 1970, 12:55-67.
- [52]Sarle, W. S. Stopped Training and Other Remedies for Overfitting. *Proceedings of the 27th Symposium on the Interface*, 1995.
- [53]Armitage P, Colton T. *Encyclopedia of biostatistics*. New York:John, 1998:3738-3744.
- [54]乔友林, 侯俊等. 我国太行山高发区食管癌流行趋势及防治策略. *中国医学科学院报*, 2001, 23(1):10-14.
- [55]黄俊, 周申范, 唐婉莹. TNT 生化降解时间序列人工神经网络预报模型. *环境科学研究*, 2000, 13(2):3-5.
- [56]王敬灏. ROC 曲线在临床医学诊断实验中的应用. *中华高血压杂志*, 2008, 16(2):175-177.
- [57]Hanley J A, McNeil B J. A method of comparing the areas under receiver operating characteristic curves derived from the same cases.*radiology*. 1983, 148:839-843.
- [58]DeLong E R., DeLong D M, Daniel L, et al. Comparing the Areas Under Two or More Correlated Receiver Operating Characteristic Curves:A Nonparametric Approach. *Biometrics*, 1988, 44(3):837-845.
- [59]陈卫中, 潘晓平, 宋兴勃, 等. ROC 曲线中最佳工作点的选择. *中国卫生统计*, 2006, 23: 157-158.
- [60]Ian H. Witten, Eibe Frank. *data mining:Practical Machine Learning Tools and Techniques(second ediction)*. China Machine Press, 2005.
- [61]陈希孺, 王松桂. *近代回归分析*. 合肥: 安徽教育出版社, 1987.
- [62]Efron B, Tibshirani R. Cross-validation and the bootstrap: estimating the error rate of a prediction rule. Technical report 176, Department of Statistics, Stanford University, 1995.
- [63]Hoeffding W. A Non-parametric Test of Independence. *Annals of Mathematical Statistics*, 1948, 19:546-557.
- [64]Hollander M. Wolfe D. *Nonparametric Statistical Methods*. Second Edition, New York: John Wiley & Sons, 1999.
- [65]Wu Y Z, Giger M L, Doi K, et al. Artificial neural networks in mammography:application to decision making in the diagnosis of breast cancer. *Radiology*, 1993, 187:81-87.
- [66]Mei-Sheng Duh, Alexander M. walker, John Z. Ayanian. Epidemiologic interpretation of artificial neural networks. *Am J Epidemiol*, 1998, 147(12):1112-1122.
- [67]Setiono R. Extracting rules from pruned neural networks for breast cancer diagnosis. *Artif Intell Med*, 2000, 18:205-219.
- [68]Efron B. *The Jackknife, the Bootstrap, and other Resampling Plans*. SIAM, Philadelphia,

- 1982:82.
- [69]Stone M. Cross-validators choice and assessment of statistical predictions (with discussion), Journal of the Royal Statistical Society, Series B, 1974, 36, 111-147.
- [70]Stone M. An asymptotic equivalence of choice of model by cross-validation and Akaike's criterion. Journal of the Royal Statistical Society, Series B, 1977, 39: 44-47.
- [71]Shtatland E S. A new strategy of model building in proc logistic with automatic variable selection, validation, shrinkage and model averaging .<http://www2.sas.com/proceedings/sugi29/191-29.pdf>.
- [72]SAS/ENTERPRISE MINER User's Guide, Version 8. Cary, NC: SAS Institute Inc., 1999.
- [73]陈峰. 医用多元统计分析方法. 北京: 中国统计出版社, 2001:83-111.
- [74]Comak E, Arslan A, Türkoğlu İ. A decision support vector machines for diagnosis of the heart valve diseases. Computers in Biology and Medicine, 2006, 37(1):1-7.
- [75]胡良平. 现代统计学与 SAS 应用. 北京: 军事医学科学出版社, 2002:257-259.
- [76]Mantel N. Why Stepdown Procedures in Variable Selection. Technometrics, 1970, 12:621-625.
- [77]Harrell F E. Predicting Outcomes: Applied Survival Analysis and Logistic Regression. Charlottesville Virginia: School of Medicine, University of Virginia, 1997.
- [78]Lawless J F, Singhal K. Efficient Screening of Nonnormal Regression Models. Biometrics, 1978, 34:318-327.
- [79]史忠植. 知识发现. 北京: 清华大学出版社, 2002:2-6.

附录 1 变量的定义及赋值方法

变 量	标 签	编 码
age	年龄	岁
sex	性别	0 女 1 男
dnf	是否并发 DPN	0 否 1 是
hunyin1	婚姻	0 异常（离异、丧偶等） 1 正常（已婚、未婚）
minzu	民族	0 汉族 1 其他
occup1	职业	0 脑力劳动（干部、职员、教师等） 1 体力劳动（工人、农民）
dmbc	糖尿病病程（年）	年
hba1c1	糖化血红蛋白（%）	
bpkzff	血控方法	1 单纯饮食控制 2 运动疗法 3 口服降糖药 4 胰岛素注射 5 口服降糖药与胰岛素注射联合使用
pgif	使用胰岛素否	0 否 1 是
dnrf	是否有糖尿病性肾病	0 否 1 是
drf	是否有糖尿病视网膜病变	0 否 1 是
hbp1	高血压否	0 否 1 是
chd	是否有冠心病	0 否 1 是
huf	是否发生高尿酸血症	0 否 1 是
ischemia	是否缺血性心脏病	0 是 1 否
dmf	糖尿病(DM)家族史	0 是 1 否
chds	冠心病家族史	0 是 1 否
zfs	中风家族史	0 是 1 否
sbs	肾病史	0 是 1 否
fps	肥胖史	0 是 1 否
zsglf	DM 后主食过量否	0 否 1 是
fsgrf	DM 后副食过量否	0 否 1 是
drinkf	饮酒情况	0 否 1 偶尔 2 经常（多于 1 次/周，连续 1 年以上）
teaf	饮茶情况	0 否 1 偶尔 2 经常（多于 3 次/周，连续 1 年以上）
coffeef	喝咖啡情况	0 经常（多于 3 次/周，连续 1 年以上） 1 偶尔 2 否
zlsjf	体力活动水平	0 轻度 1 中度 2 重度
sfdl	锻炼情况	0 经常 1 偶尔 2 几乎不
zlsjf	体力活动水平	0 小于等于 2 小时 1 大于 2 小时小于等于 4 小时 2 4 小时以上
smoke	是否吸烟	1 经常 2 偶尔 3 几乎不
smokenx	吸烟年限(年)	年
smoke3	吸烟量（支/天）	支
smokeindexf	吸烟指数分级	0 不吸烟 1 ≤ 200 轻度吸烟 2 200~400 中度吸烟 3 ≥ 400 重度吸烟

变 量	标 签	编 码
smokedmf	DM 后是否吸烟	0 否 1 是
csf	手术创伤否	0 否 1 是
BMI	BMI (kg/m ²)	0 < 25 1 25~ 2 ≥ 28
bmi _f	bmi 分级	0 正常 1 超重 2 肥胖
Bun	Bun (mmol/l)	0 < 3.57 1 3.57~ 2 ≥ 7.85
Cr	Cr (μmol/l)	0 正常 (男: 53~97; 女: 44~80) 1 异常
Ua	Ua (μmol/l)	0 偏低 1 正常 (男: 202~416; 女: 142~339) 2 偏高
Chol	Chol (mmol/l)	0 < 4.5 1 4.5~ 2 ≥ 6
TG	TG (mmol/l)	0 < 0.5 1 0.5~ 2 ≥ 1.71
HDL	HDL (U/l)	0 偏高 1 正常 (男: 1.1~1.4; 女: 1.2~1.6) 2 偏低
LDL	LDL (U/l)	0 < 2.3 1 2.3~ 2 ≥ 3.1
VLDL	VLDL (U/l)	0 < 0.88 1 ≥ 0.88

附录 2 主要程序代码

1. 用刀切法计算Logistic回归模型的ROC面积大小的SAS程序

```
proc datasets;
    delete jackdatann: /gennum=all;
    run;
%include "c:\temp\jackknife.sas";
%jackslow(dn.dataset15,274,274);run;
%macro jackknife();
%do j=1 %to 274;
    proc logistic data=TMPD&j descending noprint outest=cvestim&j;
        model dnf=dmbc csf drf dnrh hba1c1 huf zlsjf2 teaf1 fsglf drfdnrh;
        output out=model pred=prob;
        run;
    proc score data=jack&j out=cvscore&j score=cvestim&j type=parms ;
        var dmbc csf drf dnrh hba1c1 huf zlsjf2 teaf1 fsglf drfdnrh;
        run;
    data cvscore&j;
    set cvscore&j;
    phat=1/(1+exp(-dnf2));
    run;
    proc datasets;
    append base=jackdatalr data=cvscore&j;;
    run;
dm 'clear log';
%end;
%mend jackknife;
%jackknife
run;
data dn.jackdatalr;
set jackdatalr;
run;
%include "c:\temp\ROC\roc.sas";
%roc (data=dn.jackdatalr,var=phat,response=dnf);
```

2. 100次10折交叉确认法计算决策树模型的ROC面积大小的程序

```
%macro dtcv(maxbranch=2,maxdepth=6,splitsize=30,leafsize=10,
    nodesample=1500,exhaust=5000,adjust=kassafter,assess=classificati
on, minminid=minid);
%do i=1 %to 100;
    data randomize;
    set dn.dataset15;
    u=ranuni(0);
    run;
    proc sort data=randomize;
    by dnf;
    run;
    proc datasets;
    delete rr: /gennum=all;
    run;
    proc datasets;
    delete rocc: /gennum=all;
    run;
%local j;
%do j=0 %to 9 %by 1;
    proc rank data=randomize groups=10 out=crossdata;
    var u;
    by dnf;
    ranks cross;
    run;
    data dataset&j valid&j;
    set crossdata;
    if cross =&j then output valid&j;
    else output dataset&j;
    run;
    proc dmdb data=dataset&j dmdbcats=dmdset&j out=dset&j;
    var &_intrvl;
    class &_class &_targets(desc);
    target &_targets;
    run;
        proc split data=dset&j dmdbcats=dmdset&j
            criterion=probchisq
            worth=0.05
            splitsize=&splitsize
            leafsize=&leafsize
            padjust=&adjust
            subtree=largest
            maxbranch=&maxbranch
            maxdepth=&maxdepth
```

```

        nodesample=&nodesample
        exhaustive=&exhaust
        assess=&assess
        outleaf=leaf
        outmatrix=matrix;
        input &_nominal &_binary /level=nominal;
        input &_ordinal/ level=ordinal;
        input &_intrvl/ level=interval;
        target &_targets / level=&tgmeas;
        code file='c:\temp\code.sas';
        run;
    data validd&j;
    set valid&j ;
    %include 'c:\temp\code.sas';
    run;
    proc rank data=validd&j out=r&j;
    var P_dnf1;
    ranks rp;
    run;
    proc sql;
    create table roc&j as
    select sum(dnf=1) as n1,
           (sum(rp*(dnf=1))- .5*(calculated n1)*(calculated n1+1))
           /((calculated n1)*(count(dnf)-(calculated n1))) as c_nosl
    from r&j;
    quit;
    proc datasets;
    append base=rr data=r&j;run;quit;
    %end;
    data rr&i;set rr;run;
    proc append base=pp data=rr&i; run;
    dm 'clear log';
%end;quit;
%mend dtcv;
%dtcv;
data dn.cvdtscore_10_100;
set pp;
run;
proc sort data=dn.cvdtscore_10_100;
by id;
run;
proc means data=dn.cvdtscore_10_100 noprint;
by id;
var P_dnf1;

```

```

output out=b mean=mn_prob;
run;
data c(keep=id dnf);
set dn.dataset15;
run;
data dn.cvdtscorem_10_100;
merge c b;
by id;
run;
%include "c:\temp\ROC\roc.sas";
%roc (data=dn.cvdtscorem_10_100,var=mn_prob,response=dnf); run;

```

3. 1000次自引导法计算决策树模型的ROC面积大小的程序

```

data dataset15;set dn.dataset15; obs=1;
%macro boot(n_boot);
  %do i=1 %to &n_boot;
    data cboot&i(drop=n j seed obs);scan: set dataset15 end=last;n+1;
    if not last then goto scan;
    do j=1 to n;
      seed=floor(1000000000*(sqrt(time())-floor(sqrt(time()))));
      k=ceil(ranuni(seed)*n);
      set dataset15 point=k;
      if _error_ then abort;
      output;
    end;
    stop;
  run;
  proc sql;
  create table cvboot&i as
  select * from dn.dataset15 except select * from cboot&i;
  quit;
  data a3;set cboot&i ;
  newobs=_n_;
  run;
  data boot&i;set a3;
  run;
  proc dmdb data=boot&i dmdbcat=dmdset out=dset;
    var &_intrvl;
    class &_class &_targets(desc);
    target &_targets;
  run;
  proc split data=dset dmdbcat=dmdset
  criterion=probchisq
  worth=0.05

```

```

        splitsize=30
        leafsize=10
        padjust=kassafter
        subtree=largest
        maxbranch=2
        maxdepth=6
        nodesample=1500
        exhaustive=5000
        assess=classification
        outleaf=leaf
        outmatrix=matrix;
        input &_nominal &_binary /level=nominal;
        input &_ordinal/ level=ordinal;
        input &_intrvl/ level=interval;
        target &_targets / level=&_tgmeas;
        code file='c:\temp\code6.sas';
    run;
    data cvboot&i;
    set cvboot&i;
    %include 'c:\temp\code6.sas';
    run;
    data train&i;
    set boot&i;
    %include 'c:\temp\code6.sas';
    run;
    %end;
    %do j=2 %to &n_boot;
        proc append base=cvboot1 data=cvboot&j;run;
        proc append base=train1 data=train&j;run;
    dm 'clear log';
        %end;quit;
    %mend boot;
%boot(1000)
;
data dtboottrain1000;
set train1;
run;
data dtbootscore1000;
set cvboot1;
run;
proc means data=cvboot1 noprint clm;
var P_dnf1;
class id;
output out=scodt1000 mean=score_mp;

```

```
run;
proc means data=train1 noprint clm;
  var P_dnf1;
  class id;
  output out=dt1000 mean=train_mp ;
run;
proc sort data=dt1000;
by id;
run;
data a(drop=_FREQ_ _TYPE_);
set dt1000;
if id=. then delete;
run;
proc sort data=scdt1000;
by id;
run;
data b(drop=_FREQ_ _TYPE_);
set scdt1000;
if id=. then delete;
run;
proc sql;
create table main as
select * from a,b where a.id=b.id;
quit;
data c(keep=id dnf );
set dataset15;
run;
proc sql;
create table main1 as
select * from c,main where c.id=main.id;
quit;
data d(keep=id P_DNF1);
set dn.Dtalldata_model;
run;
proc sql;
create table dtboot1000 as
select * from main1,d where main1.id=d.id;
quit;
data dn.dtboot1000;
set dtboot1000;
bootprob=P_DNF1*0.368+0.632*score_mp;
run;
%include "c:\temp\ROC\roc.sas";
%roc (data=dn.dtboot1000,var=bootprob,response=dnf);
```


4. MLP选择隐层节点数及是否加跳跃层的SAS程序

```

proc dmdb batch data=dn.dataset15 dmdbc=ctr out=dtr ;
  var &_inputs;
  class dnf(desc);
run;
proc neural data=dtr dmdbc=ctr ;
  input &_inputs;
  target dnf / level=nom;
  archi mlp hidden=1;
  prelim 20;
  train outfit=of0 outest=w0;
run;
/*1+skip*/
proc dmdb batch data=dn.dataset15 dmdbc=ctr out=dtr;
  var &_inputs;
  class dnf(desc);
run;
proc neural data=dtr dmdbc=ctr;
  input &_inputs/id=in;
  target dnf / level=nom id=out;
  hidden 1/id=h1 comb=lin bias;
  prelim 20;
  connect in h1;
  connect h1 out;
  connect in out;
  train outfit=of1 outest=w1;
run;
/*2*/
proc neural data=dtr dmdbc=ctr ;
  input &_inputs;
  target dnf / level=nom;
  archi mlp hidden=2;
  prelim 20;
  train outfit=of2 outest=w2;
run;
proc dmdb batch data=dn.dataset15 dmdbc=ctr out=dtr ;
  var &_inputs;
  class dnf(desc);
run;
/*2+skip*/
proc dmdb batch data=dn.dataset15 dmdbc=ctr out=dtr;
  var &_inputs;
  class dnf(desc);
run;

```

```
proc neural data=dtr dmdbcat=ctr;
  input &_amp;inputs/id=in;
  target dnf / level=nom id=out;
  hidden 2/id=h1 comb=lin bias;
  prelim 20;
  connect in h1;
  connect h1 out;
  connect in out;
  train outfit=of3 outest=w3;
run;

.....
data nnbltxyc(keep=id _DFM_ _AIC_ _SBC_ _RMSE_ _ERR_ _MISC_);
set of0(firstobs=2) of1(firstobs=2) of2(firstobs=2) of3(firstobs=2)
of4(firstobs=2) of5(firstobs=2) of6(firstobs=2)
of7(firstobs=2) of8(firstobs=2) of9(firstobs=2) ;
id=_n_;
run;
```

致 谢

在本文即将完成之际，首先要感谢我的恩师胡良平教授。胡老师渊博的专业知识、严谨的治学态度和兢兢业业、严谨求实的工作作风、谦和的处事态度是我一生工作、学习和做人的榜样。四年来，胡老师时刻关心我的学习进展、指导我学习的方向，使我开阔了眼界，增长了见识。不仅教我知识，还教我做人。胡老师还在生活上给予我很多的帮助，为了我顺利完成学业，给予我无私的大力地支持。在此，向胡老师表示我衷心的感谢！千言万语汇聚成一句话：谢谢您胡老师！这份珍贵的师生情谊永在我心间，我会永远珍惜。

感谢我的硕士导师、天津医科大学公共卫生学院马骏教授对我的支持、鼓励和帮助！

感谢我的同学天津医科大学职心乐老师给予我的大力帮助！感谢我的师姐们北京大学张雅黎老师、清华大学博士耿新玲的关心和帮助！

感谢天津医科大学公共卫生学院的黄国伟院长、张磊副教授、孙忠教授、崔壮老师等给予的帮助和支持！

感谢军事医学科学院英语教研室鲁显生教授给予我的支持、鼓励和帮助！

感谢我的师兄李峰青、单彬给予的支持、鼓励和帮助！

感谢教研室的周诗国老师、柳伟伟老师给予我的指导、鼓励和帮助！感谢本教研室所有研究生葛毅、程瑞专、高辉、郭晋、陶丽新、王琪、毛玮对我的帮助和鼓励。几年来的日子里，教研室共同生活的点点滴滴，学术上的讨论和交流，使我终身难忘，谢谢大家！

深深感谢我挚爱的双亲，他们殷切的期待时时刻刻提醒着我，是我奋斗的动力。感谢我的姐妹，我的姐夫、妹夫、我的叔叔们等等所有我的家人，感谢你们的支持和理解！特别感谢我的爱人张庆堂在我读博期间的给予我的巨大支持和理解，他的支持和鼓励，对我生活上无私的关爱，是我完成学业的支柱。

感谢已经离开我的大姐，我的婆婆，你们永远在我的心中。

最后，感谢所有关心和帮助过我的人。

个人学习经历、工作情况、发表文章及参编著作

个人学习经历

1976 年 11 月 26 日生于天津市静海县。

1996 年 9 月考入天津医科大学预防医学专业。

2001 年 7 月本科毕业并获得医学学士学位。

2001 年 9 月进入天津医科大学预防医学专业，2004 年 7 月研究生毕业并获得医学统计学硕士学位。

2005 年 9 月 考入军事医学科学院攻读医学博士至今。

工作情况

在军事医学科学院攻读博士期间，完成了硕士生医学统计学教学工作，包括医学统计学必修课和医用多元统计选修课、军事医学科学院统计培训课共 40 学时、SAS 上机辅导课 153 学时。并于 2006 年参加了中国现场统计会议，于 2008 年参加了 SAS Enterprise Miner 培训。在学期间在中国科技核心期刊和统计源期刊上发表论文 20 篇，其中以第一作者发表论文 7 篇。参编统计学理论或应用专著 7 部，约 20 万字。

发表文章情况

- [1] 李长平, 胡良平. 医学博士学位论文中的实验设计及数据分析错误辨析. 军事医学科学院院刊, 2006, 30(5):453-456.
- [2] 李长平, 胡良平. 如何正确进行生物医学科研设计 II. 如何合理选择单因素实验设计. 中国医药生物技术, 2008, 3(2):152-154.
- [3] 李长平, 胡良平. 如何正确进行生物医学科研设计 III. 如何合理选择两因素实验设计. 中国医药生物技术, 2008, 3(3):232-234.
- [4] 李长平, 胡良平. 如何正确进行生物医学科研设计 IV. 如何合理选择三因素实验设计. 中国医药生物技术, 2008, 3(4):313-316.
- [5] 李长平, 胡良平. 《中国骨伤》杂志论文中存在的统计学错误辨析(7). 中国骨伤, 2008, 21(8):644-646.
- [6] 李长平, 胡良平. 如何正确进行生物医学科研设计 V. 如何合理选择 4 种多因素实验设计(1). 中国医药生物技术, 2008, 3(5):391-394.
- [7] 李长平, 胡良平. 如何正确进行生物医学科研设计 V. 如何合理选择 4 种多因素实验设计(2). 中国医药生物技术, 2008, 3(6):470-472.

- [8] 胡良平, 李长平. 生存分析方法在随访研究中的应用(I). 中华耳鼻咽喉头颈外科杂志. 2006, 41(1):73-76.
- [9] 胡良平, 李长平. 生存分析方法在随访研究中的应用(II). 中华耳鼻咽喉头颈外科杂志. 2006, 41(3):236-238.
- [10] 单彬, 胡良平, 李长平. 多台仪器定量检测结果的综合分析方法. 军事医学科学院院刊, 2006, 30(3):253-256. (第三作者)
- [11] 周诗国, 胡良平, 李长平. 基于置信区间宽度的样本含量估计. 军事医学科学院院刊, 2007, 31(1):66-99. (第三作者)
- [12] 高辉, 胡良平, 李长平等. 如何正确处理定性资料(一). 中西医结合学报. 2008, 6(10):1086-1089. (第三作者)
- [13] 高辉, 胡良平, 李长平等. 如何正确处理定性资料(二). 中西医结合学报. 2008, 6(11):1194-1197. (第三作者)
- [14] 高辉, 胡良平, 李长平等. 如何正确进行直线相关与回归分析. 中西医结合学报. 2008, 6(12):1131-1314. (第三作者)
- [15] 程瑞专, 胡良平, 葛毅等. 《中国骨伤》杂志论文中存在的统计学错误辨析(4). 中国骨伤. 2008, 21(5):396-399. (第四作者)
- [16] 高辉, 胡良平, 葛毅等. 《中国骨伤》杂志论文中存在的统计学错误辨析(5). 中国骨伤. 2008, 21(6):471-475. (第四作者)
- [17] 高辉, 胡良平, 郭晋等. 《中国骨伤》杂志论文中存在的统计学错误辨析(12). 中国骨伤. 2009, 22(1):72-75. (第四作者)
- [18] 高辉, 胡良平, 郭晋等. 如何正确处理正交设计和均匀设计定量资料. 中西医结合学报. 2008, 6(8):873-877. (第四作者)
- [19] 高辉, 胡良平, 金松华等. 常见试验设计定量资料统计分析错误辨析. 中西医结合学报. 2008, 6(9):979-982. (第五作者)
- [20] 胡良平, 郭晋, 龚大勇等. 如何正确认识具有交互作用的多因素试验设计——怎样在药物应用与监测研究中正确运用统计学(七). 中国药物应用与监测. 2009, 6(1):55-58. (第五作者)
- [21] Treatment of Palmoplantar Pustulosis with Arotinoid Ethylester. European J Dermatol. Accepted.(fifth author)

参编教材情况

- [1] 参编《生物医学研究的统计方法》(方积乾主编), 人民卫生出版社, 2007.06. ISBN 978-7-04-020841-2. (第12、13章)
- [2] 参编《口腔医学科研设计与统计分析》(胡良平主编), 人民军医出版社,

2007.08. ISBN 978-7-5091-1170-3. (第 7~9 章)

[3]参编《医学统计实战练习》(胡良平主编), 军事医学科学出版社, 2007.08. ISBN 978-7-80121-671-7. (第 12、13 章)

[4]参编 《新药药理学方法》(吕秋军主编), 化学工业出版社, 2007.08. ISBN 978-7-5025-9639-2. (第 5 章)

[5]参编《统计学三型理论在定量和定性资料统计分析中的应用》(胡良平主编), 人民军医出版社. 2009. (第 4、18 章). (即将出版)

[6]参编《统计分析方法与 SAS 应用-从入门到精通》(胡良平主编), 电子工业出版社. 2009. (第 16、37 章). (即将出版)

[7]参编《科研课题的研究设计与统计分析》—学位论文中的错误辨析(胡良平主编), 军事医学科学出版社. 2009. (第 17 章). (即将出版)

综 述

与预测和分类有关的三种方法（Logistic 回归、决策树、神经网络）简介及其预测性能比较的研究现状

1 数据挖掘方法与统计学方法联系与区别^[1-2]

数据挖掘是找出数据中模式的过程。数据挖掘方法应用了很多领域的思想、工具和方法，如计算机科学（包括机器学习、数据库技术）、统计学、数学等。其中统计学是支持数据挖掘的一个支柱，在解决机器学习问题中起着基础性的作用。

传统的统计学所研究的主要是渐进理论，即当样本趋于无穷多时的统计性质，主要考虑测试预想的假设是否与数据模型相吻合，大部分统计分析是确定性的分析。

数据挖掘过程是实验性的，与确定性分析不同，几乎所有的方法都集中于计算，主要的目的是发现，其发展方向主要集中在方法改进及应用等方面。

统计学和数据挖掘的相互联系，可以表现在概率分布、假设检验、模型得分、有理决策和规划、因果推断等方面。数据挖掘中很多方法运用了统计学方法，如聚类分析、回归分析、贝叶斯方法等。虽然统计学与数据挖掘有着很多联系，但也有很多不同之处。如数据挖掘主要的目的是发现，它不关心统计学领域中在回答一个特定的问题之前，如何很好的收集数据，例如实验设计和调查设计，关心的只是如何发现其中的秘密。这种实验性的数据分析可以为统计学发展提供一些参考和方向。

2 Logistic 回归、决策树和神经网络模型简介

2.1 Logistic 回归模型简介^[3]

1. Logistic 回归模型基本结构

Logistic 回归结果变量与自变量之间的关系是非线性的，非线性关系可以通过 logit 变换被转换为线性关系。Logistic 回归模型如下所示：

$$\ln\left(\frac{p_i}{1-p_i}\right) = \alpha + \sum_{k=1}^K \beta_k x_{ki} \quad (1-1)$$

其中， $p_i = P(y_i = 1 | x_{1i}, x_{2i}, \dots, x_{ki})$ 为在给定系列原因变量 $x_{1i}, x_{2i}, \dots, x_{ki}$ 的值时的事件发生概率， K 为总的原因变量个数。

2. Logistic 回归系数分析及检验

Logistic 回归系数的最大似然估计 (MLE) 是总体参数的渐近无偏和有效的点估计。Logistic 回归系数的 MLE 估计近似服从正态分布, 所以可以直接对回归系数进行显著性检验, 主要采用 χ^2 检验和似然比检验。

3. 拟合优度检验

主要有 Pearson χ^2 、偏差、Hosmer-Lemeshow 检验、信息测量指标 (如 AIC、SBC 等)。

4. 建模方法简介

(1) 向前选择法: 逐个将有统计学意义 ($\text{slentry}=p$) 的变量引入进入模型直至不再有统计学意义的变量进入模型为止。

(2) 向后剔除法: 从所有变量全部进入模型开始, 依次将无统计学意义的变量剔除 ($\text{slstay}=p$) 模型, 直至不再有无统计学意义的变量在模型中为止。

(3) 逐步法: 与向前选择法相似, 只不过每次向前选择后又加入了向后剔除的过程, 在 SAS 软件中可通过设定进入和剔除的标准 ($\text{slentry}=p_1$ 、 $\text{slstay}=p_2$) 来实现。

(4) 最优子集法: 最优子集选择基于似然得分统计量, 这种方法分别对包含一个、两个、三个变量等等, 直至包含有原因变量的模型, 输出各种原因变量组合时的得分。

2.2 决策树模型简介^[4-5]

1. 决策树的基本原理

决策树是一种非线性的判别分析方法, 它通过原因变量竞争分裂, 分裂成一系列更小的子群。在树的每个分支中重复迭代此过程, 在某种标准下, 选择与结果变量有最强关联的原因变量进行分裂^[6]。它首先对数据进行处理, 利用归纳法生成可读的规则和决策树, 然后使用决策对新数据进行分析。本质上决策树是通过一系列规则对数据进行分类的过程。决策树技术发现数据模式和规则的核心是采用递归分割的贪婪算法。决策树主要有二元分支树和多分支树。一般采用二元分裂, 因为二元分裂在穷举搜索中更加灵活。

2. 构造决策树思路

构造一个决策树分类器, 它的输入是一组带有类别标记的例子, 构造的结果是一棵二叉或多叉树。构造决策树的方法是采用自上而下的递归分割, 采用贪婪算法, 从根节点开始, 如果训练集中的所有例子是同类的, 则将其作为叶子节点, 节点内容即是该类别标记。否则, 根据某种策略选择一个属性, 按照属性的各个取值, 把训练集划分为若干个子集合, 使得每个子集上的所有例子在该属性上具

有同样的属性值，然后再依次递归处理各个子集，直到符合某种停止条件。

3. 递归分割的分裂标准

决策树的建立从根节点开始进行分割（对于连续变量将其分段），穷尽搜索各种可能的分割方式，通过分裂标准（通常用结果变量在子节点中变异的减少的多少来作为标准）来决定哪个原因变量做为候选分割变量。根节点分割后，子节点会象根节点一样重复分割过程，分割在该子节点下的观测一直到符合某种条件停止分割。分裂标准按照结果变量的分类如下：当结果变量是分类变量时，其分裂的标准主要有 Gini 系数变化（ ΔGini ）^[7]、熵值变化（ $\Delta\text{entropy}$ ）^[8-9]、 χ^2 检验^[10]3 个；当结果变量是连续变量时，其分裂的标准主要有方差^[11]、 F 检验 2 个。

4. 剪枝

最大的决策树能对训练集的准确率达到 100%，最大的分类树的结果会导致过拟合（对信号和噪声都适应）。因此建立的树模型不能很好的推广到总体中的其他样本数据中去。同样，太小的决策树仅含有很少的分支，会导致欠拟合。一个好的树模型有低的偏倚（适应信号）和低的方差（不适应噪声），模型的复杂性往往在偏倚和方差之间做一个折中，因此要对树进行剪枝。主要包括前剪枝和后剪枝。有一些研究者利用仿真数据进行了许多次试验，研究发现：前剪枝通常比后剪枝快，但不如后剪枝效果好^[12]。

5. 分类和回归树^[7]（CART:Classification and Regression Tree）

其特点是二分支树的结构（Binary Tree-structured），即根节点包含所有样本，在一定的分裂规则下根节点被分裂为两个子节点，这个过程又在子节点上重复进行，直至不可再分，成为叶节点为止。分裂的标准一般采用纯度减少（Gini 系数）的标准。

6. CHAID 树^[10]（CHAID:Chi-squared Automatic Interaction Detector）

其特点是基于 χ^2 检验基础之上的。即根节点包含所有样本，在一定的分裂规则下根节点被分裂为两个或多个子节点，这个过程又在子节点上重复进行，直至不可再分（没有统计学显著性），成为叶节点为止。分裂的标准一般采用 χ^2 检验。

2.3 神经网络简介

1. 神经网络简介

一般认为对神经网络的研究开始是在 20 世纪 40 年代。神经网络是一种模拟生物神经元工作方式的数学模型，被广泛应用于模式识别、预报预测^[13-15]等多个领域。按连接方式分，神经网络模型可分为前馈型网络和反馈型网络，而最常用

于预测的神经网络模型是多层感知器模型 (Multilayer Perceptron, 简称 MLP)^[16-17]。MLP 是一种前馈型神经网络 (如图 1 所示), 它的结构一般分为三层: 输入层、输出层、隐含层(可有多层隐含层), 每一层可包含一个或多个神经元, 其中每一层的每个神经元和前一层相连接, 同一层之间没有连接。其表达式如公式 (1-2) ~ 公式 (1-4) 所示。

$$g_0^{-1}(E(y)) = w_0 + w_1 H_1 + w_2 H_2 \quad (1-2)$$

$$H_1 = \tanh(w_{01} + w_{11}x_1 + w_{21}x_2 + w_{31}x_3) \quad (1-3)$$

$$H_2 = \tanh(w_{02} + w_{12}x_1 + w_{22}x_2 + w_{32}x_3) \quad (1-4)$$




图 1 前馈型神经网络示意图

其中 $g_0^{-1}(E(y))$ 是指目标变量 (结果变量) 的期望变换, 即为输出激活函数的反函数, 为非线性激活函数的线性合并。 $g_0(\cdot)$ 指输出激活函数。MLP 用的是 S 型激活函数 (如双曲正切函数)。其中, w 指权重。 H 分别代表隐单元。 x 指原因变量。

2. 多层感知器的学习

多层感知器的学习主要包含两个方面即学习连接权值和学习网络结构。

(1) 学习连接权值

MLP 网络权值的调整早期采用后向传播算法, 训练一个后向传播神经网络有三个步骤^[18]: ①得到一个训练实例: 在网络中使用现有的权重来计算实例的输出; ②向后传播然后计算误差——取计算结果和期望 (实际) 结果的差; ③该误差用来调整权重。我们把这个过程看作是误差通过神经网络反馈。

由于标准的后向传播算法存在着收敛速度慢, 易陷入局部最小及网络泛化能力差等缺点, 近些年各种对后向传播算法的改进算法相继提出, 并广泛用于解决各种实际问题。这类算法重要分为两类: 一类是启发式方法: 带动量、学习率的后向传播算法等, 如标准批后向传播算法、Quickprop 法、RPROP 法等。另一类

是使用数字最优化技术：如共轭梯度下降法、准牛顿法、L-M 算法^[19-20]等。

(2) 学习网络结构

一般来说，隐单元数越多，网络规模越大，其逼近能力越强，误差越小；另一方面，网络的参数是通过样本学习的，可能由于样本含量不足或学习时间不够带来的误差。要学习的参数越多，估计误差可能越大。同时，过大的网络训练时容易发生过拟合，导致网络泛化能力下降。

① 网络层数的确定。由映射存在定理可知：给定任一连续函数 $f: u^n \rightarrow r^m, f(x) = y$ 。这里 u 是闭单位区间 $[0, 1]$ ， f 可以精确地用一个三层感知器网络实现。因此，在实际问题中，隐含层数一般取 1-2 层即可，增多层数会增加网络的复杂性，可能会影响到网络收敛的速度。

② 隐层神经元数的确定。

隐层神经元数的大小依靠训练的样本数、噪声的数量和函数的复杂性而定。在实际的问题中，往往采用“试错法”，不断的增加神经元数目，看模型泛化能力的不再明显增加为止。

3. 模型过拟合

在 MLP 构建中要防止模型出现过拟合现象的发生^[21]，主要有以下两种方法：权重衰减、早停止。

(1) 权重衰减^[22]：其基本思想是惩罚大的权重，它通过构造一个目标函数，即在误差函数的基础上加一个惩罚函数，如公式 (1-5)、公式 (1-6) 所示。

$$\bar{O} = \frac{L_+ + P_+}{\sum_i \sum_k f_i} \quad (1-5)$$

$$P_+ = d \sum_l w_{(l)}^2 \quad (1-6)$$

其中， $\bar{O}$ 是指目标函数， L_+ 是指误差函数， d 是权重衰减常数， $w_{(l)}$ 是第 l 个权重去除输出偏倚。 f 指观测频数。模型的训练就是通过对目标函数进行训练，使目标函数最小化。

(2) 早停止：主要是过将数据集分成训练集和校正集进行，通过监控训练集和校正集的变化来发现模型训练何时结束。

3 统计学方法与数据挖掘方法在医学领域进行比较的研究现状及意义

目前能够建立预测模型的方法主要有统计学方法和数据挖掘方法,基于这两类方法的预测技术已逐渐被应用在生物医学研究领域,但关于多种预测技术的预测性能比较的研究仍然很少,目前仅有少量类似的研究^[23-29]:如 Delen^[27]等人于 2004 年运用 Logistic 回归、决策树和神经网络对 20 多万乳腺癌病人的生存状况的预测研究;Ture^[28]等人 2005 年进行了运用多种分类技术(Logistic 回归、判别分析、径向基函数等)对 694 例观测进行原发性高血压发生危险性的预测研究;2008 年陈建新^[29]等人采用四种方法(贝叶斯方法、RBF、SVM、Logistic 回归)对冠心病病人(共 1069 例患者)中医学分类准确率比较等。而在这些研究中,在评价模型预测性能时或均针对于较大的数据量,或对模型泛化能力比较时采用保持法进行比较,而没有涉及到小样本时如何有效利用数据信息,对模型泛化能力进行比较。

预测发生某种疾病的可能性是一项非常重要且具有挑战性的工作。将数据挖掘方法与统计学方法应用于生物医学领域来进行疾病预测性能的比较,从而建立起更为准确可靠的模型是一个非常值得研究的方向。目前普遍认为不存在某种方法能适合于任何特点的数据^[30],由于数据间复杂的关系,所适合的模型会有所不同,因此,要根据数据的实际情况,尝试不同的建模方案,对模型的泛化能力作出客观评价,找出较佳的预测模型用于指导实际工作。

参考文献

- [1] 熊朝松. 统计学和数据挖掘的异同. 科技广场, 2005:124-126.
- [2] Ian H. Witten, Eibe Frank. data mining:Practical Machine Learning Tools and Techniques(second ediction). China Machine Press, 2005.
- [3] 王济川, 郭志刚 译. Logistic 回归模型-方法与应用.高等教育出版社. 2001.
- [4] 秦文. 分类技术中的决策树算法分析. 深圳信息职业技术学院学报, 2004, 2(1):54-58.
- [5] Michael J.A. Berry, Gordon S.Linoff. Data mining technique for marketing, sales and customer support. New York: Wiley, 1997.
- [6] Ture M, Kurt I, Kurum A T, Ozdamar K, et al. Comparing classification techniques for predicting essential hypertension. Expert Systems with Applications, 2005, 29(3):583-588.
- [7] Breiman L, Friedman J H, Olshen R A, et al. Classification and Regression Trees, British:Chapman and Hall. 1984.
- [8] Ripley B D. Pattern Recognition and Neural Networks. Cambridge:Cambridge University Press, 1996.

- [9] Quinlan J R. C4.5:Programs for Machine Learning. San Mateo, Ca:Morgan Kaufmann,1993.
- [10]Breiman L. Technical Note: Some Properties of Splitting Criteria. Machine Learning, 1996, 24:41-47.
- [11]Morgan J N, Sonquist J A. Problems in the Analysis of Survey Data, and a Proposal. Journal of the American Statistical Association, 1963, 58:415-434.
- [12]Loh W, Vanichsetakul N. Tree-Structured Classification Via Generalized Discriminant Analysis (with discussion). Journal of the American Statistical Association, 1988, 83:715-728.
- [13]İnan Güler, Hüseyin Polat, Uçman Ergün. Combining Neural Network and Genetic Algorithm for prediction of Lung Sounds. Journal of Medical System, 2005, 29(3):217-223.
- [14]Dieterle F, Müller-Hagedorn S, Liebich H M, et al. Urinary nucleosides as potential tumor markers evaluated by learning vector quantization. Artificial Intelligence in Medicine, 2003, 28(3):265-279.
- [15]Aleksander M, Renata J, Neural network as a decision support system in the development of pharmaceutical formulation—focus on solid dispersions. Expert System with Applications, 2005, 28(2):285-294.
- [16]Haykin S. Neural network:A comprehensive foundation. Upper Saddle River, NJ:Prentice Hall, 1999.
- [17]Principe J, Euliano N R, Lefebvre W C. Neural and adaptive systems: Fundamentals through simulations. New York:Wiley, 1999.
- [18]张云涛, 龚玲. 数据挖掘:原理和技术. 北京: 电子工业出版社, 2004.
- [19]Pendharkar P C, Rodger J A, Yaverbaum G J,et al. Association,statistical,mathematical and neural approaches for mining breast cancer patters. Expert Systems Applications, 1999, 17:223-232.
- [20]Furundzic D, Djordjevic M, Bekic A J. Neural networks approach to early breast cancer detection. Syst Architect, 1998, 44:617-633.
- [21]Bartlett P L. For Valid Generalization, the Size of the Weights is More Important than the Size of the Network in: Advances in Neural Information Processing Systems Volume 9 (Mozer, Jordan, and Petsche eds.). Cambridge, Ma: The MIT Press, 1997.
- [22]Bishop C M. Neural Networks for Pattern Recognition. New York: Oxford University Press, 1995.
- [23]周利锋, 高尔生, 金丕焕. BP 神经网络与 logistic 回归对比初探. 中国卫生统计, 1998, 15(1):1-4.
- [24]El-Solh A A., Hsiao C B, Goodnough S. Predicting active pulmonary tuberculosis using an artificial neural network. Chest, 1999, 116(4):968-973.

- [25]Joannis G V, Dimitris A K, Manolis J H. Improved Medical Decision Making. Cambridge.2000, 201:95.
- [26]Samanta B, Bird GL, Kuijpers M,et al. Prediction of periventricular leukomalacia. Part I. Selection of hemodynamic features using logistic regression and decision tree algorithms. *Arti Intell Med.* 2009, 45(1):300-320.
- [27]Delen D, Walker G, Kadam A. Predicting breast cancer survivability:a comparison of three data mining methods. *Artificial Intelligence in Medicine* , 2005, 34(2):113-127.
- [28]Ture M, Kurt I, Kurum A T, et al. Comparing classification techniques for predicting essential hypertension. *Expert Systems with Applications*, 2005, 29:583-5883.
- [29]陈建新, 西广成, 王伟. 数据挖掘分类算法在冠心病临床应用的比较. *北京生物医学工程*, 2008, 27(3):249-252.
- [30]史忠植. 知识发现. 北京: 清华大学出版社, 2002: 2-6.