

Logistic回归变量筛选及回归方法选择实例分析

许汝福

第三军医大学新桥医院循证医学与临床流行病学中心 (重庆 400037)

摘要 目的 探讨多因素 Logistic 回归分析中自变量筛选及逐步回归方法选择应注意的问题。方法 针对冠心病危险因素病例对照调查数据 (年龄 X_1 、高血压史 X_2 、高血压家族史 X_3 、吸烟 X_4 、高血脂史 X_5 、动物脂肪摄入 X_6 、体重指数 X_7 、A 型性格 X_8 、冠心病 Y)，采用 6 种逐步回归变量筛选方法，进行多因素 Logistic 回归分析，比较不同方法筛选危险因素的差异性。结果 单因素分析可见，冠心病组与非冠心病组的年龄分布无明显差异 ($P=0.116$)，而多因素 Logistic 回归分析显示，相对于 65 岁以上人群，低年龄组为保护因素 [$OR_{<45}=0.100$, (0.000, 0.484), $P=0.020$; $OR_{45-54}=0.051$, (0.003, 0.975), $P=0.048$]。将年龄定义为分类变量进行分析，筛选出的冠心病危险因素为动物脂肪摄入 X_6 、A 型性格 X_8 、高血压史 X_5 和年龄 X_1 ($P<0.05$)；同时将年龄 X_1 当作连续性变量进行分析，结果显示年龄 X_1 无统计学意义 ($P=0.053$)。6 种逐步回归变量筛选方法得到的共同的危险因素是动物脂肪摄入 X_6 、A 型性格 X_8 ；向前 - 条件、向前 - LR、向前 - Wald 法另筛选出高血脂史 X_5 为危险因素；向后 - 条件、向后 - LR 法另筛选出高血压家族史 X_3 和年龄 X_1 为危险因素，向后 - Wald 法另筛选出高血压史 X_2 为危险因素。结论 多因素 Logistic 回归分析应采用逐步回归方法，对全部变量进行分析，包括单因素分析无统计意义的自变量；把多分类变量当作连续性变量进行分析，会损失部分信息，甚至可能漏掉重要的危险因素；当几种逐步回归变量筛选方法得到的危险因素不同时，最好结合临床和流行病学的意义以及生物学机制等专业知识，选择较为合理的结果。

关键词 Logistic 回归；自变量筛选；逐步回归

Selection for Independent Variables and Regression Method in Logistic Regression: An Example Analysis

XU Ru-fu

Evidence-based Medicine and Clinical Epidemiology Center, Xinqiao Hospital, Third Military Medical University, Chongqing 400037, China

Abstract Objective To explore the selection problem of independent variables and stepwise regression method for multiple logistic regression analysis. **Methods** According to the data of the case-control investigation for coronary heart disease, age (X_1), hypertension history (X_2), hypertension family history (X_3), smoking (X_4), hyperlipidemia history (X_5), animal fat intake (X_6), weight index (X_7), type A personality (X_8), and coronary heart disease (CHD, Y) were analyzed by SPSS 18.0 software. The multiple logistic regression analysis was done and the differences of risk factors were compared among 6 kinds stepwise regression variable selection method. **Results** The univariate analysis showed that no difference was found between CHD group and non-CHD group in age distribution ($P=0.116$). But the multivariate logistic regression analysis showed that, comparing to population over 65 years old, age was a protective factor on the low age groups ($OR_{<45}=0.100$, 0.000 to 0.484, $P=0.020$; $OR_{45-54}=0.051$, 0.003 to 0.975, $P=0.048$). If the age was defined as categorical variable, the risk factors for coronary heart disease were animal fat intake (X_6), type A personality (X_8), hypertension history (X_5) and age (X_1), respectively ($P<0.05$). If the age was defined as a continuous variable, the effect of age (X_1) was not statistically significant ($P=0.053$). The common risk factors were intake of animal fat (X_6) and type a personality (X_8) by six kinds method of stepwise variable selection. In addition, the risk factor also included hyperlipidemia history (X_5) (forward-condition, forward-LR, forward-wald), hypertension family history (X_3), age (X_1) (backward-condition, backward-LR) and hypertension history (X_2) (backward-wald). **Conclusion** Stepwise regression method should be used to analyze all the variables, including no statistically significant independent variables in univariate analysis. If the categorical variable is regarded as continuous variables, some information may be lost, and even the risk factors may be missed. When the risk factors are not the same by several stepwise regression variable selection method, it should be combined with clinical and epidemiological significance, as well as biological mechanisms and other professional knowledge.

Key words Logistic regression; Selection of independent variable; Stepwise regression

DOI: 10.7507/1672-2531.20160205

作者简介：许汝福，男（1963 年～），硕士，副教授，主要从事统计学与临床流行病学方法学及科研管理与评价研究，以循证医学为主要研究方向。Email: xurf1963@163.com

危险因素研究,常常需要使用多因素 Logistic 回归分析方法,从调查的自变量中筛选危险因素^[1-8]。但在进行多因素 Logistic 回归分析时,常由于变量及方法选择等原因,得出的回归分析结果有时不一致。笔者结合实例,就多因素 Logistic 回归分析中自变量筛选及逐步回归方法选择应注意的问题进行探讨。现报告如下。

1 资料与方法

1.1 资料

资料来源于冠心病危险因素病例对照调查数据^[2], 26 例冠心病患者和 28 例对照者,记录年龄 X_1 (<45 岁 =1, 45 ~ 54 岁 =2, 55 ~ 64 岁 =3, ≥65 岁 =4)、高血压史 X_2 (无 =0, 有 =1)、高血压家族史 X_3 (无 =0, 有 =1)、吸烟 X_4 (不吸烟 =0, 吸烟 =1)、高血脂史 X_5 (无 =0, 有 =1)、动物脂肪摄入 X_6 (低 =0, 高 =1)、体重指数 X_7 (<24=1, 24 ~ 26=2, >26=3)、A 型性格 X_8 (否 =0, 是 =1)、冠心病 Y (否 =0, 是 =1)。原始数据详见文献^[2]。

1.2 方法

采用 SPSS 18.0 软件进行统计分析,采用列联表 χ^2 检验进行单因素分析,探讨各因素与冠心病的关系;以是否发生冠心病为应变量 Y,以年龄 X_1 、高血压史 X_2 、高血压家族史 X_3 、吸烟 X_4 、高血脂史 X_5 、动物脂肪摄入 X_6 、体重指数 X_7 、A 型性格 X_8 为自变量,采用 6 种逐步回归变量筛选方法(向前 - 条件、向前 - LR、向前 - Wald、向后 - 条件、向后 - LR、向后 - Wald)^[9],进行多因素 Logistic 回归分析,筛选冠心病的危险因素;比较纳入全部变量的分析结果与纳入单因素分析有统计学意义变量的分析结果之间的差别;比较多分类变量当作连续性变量的分析结果与定义为分类协变量的分析结果之间的差别;比较几种逐步回归分析方法筛选出的危险因素的差异性。

2 结果

2.1 纳入单因素分析有意义的变量与纳入全部变量的 Logistic 回归结果的区别

文献^[2]冠心病危险因素病例对照调查数据的单因素分析结果见表 1,冠心病 Y 与年龄 X_1 无明显关系 ($P=0.116$),冠心病 Y 与其他指标 ($X_2 \sim X_8$) 均有统计学意义 ($P<0.05$)。而按照 SPSS 软件 Logistic 回归分析方法,将年龄和体重指数定义为分类协变量,采用逐步回归向后 - 条件法进行多因素 Logistic 回归分析结果见表 2,冠心病的危险因素为动物脂肪摄入

X_6 (OR=51.571, $P=0.006$), A 型性格 X_8 (OR=12.176, $P=0.008$), 高血压家族史 X_3 (OR=7.597, $P=0.023$); 相对于 65 岁以上人群,低年龄组为保护因素,OR 分别为 0.10、0.051、0.046, P 值分别为 0.020、0.048 和 0.063。显然,如果在多因素 Logistic 回归分析时,只纳入单因素分析中有统计意义的自变量,年龄 X_1 对冠心病的作用就会被忽略。

2.2 多分类变量当作连续性变量的分析结果与定义为分类协变量的分析结果之间的差别

文献^[2]中年龄 X_1 和体重指数 X_7 属于多分类变量。按照 SPSS 软件 Logistic 回归分析方法,将年龄和体重指数定义为分类协变量^[9],采用逐步回归向后 - 条件法进行分析,结果见表 2,有统计学意义的危险因素包括:动物脂肪摄入 X_6 、A 型性格 X_8 、高血压史 X_5 和年龄 X_1 。如果将年龄 X_1 、体重指数 X_7 当作连续性变量进行分析,结果见表 3,冠心病危险因素为动物脂肪摄入 X_6 、A 型性格 X_8 、高血脂史 X_5 , OR 值分别为 23.000、7.008、4.464,年龄 X_1 无统计学意义 ($P=0.053$)。显然,把多分类变量当作连续性变量进行分析,会损失部分信息,甚至可能漏掉重要的危险因素。

2.3 几种逐步回归变量筛选方法所得到的多因素 Logistic 回归分析结果的比较

文献^[2]冠心病危险因素病例对照调查数据,分

表 1 冠心病危险因素调查单因素分析结果

变量		冠心病 (例)		χ^2	P
		是	否		
X_1 (岁)	<45	1	5	5.916	0.116
	45 ~ 55	10	15		
	55 ~ 65	12	7		
	≥65	3	1		
X_2	无	11	21	5.968	0.015
	有	15	7		
X_3	无	9	18	4.747	0.029
	有	17	10		
X_4	不吸	3	10	4.311	0.038
	吸烟	23	18		
X_5	无	11	22	7.460	0.006
	有	15	6		
X_6	低	16	27	10.117	0.001
	高	10	1		
X_7 (kg ² /m)	<24	12	22	6.084	0.048
	24 ~ 26	9	4		
	≥26	5	2		
X_8	否	5	15	6.818	0.009
	是	21	13		

别使用 SPSS 软件提供的 6 种逐步回归变量筛选方法 (向前 - 条件、向前 -LR、向前 -Wald、向后 - 条件、向后 -LR、向后 -Wald) 进行分析, 结果见表 4, 筛选出的危险因素不尽相同。向前 - 条件、向前 -LR、向前 -Wald 三种方法筛选出的危险因素是相同的; 向后 - 条件、向后 -LR 两种方法筛选出的危险因素是相同的。几种方法筛选出的共同危险因素是动物脂肪摄入 X_6 和 A 型性格 X_8 , 向前 - 条件、向前 -LR、向前 -Wald 法筛选出的危险因素还有高血脂史 X_5 , 向后 - 条件、向后 -LR 法筛选出的危险因素还有高血压家族史 X_3 和年龄 X_1 , 向后 -Wald 法筛选出的危险因素还有高血压史 X_2 。从模型系数综合检验和拟合优度检验^[9] 结果来看, 向后 - 条件、向后 -LR 法的拟合效果最好, 向前 - 条件、向前 -LR、向前 -Wald 三种方法的拟合效果次之, 向后 -Wald 法的拟合效果相对较差。

3 讨论

3.1 多因素 Logistic 回归分析最好纳入全部自变量, 不要随意舍弃单因素分析无统计意义的自变量
危险因素研究, 很多文献都是通常先进行单因素分析, 单因素分析有统计学意义的变量纳入多因素 Logistic 回归分析, 无意义的变量不纳入分析^[10-18]。如在藏族居民早发冠心病危险因素的横断面研究中, 对两组患者性别、家族史、吸烟、饮酒、高血压、糖尿病和血脂水平进行单因素分析, 提取有统计学意义的因素进一步进行多因素 Logistic 回归分析^[18]。但只将单因素分析有统计学意义的因素作为自变量, 纳入多因素 Logistic 回归分析, 很可能会将重要的危险因素漏掉。如文献 2, 单因素分析可见, 冠心病组与非冠心病组的年龄分布无明显差异 ($P=0.116$), 而多因素 Logistic 回归分析显示, 相对于 65 岁以上人群, 低年

表 2 冠心病危险因素多因素 Logistic 回归分析结果 (年龄 X_1 为分类协变量)

自变量	B	S.E	Wald	df	Sig.	OR	95%CI	
							下限	上限
年龄 X_1 (1)	-4.570	1.962	5.427	1	0.020	0.010	0.000	0.484
年龄 X_1 (2)	-2.968	1.502	3.907	1	0.048	0.051	0.003	0.975
高血压家族史 X_3	2.028	0.892	5.170	1	0.023	7.597	1.323	43.623
动物脂肪摄入 X_6	3.943	1.440	7.503	1	0.006	51.571	3.070	866.395
A 型性格 X_8	2.499	0.948	6.955	1	0.008	12.176	1.900	78.026
常量	-0.433	1.387	0.097	1	0.755	0.649		

表 3 冠心病危险因素多因素 Logistic 回归分析结果 (年龄 X_1 为连续性变量)

自变量	B	S.E	Wald	df	Sig.	OR	95%CI	
							下限	上限
年龄 X_1	0.924	0.477	3.758	1	0.053	2.519	0.990	6.411
高血脂史 X_5	1.496	0.744	4.044	1	0.044	4.464	1.039	19.181
动物脂肪摄入 X_6	3.135	1.249	6.303	1	0.012	23.000	1.989	265.945
A 型性格 X_8	1.947	0.847	5.289	1	0.021	7.008	1.333	36.834
常量	-4.705	1.543	9.295	1	0.002	0.009		

表 4 冠心病危险因素研究 Logistic 回归模型比较

变量纳入方法	纳入的变量	模型系数综合检验	Hosmer-Lemeshow 拟合优度检验
向前 - 条件 向前 -LR 向前 -Wald	动物脂肪摄入 X_6 A 型性格 X_8 高血脂史 X_5	$\chi^2=24.384, P<0.001$ Cox & Snell $R^2=0.363$ Nagelkerke $R^2=0.485$	$R^2=1.065, P=0.900$
向后 - 条件 向后 -LR	动物脂肪摄入 X_6 A 型性格 X_8 高血压家族史 X_3 年龄 X_1	$\chi^2=31.032, P<0.001$ Cox & Snell $R^2=0.437$ Nagelkerke $R^2=0.583$	$R^2=1.513, P=0.982$
向后 -Wald	动物脂肪摄入 X_6 A 型性格 X_8 高血压史 X_2	$\chi^2=24.510, P<0.001$ Cox & Snell $R^2=0.365$ Nagelkerke $R^2=0.487$	$R^2=3.336, P=0.648$

龄组为保护因素, OR 分别为 0.100、0.051, P 值分别为 0.020、0.048。如果多因素 Logistic 回归分析时, 只纳入单因素分析有统计学意义的自变量, 年龄 X_1 就没有机会进入 Logistic 回归模型, 年龄对冠心病的影响就会被漏掉。因此, 在危险因素较少时宜纳入全部变量, 采用逐步回归方法, 进行多因素 Logistic 回归分析, 自动筛选有意义的变量, 不要随意舍弃单因素分析无统计意义的自变量。当危险因素较多时可采用单因素分析进行初筛, 但应注意适当调整检验水准并结合专业选择纳入多因素分析的变量, 不要随意舍弃单因素分析无统计意义的自变量, 避免漏掉重要的危险因素。

3.2 使用SPSS软件进行Logistic回归分析时应注意连续性变量与多分类变量的区别

使用 SPSS 软件进行 Logistic 回归分析时, 对于两分类 (二值) 的数字变量, 如 (0, 1) 或 (1, 2), 模型自动以低水平作为参照, 对高水平进行对比分析。但对于多分类的数字变量, 应区分是连续性变量还是多分类变量; 对多分类变量要使用“分类”按钮, 将其定义为“分类协变量”, 模型给出各水平与最低水平比较的 OR 值, 或给出各水平与最高水平比较的 OR 值^[9]。对于多分类变量, 也有文献使用哑变量的形式, 将一个自变量分为多个自变量^[19,20]。如果不将多分类变量定义为“分类协变量”, 模型将默认为连续性变量, 只给出了一个总的 OR 值, 不能体现各等级之间的差异性, 往往会损失部分信息, 甚至可能漏掉重要的危险因素。如“ICU 患者医院感染 Logistic 回归模型预测”^[21]中描述, 抗菌药物使用天数 (d) 分为 5 个等级 (0=未用, 1=1~3, 2=4~7, 3=8~10, 4 $\geq$ 10), 但给出的 Logistic 回归分析结果中, 将表示抗菌药物使用天数 (d) 5 个等级的数据 0~4, 当作连续变量进行分析, 只给出了一个总的 OR 值, 忽略了抗菌药物使用天数各等级之间的差异性。如果将文献 2 中的年龄 X_1 当作连续变量进行分析, 各年龄组之间的差异性就被忽略, 最终年龄 X_1 对冠心病的影响就会被漏掉。因此, 使用 SPSS 软件进行 Logistic 回归分析时, 对于多分类变量一定要定义为分类协变量或哑变量, 不能简单地当作连续性变量进行分析。对于连续性变量, 拟合 Logistic 回归模型时, 既可以用实测值作为连续性变量, 也可以用适宜尺度分组后作为分类变量或者哑变量纳入模型, 不同的赋值方式得到的回归分析结果往往也有所不同。实际资料处理过程中, 宜比较作为连续性变量和分类变量纳入模型时是否存在线性趋势及其好坏, 并结合专业及结果的可解释性, 选择恰

当的变量纳入赋值方式 (连续变量、分类变量、哑变量), 得出较为合理的回归分析结果。

3.3 采用逐步回归变量筛选的几种方法进行Logistic回归分析应结合专业知识确定危险因素

多因素 Logistic 回归分析的变量选择包括多种方法, 常用逐步回归方法筛选自变量。如《喀什市维吾尔族和汉族重度婴幼儿龋危险因素的横断面研究》^[22]中, 在选入变量的显著性水准为 0.05 和剔除变量的显著性水准为 0.10 标准下, 选择“Forward: Conditional”方法筛选 SECC 易感因素。《血清胆红素水平与冠脉支架植入术后患者冠脉事件复发的相关性研究》^[23]中, 对冠脉支架植入术后患者的基线资料及复查时的临床资料进行二分类 Logistic 向前逐步回归分析。《成都市城乡男性居民 COPD 患病情况及危险因素调查》^[20], 通过单因素 Logistic 回归先判断各因素与 COPD 的关系, 后将可能与 COPD 发病有关的因素 ($P<0.1$) 纳入模型进行多因素分析, 变量进入模型的方式采用逐步回归, 采用先建立全模型然后逐个筛选的方法。

SPSS 软件中多因素 Logistic 回归分析的变量选择, 提供了条件参数估计似然比检验、最大偏似然估计似然比检验、Wald 检验 3 种模型假设检验方法和向前选择法、向后剔除法两种变量进出方法, 组合成 6 种逐步回归变量选择方法 (向前-条件、向前-LR、向前-Wald、向后-条件、向后-LR、向后-Wald)^[9]。似然比检验是基于整个模型的拟合情况进行的, 结果最可靠; Wald 检验没有考虑各因素的综合作用, 当自变量间存在共线性时, 结果不可靠^[1,2,9]。如文献^[2]冠心病危险因素病例对照调查数据的分析结果说明, 使用不同变量筛选方法, 可能得到不同的回归分析结果, 筛选出的危险因素也不尽相同。分析原因, 主要是高血压史 X_2 、高血压家族史 X_3 、高血脂史 X_5 之间存在一定的相关性。

因此, 最好结合临床和流行病学的意义以及生物学机制等专业知识^[1,2], 对几种逐步回归方法的计算结果进行综合分析, 选择较为合理的结果。

参考文献

- 1 方积乾, 主编. 卫生统计学. 第五版. 北京: 人民卫生出版社, 2004: 356-367.
- 2 易东, 主编. 军事医学统计学. 北京: 军事医学科学出版社, 2009: 245-259.
- 3 Bi Y, Wang L, Xu Y, et al. Diabetes-related metabolic risk factors in internal migrant workers in China: a national surveillance study. *Lancet Diabetes Endocrinol*, 2016, 4(2): 125-135.
- 4 Yu J, Zhuang CL, Shao SJ, et al. Risk factors for postoperative fatigue after gastrointestinal surgery. *J Surg Res*, 2015, 194(1): 114-119.

- 5 Khan BT, Kiani MN, Bin Saeed MH, *et al.* Risk factors assessment for dry sockets: A logistic regression analysis study. *J Oral Maxil Surg*, 2015, 27(6): 753-756.
- 6 Chen YF, Wang DN, Chen ZT, *et al.* Risk factors associated with acute/subacute cerebral infarction in HIV-negative patients with cryptococcal meningitis. *J Neurol Sci*, 2016, 364: 19-23.
- 7 胡晓斌, 杨轶男, 白亚娜. 兰州市6825例住院孕产妇不良妊娠结局危险因素的logistic回归分析. *中国循证医学杂志*, 2011, 11(5): 505-507.
- 8 刘迎春, 吴德云, 高宗恩, 等. 高血压患者颈动脉粥样硬化与同型半胱氨酸的相关性研究. *中国循证医学杂志*, 2015, 15(5): 503-507.
- 9 张文彤, 董伟, 主编. SPSS统计分析高级教程. 第二版. 北京: 高等教育出版社, 2013: 162-180.
- 10 Wang XR, Han BR. Logistic regression analysis and nursing interventions for high-risk factors for pressure sores in patients in a surgical intensive care unit. *Chin Nurs Res*, 2015, 2(2-3): 51-54.
- 11 陈夏容, 张华平, 曾秀玉, 等. 社区产ESBLs大肠埃希菌泌尿系感染的危险因素分析. *中国循证医学杂志*, 2016, 16(2): 125-129.
- 12 王建华, 肖蕾, 张哲, 等. 心脑血管病危险因素的横断面调查. *中国循证医学杂志*, 2014, 14(4): 408-413.
- 13 张晓芳, 刘方竹, 刘明建. 血流感染的危险因素分析及其与早期炎症因子相关性研究. *中国现代医学杂志*, 2015, 25(11): 51-54.
- 14 张春莲. 引起异位妊娠相关因素的病例对照研究. *当代医学*, 2010, 16(16): 47-48.
- 15 张兰, 余进进. 子宫肌瘤发病的相关危险因素Logistic回归分析. *东南大学学报(医学版)*, 2012, 31(2): 213-216.
- 16 高海红, 谈林华, 张彩云, 等. 婴幼儿心内直视术后呼吸机相关性肺炎高危因素分析. *中华肺部疾病杂志*, 2012, 5(3): 210-215.
- 17 陈德超, 祝申跃, 田玉莲, 等. 芦山地震后3个月教师广泛性焦虑障碍的预测因素. *中国循证医学杂志*, 2015, 15(10): 1121-1126.
- 18 李洪卫, 周瑶, 王海燕, 等. 藏族居民早发冠心病危险因素的横断面研究. *中国循证医学杂志*, 2014, 14(6): 662-664.
- 19 王伟文, 廖晓阳, 杨职艺, 等. 成都市中心城区社区中老年居民抑郁筛查及其危险因素研究. *中国循证医学杂志*, 2014, 14(1): 21-24.
- 20 彭大庆, 杨职艺, 廖晓阳, 等. 成都市城乡男性居民COPD患病情况及危险因素调查. *中国循证医学杂志*, 2014, 14(8): 923-926.
- 21 谢多双, 来瑞平, 符湘云, 等. ICU患者医院感染logistic回归模型预测. *中华医院感染学杂志*, 2011, 21(12): 2424-2426.
- 22 鲍雪俐, 吉别克·乌拉儿汗, 于倩, 等. 喀什市维吾尔族和汉族重度婴幼儿龋危险因素的横断面研究. *中国循证医学杂志*, 2014, 14(3): 260-264.
- 23 罗承锋, 仁杰, 李爱群, 等. 血清胆红素水平与冠脉支架植入术后患者冠脉事件复发的相关性研究. *中国循证医学杂志*, 2014, 14(8): 905-910.

收稿日期: 2016-03-31 修回日期: 2016-09-22
本文编辑: 樊斯斯、张永刚