

基于KNN和Logistic回归方法的财务预警模型比较

■ 宁静鞭(复旦大学管理学院 上海 200433)

◆ 中图分类号:F275 文献标识码:A

内容摘要:基于我国上市公司的财务报表数据,本文使用“行业优先”的样本选择方法,采用K近邻方法和Logistic回归方法进行财务危机的预警建模研究。实证结果显示两种方法均具有很好的预测效果,但Logistic回归更适合于对短期内的预测,而K近邻方法对于基于事前信息建模的长期预测有很高的精确度。本文的研究为将来更加详尽全面的研究上市公司的财务危机预警模型提供了参考。

关键词:K近邻方法 财务预警模型 Logistic回归

随着我国经济的发展,利用财务预警模型可更好的预测上市公司财务危机的发生。本文引入了一种非参数的判别方法K近邻法,为了更好的反映和比较预警模型构建的效果,也采用了Logistic回归构建模型进行对比。

样本选取及研究假设

(一) 样本选择

本文的样本原始资料均来自于WIND数据库,从中选取了2004~2006年度所有被实施ST的公司财务数据。参考吴世农、卢贤义(2001)的研究,本文首先剔除了由于以下四个方面原因被实施ST的公司样本:出现其它异常状况,实施特别处理;在法定期限内未依法披露定期报告;被注册会计师出具无法表示意见或否定意见的审计报告;在规定期限内未对存在重大会计差错或虚假财务会计报告进行改正。在抽取正常公司样本比率选择的问题上,考虑到Logistic函数的对称性质以及国外相关文献的实践经验,本文采用1:1配对抽样的方法,基于行

业优先抽样原则选择被ST公司的配对样本构成研究总体。

在进行配对样本抽取时,对于未能取得配对样本的ST公司进行了剔除处理,得到的行业优先总体为168家,2004年36家,2005年46家,2006年86家。当公司为被实施ST的公司时,用示性变量“1”来表示,否则则为“0”。本文参考Amy Hing-Ling Lau(1987)提出的测试样本选择方法,使用年份作为区别建模样本和测试样本的原则,将2004~2005年选择出来的配对样本作为建模样本,而将2006年选出的样本作为测试样本。

(二) 模型预测时段

本文所研究的财务预警模型的时间跨度为4年,即从公司被ST起往前追溯三年。本文把公司被ST这一事件的时间定为T时刻,之前一年为第T-1年,以此类推。

(三) 变量选择及研究设计

与以往国内研究往往采用较少量的财务指标进行预警模型研究不同,本文从公司每股指标、盈利能力、现金流、偿债能力、营运周转能力等五方面选取了Wind数据库中全部52个财务指标(具体指标略)作为研究基本数据集。在T-1年总体数据集的基础上,对52个财务指标进行考察,利用独立样本的T检验,剔除了T检验P值不显著和数据缺失值较多的财务指标。在Logistic回归和KNN两种不同的建模方法中,分别使用逐步回归及逐步判别两种变量选择方法选择合适的变量

构建预警模型。

模型构建及实证结果

(一) K近邻方法建模

1. K近邻方法简介。K近邻方法(KNN)是一种基于非参数的多元变量判别方法,最早由Fix和Hodges(1952)与Cover和Hart(1967)等人提出,主要用于概率密度函数的估计和判别分析,它不仅放松了对变量正态性要求的统计假设,同时它也放松了回归中的构造链接函数的要求。KNN方法的数学语言描述形式如下:

假定所有的样本对应于n维空间 R^n 中的点,一个样本的最近邻根据标准欧氏距离所定义。设两个样本分别是 $X=(x_1, x_2, \dots, x_n)$ 和 $Y=(y_1, y_2, \dots, y_n)$,其欧几里德距离是 $d(X, Y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$,未知样本将分配到K个与之最邻近者中最公共的类,即对于训练集中的每个样本 $(x, f(x))$, $f(x)$ 被定义为函数 $f: R^n \rightarrow V$,n是样本的条件属性维数,V是样本集类别集合,这是一个s维的有限集 $(v_1, v_2, \dots, v_s)$ 。则对于一个给定的新未知样本 x_q ,它的类别可以通过以下计算得到:设 $x_1, \dots, x_k$ 是训练集中通过欧氏距离计算得到的与 x_q 最为邻近的K个样本,则 x_q 的类别为:

$$\hat{f}(x_q) \leftarrow \arg \max_{v \in V} \sum_{i=1}^k \delta(v, f(x_i))$$

$$\begin{cases} \delta(a, b) = 1, a = b \\ \delta(a, b) = 0, \text{other} \end{cases}$$

2. KNN方法建模。首先对样本的原始数据变量利用SAS的Stepwise过程选择适当变量进行模型构建,本文采用的是逐步判别方法挑选变量,分别对T-1~T-3三个时刻的样本数据进行逐步判别分析,将所得变量作为初始建模变量,变量的进入和删除标准均为默认值0.15,运算在SAS9.0统计软件上完成。对于Stepwise过程选择的变量,再利用pearson相关分析对其相关系数矩阵进行检验,删除相关

表1 逐步判别变量汇总

变量	变量名	变量	变量名
X36	保守速动比率	X38	权益乘数
X49	流动资产周转率	X24	财务费用率
X30	现金营运指数	X25	主营业务利润比重
X33	现金债务总额比	X27	净收益营运指数
X11	每股未分配利润加资本公积金	X13	资产报酬率
X46	债务总额/EBITDA		

性检验P值显著的变量，最后得到建模变量如表1。

利用获得的变量，输入SAS软件进行模型构建，基于样本的试验，同时参考Kar Yan Tam和Melody Y.Kiang (1992)的研究分别取k=3、k=4两种情况作为模型的输入参数，获得KNN方法模型判别结果如表2所示。

这里的建模样本检验方法是采用的交互验证法，该方法在样本二分回带法上有所改进，更加精确的表明了真实的判别效果。对于外生性测试样本，KNN方法构建的模型显示出很好的判别效果。KNN方法具有很好的事前信息判别效果，在我国的财务预警实践中，KNN方法构建的模型对于上市公司两三年内是否会发生财务危机具有很好的预测效果。

(二) Logistic回归建模

利用剔除T检验P值不显著和样本数据缺失值较多的财务指标之后剩余的39个变量，基于所有三年“行业优先”建模样本分别使用逐步回归过程对变量进行筛选。本文使用的逐步回归过程，变量的进入和删除标准均为0.15，运算在SAS9.0统计软件上完成。以T-3时刻的逐步回归参数估计结果为例，如表3所示。

根据表3的结果对于T-3时刻的变量进行相关性分析及相关系数矩阵检验（结果略），并没有发现明显的线性联系，这表明逐步回归之后选择的T-3时刻各变量并

未呈现明显的共线性。

因此，利用上述变量，可以构建基于样本T-3时刻Logistic判别模型如下，即IND-PRIM样本模型：

$$P(Y=1)=\frac{1}{(1+\exp(-z))}$$

其中，Z=-1.1006*X11+0.0628*X23-0.2717*X24+0.0267*X32+2.7443*X52+ε（ε为误差项）。

根据得到的Logistic回归方程，以0.5作为最佳判别点，对T-3时刻的建模样本数据进行交互回代判定，得到的交互判别正确率为76.0%。

对于建模样本来说，上面构建的T-3时刻Logistic回归模型具有良好的判别效果，在建模样本内部具有很好的预警效力。但是，对于具有相对外生性的T-3时刻的测试样本，逐步选择变量后构建的Logistic回归模型在测试样本中却没有取得很好的判别效果，总体判别效果不佳，I、II类错误概率也都比较高。

在对于测试样本的判别中，各时刻构建的Logistic回归模型都没有能够取得很好的效果，误判率和第I类错误概率都比较大，因此在我国上市公司财务预警实践中，如果采用Logistic模型进行基于事前信息（即外生测试样本）的预测时要特别注意其判别效果有效性的问题。鉴于Logistic模型的样本判别效果，在我国上市公司财务预警实践中，该模型也最好用

于对与建模样本数据相类似的外来样本进行短期内的判别。

(三) 两种方法建模判别结果比较

对比本文Logistic回归模型中的判别结果（测试样本比较如表4），KNN方法模型在大部分情况下都明显好于Logistic回归模型，对于T-3时刻这种时间较长的预测，KNN方法的测试样本预测精度均有显著提高，第I类错误概率和整体误判率都显著小于Logistic回归模型的判别结果。

KNN方法是一种黑箱技术，它基于数据挖掘技术，能够动态的调整训练集中的数据以达到适应不同样本分布和不同时期的预测要求。该方法在具有长期预测精度的同时，对于建模样本的要求也不高，引入一个外来测试样本进行检验，其预测效果波动很小。然而Logistic回归模型也有一定的优点，使用该方法构建模型较为具有相对的透明度，它所选择的变量都可以通过一定的经济含义做出解释。综合的说，KNN方法在多数数据动态预警模型构建中具有明显的优势，但这种方法也存在一些缺点，它构建的模型没有函数形式，无法从经济意义上说明每个变量具体的经济含义及其重要性。

结论及启示

实证结果证明，利用财务指标模型能够很好的预测将来公司的财务状况。并且，利用KNN方法建模，具有更高的稳定性和更高的预测精度。由于企业财务报表数据存在一些质量问题，虽然经过了一系列样本的筛选处理，运用判别模型得出的准确率仍不够理想，但从总体上来说，这样的准确率基本已达到可以接受的范围。

从模型的判别效果可以看出，从T-3年到T-2年，两类方法的判别效率都有显著的提高，这说明，上市公司的财务指标对于T-2时刻的解释效果十分理想，考虑到上市公司是否被实施ST处理是根据前两年的财务报表数据的原因，笔者认为可以在以后的研究中对于超长期的模型加入非财务指标因素的变量，以取得更好的预警模型预测效果。

参考文献：

1. 陈静. 上市公司财务恶化预测的实证分析. 会计研究, 1999 (4)
2. 吴世农, 卢贤义. 我国上市公司财务困境的预测模型研究. 经济研究, 2001 (6)

表 4

测试样本比较	建模方法	T-1	T-2	T-3
IND-PRIM 样本	KNN 方法(K=3)	6.98%	13.07%	28.88%
	Logistic方法	9.21%	10.84%	33.70%

表 2 行业优先样本 KNN 判别结果

时刻	建模样本				测试样本			
	K=3		K=4		K=3		K=4	
	第 I 类错误概率	误判率	第 I 类错误概率	误判率	第 I 类错误概率	误判率	第 I 类错误概率	误判率
T-1	0.00%	2.50%	0.00%	2.50%	0.00%	6.98%	7.14%	10.55%
T-2	15.38%	14.10%	12.82%	11.54%	23.81%	13.07%	30.95%	16.64%
T-3	23.08%	22.35%	38.46%	25.99%	26.19%	28.88%	33.33%	28.51%

表 3 T-3 时刻行业优先样本逐步回归参数估计结果表

变量	参数估计	标准差	Wald 开方统计量	显著水平
每股未分配利润加资本公积金(X11)	-1.1006	0.3451	10.1735	0.0014
管理费用率(X23)	0.0628	0.0256	6.0011	0.0143
财务费用率(X24)	-0.2717	0.0982	7.6505	0.0057
现金流动负债比(X32)	0.0267	0.0124	4.6471	0.0311
总资产周转率(X52)	2.7443	1.1058	6.1592	0.0131