

分类号_____

UDC_____

密级_____

编号_____

华中师范大学

硕士学位论文

基于加权决策树的随机 森林模型优化

学位申请人姓名: 马晓东

申请学位学生类别: 全日制硕士

申请学位学科专业: 计算机应用技术

指导教师姓名: 陈靓影 教授



硕士学位论文
MASTER'S THESIS

硕士学位论文

基于加权决策树的随机森林模型优化

论文作者：马 晓 东

指导教师：陈靓影 教授

学科专业：计算机应用技术

研究方向：机器学习

华中师范大学国家数字化学习工程技术研究中心

2017 年 5 月



硕士学位论文
MASTER'S THESIS

Optimizing Voting Process of Random Forests Algorithm Based on Weighted Decision Trees

A Thesis

Submitted in Partial Fulfillment of the Requirement

For the M.S. Degree in Education Technology

By

Ma Xiaodong


Postgraduate Program

National Engineering Research Centre for E-Learning

Central China Normal University

Supervisor: Chen Jingying

Academic Title: Professor

Signature 

Approved

May, 2017



摘 要

随机森林是一种组合分类器，它的主要思想是基于两个随机过程（训练样本随机抽取、特征集随机抽取）来构建多棵相对独立的决策树分类器，然后通过所有决策树参与投票的方式获得最终的预测结果，这样有效避免了过度拟合的问题，并且构建决策树的相对独立性适合于并行计算提高模型的预测效率，方便处理高维数据。这些特点使随机森林在各个工程应用中得到了迅速、广泛的使用，成为机器学习、数据挖掘研究中的热门算法。

虽然随机森林在模型构建过程中的随机抽样解决了过拟合的问题，但是也使得模型中不同决策树的泛化能力存在一定的差异，在传统随机森林模型中这些具有不同泛化能力的决策树拥有相同的投票权重，这影响了模型整体预测能力的稳定性。因此，为了进一步提高随机森林模型整体的预测能力，本文提出了一种优化的随机森林投票方法，通过使用决策树的分类性能与样本的统计特征来确定决策树的投票权重，使用加权决策树投票的方式提高随机森林整体模型的准确率与效率。

本文通过研究传统随机森林算法，着重优化了随机森林的投票过程，针对投票过程中存在的问题，提出改进的方法，并通过在多个公共数据集上展开实验，验证优化方法的合理性和优越性。本研究的主要工作包括：

（1）从决策树的分类能力、训练样本的统计特性入手，提出了4种计算决策树投票权重的方法，包括OOB评估、样本数据相关系数评估、卡方评估和互信息评估，通过这4种评估方法为单棵决策树计算投票权重。在8组数据集上进行对比实验，实验结果表明引入投票加权的方法可以有效的提高随机森林模型整体的泛化能力，其中以相关系数作为决策树投票权重计算依据时，模型表现出更稳定、更高的预测准确率。

（2）在引入加权投票算法的基础上，本文还提出了一种半投票量模式，对构建好的加权随机森林模型按照决策树投票权重进行降序排序，在随机森林模型进行串行投票的过程中，确定半投票量的预测终止条件，通过提前触发预测终止条件来提高模型预测的速度。本文在4组数据集上进行对比实验，验证了半投票量模式可以在不影响模型预测准确率的前提下显著提高随机森林模型的预测速度。

关键词：随机森林；投票权重；半投票量



Abstract

Random forests are a combined classifier, its main idea is to construct a multitude of decision trees based on two random processes (randomly sampling from training dataset and randomly extracting features). And the final predicted result is decided by the voting of all decision trees, which avoid over-fitting effectively. Moreover, the relative independence among each decision tree is suitable for parallel computing to improve the prediction efficiency of RF model and dealing with high dimensional datasets. All these Characteristics make RF been widely used in many engineering applications, and become a popular algorithm in machine learning and data mining.

Although the random sampling process solves over-fitting of RF model, differences exist in prediction ability among decision trees. In traditional RF, decision tree with different prediction ability have the same voting weight, which affected the stability of RF. For these reasons, this paper puts forward an optimized voting method to further improve the prediction ability of RF model. We distribute decision tree classifier's voting weight by its prediction ability and statistical characteristics of datasets. The accuracy and efficiency of the RF model are improved by weighted decision tree voting process.

In this paper, we studied the traditional RF algorithm first, mainly optimizing the voting process of RF. We propose some optimizing methods aiming at the problems existing in RF's voting process. The rationality and superiority of our optimizing methods are verified by experiments on several public datasets. The main work of this paper includes:

(1) We propose 4 methods to calculate decision tree classifiers' voting weights based on decision tree classifiers' prediction ability and statistical characteristics of datasets, including OOB evaluating, correlation coefficient of datasets, Chi-square and mutual information. We conduct experiments on 8 different datasets, the experimental results show that weighted voting process can improve prediction ability of RF.

(2) This paper presents a method named half-voting on weighted RF model. We first sorted all decision trees in descending order by their voting weights. And set the half-voting stop condition in RF's prediction process. This method is able to improve RF's prediction speed by triggering stop condition. We conduct experiments on 4



different datasets, the experimental results show that half-voting method can obviously improve the RF's prediction speed without affecting its accuracy.

Keywords: Random Forests; Voting Weight; Half-Voting



目 录

摘 要.....	I
Abstract.....	II
第 1 章 绪论.....	1
1.1 研究背景及意义.....	1
1.2 研究现状概述.....	2
1.3 本文的主要工作和组织架构.....	3
第 2 章 决策树算法和随机森林模型介绍.....	5
2.1 决策树算法.....	5
2.1.1 决策树算法概述.....	5
2.1.2 非叶子节点分类属性的选取.....	7
2.1.3 决策树的优化.....	10
2.2 随机森林算法.....	11
2.2.1 Bagging 算法介绍.....	12
2.2.2 随机森林算法描述.....	13
2.2.3 随机森林模型投票过程.....	14
2.3 随机森林的理论基础.....	15
2.4 随机森林的优缺点.....	18
2.4.1 随机森林的优点.....	18
2.4.2 随机森林的缺点.....	19
2.5 袋外数据估计.....	19
2.6 本章小结.....	20
第 3 章 基于加权决策树的随机森林.....	21
3.1 随机森林工作流程.....	22
3.2 元分类器评估依据.....	23
3.2.1 OOB 估计.....	23
3.2.2 相关系数 (Correlation coefficient)	24
3.2.3 卡方.....	26
3.2.4 互信息.....	27
3.3 算法描述和结果预测.....	29
3.3.1 基于决策树预测能力的权值计算.....	29



3.3.2 基于样本统计学指标的权值计算.....	30
3.3.3 实验预期效果.....	31
3.4 实验和结果分析.....	31
3.4.1 实验数据说明.....	31
3.4.2 实验参数说明.....	32
3.4.3 决策树棵树和模型预测准确率的关系.....	33
3.4.4 特征空间对模型预测能力的影响.....	38
3.5 本章小结.....	40
第 4 章 半投票量模式的随机森林.....	42
4.1 半投票量模式.....	42
4.2 半投票量算法描述.....	43
4.3 在投票加权算法中使用半投票量模式.....	46
4.4 实验数据说明.....	47
4.5 实验结果和分析.....	47
4.6 本章小结.....	50
第 5 章 总结和展望.....	51
5.1 算法优化总结.....	51
5.2 研究展望.....	51
参考文献.....	53
攻读硕士期间发表的论文.....	55
致 谢.....	56



第 1 章 绪论

1.1 研究背景及意义

2013 年被称为大数据的元年,标志着世界进入了大数据的时代,信息技术高速发展,各领域内的数据量呈现爆炸式增长,互联网的线上线下时刻产生着数以千万计条数据,据不完全的数据统计,每一分钟会有超过 50 个小时的视频被上传 Youtube 网站上,超过 2 亿条电子邮件信息在互联网上被发送,超过 2 百万次的 Google 搜索查询记录产生,不少于 30 万美元的交易额在互联网网购平台上进行,接近 3 万条 Tumblr 新帖发布,随着移动互联网的普及,使得数据增长的速度越来越快。

数据被认为是知识的来源,海量的数据中往往蕴藏着大量有价值的信息。正如沃尔玛通过分析用户购买商品的记录之后,发现男人们在购买婴儿纸尿裤之后,通常还会购买啤酒犒劳自己,于是对这两样商品进行捆绑营销,销售量双双增加,可见合理的数据分析,会从数据中获得巨大的价值信息。随着数据的大量增加,数据的维度同样也产生了极大的提高,海量、高维度的数据已经远远的超出了人类自身处理和分析数据的能力,为了能够更准确的挖掘海量数据中蕴含的各种各样有价值的知识和信息,如何借助于机器的力量来完成这些工作,就成为了科研工作者最重要的任务之一。与人类相比,计算机拥有着强大的计算能力,借助于计算机处理数据的能力,数据挖掘得以迅速的活跃起来,并成为 21 世纪最为前沿的研究领域之一。

数据挖掘的任务是从大量、实际数据中,通过数据分析提取到隐含的、有潜在价值的信息和知识的过程,数据挖掘常见的方向包括数据分类、回归、聚类等,而其中数据分类作为数据挖掘领域内最主要的方法之一,被应用到很多领域内,包括客户关系分类、垃圾邮件的识别、人脸表情识别等等,数据挖掘往往需要借助于数据统计学和机器学习的算法进行,使用的算法包括 k-近邻算法(k-NN)、决策树^[1-2](Decision Tree)、朴素贝叶斯^[3-4](Bayesian Classification)、Logistic 回归、人工神经网络^[5](Artificial Neural Networks, ANNs)、支持向量机^[6-7](Support Vector Machine, SVM)等等。

在众多的机器学习算法中,随机森林^[8](Random Forest, RF)是一种组合分类器,是由 Leo Breiman 于 2001 年提出,并以 Random Forest 作为商标进行注册,后



续也有很多科学家对随机森林的优化发展做出了很多的贡献。随机森林中包含了多棵决策树分类器，每棵决策树分类器的生成都是从全部训练数据集和特征集中通过随机取样、训练模型生成的弱分类器，随机森林数据分类的结果是由全部或者部分决策树综合投票决定的。本文针对随机森林投票过程对最终分类结果的影响进行研究，通过对随机森林的算法进行优化，提高了模型分类的准确率和预测速度。

随机森林作为一种组合分类器，可以进行分布式并行运算，拥有很多其他分类算法无法比拟的优点，但是仍然存在一些算法设计的不足。例如，随机森林在决策树生成的时候，并没有一种非常合理的方法来规定随机森林规模的大小，模型规模的过大或过小都会影响到模型最终的决策结果；另外，由于每棵决策树的生成所用到的数据集和特征集都是通过随机有放回的方法从总训练数据集和特征集中选取得到的，每棵决策树的优劣程度无法保证，而最后的投票结果是由全部或部分决策树的决策结果决定，这给模型分类的准确率带来了很大的不确定性，较差的决策树不仅降低了模型的泛化能力和预测准确率，而且增加了数据预测的时间。针对随机森林以上的不足，本文提出一种投票加权的决策树组成的随机森林模型，针对单棵决策树不同的泛化能力对决策树在投票过程中的决策权重进行计算，提高模型整体的预测准确率。在进一步优化过程中，我们对决策树预测能力进行排序，实时检测投票情况，加入随机森林模型预测流程终止条件，可以在所有决策树都参与预测投票过程之前结束整个预测流程，从而提高模型整体的预测速度。综上所述，本文的研究既可以提高随机森林模型决策的准确率，还可以在在一定程度上降低模型预测的时间。

1.2 研究现状概述

2001 年美国国家科学院院士 Leo Breiman，在总结了传统分类模型的精度不高且易出现过拟合等缺点，受到 Ho 关于随机子空间^[9-10]（Random subspace）方法的研究以及 Amit 和 Geman 定义的结点最优分割理论的启发，借鉴了组合分类器（classifier combination）的思想，并在贝尔实验室于 1995 年提出的随机决策森林（Random Decision Forests）的基础上，采用自助聚类（bootstrap aggregating）的方法，提出了随机森林分类模型。随机森林是一种非线性的组合分类器，采用随机有放回抽样的方式抽取训练样本和特征集，训练得到很多弱分类器，由大量弱分类器（决策树）组合成为随机森林分类器，通过投票的方式获得最终的预测结果。随机森林对噪声有很好的容忍性，避免了传统分类器容易出现过拟合的缺点，大量实验



证明 RF 有着不错的准确率, 尤其在处理大量、高维度数据的时候表现的尤为明显的优点。

随机森林作为一种组合式分类器算法, 包含很多树形分类器, 每个树形分类器都是一个弱分类器(决策树), 且各个决策树的训练和决策互不影响, 这就极大提高了整体模型的训练以及决策的速度, 而且很方便可以进行并行运算和多核运算。Sexton 和 Laake 使用随机森林模型^[11]预测了 RF 在大的数据集上的预测能力, 发现基于 bagging 算法^[12]构建的随机森林模型的预测能力更优; Coussement 等研究了 SVM, Logistic 模型和随机森林模型的预测能力^[13], 得到的结论是, 随机森林模型的预测能力始终优于 SVM 模型预测能力, 而加入了有参数选择器的 SVM 模型的预测能力则优于 Logistic 模型的预测能力。

随机森林由于其较高的预测准确率和不易过拟合的特点, 使得随机森林理论和应用得到了快速的发展, 在各行各业的预测算法中都用到了随机森林模型。Chen X W 和 Liu M 利用随机森林模型预测高维度的蛋白质域结构^[14], 达到了 79.78% 的准确率, 这比其他模型预测的最好准确率还要高; Diaz-Urizte 利用随机森林模型预测基因序列^[15], 同时使用 DLDA (Direct Linear Discriminant Analysis, 直接线性鉴别分析), KNN (ka-Nearest Neighbor, 邻近算法) 以及 SVM (Support Vector Machine, 支持向量机) 模型进行相同的预测, 发现随机森林预测效果具有明显的优点, 并称随机森林在基因预测方面为“standard tool-box”; Gislason P O 和 Benediktsson J A 等人利用随机森林模型以及其他常用的预测算法模型预测了遥感位置^[16], 发现了随机森林模型的预测准确率最高。

1.3 本文的主要工作和组织架构

随机森林模型为了解决大多数机器学习算法中容易出现过拟合等算法缺点, 使用两次随机过程, 分别对训练数据集和特征集进行抽样来构建单个决策树, 这使得构建得到的决策树的分类能力有差异。随机森林模型在数据预测的过程中, 是由所有这些分类能力有差异的决策树投票决定分类结果的, 本文针对随机森林在投票过程中表现的不足, 对原始的随机森林模型投票过程进行研究, 提出了一种决策树投票加权重的随机森林模型, 通过对比实验来验证算法的合理性和优越性。本文涉及到的主要工作和创新点:

第一, 研究了随机森林模型投票过程, 使用 4 种不同的方法来评估决策树的分类能力, 并依此作为决策树投票权值计算的方法进行投票权值计算, 在 8 个数据集



上进行实验,分析了4种投票权值计算方式构建的随机森林模型以及传统随机森林模型的预测准确率,并对4种投票权值计算方式做了比对;

第二,根据决策树的加权数值对决策树进行降序排列,确定随机森林模型停止投票的终止条件,在4个不同的数据集上进行数据预测,对比引入投票终止条件的随机森林模型和原随机森林模型的预测速度。

本文通过上面的算法改进,有效的提高了传统随机森林模型的预测准确率,并在不影响模型准确率的前提下明显的提高了模型预测的速度。

本文的章节安排:

第一章绪论主要介绍课题研究背景和研究意义,随机森林当前研究的现状以及随机森林模型的应用,本文的主要研究工作以及论文架构;

第二章决策树算法和随机森林模型介绍,介绍决策树算法,决策树生长规则,以及随机森林算法的原理和实现方法,从数学理论的角度分析了随机森林模型的优点;

第三章提出决策树加权的随机森林模型,引入了4种不同的决策树分类能力评估方法,包括OOB数据评估、卡方验证、相关系数和互信息,并以此计算单棵决策树的投票权重,并与传统随机森林模型进行对比实验,分析算法优化前后模型的预测准确率;

第四章根据前一章中对随机森林算法的优化,引入了一种新的投票模式--半投票数量模式,确定随机森林模型投票终止条件,设计对比实验验证优化之后的随机森林模型和传统随机森林模型在数据预测速度方面的优越性;

第五章总结和展望。总结上面两章中提出的算法优化,并针对算法优化过程中遇到的问题进一步提出可能的优化方向,依据随机森林模型的特点,提出一些相关的模型优化方法。



第2章 决策树算法和随机森林模型介绍

随机森林模型是由 Breiman 于 2001 年首次提出的,借鉴了 Ho 此前提出的随机子空间的定义, Amit 和 Geman 对最优分割理论的研究^[17], 以及贝尔实验室提出的随机决策树森林算法^[18], 采用自主聚类 (bootstrap aggregating) 的方法, 训练得到多个弱分类器, 综合每个弱分类器的投票情况给出最终的预测结果。随机森林作为一种组合分类器, 其基础分类器是没有进行剪枝操作的决策树。本章从决策树算法开始, 介绍随机森林的相关概念和模型工作原理。

2.1 决策树算法

决策树 (Decision Tree) 是一种树状的分类器^[19], 属于监督学习方式的一种, 它由根节点、内部节点和叶子节点组成。每一棵决策树只有一个根节点, 数据的预测和训练都是从根节点开始逐级向下延伸, 每一个非叶子节点上的数据都会按照当前节点的特征属性划分为两个或多个子数据集, 并分别交由下一级的节点处理, 数据到达叶子节点之后就不需要继续划分了, 数据所在的叶子节点就是本次分类预测的结果。决策树预测数据的过程实质上就是自上而下的^[20], 由每一级非叶子节点按照自己的特征属性划分规则进行数据分析并完成数据分类的过程。

决策树按照非叶子节点划分数据集判断标准的不同, 可以大致分为两类: 一类是基于信息熵的决策树, 比如 ID3、C4.5 决策树算法; 另一种是基于基尼指数 (Gini) 的决策树, 比如 CART^[21]决策树算法。

2.1.1 决策树算法概述

构建决策树的算法很多, 但基本都是使用自上而下的贪婪算法, 最终形成一个树状模型, 包含多个子节点, 子节点有两类: 非叶子节点和叶子节点。每个非叶子节点都是从当前特征集合中选择分类效果最好的特征元素作为当前节点的特征属性对数据集进行划分, 将数据集划分为 2 个或多个子数据集, 依照此方法反复对子数据集迭代, 直到达到决策树生长的停止条件, 则到达叶子节点, 叶子节点便是分类的结果, 叶子节点处不再对数据集进行划分, 到达叶子节点处便完成了数据分类。具体的步骤为:

(1) T 为特征集合, D 为训练数据集合;



(2) 选择一个划分训练数据集效果最好的特征 t ，并将特征 t 从特征集 T 中移除；

(3) 创建一个树节点，属性为上一步选择的特征 t ，将训练数据集划分为 2 个或多个子数据集，每个子数据集作为下一次迭代的训练数据集。

在步骤 (3) 中，划分得到子数据集，要是已经达到决策树停止生长的条件，则子数据集已经到达叶子节点，无需继续向下划分，而停止生长的条件有很多种，包括：

- ① 对应特征集 T 中的特征元素数量为零；
- ② 子数据集中数据量过少，已经低于数据集包含数据量的最小值；
- ③ 子数据集继续划分得到的信息增益量很小，或子数据集继续划分的熵值很小。

下面 2.1 给出了一个二分类决策树算法模型图：




图 2.1 二分类决策树算法模型图

在上面的算法模型图中，展示了一棵二分类的决策树，决策树从根节点开始向



下延伸，每一个非叶子节点上都会有一个不同的特征属性 t ，根据不同的特征属性制定不同的二分类划分条件，用来对输入数据进行分类，决策树通过数据属性划分最终将待预测数据划分到某一个叶子节点上，叶子节点带有分类属性标签 l ，表示当前数据的分类结果。

2.1.2 非叶子节点分类属性的选取

决策树生长的过程，实质上就是特征集合元素在决策树非叶子节点上分布排列的过程，决策树预测能力的优劣与特征集合元素的分布密切相关，如何将特征元素更合理的分布排列在一棵决策树的非叶子节点上就是决策树构建中最重要的部分，不同的决策树算法的区别也在于此，决策树节点特征属性的判断标准主要有：信息增益^[22] (information gain)、信息增益比^[23] (information gain ratio) 以及基尼指数^[24] (Gini Index) 等。

按照不同的节点属性划分标准，决策树算法主要有：ID3 决策树算法、C4.5 决策树算法以及 CART 决策树算法。

(1) ID3 决策树算法

ID3 算法^[25]中衡量特征属性对数据集的分类能力强弱的判断标准是信息增益 (information gain)。从信息论中我们知道，数据集划分之后的信息增益越大，数据集的熵值减少越多，数据集的纯度越高。ID3 算法使用信息增益作为非叶子节点特征属性划分的标准，在当前的特征集合中选择数据集划分之后信息增益最大的特征属性作为非叶子节点的特征属性来创建非叶子节点，依此方法进行递归运算构建子节点，满足叶子节点创建的条件，停止决策树的继续生长，完成一棵决策树模型的构建。ID3 算法中使用的特征选择标准是信息增益，信息增益的基础是熵 (entropy)，数据集 D 在划分之前的熵为：

$$Entrop(D) = \sum_{i=1}^c -p_i \log_2 p_i \quad (2.1)$$

其中， c 为数据集中子类别的数量， p_i 为第 i 个子类别在数据集 D 中出现的频率。

信息增益 $Gain(t)$ 被定义为数据集按照某一特征属性 t 进行划分，划分前后数据集熵值的差，就称为是信息增益。现设定 t 为特征集合 T 中的特征元素，现在按照特征 t 将样本数据集 D 划分为 $D_1, D_2, \dots, D_m$ 共 m 个子样本集。那么数据集 D 在按照特征 t 划分之后的信息增益可以表示为：



$$\text{Gain}(t) = \text{Entrop}(D) - \sum_{j=1}^m \frac{|D_j|}{|D|} \text{Entrop}(D_j) \quad (2.2)$$

其中 $|D_j|$ 为第 j 个子样本数据集样本个数， $|D|$ 为数据集中样本总个数。信息增益描述的是数据集按照某一特征属性进行划分前后，总样本的熵相对于划分之后得到的各个子样本数据集的加权熵的和（所有子样本熵的期望）之间的差值。

ID3 决策树算法将信息增益 $\text{Gain}(t)$ 作为特征属性选择的标准，递归的对每一个样本数据集计算按照当前特征集元素进行数据集划分之后的信息增益，选择信息增益最大的特征属性进行节点创建，直到达到决策树停止生长的条件，完成了一棵 ID3 决策树的构建。

(2) C4.5 决策树算法

与 ID3 算法不一样的，C4.5 算法中使用了信息增益比作为非叶子节点特征属性选择的判断标准，C4.5 使用的信息增益比中引入了拆分信息，数据集 D 按照特征 t 进行划分获得 m 个子数据集，数据集划分之后的拆分信息 $\text{split_info}(t)$ 定义为：

$$\text{split_info}(t) = - \sum_{i=1}^m \frac{|D_i|}{|D|} \times \log_2 \left(\frac{|D_i|}{|D|} \right) \quad (2.3)$$

其中 $|D_i|$ 为划分之后，第 i 个子数据集中的数据量， $|D|$ 为数据集划分前数据集的总数据量，拆分信息可以被看作是各个子样本数据等可能的熵的加权和，有了信息增益和拆分信息的定义，可以得到数据集按照特征 t 进行划分之后的信息增益比：

$$\text{GainRatio}(t) = \frac{\text{Gain}(t)}{\text{split_info}(t)} \quad (2.4)$$

C4.5 决策树算法中决策树的构建流程和 ID3 一样，只是每次从当前特征集中选择最优特征属性的判断标准是信息增益比，每次迭代的过程中都是从当前特征集中选择信息增益比最大的特征作为属性进行节点创建，直到到达决策树停止生长的条件完成整棵决策树的构建。

(3) CART 决策树算法

CART 决策树算法^[26]的全名为 Classification And Regression Tree，即分类回归树，CART 决策树既可以用来预测离散数值的分类问题，也可以预测连续数据的回归问题。与 ID3 算法和 C4.5 算法不同，CART 算法在每个非叶子节点上划分数据集的时候，无论当前特征属性在数据集中有几种类型，CART 算法总是将数据集分割为两部分，因此 CART 算法构建的决策树是二叉树模型。除此之外，CART 算法选



择最优特征属性的标准是基尼指数 (Gini Index)，对于样本数据集 D ，按照某特征属性 t 进行划分，划分之后的子样本数据集中包含 k 个类别的样本，那么子样本数据集的 Gini 指数：

$$Gini(t) = 1 - \sum_{i=1}^m p_i^2 \quad (2.5)$$

其中 p_i 表示第 i 个样本类别出现的概率，从上面的公式可以看出，Gini 指数的取值一定是大于零的。Gini(t)=0 表示分割之后数据集中的样本属于同一种类别，此时可以得到最大的信息量，数据集的熵最小；Gini 指数越小，表示数据集划分之后数据的纯度越高，熵越小，信息增益越大；反之 Gini 指数越大，表示数据集按照当前特征属性进行划分之后数据的纯度越低，熵越大，信息增益越小。

数据集 D 按照特征属性 t 进行划分，得到 m 个子数据集，分类之后得到的基尼指数为：

$$Gini(t) = \sum_{i=1}^m \frac{n_i}{n} Gini(i) \quad (2.6)$$

其中 n_i 为第 i 个子数据集的数据量， n 为总数据量，Gini(i) 为第 i 个子数据集的基尼指数。

在 CART 决策树算法构建模型的过程中，每次迭代寻找最优特征的过程都会通过计算每个特征 t 划分数据集获得的基尼指数 Gini(t)，找到使数据集分类之后 Gini(t) 最小的特征作为节点的特征属性创建新的节点，直到到达决策树停止生长的条件完成整棵决策树的构建。

需要说明的是，由于 CART 决策树算法构建的是二叉树分类器，对于特征集容量大于 2 的情况，需要构建多个二取值序列^[27]，计算每个二取值序列划分样本数据集对应的 GiniGain，取 GiniGain 最小的分类特征属性创建新的节点。

决策树作为一种树形分类器，是数据挖掘领域内常用的一种分类器，相比于大多数其他数据挖掘的算法，决策树算法更加易于理解，可视化程度高，实现比较容易，在较短的时间内可以较快的处理大量的数据，除此之外决策树算法对数据集预处理的要求比较低，对缺失数据的敏感度相对较低，决策树算法在处理特征不相关的数据集时表现的较好，无需假设先验概率分布，使得决策树模型表现的更为灵活，且算法的鲁棒性较好；在使用决策树算法的时候也发现一些缺点，对于特征相关度较高的数据集，决策树表现的不是很好，往往容易出现过拟合的现象，为了解决这种问题，对决策树构建的模型进行一定的剪枝操作就显得非常必要。



2.1.3 决策树的优化

决策树算法因为上一节中描述的多种特点，受到数据挖掘领域的广泛应用，但是决策树也有一些缺点需要解决，比如在决策树构建的过程中，往往会出现决策树和训练样本数据集出现过拟合（Overfitting）的现象，影响决策树预测数据的能力，为了避免过拟合现象的发生，就需要对决策树进行适当的剪枝操作，以此提高决策树模型的泛化能力，决策树的剪枝有两种方式：一种是预剪枝（Pre-Prune），另外一种一种是后剪枝（Post-Prune）。

预剪枝（Pre-Prune）是防止决策树在构建的过程中就生长成为“完全”树，需要在决策树节点创建的时候就加入一些适当的终止条件，判断将要创建的节点是否满足停止条件，满足则不在创建新的节点；后剪枝（Post-Prune）是将一棵生长“完全”的决策树输入，按照启发式搜索算法，尝试将决策树的某些子树转变为叶子节点，由此改变模型过拟合的情况，增加决策树的泛化能力，并将剪枝之后的模型返回。

对决策树进行剪枝的方法有很多种，常用的剪枝方法包括：错误率降低剪枝算法（Reduced-Error-Pruning, REP），悲观剪枝算法（Pessimistic-Error-Pruning, PEP），代价复杂度剪枝算法（Cost-Complexity-Pruning, CCP）等等。错误率降低剪枝算法会计算某一节点在剪枝前后预测的错误率是否有下降，如果在剪枝前后决策树模型整体的错误率下降的程度没有超过设定的阈值，那么就认为该子树是可以被剪枝的；悲观剪枝算法会计算剪枝前后模型对相同的数据集进行数据预测引起的泛化误差，要是剪枝后模型预测的误差小于剪枝前模型预测的误差，那么认为本次剪枝是必要的，通过剪枝可以提高模型的精度；代价复杂度剪枝算法进行决策树剪枝的标准是节点表面误差率的增益值，代价复杂度剪枝算法会计算每个非叶子节点的表面误差率增益值，选择那个表面误差率增益值最小的节点子树进行剪枝操作，假如计算发现多个节点表面误差率增益值一样小的非叶子节点，那么就选择子节点数量最多的非叶子节点进行剪枝操作。

在实际构建决策树的过程中，对决策树模型进行优化的方式除了进行合理的剪枝之外，还可以对训练数据集进行预处理，判断原始数据集各个特征与标签之间的相关性，进行适度的特征选择，适当的选择其中一部分特征数据进行决策树的构建，这样可能会获得泛化能力更强的决策树模型。



2.2 随机森林算法

单棵决策树模型在构建的时候,很容易受到训练数据集的影响出现过拟合的情况,为了避免过拟合的情况需要对决策树进行必要的剪枝操作,而过度的剪枝又会降低决策树的预测能力。除此之外,由于决策树在构建的过程中迭代进行特征属性选择的时候都是采用了局部贪婪法,每次从当前的特征集合中选择最优的特征进行新节点的创建,不会对模型进行回溯检测,容易造成局部最优解,使得最终获得的预测模型收敛于局部最优解。

基于以上的这些缺点, Breiman 在贝尔实验室于 1995 年提出的随机决策森林算法^[29]的基础上,综合了 Bagging 集成算法和 CART 决策树算法之后于 2001 年提出了一种新的机器学习算法模型-随机森林(Random Forest, RF),随机森林算法是一种组合分类器算法,在随机森林模型内部包含多个 CART 决策树,每一棵决策树都是通过两个随机过程进行构建的,即按照 bagging 算法随机从训练样本数据集中抽取训练样本,并从特征集中随机抽样获得特征集,利用随机抽取获得的训练样本集和特征集进行决策树模型的构建,构建得到多棵决策树组成整个随机森林模型,随机森林模型在进行数据预测的时候是利用所有决策树进行预测并通过投票的方式决定模型最终的预测结果。

下图为一个随机森林模型构建的流程图:




图 2.2 随机森林模型构建的流程图

2.2.1 Bagging 算法介绍

Breiman 在 1996 年提出了 Bagging 算法, Bagging 算法是一种重采样技术, 通过重采样技术获得训练数据集, 用来训练构建得到一个组合分类器, 提升模型整体的泛化能力。

给定一个训练样本数据集和一种元学习算法, Bagging 算法通过自主抽样法 (Bootstrap Sampling), 每次从全部训练样本中随机有放回的抽样得到一个子训练样本数据集, 子训练样本的数据量小于总样本量, 使用随机抽样得到的训练样本进行元学习算法模型训练, 得到一个元分类器, 这样循环进行多轮训练样本抽取并训练构建获得多个元分类器, 将这些元分类器组合在一起得到组合分类器。在数据预测的时候, 多个元分类器对相同的待预测数据进行相对独立的预测, 并通过投票的方式决定组合分类器最终的预测结果。实验证明, 组合分类器的泛化能力往往比单一分类器的泛化能力要强, 表现出更好的数据预测能力, 除此之外组合分类器相比于单一的分类器, 前者更不容易出现过拟合的现象。



组合分类器相比于单一的决策树分类器有着更好的泛化能力,决策树在构建的时候容易受到训练样本数据集的影响,对训练数据集本身的特性依赖程度较高,当训练样本数据的相关程度过高时,会使得决策树模型出现过拟合的情况,泛化能力下降,且随着数据集分类类别的增加会导致决策树分类器较大的错误率。组合分类器在训练的时候,首先将训练样本进行随机抽样获得很多个子样本集,这样就可以在一定程度上增加数据集的差异性,从而提高分类器整体的泛化能力,降低组合分类器整体对训练数据集的敏感度。

Breiman 通过在不同的元学习算法上引入 Bagging 算法进行预测之后发现, Bagging 算法并不是一定能够提高组合分类器整体的预测能力,这还取决于元学习算法自身的稳定性。对于不稳定的元学习算法引入 Bagging 算法构建得到的组合分类器可以表现出较好的数据预测能力,但是对于稳定的元学习算法, Bagging 算法对组合模型的预测准确率的贡献不是很明显,甚至有可能降低元学习算法模型的预测准确率。

进一步的实验证明,分类回归树、神经网络、线性回归模型属于不稳定的学习算法,这些学习算法构建的分类器和预测准确率对训练样本数据集的敏感度大,不同的训练样本构建产生的分类器的预测准确率可能存在较大的差别,使用这一类算法构建得到的组合分类器相比于原分类器有着更好的分类预测能力。Breiman 还指出,不稳定的学习算法构建的分类器的偏差比较小,构建得到的分类器预测准确率的方差比较大,针对于这样的学习算法, Bagging 算法可以有效的减小模型方差,从而提高整体预测模型的泛化能力和预测准确率;而如 k-近邻算法属于稳定的学习算法,对稳定的学习算法引入 Bagging 算法构建得到的组合分类器的预测准确率并不会有很明显的提高,甚至有降低的情况。

2.2.2 随机森林算法描述

随机森林(Random Forest, RF)是一种组合分类器,所使用的元分类器是 CART 决策树, CART 决策树算法属于不稳定学习算法,因此引入 Bagging 算法对训练样本集合进行多次随机的自主抽样,训练获得单个决策树分类器,从而构建组合模型,这样可以有效的提高模型整体的泛化能力,增加模型预测的准确率。

随机森林算法的描述是,随机森林是包含多个树形分类器的集合,形如:

$$\{h(x, \theta_i), i = 1, 2, 3, \dots\}$$

其中 $h(x, \theta_i)$ 为构成模型的元分类器,这里使用的是 CART 算法构建的没有经过



剪枝操作的分类回归树， x 表示随机森林构建的训练数据集，是一个多维的向量集合， θ_i 为一个独立同分布的随机向量集合，是从 x 中使用 Bagging 算法随机的抽取的数据向量集合， θ_i 决定了对应决策树的分类能力。在随机森林模型进行预测的时候，对于分类问题随机森林模型常用的处理方法是，每个元分类器对相同的待预测数据进行单独的预测，统计每个元分类器投票的情况，将获得投票数量最多的类别作为预测结果，而对于回归问题，模型常用的预测方法是对所有元分类器的预测结果求平均值作为最终的预测结果。

随机森林算法的元分类器是 CART 决策树，CART 决策树算法构建决策树的时候，使用全部的训练样本，通过迭代构建整棵决策树，每次迭代都是从特征集中选择一个数据分类之后 Gini 指数最小的特征作为属性创建新的节点，创建的节点满足停止条件时完成决策树的构建，否则就从剩余的特征集中选择下一个最优的节点进行节点创建，直到构建出一棵“完全”决策树模型，然后对“完全”决策树进行剪枝操作提高其泛化能力和预测准确率。随机森林使用 CART 决策树作为元分类器，但与单纯的 CART 决策树构建有所不同：

(1) 子训练样本数据集的随机选取：随机森林在构建 CART 决策树之前，使用 Bagging 算法随机有放回的从总训练样本中抽取一定数量的训练样本作为一棵决策树模型构建的训练样本集合；

(2) 子特征集的随机选取：与子训练样本数据集一样，随机森林构建单一 CART 决策树的时候不是使用全部的特征集进行决策树的构建，而是随机的在总特征集中进行抽样，获得一个子特征集作为元分类器的属性选择集合；

(3) 决策树构建：经过上面两个随机抽样的过程之后，便获得了一个 CART 决策树构建的训练样本集和特征集合，随机森林构建的 CART 决策树一般不进行剪枝操作，让决策树自由生长。

上述步骤通过多轮迭代之后就完成了随机森林模型的构建：

$$\{h(x, \theta_i), i = 1, 2, 3, \dots\}$$

2.2.3 随机森林模型投票过程

组合分类器数据预测的最终结果是有每一个元分类器决定的，随机森林模型采用元分类器投票的方式给出最终的预测结果，针对分类和回归问题随机森林使用不同的投票机制。

一般情况，对于回归问题，随机森林通过统计每个决策树的预测结果，然后采



用求平均值的方式,求得所有决策树预测结果的平均值,将这个平均值输出作为最终的预测结果;对于分类问题的预测,随机森林使用最多的投票方式是众数投票法,即统计每种分类标签收到的决策树投票的票数,将投票数量最多的分类标签作为最终的预测结果输出。比如人脸表情识别中预测的标签总数是 6,输入一个未知的人脸表情数据,随机森林中的每一棵决策树模型针对这个表情数据进行独立的预测并给出预测结果,随机森林在统计了所有投票结果之后,将投票数量最多的人脸表情标签作为最终的预测结果输出。在给出最终的预测结果的同时,随机森林还可以通过统计每种表情投票的情况,给出预测结果是某种表情的概率。

随机森林模型 $\{h_1(x), h_2(x), \dots, h_m(x)\}$ 的预测分类标签有 n 种,那么该随机森林模型进行数据预测的算法流程为:




图 2.3 随机森林模型数据预测流程图

2.3 随机森林的理论基础

随机森林算法相比于大多数机器学习算法来说结构简单、容易理解,却有着无可比拟的高预测准确率以及不易出现过拟合的特征,下面通过对随机森林的数学理论基础的阐述来介绍模型不会出现过拟合情况和高预测准确率的原因。



(1) 模型的收敛性保证随机森林不会出现过拟合
随机森林模型可以被描述为一个这样的组合分类器：

$$\{h_1(x), h_2(x), \dots, h_k(x)\}$$

是由 k ($k > 1$) 个子分类器组成的分类器集合，输入预测向量 x 得到预测输出结果为 y ，对于样本数据集 (x, y) 定义边界函数为：

$$\text{margin}(x, y) = \text{av}_k I(h_k(x) = y) - \max_{j \neq y} \text{av}_k I(h_k(x) = j) \quad (2.7)$$

上面的函数式中， $I(\text{func})$ 为示性函数，在满足 func 描述条件的时候示性函数取 1，否则取 0， $\text{av}_k(*)$ 表示对集合求平均值^[30]。边界函数计算了组合分类器对某一样本向量进行预测，预测正确的平均票数以及预测错误的情况下最大的投票数量，并求这两个指标的差值。显然边界函数的数值越大，表明分类器集合的预测能力越强，置信度越高。

组合分类器的泛化误差的定义为：

$$\text{PE}^* = P_{x,y}(\text{margin}(x, y) < 0) \quad (2.8)$$

我们希望组合分类器的边界函数的值越大越好，这样表明分类器集合的泛化能力强、预测能力高，但是也会出现组合分类器中预测错误的元分类器的个数大于预测正确的元分类器个数的情况，即 $\text{margin}(x,y) < 0$ 的情况，在这种情况下组合分类器会给出错误的预测结果，泛化误差表示的是组合分类器进行数据预测获得的 $\text{margin}(x,y) < 0$ 的概率，即组合分类器进行数据预测的错误率。

Breiman 通过 Borel 的大数定理证明了，当决策树的数量增加的时候，泛化误差 PE^* 满足一个收敛定理，即当随机森林模型的元分类器的个数趋向于正无穷大时，模型对应的泛化误差满足下面的收敛关系：

$$\text{PE}^* \xrightarrow{k \rightarrow \infty} P_{x,y}(P_\theta(h(x, \theta) = Y) - \max_{j \neq Y} P_\theta(h(x, \theta) = j) < 0) \quad (2.9)$$

其中 θ 为单个分类器对应的随机向量。

上面的证明说明了，当随机森林模型的元分类器的数量足够多时，模型整体的泛化误差是一个固定的数值，不会出现过拟合的情况。

(2) 单棵决策树的分类能力和相关性

从上面的分析可以知道，组合分类器的泛化能力主要受到两个因素的影响，一个是单一的元分类器的分类能力，另一个是元分类器之间的相关度。研究随机森林这两个影响因子可以更好的优化组合分类器整体的预测能力。



随机森林的边界函数被描述为:

$$m_r(x, y) = P_\theta(h(x, \theta) = y) - \max_{j=y} P_\theta(h(x, \theta) = j) \quad (2.10)$$

随机森林 $\{h_1(x, \theta), h_2(x, \theta), \dots, h_k(x, \theta)\}$ 的分类效能被定义为:

$$S = E_{x,y} m_r(x, y) \quad (2.11)$$

由切比雪夫 (Chebyshev) 定理可以得到当 $S \geq 0$ 时:

$$PE^* \leq \text{var}(m_r) / S^2 \quad (2.12)$$

上式中 $\text{var}(m_r)$ 是对随机森林的边界函数求方差。下面首先设定

$$\hat{j}(x, y) = \arg_{\max} P_\theta(h(x, \theta) = j) \quad (2.13)$$

那么随机森林的边界函数可以写成是:

$$m_r(x, y) = P_\theta(h(x, \theta) = y) - P_\theta(h(x, \theta) = \hat{j}(x, y)) \quad (2.14)$$

我们知道 $P_\theta(h(x, \theta) = y)$ 表示元分类器集合预测样本数据 (x, y) 的正确的概率, 引入期望 $E(*)$ 和示性函数 $I(*)$ 后, 随机森林的边界函数可以写成为:

$$m_r(x, y) = E_\theta[I(h(x, \theta) = y) - I(h(x, \theta) = \hat{j}(x, y))] \quad (2.15)$$

定义随机森林的原质函数为 $rm_g(\theta, x, y)$, 其表达式为:

$$rm_g(\theta, x, y) = I(h(x, \theta) = y) - I(h(x, \theta) = \hat{j}(x, y)) \quad (2.16)$$

对比随机森林的边界函数和原质函数可以发现, 边界函数 $m_r(x, y)$ 为原质函数 $rm_g(\theta, x, y)$ 在 θ 上的数学期望。

根据函数求导法则有恒等式:

$$\forall f, [E_\theta f(\theta)]^2 = E_\theta f(\theta) E_{\theta'} f(\theta') = E_{\theta\theta'} f(\theta) f(\theta') \quad (2.17)$$

根据上面的恒等式, 对随机森林的边界函数有:

$$m_r^2(x, y) = [E_\theta rm_g(\theta, x, y)]^2 = E_{\theta\theta'} rm_g(\theta, x, y) rm_g(\theta', x, y) \quad (2.18)$$

因此随机森林的边界函数的方差 $\text{var}(m_r)$ 也可以写成:

$$\text{var}(m_r) = E_{\theta\theta'} \text{cov}_{x,y}[rm_g(\theta, x, y), rm_g(\theta', x, y)] \quad (2.19)$$

令 $\rho(\theta, \theta') = rm_g(\theta, x, y) / rm_g(\theta', x, y)$, 成为原质函数的相关系数, $sd(\theta)$ 为原质函数 $rm_g(\theta, x, y)$ 的偏差水平, 于是方差 $\text{var}(m_r)$ 简写为:



$$\text{var}(m_r) = \bar{\rho}^2 (E_{\theta} \text{sd}(\theta)) \leq \bar{\rho} (E_{\theta} \text{var}(\theta)) \quad (2.20)$$

其中 $\bar{\rho}$ 为相关系数 ρ 的平均值:

$$\bar{\rho} = E_{\theta\theta'} \rho(\theta, \theta') \text{sd}(\theta) \text{sd}(\theta') / E_{\theta\theta'} \text{sd}(\theta) \text{sd}(\theta') \quad (2.21)$$

由于方差的数学期望值满足:

$$E_{\theta} \text{var}(\theta) \leq E_{\theta}^2 (E_{x,y} r m_g(\theta, x, y)) - s^2 \leq 1 - s^2 \quad (2.22)$$

因此可以得到随机森林的泛化误差 PE^* 满足不等式:

$$PE^* \leq \bar{\rho} (1 - s^2) / s^2 \quad (2.23)$$

从上面的不等式中我们可以看到, 随机森林模型的泛化误差的上限由元分类器之间的平均相关度 $\bar{\rho}$ 和系数 s 共同决定, 减小元分类器之间的相关度可以降低模型的泛化误差, 同时系数 s 正比于模型的原质函数, 原质函数标示一棵决策树的预测能力, 也就是说, 增加决策树的预测能力同样可以减小模型整体的泛化误差。

2.4 随机森林的优缺点

2.4.1 随机森林的优点

随机森林模型作为一种组合分类器, 包含多个 CART 决策树, 与其他的数据挖掘算法相比有自己的优点:

(1) 泛化能力强, 不易出现过拟合。随机森林采用了 Bagging 算法结合 CART 决策树进行构建, 两个随机过程-随机有放回的抽样训练样本数据集, 随机的抽取特征集, 进行元分类器的训练, 这样增加了数据集之间的差异性, 降低了数据之间的相关性, 增强了模型整体的泛化能力, 不易出现单决策树模型发生的过拟合现象;

(2) 在高维度的数据集上的效果较好, 随机森林在处理高维度数据的时候表现的效果很好, 不需要额外的进行特征评估和特征选取;

(3) 随机森林适合做并行处理, 随机森林中包含多棵互不相关的决策树, 每棵决策树的构建以及数据预测是互不影响的, 这样就可以对整个随机森林模型的构建以及结果预测进行任务拆分, 从而大大的缩短模型运算的时间, 这是其他学习算法无法比拟的;



(4) 实现简单, 算法效率高, 准确度高, 随机森林是一种组合分类器, 基础分类器为决策树, 这使得随机森林模型相比于其他算法模型易于构建、易于理解, 大量的实验证明, 随机森林模型相比其他的预测模型有较高的预测准确率;

(5) 在大数据集上处理的效果较好, 当数据集中出现数据缺失的时候, 模型仍然可以保证比较高、比较稳定的预测效果, 对数据集中噪声的敏感程度比较低。

(6) 随机森林模型可以给出单个特征的重要性, 这为评估每个参与预测的特征属性的贡献度提供了依据, 便于对随机森林模型进行算法优化。

2.4.2 随机森林的缺点

随机森林是一种组合分类器, 相比于其他单分类器而言, 随机森林模型的组合特征让模型整体的泛化能力提高, 泛化误差降低, 不容易出现过拟合的情况, 从而提高了模型整体的预测能力, 但是随机森林并不是始终表现出较高的预测准确性, 模型整体的预测能力受到元分类器的影响。元分类器对随机森林模型的影响主要包括:

(1) 决策树之间的相关性: 由于随机森林的元分类器 (CART 决策树) 是通过训练样本集和特征集进行随机有放回的自主抽样得到的, 那么抽样次数较少的情况下, 就有可能出现某些数据向量以及某些特征被多次抽取, 而某些数据向量和某些特征很少被抽中, 这样训练得到的分类器集合中就会出现某些决策树之间的相关性过大, 从而降低了模型整体的泛化能力, 影响了模型的预测能力;

(2) 单棵决策树模型的预测能力: 我们知道随机森林模型在预测数据时, 首先是所有的决策树对相同的待预测数据进行独立的预测, 然后在同等的状态下统计所有决策树的预测结果, 进而给出最终的预测结果, 而模型的元分类器中决策树的预测能力是有差别的, 较强的分类器会增加模型整体的预测效果, 而较弱的分类器可能会增加模型的泛化误差, 降低模型整体的预测准确率。

2.5 袋外数据估计

在随机森林模型构建的过程中, 每棵决策树构建时使用的训练样本数据集都是通过 Bagging 算法, 通过步步为营的方法 (Bootstrapping) 随机有放回的抽取得到的。一般情况下, 会抽取总训练样本集合中大约 67% 的样本进行决策树的构建, 被抽中的数据称为袋内数据, 而未被抽中的数据被称为袋外数据^[31] (Out-Of-Bag,



OOB)。

在上一节中,我们已经知道随机森林模型采用 Bagging 算法为元分类器随机抽取训练样本从而进行决策树的构建,这样可以有效的降低模型整体的泛化误差,使得随机森林模型不会出现过拟合的情况,提高模型整体的预测能力。对于单棵决策树,它的袋外数据虽然没有参与决策树的构建,但却也有重要的作用。

袋外数据最重要的作用有两个,一个是可以利用袋外数据计算单棵决策树的泛化误差,另一个是利用袋外数据可以计算得到单个特征的重要性。

(1) 单个决策树的泛化误差:1996 年 Tibshirani 就提出了利用袋外数据(OOB)来评估单个分类器的泛化误差,并给出了利用袋外数据进行误差评估的分类器示例; Wolpert 和 Macready 在比对了通过交叉验证法评估组合分类器的泛化误差,以及利用袋外数据进行组合分类器的泛化误差评估之后,发现两者之间的预测结果近似相等,但是利用袋外数据进行泛化误差评估可以在每棵决策树构建的时候同时进行计算,只需要对少量的数据进行运算便可以得到结果,这比交叉验证计算组合分类器的泛化误差的效率要高。

(2) 单个特征的重要性评估:随机森林模型的一大特点就是可以进行单个特征重要性的评估,对数据集中单个特征重要性的评估可以作为特征对随机森林模型的预测能力的贡献度的判断标准,进一步可以尝试去除掉一些贡献度小,乃至是贡献度为负的特征,以此降低模型的泛化误差,提高模型的预测能力。单个特征的重要性的度量很简单,是利用启发式思维,人为的在袋外数据中引入噪声,分别计算噪声引入前后随机森林模型预测的准确率,并将这两个准确率的差作为对应特征属性重要性的度量,这个数值越大说明该特征的重要性越高,相反要是这个度量值越小说明该特征对模型整体准确率的影响比较小。

2.6 本章小结

本章介绍了随机森林的元分类器--决策树的原理,主要介绍了三种决策树模型:ID3, C4.5 和 CART,并分析了三种决策树属性选择的差异,针对决策树算法的特点介绍了决策树优化的方法。接着介绍了随机森林模型,分析了随机森林不会出现过拟合的理论基础,给出了随机森林进行结果预测时分类器集合进行投票的流程,最后总结了随机森林的优缺点,提出了影响随机森林泛化误差的主要原因,为下一章中对随机森林进行优化做准备。



第3章 基于加权决策树的随机森林

随机森林模型利用两个随机过程（元分类器训练数据集随机抽样和元分类器特征随机抽样），有效的解决分类器出现过拟合的情况，相比于其他的分类器随机森林采用组合分类器的方式，很大程度的降低了模型泛化误差，使得模型的预测能力得到很大的提高。在上一节中，我们已经分析到影响随机森林模型预测准确率的两个主要因素，一个是元分类器之间的相关性，另外一个为单个分类器的分类能力。随机森林采用两个随机过程极大的提高模型整体的性能，但也由于元分类器构建过程中的随机性，使得构建得到的元分类器的分类能力得不到一定的保证，分类能力不同的元分类器组合在一起构成完整的随机森林模型，共同参与模型数据预测的过程，分类能力不同的元分类器在预测结果决策的过程中起着同样重要的作用，这样就会对最终的预测结果有不合理的影响。基于此，本章提出了一种基于加权决策树的随机森林预测模型，根据元分类器本身分类能力的强弱计算权重，使得元分类器在模型整体决策过程中占有不同权重的投票份量。

Hussein M 等提出了 Reduced-RF 模型^[23]，并评估单棵决策树的预测准确率，根据单棵决策树的预测准确率对所有决策树分类器进行升序排序，并按照排序后元分类器的次序计算每棵决策树分类器的加权值，随机森林模型中每棵决策树分类器的加权值只与该分类器模型在升序队列中的下标有关。在投票阶段，队列中的决策树依次投票，要是某一种分类结果投票数量达到阈值，则停止投票给出模型决策结果，反之则等待全部决策树投票完成再确定模型预测的结果。Reduced-RF 模型按照决策树预测准确率的高低进行排序并计算决策树投票的权值，为预测准确率高的决策树分类器赋予更高的预测权值，按顺序进行投票，在投票结果达到阈值时可以提前结束预测过程，减少模型预测的时间。Hussein M 提出的 Red-RF 利用具有不同预测准确率的决策树分类器进行数据预测，达到了更合理的投票效果，并且在一定程度上降低了预测所需要的时间。但是在 Hussein M 提出的新的随机森林模型投票模式中，单棵决策树分类器的投票权重是按照决策树分类器在升序排序队列中的排列顺序计算的，且只与决策树分类器在排序序列中的下标有关，这样并不能非常合理的反应每棵决策树之间预测能力的差异，存在一定的不合理的地方。

基于上述的原因，本章按照决策树的分类性能的强弱，对构建好的随机森林模型引入权值计算方法，根据单一决策树不同的分类性能计算不同的投票权值，优化模型投票的过程。本章对元分类器权值分配采用了两种不同的策略，一种是利用袋



外数据来评估决策树的预测准确率，另外一种通过计算训练样本数据集的统计特性，包括相关系数、卡方、互信息，为每个特征属性计算特征重要度，从而根据不同决策树在构建时使用的不同特征集合为对应的决策树计算出对应的权值。本章将详细介绍这两种权值加权后的随机森林模型，并与优化之前的随机森林模型进行预测准确率对比，验证算法的优越性。

3.1 随机森林工作流程

随机森林是组合分类器，由多个元分类器组成，每个元分类器之间相对独立，模型结果预测的过程就是每个元分类器分别进行结果预测并给出所有决策树投票情况统计结果的过程，对于组合分类器 $\{h_1(x), h_2(x), \dots, h_k(x)\}$ ，有输入向量 x ，模型工作流程如下图 3.1 所示：




图 3.1 随机森林模型工作流程图

当输入数据为 x ，每个元分类器相对独立的对 x 进行结果预测，随机森林模型获得所有元分类器的预测结果之后，通过设定的统计规则给出模型整体的预测结果。一般的，对于分类问题，元分类器给出的预测结果为指定的某一种分类结果，随机森林对所有分类结果进行统计，给出投票数量最多的那一个分类作为最终的预测结果；而对于回归问题，随机森林一般是通过计算所有元分类给出的预测结果的平均数，作为最终的预测结果。

在第二章中，我们知道随机森林在构建元分类器的过程中采用随机有放回的抽样方式，为每个决策树模型抽取训练数据集和特征集，从而构建得到不同的决策树



模型,由于抽样的随机性,导致构建得到的决策树模型的预测能力具有一定的差异,在传统随机森林算法中这些具有不同预测能力的决策树具有相同的投票权值(通常为单位1),这种投票机制存在着一定的不合理性,如何通过决策树的相关指标来分配决策树投票的权值,从而提高模型整体的预测准确率,就是加权随机森林模型最主要的研究方向。

3.2 元分类器评估依据

在进行元分类器预测能力的评估中,使用多种评估依据,包括袋外预测准确率、相关系数、卡方、互信息,这些评估标准可以大致分为两种:

(1) 利用袋外数据评估决策树的预测能力,这种评估方法是针对决策树整体的预测能力而言的,而不去关心决策树构建的过程;

(2) 决策树预测能力的评估依据是基于样本特征的,我们知道随机森林模型的元分类器是 CART 决策树, CART 决策树进行节点选择的标准是 Gini 指数,在每次创建非叶子节点的时候,选择数据集分类前后 Gini 指数最小的特征作为节点特征属性创建新的节点, Gini 指数最小的特征在数据分类的时候可以获得最大的信息量,说明该特征对模型预测的贡献度最大,基于这样的原因,我们首先利用训练样本数据对各个特征进行重要性评估,然后对包含不同特征的决策树进行特征重要性叠加,将叠加结果作为单棵决策树的投票权值,而对特征重要性的分析可以采用相关系数、卡方、互信息。

3.2.1 OOB 估计

在第二章可以知道,随机森林为了降低模型整体的泛化误差,将 Bagging 方法应用到随机森林元分类器训练样本的抽取上,随机有放回的抽取训练样本中的部分样本作为单棵决策树训练的样本集,未被抽中的数据集被称为袋外数据(Out-Of-Bag, OOB),利用袋外数据对决策树进行的预测能力的评估就成为 OOB 估计。在随机森林模型构建的过程中,决策树的构建与决策树 OOB 估计可以串行的完成,在随机森林模型完成构建的同时,每棵决策树就获得了一个对应的 OOB 评估数值,以此分配对应决策树的权值,对于决策树 $h(x)$,定义它的投票加权值为 p_{OOB} ,表示为:

$$p_{OOB} = \alpha \times \frac{S_+}{S} \quad (3.1)$$



其中 S_+ 为决策树利用 OOB 数据进行数据预测, 预测正确的样本数量, S 表示参与决策树进行 OOB 评估的样本总量, α 为调参因子。

利用 OOB 来评估决策树的泛化误差以及预测准确率, 要比使用交叉验证的方法来评估决策树和随机森林的泛化误差需要更少的计算量, 利用 OOB 作为决策树泛化误差评估标准的可行性已经被 Breiman 所证实, 使用 OOB 评估决策树的泛化误差非常近似于交叉验证得到的计算结果。

在实验中, 我们训练得到随机森林模型 $\{h_1(x), h_2(x), \dots, h_k(x)\}$, 并同时获得每棵决策树的 OOB 预测准确率 $\{p_1, p_2, \dots, p_k\}$, 那么最终模型的预测结果可以表示为:

$$\max\{c \mid c_i = \sum_{j=1}^k p_{OOB_j} I(h_j(x) = l_i), l_i \in C, j = 1, 2, 3, \dots, k\} \quad (3.2)$$

其中 C 为所有类别标签的集合, l_i 为集合 C 中第 i 个分类标签, $I(h(x)=l_i)$ 为示性函数, 当决策树 $h(x)$ 的预测结果为类别标签 l_i 的时候示性函数等于 1, 否则等于 0, p_j 为第 j 个决策树在投票过程中的加权值, c_i 为第 i 个类别标签获得的投票加权结果, 模型最终预测结果为各个分类标签获得的加权投票总数中最大的那一个分类标签。

3.2.2 相关系数

为了解决相关表和相关图无法确切的表示两个变量之间的相关度, 且不能够作为判断两个变量之间相关性度量的标准的情况, 由卡尔·皮尔逊提出了相关系数 (Correlation coefficient) 这一统计学指标, 作为两个变量之间线性相关性判断的依据, 相关系数是判断变量之间相关度的重要指标之一, 也是被使用最多的统计学指标, 根据被描述变量的不同特征, 相关系数也有多种定义方式, 包括线性相关系数、非线性相关系数以及复线性相关系数。

在计算两个变量之间的相关系数的时候, 会首先计算单个变量与各自均值之间的差值, 使用两个差值的乘积作为相关系数的计算基础, 两个变量 x 和 y , 分别有统计数据集合 $x\{x_1, x_2, \dots, x_k\}$ 和 $y\{y_1, y_2, \dots, y_k\}$, 那么变量 x 与 y 之间的相关系数 r 可以表示为:

$$r = \frac{\sum_{i=1}^k (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^k (x_i - \bar{x})^2 \sum_{i=1}^k (y_i - \bar{y})^2}} \quad (3.3)$$

上式中 $\bar{x}$ 和 $\bar{y}$ 分别是变量 x 和 y 的统计数据的平均值。



值得注意的是相关系数的数值分布在-1 到+1 的范围内, 即 $|r| \leq 1$ 。当 $r > 0$ 时表示两个变量正相关, 反之当 $r < 0$ 时表示两个变量呈现出负相关性, 当变量相关系数 $|r| = 1$ 的时候, 表示两个变量呈现出绝对的相关性, 当 $r = 0$ 的时候说明两个变量之间不存在相关性。

虽然相关系数与相关表、相关图等统计指标相比可以更加准确的度量两个变量之间的相关性, 在统计学领域内受到广泛的使用, 但是相关系数也存在着一一定的缺陷, 相关系数的稳定性会受样本数据总量 k 的影响比较大, 一个极端的例子是, 当样本总量为2的时候, 相关系数 $|r| = 1$, 在样本总量 k 比较小的情况下相关系数的稳定性比较差, 相关系数可能随着样本数量的变化出现较大的波动。

在实验中, 我们首先构建得到一个完整的随机森林模型, 计算得到每个特征变量与类别标签之间的相关系数, 作为特征权重的分配依据, 因为相关系数的取值在-1 到+1 之间, 当相关系数小于零时, 只是说明两个变量呈现出负相关性, 一个变量的改变对另一个变量的影响仍然是存在的, 因此在利用特征的相关系数计算特征权重的时候应该对相关系数求绝对值, 利用相关系数的绝对值进行对应特征权重的计算。

对于 n 维度特征集合 $\{t_1, t_2, \dots, t_n\}$, 使用训练样本数据集计算得到对应的相关系数集合 $\{r_1, r_2, \dots, r_n\}$, 使用该特征集和该训练数据集构建得到随机森林模型 $\{h_1(x), h_2(x), \dots, h_k(x)\}$, 对于决策树 $h(x)$ 定义投票加权值:

$$p_r = \alpha \sum_{j=1}^m |r_j| \quad (3.4)$$

上式中对构建决策树 $h(x)$ 的所有特征相关系数的绝对值进行求和, 其中 α 为调参因子, m 为构建该决策树使用到的特征数量, 因为相关系数本身数值比较小, 加入调参因子适当调节决策树的投票加权数值。

随机森林模型 $\{h_1(x), h_2(x), \dots, h_k(x)\}$ 拥有加权重值 $\{p_1, p_2, \dots, p_k\}$, 对于任意输入向量 x , 模型预测的结果表示为:

$$\max\{c \mid c_i = \sum_{j=1}^k p_{r_j} I(h_j(x) = l), l \in C\} \quad (3.5)$$

其中 C 为所有分类标签的集合, p_{r_i} 为第 i 棵决策树分类器的投票权值, $I(*)$ 为示性函数, 上式中统计各个分类标签加权投票的数量, 并将加权投票数量最大的分类标签作为最终的预测结果输出。



3.2.3 卡方

卡方 (Chi-square) 是统计学中使用比较频繁的一种假设检验的指标, 卡方的主要作用是比较两个或多个样本量之间的相关性, 通过比较待分析样本的理论频数和实际频数之间的吻合度来给出变量之间的关联性。

卡方分析的过程中会首先假设两个变量之间是相互独立互不相关的, 统计两个变量的分布情况, 如果假设成立计算得到变量的理论分布情况, 比较实际分布和理论分布之间的差异, 如果差值越大说明原假设和实际分布相差越大, 差值越小表明原假设和实际分布相差越小。这种分布的差异在统计学中使用卡方来表示, 如果卡方变量的数值越小, 卡方检验的结果越不明显, 则越不能拒绝原假设, 那么认为两个变量之间相互独立, 关联性越小; 反之, 如果卡方变量的数值越大, 卡方检验的效果越显著, 则可以拒绝原假设, 认为两个变量之间的相关性越大。

卡方统计量的计算可以用下面的公式来解释:

$$\chi^2 = \sum \frac{(A - T)^2}{T} \quad (3.6)$$

上面的表达式中, A 表示变量的实际分布频数, T 表示该变量的理论分布频数。

卡方检验可以对两个变量进行相关度分析, 卡方统计量数值越大表示两个变量之间的相关度越高, 反之两个变量相关度越低, 一个变量发生变化的时候对另外一个变量的影响越小。

基于卡方检验以上的特征, 我们使用训练样本对样本中的每一个特征属性和类别标签之间进行卡方检验, 计算得到每一个属性特征和类别标签之间的卡方统计量, 作为每个属性特征和类别标签之间的相关度度量依据, 这个数值越大表示属性特征和类别标签之间的相关性越大, 当属性特征发生改变的时候对类别标签的影响越大, 反之类别标签受到特征属性变化的影响越小, 当一个属性特征和类别标签的相关度越高, 那么这个属性特征就应该被赋予越高的重要性评估数值, 在进行决策树构建的过程中, 参与决策树构建的特征的重要性评估数值的加和结果越大, 则表示该决策树的分类能力越强, 决策树具有越强的泛化能力和预测能力。

在具体操作中, 首先通过传统随机森林算法训练、构建得到一个随机森林模型, 通过卡方检验的方法得到每个特征的卡方统计数值, 再根据每棵决策树在构建过程中参与其构建的特征集合, 对该特征集合中每个特征的卡方数值进行加和处理, 求得的数值作为该决策树的投票权值。

从第二章中我们得知, 特征重要性评估数值越大的特征属性在数据集合分类前



后可以更好的降低熵，从而得到更大的信息增益，那么一棵决策树在构建的过程中包含的特征属性的重要性评估数值加和结果越大，这棵决策树的返还管理和分类能力也是越好的，因此上面的操作可以作为决策树投票权值的计算方法。

训练样本具有 n 维特征 $\{t_1, t_2, \dots, t_n\}$ ，首先对 n 维特征进行卡方验证，计算得到每个特征的卡方数值 $\{\chi_1^2, \chi_2^2, \dots, \chi_n^2\}$ ，使用该训练样本集构建的随机森林模型可以表示为 $\{h_1(x), h_2(x), \dots, h_k(x)\}$ ，决策树 $h(x)$ 的投票权值可以定义为：

$$p_c = \alpha \sum_{j=1}^n \chi_j^2 \quad (3.7)$$

上式中通过对参与决策树 $h(x)$ 构建的所有特征的卡方数值进行加和，作为决策树的投票权重， χ_j 为该决策树构建使用的特征集中第 j 个特征的卡方数值， α 为投票参数的调参因子。

使用已经构建得到的随机森林模型 $\{h_1(x), h_2(x), \dots, h_k(x)\}$ 预测数据 x 的分类结果为：

$$\max\{c \mid c_i = \sum_{j=1}^k p_{c_j} I(h_j(x) = l), l \in C\} \quad (3.8)$$

其中 C 为所有分类标签的集合， $I(*)$ 为示性函数， $I(h(x)=l)$ 在决策树预测结果为 l 的时候取值为 1，反之取值为 0。上面的表达式中统计了投票过程中各个分类标签投票的加权结果，将获得加权投票量最多的分类标签作为最终的预测结果输出。

3.2.4 互信息

互信息 (Mutual Information) 是信息论中用来标识两个变量之间相关性强弱的一种度量方法，互信息反映了在给定一个随机变量 x 之后，另外一个随机变量 y 的不确定性的减小程度，或者说随机变量 y 在随机变量 x 出现之后带来的信息量的增加。互信息取值的最小值为 0，表示随机变量 x 的出现并没有为变量 y 带来任何的信息量，此时随机变量 x 与随机变量 y 之间没有任何关系，两个变量之间不会有相互影响；互信息的最大值为随机变量 y 的熵，表示随机变量 x 的出现可以完全消除变量 y 的不确定性。

已知两个随机变量 X 与 Y ，那么这两个变量的互信息被定义为：

$$I(X; Y) = \iint_{x,y} P(X, Y) \log \frac{P(X, Y)}{P(X)P(Y)} \quad (3.9)$$



其中 $P(X,Y)$ 表示变量 X 和变量 Y 的联合分布, $P(X)$ 和 $P(Y)$ 分别是变量 X 和变量 Y 的边际分布。变量 Y 的不确定性是由变量 Y 的熵来描述的, 变量 Y 的熵 $H(Y)$ 可以被描述为:

$$H(Y) = -\int_Y P(Y) \log P(Y) \quad (3.10)$$

有积分定理可以将互信息 $I(X;Y)$ 改写为:

$$I(X;Y) = H(Y) - H(Y|X) \quad (3.11)$$

上面的表达式中, $H(Y)$ 表示变量 Y 的熵, 当变量 Y 分布的离散程度越高, Y 的熵 $H(Y)$ 越大, $H(Y|X)$ 表示已知变量 X 的情况下 Y 的熵的大小。由上面随机变量 X 与随机变量 Y 互信息的表达式可以知道:

- (1) 互信息 $I(X;Y)$ 的值大于或等于 0;
- (2) 当 $H(Y|X)=0$, 即随机变量 X 的引入使得随机变量 Y 的不确定性变为 0, 此时互信息 $I(X;Y)$ 取到最大值为变量 Y 的熵 $H(Y)$;
- (3) 当随机变量 X 和随机变量 Y 相互独立的时候, 互信息 $I(X;Y)=0$ 。

互信息反映了两个变量之间的关联性的强弱, 可以作为判定某一特征与分类标签之间相关性评估的依据。在实际操作中, 有训练样本集合 $\{x_1, x_2, \dots, x_n | y\}$ 计算得到互信息为 $\{I_i = I(x_i; y), i=1, 2, \dots, n\}$, 使用该训练样本进行随机森林模型的构建, 得到的分类器为 $\{h_1(x), h_2(x), \dots, h_k(x)\}$, 对于决策树 $h(x)$ 计算得到权重:

$$p_l = \alpha \sum_{j=1}^n I(x_j; y) \quad (3.12)$$

上面的表达式中, 通过加和的方式将参与决策树 $h(x)$ 构建的所有特征的互信息进行加和处理, 作为决策树投票权重计算的方法, $I(x_j; y)$ 为该决策树构建特征集中第 j 个特征的互信息, α 为调参因子。

引入加权投票的随机森林模型 $\{h_1(x), h_2(x), \dots, h_k(x)\}$, 投票的结果表示为:

$$\max\{c | c_i = \sum_k p_{1_i} I(h_j(x) = l), l \in C\} \quad (3.13)$$

其中 C 为所有分类标签的集合, p_l 为单棵决策树的互信息投票权重, 上面的表达式统计了一次数据预测中所有分类标签获得的加权投票量, 并将拥有最多投票量的分类标签作为最终的预测结果输出。



3.3 算法描述和结果预测

上面使用 4 种统计方法（OOB 估计、卡方、相关系数和互信息）分别计算组合分类器中元分类器的投票权重，利用引入投票加权机制的随机森林模型对数据进行预测，与传统随机森林模型的预测准确率进行对比。本文使用 Python 实现全部的算法流程，借助于 scikit-learn 机器学习库实现算法模型的构建和模型预测准确率的计算。算法实现的过程中构建一套随机森林模型，对比引入投票权重和不引入投票权重时，模型整体的预测准确率，实验流程图如下：




图 3.2 投票加权的算法流程

上面的 4 种统计方法按照算法流程的不同大概可以分为两种：基于决策树预测能力的权值计算和基于特征统计学特性的权值计算，其中 OOB 估计属于前者，利用卡方、相关系数和互信息这些统计特性的方法属于后者，不同的算法流程实现过程不完全相同。

3.3.1 基于决策树预测能力的权值计算

基于决策树预测能力的大小来计算决策树在投票过程中的投票权值，首先要利用数据集对训练得到的随机森林模型中每一棵决策树进行泛化能力的评估，可以使用数据交叉验证，但是这样会带来很大的计算量，已由 Breiman 验证利用袋外数据(OOB)进行决策树泛化能力的评估结果是特别接近使用数据交叉验证得到的结果的。这里为了减小计算量，使用 OOB 评估计算得到决策树的数据预测能力。



算法描述——随机森林(基于 OOB 估计的投票权值计算)

Input: D 训练数据集

T 特征集合

s 每棵决策树构建分配的特征个数

k 随机森林包含的决策树的棵树

RF 随机森林模型

Output: 加投票权重的 RF 模型

算法:

For $i = 1$ to k :

- 1) 利用 Bagging 算法将数据集 D 分为袋内数据和袋外数据;
 - 2) 从特征集 T 中随机选择 s 个特征;
 - 3) 构建单棵决策树;
 - 4) 使用袋外数据(OOB)评估决策树的泛化能力, 依次分配权重;
 - 5) 将带权重的决策树加入到随机森林模型 RF 中。
-

3.3.2 基于样本统计学指标的权值计算

随机森林模型是由多棵决策树分类器构成的, 决策树的构建是通过非叶子节点的创建, 而非叶子节点的创建是以特征属性对数据集进行计算前后信息量的增加为依据的, 数据相关性较好的特征在数据集计算前后可以带来更多的信息量, 使得决策树有更强的泛化能力。基于此, 我们计算得到训练数据集中各个特征属性与分类标签之间的相关度, 作为决策树泛化能力的判定依据, 并依此计算决策树分类器的投票权值, 本文中使用了三种统计方法, 分别是卡方、相关系数和互信息。

算法描述——随机森林(基于特征统计学指标的权值计算)

Input: D 训练数据集

T 特征集合

s 每棵决策树构建分配的特征个数

k 随机森林包含的决策树的棵树

RF 随机森林模型



Output: 加投票权重的 RF 模型

算法:

计算特征的卡方/相关系数/互信息, 得到特征统计指标集合 Q

根据统计指标集合 Q 为每一个特征分配权值

For $i = 1$ to k :

- 1) 利用 Bagging 算法获取决策树的训练数据集;
 - 2) 从特征集 T 中随机选择 s 个特征, 根据这 s 个特征计算得到决策树的投票权值;
 - 3) 构建单棵决策树;
 - 4) 将带权重的决策树加入到随机森林模型 RF 中。
-

3.3.3 实验预期效果

我们通过对决策树分类器预测能力的评估以及特征的评估来为每棵决策树分类器计算投票权值, 希望可以增强随机森林模型整体的泛化能力, 提高模型的数据预测准确率。下面设计了实验, 通过在 8 个数据集上的预测, 对比了传统随机森林模型和投票加权重的随机森林模型在不同的数据集, 不同决策树棵树的情况下模型预测的准确率, 依此说明投票权重引入的有效性, 并对比 4 种投票权重计算情况下, 对模型预测准确率的影响。

3.4 实验和结果分析

在这一节中, 我们将使用 8 个数据集来验证投票加权随机森林模型的合理性与优越性, 使用相同情况下构建得到的随机森林模型分别引入 OOB 加权方式、相关系数加权方式、卡方加权方式和互信息加权方式, 在 8 种不同的数据集上进行模型预测准确率的验证, 并与传统随机森林模型的预测准确率进行对比。在下面的实验中使用 Python 完成算法实现, 并借助与 scikit-learn 工具包进行模型构建。

3.4.1 实验数据说明

在本文的实验中, 使用了 8 个数据集, 其中 6 个数据集 (dermatology, ecoli, glass,



pima_indians_diabetes,wine,iris) 来自于 UCI^[18]提供的公用数据集, 另外 2 个数据集 (study_data,vision_data) 来自于我们实验室采集的数据集, 各个数据集的数据情况如下:

表 3.1 数据集说明

Datasets	Instances	Attrib.	Classes	Train/Test
study_data	710	7	4	4:1
vision_data	561	9	3	4:1
dermatology	366	34	6	4:1
ecoli	336	7	8	4:1
glass	213	9	7	4:1
pima_indians_diabetes	768	8	2	4:1
wine	178	13	3	4:1
iris	150	4	3	4:1

3.4.2 实验参数说明

为了将投票加权重的随机森林算法与传统随机森林算法进行对比, 实验中使用 4 种权重计算方法, 统计了随机森林模型包含的决策树的棵树在 2-100 之间时, 算法改进前后的预测准确率, 并统计了决策树在 100 棵时, 投票加权重的随机森林算法与传统随机森林算法在不同数量的不同特征空间上的预测准确率。

(1) 不同数据集

实验使用了 8 种数据集, 其中包含 UCI 提供的 6 个公共数据集, 对比、分析传统随机森林算法和投票加权重的随机森林算法在这 8 个数据集上的预测准确率;

(2) 决策树个数

实验中统计了投票权值加入前后, 模型中决策树个数在 2-100 棵之间变化的时候, 模型的预测准确率;

(3) 投票权重计算方法

实验中分别对不同的投票权重计算方法下构建的决策树模型的预测准确率进行统计, 并与传统随机森林模型进行对比, 来说明投票权重计算的合理性;

(4) 运行次数

实验中在具有相同的数据集、决策树棵树以及相同的投票权值计算方法的前提



下，重复构建 10 次模型，输出模型预测准确率平均值和最大值。

3.4.3 决策树棵树和模型预测准确率的关系

下面的实验中，分别在上面 8 个样本数据集上构建决策树规模在 2-100 之间的随机森林模型，给出传统随机森林模型的预测准确率，以及引入 4 种投票权值计算的随机森林模型的预测准确率，算法在运行的过程中会重复构建 10 次模型，得到 10 次预测准确率的平均值，并将每个数据集上运行得到的 5 条模型预测准确率曲线绘制出来：




图 3.3 在 8 个数据集上对 4 种权值计算方法下模型包含不同个数的决策树时的预测准确率




图 3.4 在 8 个数据集上对 4 种权值计算方法下模型包含不同个数的决策树时的预测准确率




图 3.5 在 8 个数据集上对 4 种权值计算方法下模型包含不同个数的决策树时的预测准确率




图 3.6 在 8 个数据集上对 4 种权值计算方法下模型包含不同个数的决策树时的预测准确率

从上面的统计图中可以看出，在 8 个数据集上，使用投票加权的随机森林模型的预测准确率都要比传统随机森林模型的预测准确率要高，说明通过评估单棵决策树分类能力的大小来计算决策树在随机森林模型数据预测过程中的权值的方法是合理的，通过引入投票权重之后，可以提高随机森林模型整体的泛化能力。

相同的随机森林模型，使用四种投票权重计算方式得到的模型都要比传统随机森林模型的泛化能力强，但四种不同投票权重对应的随机森林模型的预测能力也有不同，从上面的实验结果可以看到，大部分情况下使用相关系数评估特征属性以及决策树分类器权值的方法得到的模型准确率相对较高，使用 OOB 来评估决策树投票权重的方法得到的模型预测准确率波动较大，这是因为特征集的随机抽取使得单次训练得到的决策树的泛化能力可能出现较大的差异，在决策树个数较小的情况下表现出的泛化能力相对较弱，随着决策树个数的不断增加，因为特征集随机抽取而导致的决策树泛化能力差异较大的情况得以相互抵消，使用 OOB 评估决策树投票



权重的模型的泛化能力相对较强,另外当样本数据集分布较好,模型整体泛化能力较强的时候,使用 OOB 评估决策树权重的模型的泛化能力表现的比其他权值计算方式下的随机森林模型的泛化能力要强一些。

上面的统计图中给出了模型预测准确率的平均值,下面以表格的方式给出 8 个数据集在随机森林模型的规模在 10,20,....,100 棵决策树的时候,传统随机森林模型预测准确率以及 4 种不同权值计算的模型预测准确率的最大值进行比较,我们将包含有相同数量的决策树分类器、不同投票方式的维度上最高的预测准确率使用黑体加粗标出:

表 3.2 study_data 数据集上模型预测准确率的最大值对比

n_trees	Original	OOB	Chi-square	Cor-coefficient	Mut-Info
10	0.53118	0.58644	0.57966	0.59661	0.57966
20	0.58711	0.62881	0.63050	0.63050	0.63389
30	0.63949	0.68118	0.68610	0.69796	0.69118
40	0.62954	0.67584	0.68476	0.68084	0.68254
50	0.60615	0.68915	0.69237	0.70576	0.69845
60	0.61491	0.68491	0.68822	0.69033	0.68861
70	0.59203	0.68203	0.68033	0.69101	0.68033
80	0.60932	0.70932	0.71101	0.69906	0.70932
90	0.63976	0.70559	0.69745	0.70389	0.69915
100	0.62389	0.69915	0.68728	0.69915	0.68559

表 3.3 vision_data 数据集上模型预测准确率的最大值对比

n_trees	Original	OOB	Chi-square	Cor-coefficient	Mut-Info
10	0.41261	0.41081	0.45225	0.44504	0.44504
20	0.63963	0.68288	0.69189	0.69288	0.68288
30	0.70450	0.72351	0.73171	0.74711	0.73990
40	0.68747	0.72828	0.76270	0.76189	0.75288
50	0.67873	0.69954	0.76135	0.76036	0.76396
60	0.68846	0.71549	0.76450	0.76810	0.74630
70	0.70612	0.74935	0.76414	0.76693	0.74135
80	0.70891	0.73972	0.76333	0.76072	0.76511
90	0.69990	0.76881	0.76792	0.75891	0.74711
100	0.69054	0.76814	0.75153	0.75513	0.76432



表 3.4 dermatology 数据集上模型预测准确率的最大值对比

n_trees	Original	OOB	Chi-square	Cor-coefficient	Mut-Info
10	0.63352	0.65577	0.66197	0.64507	0.68169
20	0.86760	0.83140	0.85352	0.87995	0.87887
30	0.90140	0.90154	0.94267	0.93704	0.93704
40	0.92957	0.93366	0.96521	0.96539	0.95394
50	0.92957	0.92014	0.95957	0.95957	0.96239
60	0.91830	0.93112	0.95957	0.96239	0.95267
70	0.92211	0.91549	0.95521	0.96056	0.95802
80	0.92112	0.90295	0.94267	0.93704	0.94267
90	0.93211	0.97084	0.96492	0.97084	0.96774
100	0.92929	0.90985	0.96929	0.97774	0.95929

表 3.5 ecoli 数据集上模型预测准确率的最大值对比

n_trees	Original	OOB	Chi-square	Cor-coefficient	Mut-Info
10	0.52238	0.55671	0.58328	0.59850	0.54328
20	0.68373	0.72776	0.73149	0.73567	0.73656
30	0.69298	0.71343	0.72955	0.73373	0.72343
40	0.68582	0.72388	0.74447	0.73268	0.74746
50	0.69656	0.72820	0.74731	0.73537	0.74328
60	0.69358	0.71701	0.75537	0.74134	0.72537
70	0.67477	0.74477	0.75149	0.72552	0.71044
80	0.69552	0.72298	0.76417	0.74835	0.75820
90	0.70761	0.73805	0.76134	0.77044	0.76029
100	0.71074	0.75970	0.74835	0.75358	0.74940

表 3.6 glass 数据集上模型预测准确率的最大值对比

n_trees	Original	OOB	Chi-square	Cor-coefficient	Mut-Info
10	0.47282	0.49743	0.50769	0.50230	0.49230
20	0.67179	0.66667	0.68205	0.68717	0.69230
30	0.70846	0.72923	0.72307	0.73333	0.74358
40	0.71794	0.72410	0.74153	0.76179	0.74282
50	0.74358	0.74974	0.73743	0.77307	0.73846
60	0.74948	0.74974	0.75358	0.75897	0.77435
70	0.73333	0.75461	0.74333	0.74358	0.75384
80	0.73384	0.76934	0.77871	0.78897	0.77410
90	0.73333	0.77487	0.77846	0.79333	0.77871



100	0.75025	0.82487	0.81435	0.82487	0.81025
-----	---------	----------------	---------	----------------	---------

表 3.7 pima_indians_diabetes 数据集上模型预测准确率的最大值对比

n_trees	Original	OOB	Chi-square	Cor-coefficient	Mut-Info
10	0.62882	0.62352	0.63267	0.63790	0.63790
20	0.70065	0.71241	0.69019	0.71764	0.71764
30	0.68889	0.69281	0.70849	0.70457	0.70980
40	0.70196	0.71326	0.71588	0.71849	0.71718
50	0.69019	0.69758	0.71196	0.71065	0.71588
60	0.69797	0.72104	0.72843	0.72718	0.72803
70	0.68235	0.71366	0.74503	0.75326	0.71411
80	0.68843	0.72104	0.72758	0.73934	0.73542
90	0.69019	0.71934	0.72764	0.74594	0.73895
100	0.69150	0.74411	0.74895	0.75026	0.73849

表 3.8 wine 数据集上模型预测准确率的最大值对比

n_trees	Original	OOB	Chi-square	Cor-coefficient	Mut-Info
10	0.71764	0.27647	0.72941	0.71176	0.76470
20	0.92294	0.93529	0.94823	0.92941	0.95294
30	0.94117	0.99411	0.95411	0.96529	0.95529
40	0.95058	0.99411	0.95529	0.96882	0.97058
50	0.94411	0.99411	0.93529	0.98823	0.98235
60	0.94235	0.99524	0.96588	0.98235	0.98235
70	0.93411	1.00000	0.96588	0.99411	0.99411
80	0.93058	0.99812	0.94705	0.97058	0.97058
90	0.96823	0.99628	0.96117	0.98823	0.98823
100	0.94235	1.00000	0.97470	0.97058	0.98235

表 3.9 iris 数据集上模型预测准确率的最大值对比

n_trees	Original	OOB	Chi-square	Cor-coefficient	Mut-Info
10	0.48965	0.49310	0.58620	0.58620	0.58620
20	0.93793	0.9500	0.95172	0.95772	0.95172
30	0.91034	0.96551	0.95724	0.97724	0.95724
40	0.94482	0.94931	0.94482	0.95172	0.95172
50	0.93551	0.93448	0.95862	0.95862	0.95862
60	0.91724	0.93862	0.93793	0.94482	0.95172
70	0.95862	0.97655	0.97172	0.97982	0.97482



80	0.96241	0.99724	0.97862	0.97241	0.97241
90	0.93103	0.91379	0.93793	0.95992	0.95172
100	0.95862	0.96512	0.97162	0.97551	0.96551

上面的表格记录了传统随机森林模型和引入 4 种投票权值的随机森林模型预测准确率的最大值，我们使用加粗的方式标注了具有相同个决策树分类器的随机森林模型、在不同投票方式下预测准确率的最大值，可以发现引入投票加权的模型的准确率要比传统随机森林模型的要高，这说明相同的随机森林模型在引入投票权重之后，模型整体的泛化能力被提高了，说明通过引入投票加权的方式来改进传统随机森林算法的思想是合理的。

除此之外，我们发现更多的最大值分布在使用相关系数进行决策树分类器投票权值计算的方式上，这和前面使用平均值进行 5 种投票方式比较的情况一致，使用相关系数来评估特征属性和分类标签之间的关系，为特征属性进行重要性评估，从而给出对应决策树投票权值的方式可以更好的增加模型整体的泛化能力，使得模型整体的预测准确率更高。

另外，我们也发现使用袋外数据进行决策树投票权值计算的方式，在决策树数量较少的情况下模型整体的预测准确率没有另外三种投票权值计算方式下模型预测准确率高，随着决策树规模的增加，使用 OOB 进行投票权值计算得到的模型的预测准确率开始接近或超过其他三种投票方式模型的准确率。另外当样本数据集本身特征较好的时候，使用 OOB 进行投票权值计算的随机森林模型表现出比引入其他 3 种投票方式的随机森林模型的准确率都要好。

从上面的数据分析我们可以得知，对于一般的数据集，使用相关系数进行决策树投票权值计算的随机森林模型表现出更好的预测能力，可以进一步提高随机森林模型整体的数据预测能力，对于数据样本特征属性表现很好的数据集，可以使用 OOB 评估决策树的投票权值，可能会得到更好的预测准确率。

3.4.4 特征空间对模型预测能力的影响

上一节的实验中通过计算包含不同个数决策树分类器的随机森林模型，在引入不同投票权值计算方式前后的数据预测能力，实验证明随机森林模型在包含不同个数的决策树分类器的情况下，通过引入投票权重的方法是合理的，可以提高随机森林模型整体的预测能力。除了模型包含的决策树的个数会影响模型整体预测能力，训练样本数据本身对 4 种方法计算之后的投票权值的影响是不得不被考虑的，相同



的数据集使用不同的特征空间计算得到的投票权值是不相同的，下面通过实验来探索不同特征空间对随机森林模型整体的泛化能力的影响。

下面的实验中，我们采用决策树个数为 100，参与模型构建的特征从 2 个开始逐渐增加并抽取获得不同的特征空间，在不同的特征空间上构建随机森林模型并进行决策树投票权值的计算，在 8 个数据集上分别计算 4 种投票权值计算的随机森林模型和传统随机森林模型的预测准确率，在每一个特征空间上算法重复构建 10 次模型获得预测准确率的最大值并进行曲线绘制。




图 3.7 在 8 个数据集上对 4 种权值计算方法下模型在不同特征空间的预测准确率




图 3.8 在 8 个数据集上对 4 种权值计算方法下模型在不同特征空间的预测准确率




图 3.9 在 8 个数据集上对 4 种权值计算方法下模型在不同特征空间的预测准确率




图 3.10 在 8 个数据集上对 4 种权值计算方法下模型在不同特征空间的预测准确率

上面的实验分析了传统随机森林模型和引入 4 种投票权值之后的随机森林模型在不同特征空间上预测能力的变化，采用随机抽取不同个数的特征组成新的特征集合进行模型的构建，从上面的实验结果可以看到，在不同的特征集上，引入投票加权的随机森林模型有着更好的预测准确率。

3.5 本章小结

本章针对传统随机森林算法中投票不合理的情况引入了投票加权算法，使用了 4 种计算投票权值的方式来重构随机森林模型，在 8 个数据集（6 个 UCI 公共数据集）上进行算法验证，通过对比算法优化前后模型在不同决策树个数时的预测准确率，以及在不同特征空间上的预测准确率，说明了引入投票权重算法的合理性和优越性，实验证明投票权值的引入可以增加模型整体的预测能力，提高模型的预测准



确率；除此之外，我们还从 4 种投票权值计算的方式的实验数据中分析得到各种统计量进行投票权值计算的特点。



第4章 半投票量模式的随机森林

随机森林模型是一种组合分类器，组合分类器是由多个相对独立、互不影响元分类器构成的，相比于单一的分类器，组合分类器有一个特有的优势，那就是可以进行并行运算，从而提高模型构建和数据预测的效率，实验也证明随机森林模型在处理大数据量和高维度数据时表现出更高的预测准确率和更快的预测速度。

随机森林模型在构建过程中由于训练样本的随机抽取，使得模型整体不会出现过拟合的问题，从而不需要对模型进行剪枝处理，模型会使用所有的特征进行模型构建，这也是之前实验中使用 OOB 评估决策树投票权值的模型出现预测准确率波动较大的原因，在本章中会进一步研究随机森林模型投票的方式，在不影响模型整体预测准确率的前提下，提出一种可以加快模型预测速度的方法。

在传统随机森林模型预测的过程中，模型一般是使用所有的分类器对一条数据进行预测投票，在所有决策树完成数据预测和投票过程之后，模型统计投票结果并给出预测结果，针对这种全投票的方式，本文为了提高随机森林模型的预测速度，提出一种半投票量的方法，只通过部分决策树的加权投票就可以获得与全投票方法一样的结果，因为只是使用部分决策树进行投票，模型预测的速度要比全投票方式快。

4.1 半投票量模式

第三章中针对传统随机森林模型中不同预测能力的决策树具有相同投票权值的情况进行了改进，通过对决策树泛化能力的评估引入投票权重，使具有不同泛化能力的决策树在模型数据预测的过程中具有不同的投票权重，实验证明在不同的条件下，引入投票权重的随机森林模型具有更好的预测能力。第三章的实验中对决策树投票权重计算引入了4种不同的评估方法，与传统随机森林模型相比较，4种评估方法得到的模型预测能力都有明显的提高，其中使用相关系数进行决策树投票权值评估的方法在4种投票权值计算的方法中表现出最稳定、最高的预测准确性。

随机森林模型是一种组合分类器，是由很多相对独立、互不影响的决策树分类器组成的，随机森林在进行数据预测的时候，每棵决策树独立的对这条输入数据进行结果预测，给出自己的预测分类，并对对应的分类标签进行投票，由随机森林模型统计每一棵决策树的投票结果，计算得到每种分类标签获得的投票情况，将获得



投票最多的分类标签作为模型整体的预测结果输出。

对一个 n 分类的随机森林模型，在投票过程中每个分类标签获得投票的可能性是一样的，模型最终的结果取决于那个获得投票最多的分类标签，传统随机森林模型中会让所有的决策树对一个预测数据进行相互独立预测并对分类结果进行投票，最终给出投票数量最多的那一个分类标签作为模型的预测结果。本文中对这种投票模式进行改进，引入半投票量的模式，目的是为了不影响随机森林算法准确率的前提下，提高模型预测的速度。

为了更好的说明算法的思想流程，首先定义一些概念：

1) 全投票量 S ：传统随机森林模型中所有的决策树对同一个分类标签进行投票，该分类标签获得的总投票量，对于没有引入投票权值的随机森林模型来说，总投票量就等于组合模型包含的决策树的棵树，总投票量可以用下面的表达式表示：

$$S = \sum_{i=1}^k p_i \quad (4.1)$$

其中 k 为组合分类器包含的决策树的个数， p_i 为随机森林模型中第 i 棵决策树的投票权重，在传统随机森林模型中所有决策树的 p_i 为 1，传统随机森林模型的总投票就等于模型包含的决策树的个数。

2) 半投票量 S_h ：全投票量 S 的一半被定义为半投票量，半投票量 S_h 的表达式为：

$$S_h = S / 2 \quad (4.2)$$

4.2 半投票量算法描述

随机森林模型在进行半投票量模式的过程中，模型在逐个调用单棵决策树进行结果预测和加权投票的同时，模型会检测各个分类标签当前的投票结果，如果某一分类标签获得的投票数量已经达到了全投票量的一半，那么就终止后续决策树预测和投票，将这个分类标签作为模型最终的预测结果输出。具体可以描述为：

算法描述——半投票量模式的随机森林

Input: RF 随机森林模型，包含 k 个决策树， $\{h_i(x), i=1, 2, \dots, k\}$



d 待预测数据

L 分类标签集合, $\{label_j, j=1, 2, \dots, n\}$, n 分类模型

sum 模型的全投票量

Output: label 预测结果

算法描述:

1. 设定分类标签投票结果统计集合 $\{c_{ij}, j=1, 2, \dots, n\}$, c_j 为第 j 个分类标签获得的投票数量

2. For i in k:

1) 调用 $h_i(x)=label_j$ 对数据 d 进行预测, 并对分类标签 $label_j$ 进行投票, 更新投票结果统计集合 $\{c_{ij}, j=1, 2, \dots, n\}$

2) 分析已投票结果, 决定是否终止预测

For j in n:

If $c_j \geq \text{sum} \times 50\%$:

终止, 输出预测结果为 $label_j$

Else:

Continue.

输出结果 label ($\max\{c_j\}$)

针对传统随机森林模型投票的模式, 改进之后的投票模型引入了实时统计各分类标签获得投票数量的机制, 在每次调用决策树进行数据预测和加权投票之后, 模型会检查当前各个分类标签已经获得的投票数量, 如果某一分类标签的投票数量已经达到了全投票量的一半, 就立即触发预测终止条件终止预测流程, 将该分类标签作为模型的预测结果输出, 要是预测过程中一直没有检测到满足终止条件的分类标签, 则在整个预测流程完成之后, 将获得投票数量最大的分类标签作为模型最终的预测结果输出。

半投票量算法的流程图如下图 4.1 所示:




图 4.1 半投票量模式工作流程图

上面的算法流程图说明了半投票量模式的算法流程，通过①和②两种路径都可以得到随机森林模型最终的投票结果，其中①路径预测结果的获得是在没有完成所有决策树预测投票的情况下，触发了半投票量模式的终止条件提前结束了整个预测流程，通过路径②获得的预测结果是完成了所有决策树数据预测和投票之后分析各个分类标签投票情况获得的。

从上面的流程图可以看出，一般情况下，半投票量模式会在传统随机森林模型完成所有决策树投票之前就终止预测流程获得预测结果，但在整个投票过程中如果始终没有出现投票数量达到全投票量一半的分类标签，那么整个半投票量模式的终



止条件就不会被触发,需要在全部决策树分类器完成数据预测和投票之后再给出模型预测结果。

半投票量模式获得的预测结果和传统随机森林模型获得的预测结果是一致的,但前者可以在没有进行全预测投票之前就可以终止预测流程给出预测结果,显然比传统随机森林模型预测速度快,且随着模型中决策树泛化能力的增强,半投票量模式进行投票时越容易触发投票终止条件更快的给出预测结果,使得预测的速度加快。但是半投票量模式也存在一定的不足,半投票量模式虽然可以提高随机森林模型预测的速度,但在给出预测结果的同时无法计算得到预测结果的置信度,这也是因为半投票量模式提前终止预测流程而造成的。

4.3 在投票加权算法中使用半投票量模式

在第三章中我们为了解决不同泛化能力的决策树拥有相同投票权重的问题而引入了投票权值,通过对每棵决策树泛化能力的评估为决策树计算投票权值,在加权投票的随机森林模型中每棵决策树根据其泛化能力的大小有不同的投票权值。

在传统随机森林模型中,由于每棵决策树具有相同的投票权值,无法对决策树进行排序,在投票加权的随机森林模型由于我们已经为不同预测能力的决策树分类器计算了不同的投票权值,我们可以按照投票权值的大小进行降序排列,将泛化能力强的决策树排在前面。在随机森林模型进行数据预测的过程中,序列中的决策树分类器按顺序进行数据预测和分类标签的投票,并实时监测分类标签的投票数量进行预测流程终止判断。与传统随机森林模型相比,通过投票加权、投票权值降序排序之后的随机森林模型不但提高了模型整体的预测准确率,还提高了模型整体的预测速度。

与在传统随机森林模型中引入半投票量模式不同,加权投票的随机森林模型中的全投票量有所不同,传统随机森林模型的全投票量等于模型中决策树的个数,但在加权投票的随机森林模型中全投票量和每棵决策树的投票权重相关,加投票权值的随机森林模型的全投票量可以表示为:

$$S = \sum_{i=1}^k p_i \quad (4.3)$$

上面的表达式中, k 为模型包含决策树的个数, p_i 为投票加权值的随机森林模型中第 i 棵决策树分类器的投票权值,全投票量就等于所有决策树投票权值的算术



加和。

4.4 实验数据说明

为了验证半投票量模式的引入对模型预测速度的改善，我们使用维度较高，数据量较大的4个数据集，这4个数据集是UCI^[18]提供的公用数据集，数据集情况如下：

表 4.1 数据集说明

Datasets	Instances	Attrib.	Classes	Train/Test
abalone	4177	8	29	3:1
ionosphere	351	34	2	3:1
sk_face	34141	112	6	4:1
soybean	307	35	19	3:1

4.5 实验结果和分析

实验中使用了4个不同的数据集进行算法验证，分别使用传统随机森林模型（RF）、引入半投票量模式的传统随机森林模型（RF-50%）、加投票权重（Cor-RF,相关系数评估决策树投票权值）的随机森林模型以及在该加投票权重随机森林模型上引入半投票量模式的随机森林模型（Cor-RF-50%），总共四种算法模型，来统计数据预测的时间，为了降低统计误差对实验结果的影响，在统计过程中通过统计模型对多条数据进行预测所需要的总时间，通过求平均值的方式给出模型预测单条数据所用时间，表4.2-4.5中给出了四种模型时间的结果：

表 4.2 abalone 数据集上运行结果对比

算法模型	预测准确率	预测总时间(ms)	预测数据量	单条数据预测时长(ms)
RF	0.51823	695094.77	1042	667.07
RF-50%	0.51823	613596.46	1042	588.86
Cor-RF	0.62535	697014.84	1042	668.92
Cor-RF-50%	0.62535	451043.12	1042	432.86



表 4.3 ionosphere 数据集上运行结果对比

算法模型	预测准确率	预测总时间(ms)	预测数据量	单条数据预测时长(ms)
RF	0.89655	58633.94	87	673.95
RF-50%	0.89655	51278.56	87	589.40
Cor-RF	0.92721	58436.00	87	671.67
Cor-RF-50%	0.92721	49187.92	87	565.37

表 4.4 sk_face 数据集上运行结果对比

算法模型	预测准确率	预测总时间(ms)	预测数据量	单条数据预测时长(ms)
RF	0.97721	4703525.27	6827	688.95
RF-50%	0.97721	2335069.83	6827	342.03
Cor-RF	0.99751	4707758.48	6827	689.57
Cor-RF-50%	0.99751	2119141.14	6827	310.40

表 4.5 soybean 数据集上运行结果对比

算法模型	预测准确率	预测总时间(ms)	预测数据量	单条数据预测时长(ms)
RF	0.89221	112385.78	167	672.96
RF-50%	0.89221	98697.25	167	591.01
Cor-RF	0.93023	113105.65	167	677.27
Cor-RF-50%	0.93023	85136.85	167	509.80

为了能够更直观的对比三种模型在 4 个数据集上运行的情况,下面将实验获得的数据绘制成柱状图,如图 4.2-4.5 所示,每个数据集包含两张柱状图,左边是四种模型单条数据预测使用的平均时间,右边是四种模型的预测准确率:




图 4.2 abalone 数据集上运行结果对比




图 4.3 ionosphere 数据集上运行结果对比




图 4.4 sk_face 数据集上运行结果对比




图 4.5 soybean 数据集上运行结果对比



从以上的图表信息可以看出，在 4 种不同的数据集上，进行原随机森林模型、加投票权值的随机森林模型和是否引入半投票量模式进行对比实验，从实验结果可以看到，通过添加投票权值可以有效的提高原随机森林模型的预测准确率；对已有的随机森林模型引入半投票量模式可以有效的加快整体数据预测的速度；相比在原随机森林模型上引入半投票量模式，对加投票权值的随机森林模型进行半投票量模型可以更好的提高模型预测速度，这是因为后者对不同投票权值的决策树进行排序，让投票权重较大的决策树优先参与模型的预测，使得半投票量终止条件能够尽早满足。

4.6 本章小结

本章在原有的随机森林模型上引入一种新的投票模式--半投票量模式，在数据预测的过程中确定了预测流程终止条件，分别在传统随机森林模型和决策树加权的随机森林模型上引入半投票模式，在 4 个数据集上进行对比验证，通过分析实验数据可以知道，半投票量模式可以在不影响模型整体预测准确率的前提下，显著的提高模型数据预测的速度。



第5章 总结和展望

5.1 研究总结

随机森林算法通过引入两个随机过程和多个元分类器组合的方式,使得模型整体表现出非常明显的优点,包括不易出现过拟合、准确率高、具有处理高纬度大量数据的能力、算法设计简单、模型构建容易等。随机森林模型作为一种组合分类器,在数据预测阶段是通过所有决策树投票的方式来给出最终的预测结果。然而在传统随机森林算法的投票过程中,并没有考虑到单棵决策树泛化能力的差异性对最终投票结果的影响,针对随机森林中存在的这一不足,本文提出了加权决策树的随机森林模型优化方法。

本文提出了4种决策树投票权值计算的方法,对构建的随机森林模型进行投票权值计算,优化模型投票过程,提高预测准确率。除此之外,本文进一步研究随机森林模型数据预测的过程,提出了半投票模式的算法进行数据的预测,提高了模型数据预测的速度。本文主要的研究包括:

(1) 对随机森林算法进行了全面的描述,并通过数学推理的方式给出了模型不易出现过拟合的论证,讨论了模型的优缺点,描述了影响随机森林模型预测准确率的两个主要方面:单棵决策树预测能力和决策树之间的相关性。

(2) 介绍了OOB评估、数据的相关系数、卡方验证以及互信息方法,并在构建的随机森林模型中通过引入这4种不同的方法,为单棵决策树计算投票权值。本文在随机森林模型包含不同决策树个数和不同的特征空间的情况下进行对比实验,分析在8组数据集上的实验结果,证明了引入投票加权的方式的合理性和优越性。

(3) 在引入投票权重的基础上,进一步优化随机森林算法,提出了半投票量投票模式,为随机森林模型确定预测终止条件,以提高模型数据预测速度。本文在传统随机森林算法和加权决策树的随机森林算法中分别引入半投票量模式,实现对比实验,分析了在4组数据集上的实验结果,证明了半投票量方法可以在不影响模型整体预测准确率的前提下,明显提高模型的预测速度。

5.2 研究展望

本文针对传统随机森林单棵决策树分类能力不同的问题,提出了加权决策树的



随机森林模型优化方法,在多个数据集上进行对照实验分析证明了算法的合理性和优越性。通过引入投票权值提高了模型的预测能力。同时,本文还通过引入半投票量的方式提高了随机森林模型预测的速度。本文提出的方法在一定程度上优化了随机森林模型的性能,但仍然有一些地方有待于进一步的优化处理:

(1) 决策树分类能力的控制。由于随机森林模型构建过程中特征集合的随机抽样,使得训练得到的决策树分类能力的分布情况具有一定随机性,容易出现较多的决策树分类能力差异很大的情况。目前可以通过增加随机森林模型中决策树的数量来降低分布的不均衡现象。也可以通过特征属性相关性分析,为各个特征属性确定重要度,对样本特征属性进行排序并划分若干个重要度级别的子特征集,在构建决策树进行特征随机抽取的过程中,在不同级别的特征子集中进行随机抽样,更为有效的控制决策树的分类能力。

(2) 随机森林模型的并行化。随机森林模型可以很方便的进行并行计算,从而大幅度的提高模型的构建和数据预测速度。在处理数量特别大、特征维度特别高的数据集时,可以将多台计算机通过网络进行连接,计算机之间通过制定好的数据格式进行通信,多台计算机通过并行的方式分别构建决策树分类器,在数据预测阶段多台计算机并行预测数据,这样可以更好的提高随机森林模型的预测速度。



参考文献

- [1] TT.Niblett, I.Bratko. Learning Decision Rules in Noisy Domain, Proc. Expert Systems'86, Cambridge, England: Cambridge University Press, 1986.
- [2] Salzberg Steven L. Book Review:C4.5 programs for machine learning by J.Ross Quinlan[J]. Machine Learning. 1994, 3:235-240.
- [3] Jose M Bernardo, Adrian F M Smith. Bayesian Theory. Measurement Science and Technology, 2001, 12, 221.
- [4] Huelsenbeck, J.P and Ronquist, F. et al. Bayesian inference of phylogeny. Bioinformatics, 2001, 17, 754-755.
- [5] L.K. Hansen, P.Salamon. Neural Network Ensembles. IEEE Transactions on Pattern Analysis and Machine Intelligence, 1990, 12(10): 993-1001.
- [6] 邓乃扬, 田英杰. 数据挖掘中的新方法-支持向量机[M]. 北京: 科学出版社, 2004.
- [7] O.Chapelle, V.Vapnik, O.Bousquet, et al. Choosing multiple parameters for support vector machines. Machine Learning, 2002, 46(1):131-159.
- [8] Breiman L. Random forests. Machine Learning. 2001. 18 45(1): 5-32+.
- [9] T.K.Ho, Random Decision Forest. In Proceedings of the 3rd International Conference on Document Analysis and Recognition, Montreal, Canada, 1995, 8L: 278 -282.
- [10] T.K.Ho, The Random Subspace Method for Constructing Decision Forests, IEEE Transactions on Pattern Analysis and Machine Intelligence, 1998, 20(8): 832-844.
- [11] Sexton J, Laake P. Standard Errors for Bagged and Random Forest Estimators[J]. Computational Statics & Data Analysis, 2009, 53(1).
- [12] Breiman L. Machine Learning. Bagging Predictors[J]. 1996, 24(2): 123-140.
- [13] Coussement K, Poel D V D. Churn Prediction in Subscription Services: An Application of Support Vector Machines While Comparing Two Parameter-Selection Techniques[J]. Expert Systems with Applications, 2008, 34(1).
- [14] Diaz-Uriate R, Andres S A D. Gene Selection and Classification of Microarray Data Using Random Forest[J]. BMC Bioinformatics, 2006, 7(3).
- [15] Chen X W, Liu M. Prediction of Protein-protein Interactions Using Random Decision Forest Framework[J]. Bioinformatics, 2006, 21(24).



- [16] Gislason P O, Benediktsson J A, Sveinsson J R Random Forests for Land Cover Classification[J]. Pattern Recogn. Lett, 2006, 27(4).
- [17] Quinlan J R. C4.5: programs for machine learning [M]. DBLP, 1993.
- [18] Breiman, L, Friedman, J.H. Olshen. Classification and Regression trees, Belmont, CA: Wadsworth International Group, 1984.
- [19] Robert Tibshirani: Bias, variance and prediction error for classification rules. 1978.
- [20] UCI: Machine Learning Repository: <http://archive.ics.uci.edu/ml/index.html>.
- [21] Breiman L, Friedman J H, Olshen R, et al. Classification and Regression Trees [J]. Biometrics, 1984, 40(3):358.
- [22] Simon Bernard, Sebastien Adam, Laurent Heutte. Dynamic Random Forests. Pattern Recognition Letters 33(2012), 1580-1586.
- [23] Hussein Mohsen, Hasan Kurban, Jurt Zimmer et al. Red-RF: Reduced Random Forest for big data using priority voting and dynamic data reduction. 2015 IEEE International Congress on Big Data.
- [24] Quinlan J R. Machine Learning. Induction of decision trees[J]. 1986, 1(1): 81-106.
- [25] Tibshirani R. Bias, Variance and Prediction Error for Classification Rules[J]. 1996.
- [26] Wolpert D H, Macready W G. No free lunch theorems for optimization[J]. IEEE Transactions on Evolutionary Computation, 1997, 1(1): 67-82.
- [27] Gall, J., Yao, A., Razavi, N., et al. Hough forests for object detection, tracking, and action recognition. IEEE Trans. Pattern Anal. Machine Intell. 2011, 33(11), 2188-2202.
- [28] Latinne, P., Debeir, O., Decaestecker, C. Limiting the number of trees in random forests. 2001. In: 2nd Internat. Workshop on Multiple Classifier Systems, pp. 178-187.
- [29] Robnik-Sikonja, M.. Improving random forests. European Conf. on Machine Learning, LNAI 3210. 2004, Springer, Berlin, pp. 359-370.
- [30] Tsymbal, A., Pechenizkiy, M., Cunningham, P., 2006. Dynamic integration with random forests, In: European Conf. on Machine Learning and Principles and Practice of Knowledge Discovery in Databases, pp. 801-808.
- [31] Wang, A., Wan, G., Cheng, Z., Li, S., 2009. An incremental extremely random forest classifier for online learning and tracking. In: ICIP'09 Proceedings of the 16th IEEE International Conference on Image Processing, pp. 1433-1436.
- [32] Zhou Qifeng, Zhou Hao, Li Tao. Cost-sensitive feature selection using random forest: Selecting low-cost subsets of informative features[J]. Knowledge-Based



- Systems, 2016, 95:1-11.
- [33] Rodriguez-Galiano V F, Ghimire B, Rogan J, Chica-Olmo M, Rigol-Sanchez J P. An assessment of the effectiveness of a random forest classifier for landcover classification[J]. ISPRS J. Photogramm. Remote Sens. 2012, 67, 93 - 104.
- [34] A. Torsello, A. R. Kelly, E. R. Hancock. Discovering Shape Classes using Tree Edit-Distance and Pairwise Clustering. International Journal of Computer Vision. 2007, 72(3):259-285
- [35] Siddharth Hariharan, Siddhesh Tirodkar, Avik Bhattacharya. Polarimetric SAR decomposition parameter subset selection and their optimal dynamic range evaluation for urban area classification using Random Forest[J]. International Journal of Applied Earth Observation and Geoinformation, 2016, 44: 144-158.
- [36] Tsamardinos I, Rakhshani A, Lagani V. Performance-Estimation Properties of Cross-Validation-Based Protocols with Simultaneous Hyper-Parameter Optimization[J]. International Journal on Artificial Intelligence Tools, 2015, 24(05): 1540023.
- [37] V. Segura, A. Ouangraoua, P. Ferraro, E. Costes. Comparison of Tree Architecture using Tree Edit Distances: Application to 2-year-old Apple Hybrids. Euphytica. 2008.5, 161(1, 2):155-164
- [38] D. O. Hebb. The Organization of Behavior: A Neuropsychological Theory. Science Education. 2006, 34(5):336-337
- [39] 邵信光, 杨慧中, 陈刚. 基于粒子群优化算法的支持向量机参数选择及其应用[J]. 控制理论与应用, 2006, 23(5): 740-744.
- [40] 李毓, 张春霞. 基于 out-of-bag 样本的随机森林算法的超参数估计[J]. 系统工程学报, 2011, 26(4): 566-572.
- [41] 马骊. 随机森林算法的优化改进研究[D]. 暨南大学 硕士论文, 2016.
- [42] 雍凯. 随机森林的特征选择和模型优化算法研究[D]. 哈尔滨工业大学 硕士论文, 2008.



攻读硕士期间发表的论文

- [1] 软著：基于人脸识别的智能考勤系统 V1.0，软著登字第 0532072 号。
- [2] 软著：面向孤独症儿童的智能化学习平台（Android 版）V1.0，软著登字第 0695761 号。
- [3] 软著：未来教室学生身份识别系统 V1.0，软著登字第 0923644 号。



致谢

随着毕业时间的临近，毕业论文逐渐完成，猛然回首间，研究生三年的学习生涯就快要结束，回望这三年的学习、工作和生活，感觉异常的充实。研究生一年级参加全国 APP 设计大赛；研究生二年级利用课余时间参加创业项目；研究生三年级顺利获得心仪的工作机会；这些美好的经历充实着我的生活，当然这些成果也都离不开老师和同学的帮助和鼓励。

在此，我必须要感谢我的导师陈靓影教授，陈老师知识渊博，视野开阔，科研态度严谨。研究生期间陈老师一直指导我在学术上的研究，并帮助提高做工程项目的的能力，在生活上也给予了我很多指导和帮助。本论文也是在陈老师的指导和帮助下完成，从选题到内容的实现，再到论文的书写和完成后修改，陈老师都给予了很多建议和帮助。同时也感谢项目组里的刘乐元老师，张坤老师，徐如意老师，他们在学术研究上也给予了我很多帮助，非常感谢你们。

其次，也要感谢项目组的所有同学，大家共同协作完成同一个科研任务，相互学习，交流学习心得，共同进步；感谢研究生期间遇到的所有人，有你们的陪伴，生活才会如此美好。

最后，要感谢我的家人，是他们为我提供良好的学习环境，鼓励支持我所有的决定，在我遇到困难时，开导帮助我，在我取得成绩的时候，为我开心，同时也鞭策我戒骄戒躁，是你们让我离我的梦想更近，是你们让我的生活更加美好。总之，感谢所有出现在我生命中的人。