

基于随机森林特征重要性的 K-匿名特征优选

黄 梅 朱 焱

(西南交通大学信息科学与技术学院 四川 成都 611756)

摘 要 大数据时代,数据的共享与挖掘存在隐私泄露的安全隐患。针对使用 K-匿名隐藏实现隐私保护会大幅降低数据分类挖掘性能问题,提出一种基于随机森林特征重要性的 K-匿名特征选择算法(RFKA)用于分类挖掘。使用随机森林特征重要性度量特征的分类性能;采用前向序列搜索策略每次选择不破坏 K-匿名且分类性能最大的特征加入特征子集;使用特征子集对应的数据集构建模型进行分类实验。实验结果表明,该算法能更有效地平衡 K-匿名和分类挖掘性能,且算法运行效率更高。

关键词 特征选择 K-匿名 随机森林 分类

中图分类号 TP309.2

文献标志码 A

DOI: 10.3969/j.issn.1000-386x.2020.03.045

K-ANONYMITY FEATURE OPTIMIZATION BASED ON THE IMPORTANCE OF RANDOM FOREST FEATURES

Huang Mei Zhu Yan

(College of Information Science and Technology, Southwest JiaoTong University, Chengdu 611756, Sichuan, China)

Abstract In the era of big data, the sharing and mining of data has security risks of privacy leakage. Aiming at the problem that the use of K-anonymity hiding to achieve privacy protection can greatly reduce the performance of data classification mining, we propose a K-anonymity feature selection algorithm(RFKA) based on the importance of random forest features for classification mining. The classification performance of feature was measured by random forest feature importance. Then, we adopted the forward sequence search strategy to select the features without destroying k-anonymity and added the highest classification performance to a feature subset. We used the data set corresponding to the feature subset to construct the model for classification experiments. The results show that our algorithm can balance K-anonymity and classification mining performance more effectively, and the algorithm runs more efficiently.

Keywords Feature selection K-anonymity Random forest Classification

0 引 言

近年来,随着互联网技术和数据存储技术的快速发展,从数据中提取隐含的、具有潜在价值的信息变得更加便捷。数据挖掘技术常用于决策支持和科学研究,数据在拥有者和使用者之间共享屡见不鲜。然而,这些数据中可能包含了某些敏感隐私信息,如个体隐私、政府机密及商业情报等。如果将这些数据不加处理的发布共享,就会造成隐私信息的泄露。近年来,随着多起隐私数据泄露事件,如 NetFlex 的推荐比赛中用

户观影记录泄露^[1]、FaceBook 与数据分析公司 Cambridge Analytica 的不当共享造成 8 700 万用户个人信息泄露^[2]等,隐私保护技术得到极大关注,成为数据挖掘和信息安全领域的研究热点。

自隐私保护数据挖掘(Privacy Preserving Data Mining,PPDM)作为知识发现应用领域的核心问题,不断有学者对其进行研究,并试图制定提供隐私保护的模型,经典的包括 K-匿名^[3]、L-多样性和 T-接近及差分隐私等。其中,K-匿名因其灵活有效,在隐私保护领域得到广泛研究。该模型最早由 Sweeney 等^[4]提出,并提出使用 MinGen^[5]算法来选取最优泛化操作,

收稿日期:2019-03-29。四川省科技计划项目(2019YFSY0032)。黄梅,硕士生,主研领域:隐私保护数据挖掘。朱焱,教授。

使待发布数据满足 K-匿名原则。韩建民等^[3]针对隐私的敏感度提出了面向敏感值的个性化(a, K)-匿名隐私保护模型。这种方法对低敏感值的敏感属性使用较低的 K-匿名约束,对高敏感值的敏感属性则用较高的 K 值进行约束,降低了单敏感属性因隐私保护而引起的信息损失。此外,许多研究者通过结合聚类实现 K-匿名。Li 等^[4]应用聚类思想,依据合并泛化信息损失量最小原则,每次随机选取一个元组数小于 K 的类簇与另一个类簇进行合并,直至所有类簇的元组数大于等于 K。Zhang 等^[5]提出在 K-匿名聚类中应用信息熵,先将表数据聚类为不同的簇,然后将记录数小于 1K 的簇合并,大于 2K 的簇拆分,使每个簇的记录数在 1K 于 2K 之间,最后再对每个簇进行泛化。文献^[6]根据泛化树层次的类别分别度量元组间和等价类间的信息损失,按照 K 值每次选择一条记录加入类簇,实现等价类的均衡划分。

K-匿名作为常用的隐私保护模型,泛化和隐藏是实现该模型的主要手段。上述方法均是采用泛化,即采用一个域更广的新值代替原始具体值,如年龄值 24 和 34 都可以泛化到区间(20,40]。泛化需要预先制定泛化层次,而不同的泛化层次对结果的影响较大。例如年龄 24 可以泛化到(20,30],也可以直接泛化到(20,40]。而隐藏一般在确定无法泛化到更高层级后才使用。比如性别特征取值只有“男”和“女”,没有更高的域值包含这两个值,那么直接从数据集中删除该特征或用“*”代替。不同于以往,文献^[6]提出的 Greedy_Hamdist 算法,无需预先制定泛化层次,而是通过隐藏分类性能低的特征使特征子集对应数据集满足 K-匿名,扩展了 K-匿名实现的新思路。

本文受文献^[6]的启发,提出一种基于随机森林特征重要性的分类性能度量方法,并结合 K-匿名要求,用于选择满足 K-匿名的特征子集,具体工作流程如图 1 所示。通过在两个真实数据集上进行实验,并与基于 Greedy_Hamdist 的特征选择算法比较可知,本文算法更有效地保证了隐私保护与数据挖掘性能之间的平衡,运行效率也更优。




图1 工作流程

1 相关技术

1.1 K-匿名特征选择

K-匿名模型常用于抵抗链接攻击,该模型可以消除个体与敏感隐私信息之间的关联关系^[7]。为方便讨论,假定待发布的数据表包含 n 个记录,属性集合由 d 个准标识属性和 1 个敏感属性构成。设 $T = (t_1, t_2, \dots, t_n)$ 为待发布的数据表, $t_j (j = 1, 2, \dots, n)$ 为表中第 j 个元组。记 $A = (A_1, A_2, \dots, A_d)$ 为表中所有准标识属性, $A_i (i = 1, 2, \dots, d)$ 为表中第 i 个准标识属性, A_s 为敏感属性,则数据表可以用表 1 表示。

表1 数据表

记录	属性				
	A_1	A_2	$\dots$	A_d	A_s
t_1	$t_1[A_1]$	$t_1[A_2]$	$\dots$	$t_1[A_d]$	$t_1[A_s]$
t_2	$t_2[A_1]$	$t_2[A_2]$	$\dots$	$t_2[A_d]$	$t_2[A_s]$
$\vdots$	$\vdots$	$\vdots$		$\vdots$	$\vdots$
t_n	$t_n[A_1]$	$t_n[A_2]$	$\dots$	$t_n[A_d]$	$t_n[A_s]$

定义 1(等价类) 在数据表中,具有相同 A 取值的若干记录组成的集合称为一个等价类,记为 C_i ,则有 $\forall t_i, t_j \in C_w$, 有 $t_i[A] = t_j[A], i \neq j, w \in [1, m]$ 。其中 m 为等价类的个数。

一个数据表中的任意两个等价类之间没有共同元组,所有等价类的集合构成数据表本身。即 $\cup_{i=1}^m C_i = T, C_i \cap C_j = \emptyset, i \neq j$ 。

定义 2(K-匿名) 将数据表 T 经匿名技术处理后,划分为多个等价类,每个等价类包含至少 K 条记录,则称数据表 T 满足 K-匿名。

可见,K-匿名要求对数据表中任一元组,至少存在 $K-1$ 个其他元组,它们在准标识属性上的取值相同,理论上侵犯者最多只有 $1/K$ 的概率能够定位出个体用户所属的记录并获得敏感属性,即 K 值的大小决定了隐私泄露的风险, K 值越大,隐私泄露风险越低,反之越高。

假设表 2 为待匿名数据集,由于每条记录与其他记录在准标识符属性上不具有相同的特征取值,所以数据集不满足 2-匿名。但如果特征集为 (A_1, A_2, A_5) 时,即表中灰色部分,数据集中的任意一条记录都存在至少 1 条其他记录与其取值相同,满足 2-匿名。

表2 特征选择实现 2-匿名示例

记录	属性					
	A_1	A_2	A_3	A_4	A_5	A_6
t_1	0	0	0	1	1	+1
t_2	1	0	1	0	1	+1
t_3	0	0	1	0	1	-1
t_4	1	0	0	1	1	-1

因此通过特征选择的方式,可以使数据满足 K-匿名以达到隐私保护的目的。基于以上思想,可以使用特征选择得到合适的特征子集,使对应的数据集满足 K-匿名。但是从全部特征中得到最佳匿名特征子集是 NP 完全问题^[3],表 2 除了 (A_1, A_2, A_5) 满足 2-匿名条件外, (A_2, A_3, A_4) 也是满足 2-匿名的。不同的特征子集具有不同的分类挖掘性能,为了使满足 K-匿名的特征子集具有较好的分类性能,本文提出使用随机森林特征重要性度量特征的分类性能,并采用前向序列搜索策略选择特征。

1.2 随机森林特征重要性

随机森林(Random Forest, RF)是一种基于 Bagging 的集成分类器,由多棵完全生长的决策树组成。在分类预测中,样本的类标由这些决策树输出类标的众数决定^[4]。

RF 中每棵决策树的训练集由自助重采样(Bootstrap resampling)产生,即从数量为 N 的原始训练集中有放回地重复随机抽取 N 个样本。有的样本在自助重采样下可能会多次被抽取,而有的样本则可能不会被抽取。据统计,每棵决策树的训练集大约会含有原始训练集的 $2/3$ 样本,而其余没被抽到的 $1/3$ 样本构成袋外数据(out of bag data, OOB data),用于计算特征的重要性^[5]。随机森林在构建决策树时,随机地从 d 个属性中抽取 $\sqrt{d}$ 个属性,再根据 Gini 增益最大化原理^[6]选择分类能力最好的属性作为分裂属性,并将节点的数据划分到新子节点中。Gini 值常用于度量数据 D 的纯度,其计算公式为:

$$Gini(D) = 1 - \sum_{k=1}^{|y|} p_k^2 \quad (1)$$

式中: p_k 表示第 k 个类标在数据中所占比例。 $|y|$ 表示类标取值种类数。 $Gini(D)$ 反映了从数据集 D 中抽取两个样本,其类别不一样的概率。所以, $Gini(D)$ 越小,数据集 D 的纯度越高。数据集 D 根据属性 a 分裂得到的 Gini 增益可由下式计算得到:

$$\Delta I_G(a) = Gini(D) - \sum_{v=1}^V \frac{|D^v|}{|D|} Gini(D^v) \quad (2)$$

式中: V 表示 a 的取值种类数, $|D^v|$ 则表示第 v 种取值对应的样本数。 Gini 增益最大化原理就是计算节点所有属性的 Gini 增益,并选择 Gini 增益最大的属性作为分裂属性。根据该原理得到的分裂属性可以使子节点数据集纯度最高,说明该属性的分类性能最好。分类性能越好的属性在特征集中越重要,因此特征的重要性可以根据决策树节点的划分体现。然而,由于随机森林的双重随机机制,仅使用属性在随机森林决策树中的出现频率来体现特征重要性不可取,因此为了更准确地反映出特征的重要性,本文选择基于 OOB data 分类正确率的方法度量特征的重要性。假设 RF 中有 k 棵决策树,则特征 a 的重要性可由以下步骤得出:

- 1) 初始时令 $k=1$,采用自助重采样生成训练集和袋外数据集 OOB,在训练集上构建决策树 T_k ;
- 2) 基于 T_k 对 OOB 数据进行预测分类,统计分类正确的样本数,记为 R_k ;
- 3) 对 OOB 中特征 a 的值进行扰动,得到新的 OOB 样本集,再使用 T_k 对新 OOB 样本集进行分类预测,统计分类正确的样本数,记为 R'_k ;
- 4) 令 $k=2,3,\dots,K$,重复步骤 1 至步骤 3;
- 5) 特征 a 的重要性可由下式计算得出:

$$IMP(a) = \frac{1}{K} \sum_{k=1}^K (R_k - R'_k) \quad (3)$$

对特征 a 的值进行扰动,如果扰动前和扰动后分类正确率没有多大变化,说明特征 a 在分类时起到的作用不大,分类性能低。此时 $R_k - R'_k$ 的值将会很小,所以 $IMP(a)$ 值越大,说明特征 a 的分类性能越好。

2 算法设计

为了保证数据匿名后还能保持较高的分类性能,本文提出使用选择随机森林度量特征的分类性能,对原始集的特征进行排序,并采用序列前向搜索的贪心策略,进行 K-匿名特征选择。初始化特征子集为空,每次选择分类性最高的特征加入,并判断数据的匿名性,留下满足 K-匿名的特征,否则剔除,直到没有特征可加入,最终得到满足 K-匿名的特征子集。具体如算法 1 所示。

算法 1 RFKA(D, k)

输入: 数据集 D , 隐私值 K

输出: 满足 K-匿名的数据集 D'

Begin:

1. 构建随机森林计算每个特征的重要性
2. 根据特征重要性对特征降序排序,得到 F_IMP_List

```

3. 初始化特征子集 sub = {}
4. for F_IMP_List 中的每个特征 X:
5.     sub = sub.append(X)
6.     D' = D 在 sub 上的投影数据集
7.     if privacy_test(D'):
8.         sub = sub.delete(X)
9.     D' = D 在 sub 上的投影数据集
10. 输出数据集 D'
End

```

注意,数据集 D 只包含准标识属性,不包括敏感属性。算法第 7 行 `privacy_test(D')` 对数据集 D' 进行了是否违反 K -匿名的判断,判断条件是根据 K -匿名的定义设计的,即任意一条数据都至少存在 $K-1$ 条数据与其具有相同的准标识符。本文中的准标识符即样本在特征子集上的取值,所以 `privacy_test(D')` 的具体实现如算法 2 所示,其中 2~9 行为等价类划分过程。

算法 2 `privacy_test(D')` 输入:数据集 D' ,隐私值 k
 输出: True 或 False //True: 满足, False: 不满足
 Begin
 1. 初始化字典 `record = {}`
 2. for D' 中的每一个样本 t :
 3. 准标识符 $q = t$ 的取值
 4. if q 在字典中:
 5. `record[q] ++`
 6. else
 7. `record[q] = 1`
 8. end if
 9. end for
 10. for `record` 字典中每一个等价类 C :
 11. if `len(C) < k`:
 12. return false
 13. end if
 14. end for
 15. return true
 End

3 实验设置

3.1 数据集与预处理

为了验证本文算法能有效地平衡数据隐私保护程度与分类挖掘性能,本文选用了 UCI 两个经典真实数据集——乳腺癌数据集 (Breast-Cancer) 和 Adult 数据集进行实验,并将本文算法与文献 [6] 中的 Greedy_Hamdist 从分类性能和运行效率两个方面进行对比。乳腺癌数据集总计 699 条数据,本文将病态为良性的记录作为正类,恶性则为负类。将包括 Clump Thickness、

Bare Nuclei、Uniformity of Cell Size 等在内的 8 个离散型属性均作为准标识符属性。Adult 数据集为隐私保护领域常用的经典数据集,本文按正负类原始比例随机抽取 2000 条样本进行实验,正类为年收入大于 5 万的记录,负类为年收入小于等于 5 万的记录。属性集包括 6 个连续性属性,如 Age、fnlwgt、education-num 等,8 个离散型属性,例 workclass、marital-status、relationship 等,本文将这 14 个属性均作为准标识符属性。两个数据集均不含有缺失值,分类的类标即为敏感属性。

由于 Greedy_Hamdist 只能处理二值数据,为了使本文算法与其更具有可比性,需要对原始数据中的连续型数据进行离散,然后进行 OneHot 处理。离散化采用常用的等距处理,如年龄值离散到 $(0, 20]$ 、 $(20, 40]$ 、 $(40, 60]$ 、 $(60, 80]$ 、 $(80, \infty)$ 。

3.2 评价指标与实验设置

为了验证本文算法选择的特征子集优于 Greedy_Hamdist,本文使用 ROC 曲线下的面积 AUC 值分类指标客观地评价特征子集对应数据集的分类挖掘性能,此外,还会从运行时间对两个算法进行比较。

最后为了评价特征子集对应数据集分类挖掘性能,本文采用 sklearn 中默认设置的 SVM 分类器对特征选择后的数据进行分类,核函数设置为径向基函数,并使用五折交叉验证方式来保证分类的稳定性。随机森林的决策树数量 `n_estimators` 设置为 1 000,使用袋外数据衡量训练集特征重要性 `oob_score` 为 True,其余采用 sklearn 中随机森林的默认设置。实验环境为: Intel(R) Core(TM) i5-6200U CPU @ 2.30 GHz 2.40 GHz; 4.00 GB (RAM) 内存; Windows 10 64 位操作系统。算法均采用 Python 实现。

4 结果与分析

4.1 分类挖掘性能分析

使用本文提出的 RFKA 算法与文献 [6] 中的 Greedy_Hamdist 算法分别在 Adult 数据集和 Breast-Cancer 数据集上进行不同 K 值下的分类实验,得到如图 2 和图 3 所示的实验结果。当 $K=0$ 时,表示不对原始数据做隐私保护。随着 K 值越来越大,对应数据集的隐私泄露风险越来越低,隐私保护程度越高。由于剔除了原始数据中不满足 K -匿名要求、但重要性高的特征,所以分类性能会降低,但本文的算法无论在 K 值为多少时, AUC 都是大于等于 Greedy_Hamdist 算法的,说明使用随机森林度量特征重要性比 Hamdist 方法更优,更适合用于 K -匿名的实现。




图2 Adult 数据集在不同 K 值下的 AUC 值




图3 Breast-Cancer 数据集在不同 K 值下的 AUC 值

4.2 运行时间分析

在运行时间方面得到的实验结果如图4和图5所示。在两个数据集上,不同 K 值下,本文的 RFKA 算法所用时间均比 Greedy_Hamdist 更短,表明本文算法在实现 K-匿名时的运行效率更优。




图4 Adult 数据集在不同 K 值下的运行时间




图5 Breast-Cancer 数据集在不同 K 值下的运行时间

5 结语

本文借助随机森林特征重要性度量特征的分类性能,并结合 K-匿名约束对数据实现特征选择,使得特征子集对应的数据集满足 K-匿名隐私保护条件。实验结果证明,无论是从挖掘性能还是运行效率上,本文提出的算法都优于 Greedy_Hamdist。

在隐私保护领域,K-匿名只是基础的隐私保护模

型,因此可以考虑将特征选择结合其他模型实现隐私保护作为未来工作扩展,也可以提出更优的特征分类性能度量方法,进一步优化隐私保护与挖掘性能之间的平衡。

参考文献

- [1] Narayanan A, Shmatikov V. Robust De-anonymization of Large Sparse Datasets [C] // 2008 IEEE Symposium on Security and Privacy (sp 2008). Oakland: IEEE, 2008.
- [2] 梁丽雯. Facebook“泄露门”:大数据零隐私? [J]. 金融科技时代, 2018(5): 92.
- [3] Sweeney L. K-Anonymity: A model for protecting privacy [J]. International Journal of Uncertainty Fuzziness and Knowledge-Based Systems, 2002, 10(5): 557-570.
- [4] Sweeney L. Achieving k-anonymity privacy protection using generalization and suppression [J]. International Journal of Uncertainty Fuzziness and Knowledge-Based Systems, 2002, 10(5): 571-588.
- [5] 韩建民, 于娟, 虞慧群, 等. 面向敏感值的个性化隐私保护 [J]. 电子学报, 2010, 38(7): 1723-1728.
- [6] Li J, Wong C W, Fu W C, et al. Achieving k-anonymity by clustering in attribute hierarchical structures [C] // Proceedings of the 8th international conference on Data Warehousing and Knowledge Discovery. Springer Berlin Heidelberg, 2006: 405-416.
- [7] Zhang J, Zhao Y, Yang Y, et al. A K-anonymity clustering algorithm based on the information entropy [C] // Proceedings of the 2014 IEEE 18th International Conference on Computer Supported Cooperative Work in Design (CSCWD). IEEE, 2014.
- [8] 姜火文, 曾国荪, 马海英. 面向表数据发布隐私保护的贪心聚类匿名方法 [J]. 软件学报, 2017, 28(2): 341-351.
- [9] Zhang B, Dave V, Mohammed N, et al. Feature selection for classification under anonymity constraint [J/OJ]. Transactions on Data Privacy, 2017(10). (2017-05-06) [2018-12-05]. <https://arxiv.org/abs/1512.07158.html>.
- [10] Fang W W, Liang X M, Li S X, et al. VMPlanner: optimizing virtual machine placement and traffic flow routing to reduce network power costs in cloud data centers [J]. Computer Networks, 2013, 57(1): 179-196.
- [11] Breiman L. Manual on setting up, using, and understanding random forests V3.1 [EB/OJ]. [2012-05-05]. http://oz.berkeley.edu/users/breiman/Using_random_forest.
- [12] Uwe H, Ralf M, Michael K B, et al. A comparison of random forest and its Gini importance with standard chemometric methods for the feature selection and classification of spectral data [J]. BMC Bioinformatics, 2009, 10(1): 1-16.
- [13] 豆育升, 崔晟圆, 唐红, 等. 云数据中心高性能的虚拟机放置算法 [J]. 小型微型计算机系统, 2014, 35(11): 2543.