

基于随机森林的变量重要性研究

曹桃云^{a,b}

(广东财经大学 a.大数据与教育统计应用实验室; b.统计与数学学院, 广州 510320)

摘要:对变量进行重要性度量是变量选择的依据。变量选择在复杂数据的统计建模和解释预测中具有广泛的研究背景。基于随机森林算法,文章对回归问题中的最小深度、变量在根节点的分裂频次、置换重要性、节点纯度等变量重要性度量进行了原理阐述,并采用数值模拟研究了各种重要性度量的性能,为新方法的设计提供了基础。

关键词:随机森林;最小深度;分裂频次;节点纯度;置换重要性

中图分类号:TP181;O212

文献标识码:A

文章编号:1002-6487(2022)04-0060-04

0 引言

随机森林是 Breiman (2001)^[1]提出的基于分类回归树的集成算法。通过随机抽样和在分裂变量中加入随机性,使得随机森林中树之间的独立性增强,缩小了泛化误差的上界,同时给出了变量重要性的度量,如置换重要性和节点纯度重要性,为变量选择提供了依据,并被广泛研究^[2-4]。Athey 等 (2019)^[5]提出广义随机森林 (Generalized Random Forests),该算法灵活有效且完善了理论基础,同时给出了变量的重要性度量,是在控制最大深度的前提下,对分裂变量在随机森林所处树模型的深度和频次进行加权求和得到的。随机森林中根据树结构进行的重要性度量, Ishwaran 等 (2010)^[6]提出基于最大子树的最小深度,研究了最小深度的概率分布,消除了对预测误差的依赖,将问题集中在更基本的拆分规则上。目前基于随机森林的回归问题,可以计算的变量重要性有多种,本文对其中最具代表性的最小深度、变量在根节点的分裂频次、置换重要性、节点纯度这四种变量重要性度量进行了原理阐述,并采用数值模拟研究了各种重要性度量的性能,为进一步发展集成算法的变量选择提供依据。

1 变量重要性的度量

基于随机森林的变量重要性度量按照度量策略可分为两类:一类是根据随机森林中树模型的结构,如最小深度和根节点的分裂频次;另一类是根据随机森林的预测性能,如置换重要性和节点纯度。对于置换重要性,文献[7]研究基于 AUC 统计量的评价方法,克服类别间比例不平

衡的影响。由于本文关注回归问题的重要性度量,因此不再赘述,下面阐述四种重要性度量的基本原理。

假设样本 $S = \{Y_i, X_{i1}, \dots, X_{ip}\}$ 中有 n 个观测值 $i = 1, 2, \dots, n$ 和 p 个特征变量,连续型变量 $Y (\in R)$ 是反馈变量,通过 Bootstrap 有放回的重抽样得到独立同分布的来自 S 的 B 个样本 $S_1, \dots, S_B$, 其中在 $S_j (j = 1, 2, \dots, B)$ 中的样本称为袋内数据,没有被抽到的样本称为 S_j 的袋外数据 (out-of-bag, OOB), 对 $S_1, \dots, S_B$ 这 B 个样本分别运用二叉分裂递归拆分得到 B 棵回归树且不对树做修剪生成随机森林, OOB 可以作为测试集对随机森林进行预测的评判^[1]。

1.1 最小深度

最大子树的最小深度是指变量的最大子树的根到树的根节点的距离,如果距离越小,它提供的信息越多,且最小深度消除了对预测误差的依赖性,将问题集中在树模型的基本概念拆分规则上。对给定的变量 $X_v, v = 1, 2, \dots, p$, D_v 表示从树的根节点到最近的最大 v 子树的根的距离,则 D_v 是一个随机变量,取值为 $\{0, \dots, D(T)\}$, 其中, $D(T)$ 表示树 T 的深度。 D_v 作为变量 X_v 的最小深度,测量了一个样本在用树 T 做拟合时第一次遇到分裂变量 X_v 的距离。在满足一定条件下,如当 $D(T) \geq 1, l_d = 2^d$ (l_d 为深度为 d 的节点的个数)时,就有最小深度 D_v 的概率分布 $P\{D_v = d\} = [\prod_{j=0}^{d-1} (1 - \pi_{v,j} \theta_{v,j})] [1 - (1 - \pi_{v,d} \theta_{v,d})^{l_d}]$, 其中, $0 \leq d \leq D(T) - 1, \pi_{v,j}(t) = \pi_{v,j}$ 表示节点为 t 、深度为 j 且 X_v 为候选分裂变量的概率, $\theta_{v,j}(t) = \theta_{v,j}$ 表示节点为 t 、深度为 j 且 X_v 为候选分裂变量的情形下分裂了节点 t 的概

基金项目:广东省自然科学基金面上项目(2020A1515011580);广东财经大学校级学位与研究生教育改革研究项目(2021YB08);广东高校省级重点平台和重大科研项目特色创新项目(2018GKTSX010)

作者简介:曹桃云(1968—),女,山西晋中人,博士,副教授,研究方向:概率论与数理统计。

率,同时在深度小于 j 时没有最大 v 子树存在。如果用 VIM_v^{depth} 表示变量 X_v 在随机森林中的最小深度重要性, $D_{v,i}$ 表示变量 X_v 在第 i 棵树的最小深度,则 $VIM_v^{depth} = \frac{1}{ntree} \sum_{i=1}^{ntree} \{D_{v,i}\}$, 其中的 $ntree$ 表示随机森林中树的个数。最小深度依赖于其中的参数 $mean_sample$, 本文的计算是在最常用的缺省状态下进行的。 VIM_v^{depth} 越小,即最小深度值越小,变量越重要。

1.2 根节点的分裂频次

根节点的分裂频次也是基于最大子树的,是最小深度的一种特例,原理同上。出现在根节点分裂变量的频次,意味着通过变量 $X_v (v=1, 2, \dots, p)$ 的分裂,根节点中的样本分裂成左右两个子节点中的样本。如果用 VIM_v^{root} 表示变量 X_v 在随机森林中的根节点的分裂频次重要性,则 $VIM_v^{root} = \sum_{i=1}^{ntree} \{ |X_v| \}$, $|X_v|$ 表示 X_v 出现在随机森林第 i 棵树的根节点。最小深度依赖于其中的参数 $mean_sample$, 本文的计算是在最常用的缺省状态下进行的。 VIM_v^{root} 越大,即根节点的分裂频次值越大,变量越重要。

1.3 置换重要性

置换重要性就是随机打乱变量 $X_v (v=1, 2, \dots, p)$ 在 OOB 中的值,得到新的 OOB' , 计算打乱前后的平均平方误(MSE)的差异,如果变量重要,则打乱后 MSE 增加,且增加的幅度越大,说明变量越重要。具体计算公式为:

$$VIM_v^{mse} = \frac{1}{ntree} \sum_{i=1}^{ntree} \{MSE(OOB'_{iv}) - MSE(OOB_{iv})\}, \text{其中,}$$

$MSE(OOB_{iv})$ 、 $MSE(OOB'_{iv})$ 分别表示将第 i 棵树的 OOB 数据代入第 i 棵树得到的平均平方误,第 i 棵树的第 v 个变量的 OOB 数据打乱后代入第 i 棵树得到的平均平方误,右下标的 i 和 v 分别表示第 i 棵树和第 v 个变量。从公式可以看出,变量如果很重要,则随机打乱 OOB 后得到的 MSE 就会很大,故 VIM_v^{mse} 的值越大,变量越重要。

1.4 节点纯度增加的重要性

根据随机森林树模型中节点分裂前后不纯度的下降作为子节点纯度的增加,回归问题中节点的不纯度函数^[8]为 $i(\tau) = \sum_{m \in \tau} (Y_m - \bar{Y}(\tau))^2$, 其中, m 和 $\bar{Y}(\tau)$ 分别表示节点 τ 的样本数和 τ 内反馈变量 Y 的样本均值,经过分裂变量 $X_v (v=1, 2, \dots, p)$, 父节点到左右子节点的不纯度下降,最后对随机森林中树模型求平均。具体计算公式为:

$$VIM_v^{purity} = \frac{1}{|T|} \sum_{X_v \in T} \{i_v(\tau) - i_v(\tau_L) - i_v(\tau_R)\}, \text{其中, } i_v(\tau),$$

$i_v(\tau_L)$ 、 $i_v(\tau_R)$ 分别表示父节点 τ 的不纯度函数 $i_v(\tau)$ 经过 X_v 分裂后得到的左子节点 τ_L 的不纯度函数 $i_v(\tau_L)$ 和右子节点 τ_R 的不纯度函数 $i_v(\tau_R)$, 对随机森林中所有的树模型 T 中的所有 X_v 的不纯度下降求和,如果在一棵树中有多次出现分裂变量 X_v , 就要把每次分裂导致的不纯度下降加起来, $|T|$ 表示随机森林中包含 X_v 分裂变量的那些树的个

数,最后求平均。变量越重要,作为分裂变量的左右子节点的不纯度下降越大,也就意味着子节点的纯度越高。故 VIM_v^{purity} 的值越大,变量越重要。

2 数值模拟比较

为了比较几种重要性度量的性能,本文设计了线性函数模型、二次函数模型和采用文献[9]中的含有一次函数、二次函数、交叉项、三角函数等的复杂模型。

模型一为: $Y = 5X_1 + 5X_2 + \varepsilon$

模型二为: $Y = 5X_1^2 + \varepsilon$

模型三为: $Y = 10 \sin(\pi X_1 X_2) + 20(X_3 - 0.5)^2 + 10X_4 + 5X_5 + \varepsilon$

随机误差项 ε 分别服从标准正态分布和位置参数为 0、尺度参数为 1 的柯西分布。生成样本量 $n=100$ 、解释变量个数 $p=10$ 的服从独立同分布 $\text{Uniform}(0, 1)$ 的数据,模拟基于 R 软件包 random Forest、random Forest Explorer 并辅以部分编程实现,随机森林中的参数 $ntree=500$, 缺省值也是最常用的参数值。所有的模拟均通过随机产生数据的方式进行了 100 次。给出四种重要性的箱线图对比他们在区分真正变量和噪声变量上的性能。

首先从模型一的线性函数模型 $Y = 5X_1 + 5X_2 + \varepsilon$ 中,可以看到在 10 个解释变量中,和反馈变量 Y 有关的只有 X_1 、 X_2 , 其余的都是噪声变量。图 1 展示了随机误差项服从正态分布的情形下重要性度量的四种方法对比,其中图中的横坐标表示 10 个解释变量,纵坐标表示不同的重要性度量,标有 *Depth* 的是平均最小深度的箱线图(深度越小,重要性越大),标有 *Root* 的是变量出现在根节点的分裂频次的箱线图(频次越多,重要性越大),标有 *MSE* 的是置换重要性箱线图(MSE 越大,重要性越大),标有 *Purity* 的是纯度重要性的箱线图(纯度越高,重要性越大),以下出现的图均类似。清楚看到尽管四种重要性度量刻画的尺度不同,但都明显区分出真正变量 X_1 、 X_2 和噪声变量 $X_3, \dots, X_{10}$ 。下页图 2 展示的是随机误差项服从柯西分布的情形,可以看到后面两种重要性,即置换重要性和纯度重要性已分辨不出真正变量 X_1 、 X_2 和噪声变量 $X_3, \dots, X_{10}$, 而最小深度和根节点分裂频次能分辨出真正变量和噪声变量。







图1 模型一中 $\varepsilon \sim N(0, 1)$ 四种重要性度量的比较



图2 模型一中 $\varepsilon \sim \text{Cauchy}(\text{location}=0, \text{scale}=1)$ 四种重要性度量的比较

其次在模型二的二次函数模型 $Y=5X_1^2+\varepsilon$ 中, 可以看到在10个解释变量中和反馈变量 Y 有关的只有 X_1 , 其余的都是噪声变量。图3展示的随机误差项服从正态分布的情形, 尽管四种重要性度量刻画的尺度不同, 但都明显区分出真正变量 X_1 和噪声变量 $X_2, \dots, X_{10}$ 。图4展示的是随机误差项服从柯西分布的情形, 可以看到后面两种重要性, 即置换重要性和纯度重要性分辨不出真正变量 X_1 和噪声变量 $X_2, \dots, X_{10}$, 而前两种能区分出真正变量和噪声变量, 模型二和模型一有着类似的结果。

图3 模型二中 $\varepsilon \sim N(0, 1)$ 四种重要性度量的比较图4 模型二中 $\varepsilon \sim \text{Cauchy}(\text{location}=0, \text{scale}=1)$ 四种重要性度量的比较

最后采用文献[9]中的模型 $Y=10\sin(\pi X_1 X_2)+20(X_3-0.5)^2+10X_4+5X_5+\varepsilon$ 作为模型三, 前5个解释变量 $X_1, \dots, X_5$ 和反馈变量 Y 有关, 其余都是噪声变量。从对图5的分析发现随机误差项服从正态分布时, X_4 在所有方法中都被选为最重要的变量; 平均最小深度最小、被选为根节点

分裂变量的频次最高、随机置换后引起的 MSE 最大、纯度重要性度量的纯度最高。 X_1, X_2 紧随其后, 由于模型中 X_1, X_2 以交叉项出现, 也就容易理解 X_1, X_2 的重要性是一致的; 在真正的5个变量中, X_3, X_5 的重要性是排在最后的, X_5 的重要性略微大于 X_3 。图6反映了和模型一、模型二类似的结果: 在柯西分布中最小深度重要性和根节点分裂变量的频次依然保持了和正态分布几乎完全相同的重要性排序。

图5 模型三中 $\varepsilon \sim N(0, 1)$ 四种重要性度量的比较图6 模型三中 $\varepsilon \sim \text{Cauchy}(\text{location}=0, \text{scale}=1)$ 四种重要性度量的比较

3 总结及展望

通过模拟比较四种重要性度量的性能, 可以看出: 在线性函数模型、二次函数模型和已有文献的复杂模型中, 所有方法在随机误差项服从正态分布时, 都能够明确区分真正变量和噪声变量, 但在随机误差项服从柯西分布时, 最小深度和根节点的分裂频次依然全部区分真正变量和噪声变量, 而置换重要性和节点纯度则区分不出。即在正态分布或渐近正态分布时, 现有的重要性都能够很好地给出度量, 但在厚尾分布时, 最小深度和根节点的分裂频次优势明显, 其中最小深度重要性比根节点的分裂频次在三个模型中的效果更有优势。

随机森林作为一种集成学习算法, 在变量重要性和变量选择问题的研究中被广泛关注。本文对目前基于随机森林的回归模型中的变量重要性度量做了一个比较全面的分析, 以具有代表性的四种变量重要性的基本原理阐述和数值模拟研究了这些重要性度量的性能, 为新方法的设计提供了基础。但也注意到, 在以下两个方面值得做进一

步的探讨:

(1)阈值的选取:大多数的变量重要性度量和变量选择都是基于随机森林的变量平均重要性进行排序,利用阈值作出决策。阈值的确定影响到选出的变量,目前对于阈值没有确定标准,如何能够根据具体的问题,自适应地确定阈值是值得深入研究的。

(2)修剪随机森林和变量重要性的关系研究:通过对随机森林进行修剪,可以从树的相似性、预测率、边缘函数、子森林和随机森林的预测差异是否显著等角度,使得随机森林在可解释性和预测性提高的基础上,进行变量重要性的研究。

参考文献:

- [1]Breiman L. Random Forests [J].Machine Learning,2001,(45).
- [2]Wager S, Athey S. Estimation and Inference of Heterogeneous Treatment Effects Using Random Forests [J].Journal of the American Statistical Association,2017,(114).
- [3]冯盼峰,温永仙.基于随机森林算法的两阶段变量选择研究[J].系统与数学,2018,38(1).
- [4]夏晓圣,陈菁菁,王佳佳,等.基于随机森林模型的中国PM_{2.5}浓度影响因素分析[J].环境科学,2020,41(5).
- [5]Athey S, Wager S, Tibshirani J. Generalized Random Forests [J].Annals of Statistics,2019,(47).
- [6]Ishwaran H, Kogalur U B, Gorodeski E Z, et al. High-dimensional Variable Selection for Survival Data [J].Journal of the American Statistical Association,2010,(105).
- [7]Janitza S, Strobl C, Boulesteix A L. An AUC-based Permutation Variable Importance Measure for Random Forests [J].BMC Bioinformatics, 2013,14(1).
- [8]曹桃云.基于CART模型的不纯度函数在不同数据类型中的分类[J].统计与决策,2018,(10).
- [9]Friedman J H. Multivariate Adaptive Regression Splines [J].The Annals of Statistics,1991,19(1).

(责任编辑/易永生)

Study on the Importance of Variables Based on Random Forest

Cao Taoyun^{a,b}

(a. Laboratory of Big Data and Education Statistics Application, b. School of Statistics and Mathematics, Guangdong University of Finance and Economics, Guangzhou 510320, China)

Abstract: Measurement on the importance of variables is the basis of variable selection. Variable selection has a wide research background in statistical modeling and interpretation prediction of complex data. This paper describes the principle of measuring the importance of variables such as the minimum depth, the splitting frequency of variables in the root node, the importance of substitution, and the purity of nodes in the regression problems, and then uses numerical simulation to study the performance of various importance measurement, thus providing a basis for the design of new methods.

Key words: random forest; minimum depth; splitting frequency; the purity of nodes; substitution importance