

多重筛选逐步回归特征选择法及其应用*

钱 学 双

(中国科学院自动化研究所)

〔提要〕本文介绍了利用统计模式识别中的多重筛选逐步回归特征选择法,对五类白血球进行特征选择,并对所选用的特征用训练集和测试集进行识别效果检验,得到了训练集和检测集上的两个混淆矩阵。

一 引 言

逐步回归分析作为预报因子的选定,已是一种较为成熟的统计计算方法。用于分类判别, R. A. Fisher 在三十年代就提出了构造二元回归模型的思想^[1],以后又有人构造多元回归模型,以用于多类模式的判别^[2]。我们在白血球的计算机自动分类过程中,根据五类细胞的判别,按图1树状分类器的各个节点构造二元回归模式。对所需特征进行多重筛选,反复




图 1 树状分类器

比较,从而找出该节点分类效果最好的特征子集。根据文献[3]描述白血球的187个特征,对白血球中嗜中性 (NEU), 淋巴 (LYM), 单核 (MON), 嗜酸 (EOS), 嗜硷 (BAS) 五类细胞进行特征选择。用1204个细胞样本,一半作训练集,一半作测试集进行识别效果检验。五类细胞总识别率,训练集内为89.9%,测试集内为83.7%,结果较为满意。

二 方法、过程及程序流程

1. 方法概述

我们知道,逐步回归研究的是回归方程各因子 $(x_1, \dots, x_n)$ 与因变量 y 的关系程度,通过方差贡献找出对 y 关系最为密切、最具代表性的 p 个因子,建立偏回归方程

$$\hat{y} = b_{k0} + \sum_{i=1}^p b_{ki} x_{ki} \quad (1)$$

若从 l 个回归因子中去掉一个因子 x_i , 此时对 y 的方差贡献^[3]为

$$Q_i = \sum_{j=1}^l b_{ij} s_{ij} - \sum_{j=1}^l b'_{ij} s_{ij} \quad (2)$$

其中 b'_{ij} 为去掉 x_i 后从剩下诸因子中得到的回归方程中的权系数。剩余平方和为

$$Q_{\text{余}} = \sum_{j=1}^l b_{ij} s_{ij} \quad (3)$$

这里 b_{ij} 由公式 (4) 确定。

$$\sum_{i=1}^l \sum_{j=1}^l s_{ij} b_{ij} = s_{iy} \quad (4)$$

其中

$$s_{ij} = \sum_{t=1}^m (x_{it} - \bar{x}_i)(x_{jt} - \bar{x}_j) \quad (5)$$

$$s_{iy} = \sum_{t=1}^m (x_{it} - \bar{x}_i)(y_t - \bar{y}) \quad (6)$$

* 收到本文的时间是1985年11月30日。

可作统计量

$$F = \frac{Q_i}{Q_{\text{余}}} (m-l-1) \quad (7)$$

由自由度为 $(1, m-l-1)$ 和给定的信度 α , 确定 F 分布的临界值 F_α , 并假设 $H_0: b_i = 0$. 若假设成立, $F \leq F_\alpha$, x_i 应从方程中剔除, 否则保留。

选入因子 x_{l+1} , 可作统计量

$$F = \frac{Q_{l+1}}{Q_{\text{余}}^+} (m-l-2) \quad (8)$$

Q_{l+1} 表示增加因子 x_{l+1} 后的剩余平方和。

$$Q_{\text{余}}^+ = Q_{\text{余}} - Q_{l+1} \quad (9)$$

仍作假设 $H_0: b_{l+1} = 0$, 由自由度 $(1, m-l-2)$ 和信度 α 可得 F 的临界值 F_α , 若 $F > F_\alpha$, 拒绝 H_0 , 将 x_{l+1} 引入方程, 否则不予引入。

2. 多重筛选特征选择过程

设 A, B 分别为两类细胞, 其特征数据矩阵分别为

$$X^A = (x_{g,j}^a)_{m_a \times (n-1)} (g=1, \dots, m_a; j=1, \dots, (n-1)) \quad (10)$$

$$X^B = (x_{t,j}^b)_{m_b \times (n-1)} (t=1, \dots, m_b; j=1, \dots, (n-1)) \quad (11)$$

回归变量 y 设置为

$$y = \begin{cases} 1 & x \in A \text{ 类细胞} \\ 0 & x \in B \text{ 类细胞} \end{cases} \quad (12)$$

两特征矩阵合并, 并加入回归变量 y 的设置

$$X = (x_{v,j})_{m \times n} = \begin{pmatrix} x_{11}^a & \cdots & x_{1,n-1}^a & 1 \\ \vdots & & \vdots & \vdots \\ x_{m_a,1}^a & \cdots & x_{m_a,n-1}^a & 1 \\ x_{11}^b & \cdots & x_{1,n-1}^b & 0 \\ \vdots & & \vdots & \vdots \\ x_{m_b,1}^b & \cdots & x_{m_b,n-1}^b & 0 \end{pmatrix} \quad (13)$$

这里 $m = m_a + m_b$.

对 X 阵进行规格化处理, 并通过求协方差矩阵 S 和相关矩阵 R 确定方程组

$$r_{i1}b_1 + r_{i2}b_2 + \cdots + r_{in}b_{n-1} = r_{iy} \\ i = 1, \dots, n \quad (14)$$

这里 $S = (s_{ij})_{n \times n}$ (15)

$$s_{ij} = \sum_{j=1}^m (x_{vi} - \bar{x}_i)(x_{vj} - \bar{x}_j) \quad (16)$$

$$R = (r_{ij})_{n \times n} \quad (17)$$

$$r_{ij} = s_{ij} / \sigma_i \sigma_j \quad (18)$$

$$\text{其中 } \sigma_i = \sqrt{s_{ii}} \quad (19)$$

R 相关矩阵最后一列不参加选元, 其中各回归因子的方差贡献由公式 (20) 确定。

$$Q_i^{(l)} = Q_i^{(l-1)} V_i^{(l)} \quad (20)$$

$$\text{其中 } V_i^{(l)} = r_{in}^{(l)} r_{in}^{(l)} / r_{ii}^{(l)} \quad (21)$$

$Q_i^{(l)}$ 为第 l 步矩阵变换中第 i 个因子当前的方差贡献。因 $\sigma_i^{(l)}$ 恒定, 方差贡献大小最终决定于 $V_i^{(l)}$ 。若 $V_i^{(l)} < 0$, 表明 x_i 在第 l 步偏回归方程中; 若 $V_i^{(l)} > 0$, 表明 x_i 不在第 l 步回归方程中。对 $V_i^{(l)}$ 小于零的所有因子, 找出其中 $V_i^{(l)}$ 的绝对值最小者, 记为 V_{kmin} ; 对 $V_i^{(l)}$ 大于零的所有因子, 找出其中 $V_i^{(l)}$ 最大者, 记为 V_{kmax} 。由公式 (22) 计算统计量 F , 并与设定的临界值 F_α 相比较, 考虑是否剔除和引入。

$$F = \begin{cases} |V_{kmin}|(m-l-1)/r_{nn}^{(l)} \sim F(1, m-l-1), & \text{当 } V_i^{(l)} < 0 \\ V_{kmax}(m-l-2)/(r_{nn}^{(l)} - V_{kmax}) \sim F(1, m-l-2), & \text{当 } V_i^{(l)} > 0 \end{cases} \quad (22)$$

利用逐步回归方法进行特征选择, 其回归变量 y 是人工设置, 即强迫细胞的特征参量与“0”“1”结缘, 因此选元过程与有些文献上的“先进后出”^[4]有所不同, 而是多重筛选, 有进有出。这里包括四个循环域。首先, 对当前已在偏回归方程中的因子 (全部 $V_i < 0$ 的项), 逐个通过 F 统计量检验, 考察是否可以剔除, 直到均不能剔除为止。其次, 对当前不在回归方程中的因子, 根据方差贡献的大小和 F 统计量检验, 确定哪些因子可以引入回归方程。第三, 在前两步的基础上, 对回归方程中的所有参量 (包括第一步留下的和第二步选入的参量) 再次进行筛选, 在新的变量子集中是否可以将某些参量剔除。最后, 对当前回归方程之外的全部因子 (包括第一、三步删除的和第二步留下的), 检验它们之中的变量是否有可能再次引入。通过这四重筛选, 最后留在回归方程中的参量即为所需选用的最佳特征子

集。

最终选定的特征数量，还取决于统计量临界值设定 F_α ，在选元过程中，有时要根据识别效果来调整 F_α 的值。根据白血球特征选择情况， F_α 一般取值在1—10之间。

主元选定后，还要以主元因子为轴心进行“高斯-若当”变换。这一过程通过公式(23)——(26)来实现。

$$r_{ij} = r_{ij} - r_{ik} \cdot r_{kj} / r_{kk} \quad i, j \neq k \quad (23)$$

$$r_{ik} = -r_{ik} / r_{kk} \quad i \neq k \quad (24)$$

$$r_{kj} = r_{kj} / r_{kk} \quad j \neq k \quad (25)$$

$$r_{kk} = 1 / r_{kk} \quad \text{其他} \quad (26)$$

其中 r_{kk} 为选定的第 k 个特征为轴心的主元。

回归权系数由公式 (27)，(28) 给出。

$$b_j = r_{jn} \sigma_n / \sigma_j \quad (27)$$

$$b_0 = \bar{x}_n - \sum_{j=1}^L b_j \bar{x}_j \quad (28)$$

L 为最后选入回归方程中的因子的数量，即入选特征个数。 $\bar{x}_n$ 为所设定的回归变量 y 经 l 步变换后的平均值。

3. 程序框图及说明

图2为实现多重筛选逐步回归特征选择法编拟的程序流程图。程序用FORTRAN语言编写，分别在HP-3000和NOVA-4X计算机上实现。

框图中<1>—<3>为数据输入，回归变量设置，矩阵合并，求协方差矩阵和相关矩阵。

<4>—<21>为特征选择过程的核心，它反映多重筛选逐步回归选择法的全过程。这一阶段又大致包括本阶段的准备，将全部需计算的参数和程序中的数组单元清零或置数，并计算全部因子的方差贡献和参量 V_j 。<8>—<11>为寻找所有不在 L 步回归方程中的因子方差贡献最大者，考虑是否可以引入回归方程。<12>，<13>和<10>，<11> 为寻找当前 L 步回归方程里的因子中方差贡献最小者，考察是否可以将其剔除出方程。<14>—<17>在全部已选定好的因子中，再次进行检验，找出其中方差贡献最小

者，以决定其弃留。<18>—<21>对最后剩下的方程外的参数进行检验，以决定最后有没有可以引入的特征参量。

框图<22>为选元结束后计算 L 步回归方程的权系数 b_i 和零指数项 b_0 。<23><24>为识别效果检验，这一步是对特征选择效果和统计量 F_α 的设置量大小是否合适的全面考核。此步是以得到的回归方程作为判决函数，将参加训练的两类细胞按选定的特征集逐一代入方程进行识别率的检验。因为两类细胞回归变量设置为“1”和“0”，两者之中值0.50为 y_A 和 y_B 的判决阈值。大于0.50属A类，小于0.50属B类。




图2 程序流程图

三 识别效果检验

在图象识别过程中,识别率的高低是检验图象处理、特征选择和分类器设计等处理方法的基本标准,由于多类细胞采用二值判决,我们设计了图1那种树状结构的分类器。它是根据血液学专家和化验员的经验,并在参考其他一些选元方法^[5]的基础上建立的。由于本文主要介绍特征选择方法,对分类器设计的最佳性问题这里不予讨论。

文献[3]描述的白血球各类细胞特征包括光密度参数、几何参数和纹理参数共187个。由于计算机内存容量的限制,不能同时将全部参量当成特征选择的基元。按其物理属性和数学意义,将它们分成六个特征组,即①光密度参数组(24个),②基本几何参数组(22个);③细胞核轮廓的各阶付氏级数系数组(80个),④灰度共生矩阵组(20个),⑤灰度游程长度矩阵组(20个),⑥梯度一阶统计及灰度共生矩阵组(21个)。先从各组选出一定的特征,再从这些入选的特征中选取最佳特征子集。

全部细胞子样共1204个。其中嗜中性细胞400个,淋巴细胞282个,单核细胞170个,嗜酸性细胞254个,嗜硷性细胞98个。各类细胞依次排队,序号为奇数的细胞作训练集,偶数的为测试集。

下面列出图1分类器四个节点上的选元情况,该点的回归方程以及训练集和测试集中的识别率。

第一节点 对嗜中性与淋巴、单核、嗜酸、嗜硷细胞分类: ($F_a = 2$)

入选特征(共11个):

9, 16, 25, 28, 29, 32, 131, 136, 137, 166, 178

回归方程: $y = 5.96984 - 0.70498x_9 + 0.01056x_{16} - 0.12577x_{25} + 0.22059x_{28} + 0.00103x_{29} - 0.00146x_{32} - 0.02141x_{131} + 0.02702x_{136} - 0.11843x_{137} + 0.01731x_{166} + 0.23887x_{178}$

识别率:

训练集 97.01% 测试集 96.18%

第二节点 对淋巴、单核与嗜酸、嗜硷细胞

分类: ($F_a = 7$)

入选特征(共11个):

6, 25, 37, 128, 133, 140, 141, 145, 170, 176, 183

回归方程: $y = 4.25095 - 0.01810x_6 + 0.31884x_{25} - 0.248963x_{37} + 4.84842x_{128} - 2.49861x_{133} - 46.7629x_{140} - 0.01987x_{141} + 2.6724x_{145} + 2.09137x_{170} + 0.58029x_{176} + 0.53510x_{183}$

识别率:

训练集 93.78% 测试集 88.31%

第三节点 淋巴与单核细胞分类: ($F_a = 1$)

入选特征(共8个):

25, 36, 39, 144, 163, 168, 179, 186

回归方程: $y = 0.87539 + 0.15136x_{25} + 0.02446x_{36} - 0.10049x_{39} + 0.35133x_{144} - 0.00238x_{163} + 0.15482x_{168} + 0.04693x_{179} + 0.78348x_{186}$

识别率:

训练集 94.24% 测试集 88.05%

第四节点 嗜酸与嗜硷的分类: ($F_a = 2$)

入选特征(共10个):

2, 9, 25, 36, 37, 157, 160, 165, 168, 179

回归方程: $y = -3.29107 - 5.25335x_2 + 0.32447x_9 - 0.28651x_{25} + 0.06679x_{36} - 0.42666x_{37} - 0.01955x_{157} - 3.4133x_{160} - 0.01650x_{165} + 0.12253x_{168} + 7.172949x_{179}$

识别率:

训练集 96.02% 测试集 91.47%

为了反映各类细胞总的识别效果,按图1树状流程,分别将训练集和测试集中的细胞(各602个)逐个代入各节点的回归方程统计计算,得到反映训练集和测试集识别状况的两个混淆矩阵(见表1,表2)。矩阵中对角线上的数为正确识别细胞数,元素 a_{ij} ($i \neq j$)为

第 j 类细胞误分到第 i 类细胞中的数。

训练集混淆矩阵 表 1

人判 机判	NEU	LYM	MON	EOS	BAS
NEU	188	3	0	2	1
LYM	2	128	4	7	2
MON	4	8	71	2	2
EOS	2	2	9	115	5
BAS	4	0	1	1	39

测试集混淆矩阵 表 2

人判 机判	NEU	LYM	MON	EOS	BAS
NEU	188	1	0	5	5
LYM	1	127	15	12	1
MON	4	7	61	10	5
EOS	3	6	8	97	7
BAS	4	0	1	3	31

通过识别统计,训练集中分对的细胞数(表 1 对角线元素总和)为 541 个,识别率为 89.9%;测试集中分对的细胞数(表 2 对角线元素总和)为 504 个,识别率为 83.3%。

(上接第 41 页)

和扩展。若对内容丰富、功能较多的主要模块采用哑实结合的形式,则将因为过多地设置哑元而增加编写困难和留下隐患,低层子程序不使用公用区减少了公用区管理的难度,而且使得低层功能块具有更强的通用性,易于他途。

结 语

MFCSDP 经过反复检验与实例应用证明

四 结 语

多重筛选特征选择法,能多次对各回归因子以充分的挑选机会,经反复剔除和引入,从而得到最佳特征子集。分类结果表明,它是统计模式识别中一种比较好的特征选择方法。

这项工作曾得到洪继光及有关同志的热情帮助,在此表示衷心感谢。

参 考 文 献

- [1] Fisher, R.A., The Use of Multiple Measurements in Taxonomic Problems, Ann. Eugen., 7, 1936, 179—188.
- [2] 杨自强, 用多因变量逐步回归作多类逐步判别, 计算数学, 1979 年第 3 期。
- [3] 洪继光等, 细胞图象的特征描述, 信息与控制, 1983 年第 3 期。
- [4] 南京大学数学系计算数学专业, 概率统计基础和概率统计方法, 科学出版社, 1977。
- [5] Cochran W.G., The Omission or Addition of an Independent Variate in Multiple Linear Regression, Supplement to the Journal of the Royal Statistical Society, Vol. 5, No. 2 (1938).
- [6] 钱学双, 类间散度特征选择法及其应用, 自动化学报, 1986 年第 1 期。

设计是合理的, 结构清晰, 可读性强, 易于修改和扩展, 设计方法适用、有效, 使用方便, 结果可行、可靠。因此, 可以认为 MFCSDP 的设计目标已经达到, 今后的发展, 应是更全面的功能设置和更加面向实际问题的命令语言。工程数据库、知识库以及某些“自学习”功能的设置则将使 CAD 软件系统具有更强的功能。以问题求解语言形式出现的, 以公共数据库为核心的一体化、工程化软件系统是 CSCAD 系统的发展方向。

ABSTRACTS

Adaptive Control for a Class of Discrete Time Systems with Input Nonlinearity

Zhang Jingxin Lang Shijun

This paper has studied the adaptive control for the discrete time linear system having input nonlinearity of asymmetric gain with dead zone. Describing dead zone as an equivalent disturbance, the authors present an adaptive control algorithm which can effectively eliminate the effect of such nonlinearity. Simulation results show that the algorithm works well in both stochastic and deterministic situation.
(p.1)

A Multiple Sieving Stepwise Regression Method for Feature Selection and Its Application

Qian Xueshuang

In this paper, a multiple sieving stepwise regression method for feature selection in statistical pattern recognition is introduced. The method is applied to feature selection for five classes of leucocyte, and the recognition effectiveness of the selected features is examined with train set and test set. Two mixed-matrices in the train set and test set are obtained. (p.6)

A Syntax-Directed Expanding-Shrinking Method of Outline-Drawing — Computer Assisted Outline-Drawing in Squared Paper Design of Silk Figured Fabric

Yao Chengfu

The outline-drawing in squared paper design is to modify boundaries of given 4-connected regions representing figures in a squared paper picture. Based on some concepts about the set of boundary points in a digital picture, the paper gives a mathematical description to the requirements of outline-drawing, and in analogy to the handed work, regards the modification of boundaries as the expanding and shrinking of edges. In order to make sure of necessary modifications automatically, the paper regards the boundaries of 4-connected regions satisfying a certain kind of outline-drawing as a boundary pattern, and thus put forward a syntax-directed expanding-shrinking method. The method is suitable for the realization of an interactive processing in computer and therefore can be applied in CAD of squared paper design.
(p.11)