

分类号: _____

密级: _____

UDC: _____

编号: _____

工学博士学位论文

面向医学数据的随机森林特征选择及分类方法 研究

博士研究生: 姚登举

指导教师: 杨 静 教授

学科、专业: 计算机应用技术

哈尔滨工程大学

2016 年 3 月

分类号: _____

密级: _____

UDC: _____

编号: _____

工学博士学位论文

面向医学数据的随机森林特征选择及分类方法 研究

博士研究生: 姚登举

指导教师: 杨静 教授

学位级别: 工学博士

学科、专业: 计算机应用技术

所在单位: 计算机科学与技术学院

论文提交日期: 2015 年 09 月 15 日

论文答辩日期: 2016 年 03 月 10 日

学位授予单位: 哈尔滨工程大学

Classified Index:

U.D.C:

A Dissertation for the Degree of D. Eng

Research on feature selection and classification
method based on random forest for medical
datasets

Candidate: Yao Dengju

Supervisor: Prof. Yang Jing

Academic Degree Applied for: Doctor of Engineering

Specialty: Computer Applied Technology

Date of Submission: Sept. 15, 2015

Date of Oral Examination: Mar. 10, 2016

University: Harbin Engineering University

摘 要

医学数据挖掘是数据挖掘技术的重要研究方向,多年来始终是计算机科学和医学领域的研究热点。近年来,医学数据挖掘对象正逐渐由临床诊断数据转变到基因芯片数据。目前,许多优秀的数据挖掘算法被应用于各种医学研究工作中,如决策树、支持向量机和人工神经网络等。然而,医学数据所固有的高维特征空间、高度特征冗余、特征高度相关、样本类别不平衡等特点以及医学研究对于数据挖掘结果的可理解性要求,使得传统的数据挖掘算法难以直接应用于医学数据挖掘任务中。

随机森林算法是一种基于决策树的集成机器学习算法。一方面,随机森林因为具有分类精度高、运算速度快、能够从具有小边际效应和复杂相互作用的特征中识别主相关特征的优点,在医学数据分析中得到广泛应用;另一方面,有研究表明随机森林在类别不平衡数据集和高维数据集上,其分类能力和稳定性会受到削弱。针对医学数据集的特征高维性、冗余性、相关性以及样本类别不平衡等问题,本文以 UCI 标准数据集、糖尿病临床诊断数据集和基因芯片数据集为对象,研究了基于随机森林的特征选择和数据分类方法,主要开展了以下几个方面的工作。

首先,针对医学数据集的样本类别不平衡问题,提出了一种基于有放回地随机重采样技术和集成机器学习思想的随机森林改进算法。该算法首先从原始训练数据集中利用有放回地随机重采样技术构建样本类别平衡的数据集,然后在每一个采样数据集上训练随机森林分类器,最后所有采样数据集上生成的随机森林分类器通过多数投票方式确定未知样本的分类类别。在 UCI 数据集上的实验结果表明,与传统的基于随机降采样和基于代价敏感的方法相比,本文提出的算法能够有效提高分类器的分类性能尤其是少数类样本的查全率。

其次,针对医学临床数据集的高维特征空间和特征间高度相关问题,提出了一种基于随机森林的 Filter 式特征选择算法。该算法首先基于随机森林变量重要性分数对数据集中的特征进行排序,然后通过迭代实验确定特征选择的阈值,选取重要性分数最大的前若干个特征构成特征子集,最后在选出的特征子集上训练分类器。在 UCI 数据集和糖尿病临床数据集上的实验结果表明,基于随机森林变量重要性分数的算法的分类性能明显高于现有的基于特征子集区分度和特征相关性等度量的算法。

再次,针对医学数据集特征之间高度相关和高度冗余的问题,提出了一种基于随机森林和序列联合搜索策略的 Wrapper 式特征选择算法。该算法利用随机森林善于从

具有小边际效应和复杂相互作用的特征中识别主相关特征的能力，以随机森林变量重要性分数作为特征重要性度量，采用序列后向和序列前向相结合的序列联合特征搜索策略选择特征子集，以特征子集上分类器的分类正确率评价特征子集的质量，最后选择分类正确率最高的特征子集作为最优特征子集。在 UCI 数据集、糖尿病临床数据集和微阵列表达数据集上的仿真实验表明，本文提出的算法的分类正确率和特征子集质量均优于基于过滤式的方法和基于其它度量的方法。

最后，针对微阵列表达数据集存在大量不相关特征、噪声特征和冗余特征的问题，提出了一种基于 Filter 和 Wrapper 相结合的随机森林特征选择算法。该算法首先采用 Filter 特征选择算法过滤掉与目标变量明显不相关的基因，然后采用基于随机森林的 Wrapper 特征选择算法选择最优特征子集。在 Wrapper 特征选择过程中，针对微阵列表达数据的特点，基于随机森林变量重要性分数，提出了序列前向特征选择和序列后向特征选择相结合、分层剔除冗余特征和不相关特征的特征搜索策略。在微阵列表达数据集上的仿真实验表明，本文提出的算法在分类正确率上优于现有的算法。

关键词：医学数据挖掘；特征选择；微阵列表达数据分析；随机森林；支持向量机

Abstract

Data mining in medicine is one of the important research directions of data mining technology. It is always the research hotspot in the field of computer science and medical research for many years. In recent years, the medical data mining is gradually changing from medical clinical data to the gene chip data, and many excellent data mining algorithms have been applied to a variety of medical research, such as Decision Tree, Support Vector Machine and Artificial Neural Network. However, it is difficult to directly apply the data mining technology to the medical data analysis tasks, which is characterized by high dimensional feature space, existing complex interactions among multiple features, imbalanced example classes, and the requirements of transparency and intelligibility of data mining results in medicine and life science, etc..

Forest Random algorithm is a kind of ensemble machine learning algorithm based on decision tree. On the one hand, It has be widely used in medical data analysis because of its high classification accuracy, fast computing speed and the capacity aof identifying the main related features from the datasets with small marginal effect and complex interaction among features. On the other hand, there are studies that show that the classification ability and the stability of the random forest are weakened in the imbalanced datasets and high dimensional datasets. In this paper, aiming at the characteristics of medical datasets, such as high dimension, redundancy, correlation and sample class-imbalanced, this paper studies the feature selection and data classification method based on random forest, which is based on UCI standard data set, diabetes clinical dataset and gene chip datasets. The paper mainly focuses on the following aspects.

Firstly, a new random forest classification method based on Bootstrap data sampling technique is proposed to improve the classification performance of random forest classifier on medical datasets with imbalanced sample classes. The algorithm firstly constructed class-balanced training datasets from the original training sample dataset using random re-sampling technology with a back, then trained a random forest classifier on each sampling training dataset, and finally the classification of unknown samples is determined by the majority voting method. Simulation experiments on UCI standard datasets show that

the proposed algorithm can effectively improve the precision while maintain higher recall in class-imbalanced datasets compared with algorithms based on random under sampling and based on cost-sensitive.

Secondly, a new filter feature selection algorithm based on random forest is proposed for the high dimensional feature space and height correlation among features of medical clinical dataset. The method is based on the variable importance scores of random forests, and the threshold of feature selection is determined through the iterative experiments. Then, the algorithm select top k features with the largest important score to result feature subsets, and finally training classifiers on the selected feature subset. Simulation experiments on UCI standard datasets and independently collected diabetes clinical datasets show that the classification accuracy of the proposed algorithm are obviously higher than algorithms based on Discernibility of Feature Subsets and Correlation based Feature Selector.

Thirdly, aiming at the problems of complex mutual effects among multiple features and higher feature redundancy in medical datasets, a new Wrapper feature selection algorithm based on random forest is proposed. The method select the best optimal features subset from the original feature space based on variable importance scores of random forest algorithm, using the random forest's advantage of recognizing main related features from datasets with small marginal effect and the complex interactions among multiple features. It combines the SBS and SFS feature searching strategy and uses the classification accuracy of classifier on the feature subsets as evaluation function of the feature subset. Finally, the feature subset with the highest classification accuracy is used as the optimal feature subset. Simulation experiments on the UCI standard data sets and real clinical diabetes dataset show that the proposed algorithm can effectively improve the quality of the selected optimal feature subset and classification accuracy of SVM classifier, and its performance is better than the existed algorithms based on Filter and based on other criteria.

Finally, aiming at the problem there are lots of noisy data, redundant genes and unrelated genes in microarray expression dataset, a new feature selection method based on the combination of Wrapper and Filter is proposed. The proposed algorithm first filter out apparently unrelated noise gene using Filter feature selection algorithm based on statistical, and then select the optimal subset of features using Wrapper feature selection method based

on random forest. In the process of Wrapper feature selection, based on the variable importance measure of the random forest algorithm, a feature searching strategy is proposed, which combined the sequence forward feature search and the sequence backward search strategy and eliminated the unimportant and redundancy features iteratively in stratified feature space. Simulation experiments on micro-array expression datasets show that the proposed algorithm is superior to the existing algorithms in the classification accuracy.

Keywords: data mining in medicin; feature selection; micro-array expression data analysis; random forest; support vector machine

目 录

第 1 章 绪论	1
1.1 研究背景及意义	1
1.2 医学数据的特点	3
1.2.1 多样性和异质性	3
1.2.2 样本类别不平衡和内容不完整	3
1.2.3 特征高维性、冗余性和高度相关性	3
1.3 国内外研究现状	4
1.3.1 医学数据挖掘研究现状	4
1.3.2 特征选择技术研究现状	7
1.3.3 类别不平衡数据分类研究现状	11
1.3.4 随机森林算法研究现状	13
1.4 论文研究思路及主要研究内容	18
1.5 论文组织结构	20
第 2 章 面向类别不平衡数据集的 RF 分类算法研究	23
2.1 引言	23
2.2 概念定义	26
2.3 随机森林模型	28
2.3.1 随机森林的定义	28
2.3.2 随机森林的收敛性	28
2.3.3 随机森林的泛化误差上界	29
2.3.4 随机重采样技术	31
2.3.5 训练决策树	32
2.3.6 随机森林算法	33
2.4 面向类别不平衡数据集的 RF 分类算法 BRF	33

2.4.1	BRF 算法设计	33
2.4.2	算法分析	35
2.5	实验及结果分析	37
2.5.1	实验设计	37
2.5.2	实验数据与参数设置	38
2.5.3	实验一结果及分析	39
2.5.4	实验二结果及分析	41
2.5.5	参数设置讨论	42
2.6	本章小结	46
第 3 章	基于 RF 的 Filter 式特征选择算法研究	47
3.1	引言	47
3.2	算法基础及相关工作	48
3.2.1	特征选择的概念	48
3.2.2	特征选择的分类	49
3.2.3	特征相关性度量	52
3.2.4	变量重要性分数	54
3.2.5	多元自适应回归样条 MARS	56
3.3	基于 RF 的 Filter 式特征选择算法	58
3.3.1	算法设计	58
3.3.2	算法分析	60
3.4	仿真实验及结果分析	61
3.4.1	实验数据及参数设定	61
3.4.2	特征选择与分类性能分析	61
3.4.3	参数设置分析	64
3.4.4	在糖尿病临床数据集上的结果分析	67
3.5	本章小结	69

第 4 章 基于 RF 的 Wrapper 式特征选择算法研究	71
4.1 引言	71
4.2 基于 RF 和 GSBS 的 Wrapper 式特征算法	72
4.2.1 算法设计	72
4.2.2 时间复杂度分析	73
4.3 RF-GSBS 算法实验分析	74
4.3.1 实验数据与环境	74
4.3.2 评价函数的性能分析	75
4.3.3 特征选择过程分析	75
4.3.4 算法的有效性分析	79
4.3.5 参数 L 的设置讨论	80
4.4 基于 RF 的序列联合特征搜索策略	81
4.4.1 算法设计	82
4.4.2 时间复杂度分析	84
4.5 仿真实验及结果分析	84
4.5.1 实验数据集	84
4.5.2 UCI 数据集和 HYDD 数据集上的实验	85
4.5.3 ALLb 数据集上的实验	87
4.6 本章小结	88
第 5 章 面向微阵列表达数据的 RF 特征选择算法研究	89
5.1 引言	89
5.2 相关工作	90
5.3 面向微阵列表达数据的 RF 特征选择算法	91
5.3.1 基因过滤	92
5.3.2 分层特征搜索策略	93
5.3.3 特征子集评价函数	94

5.3.4	基于分层特征搜索策略的 RF 特征选择算法·····	94
5.3.5	算法的时间复杂度分析·····	97
5.4	实验分析·····	98
5.4.1	实验数据集·····	98
5.4.2	参数设置讨论·····	100
5.4.3	基因过滤结果·····	100
5.4.4	特征选择算法的性能比较·····	101
5.4.5	分层特征搜索策略的性能分析·····	101
5.4.6	特征子集评价算法研究·····	106
5.5	本章小结·····	109
结 论	·····	111
参考文献	·····	113
攻读博士学位期间发表的论文和取得的科研成果	·····	125
致 谢	·····	126
个人简历	·····	127

第1章 绪论

1.1 研究背景及意义

信息技术高速发展，各行各业积累了大量的甚至是海量的数据，人类社会已经进入到大数据时代。“数据爆炸、知识贫乏”成为信息时代的真实写照，如何从日益丰富的数据中发现有价值的信息成为统计学、机器学习、人工智能等领域的研究热点。数据挖掘（Data Mining，DM）是当前最流行的数据分析技术之一，通过数据挖掘，可以将隐含的、尚不为人所知的同时又是潜在有用的信息从数据中提取出来，建立计算机程序以发现规律或者模式^[1]。近年来，各种数据挖掘技术已经被广泛应用于电信、保险、环境、金融、医学等数据分析任务中。数据挖掘技术从被提出之日起就被应用到医学数据研究中，随着医学研究对象逐渐从临床诊断数据到生物信息学数据转变，医学数据挖掘日益成为数据挖掘技术最活跃的研究与应用领域之一。

一方面，长期以来，各大医院收集保存了大量的临床诊断数据，这些数据既包括对病人的血糖、血脂、肝功、肾功等生物指标进行测验得到的数值数据，还包括病人的身高、体重、年龄、性别、职业等自然数据，以及疾病史、吸烟史、饮酒史、患病症状、用药及治疗方案等众多非数值数据，同时病人的临床数据随着时间的推移也会不断发生变化。这些临床诊断数据中蕴藏着大量的有价值的信息，对不同疾病患者的临床诊断数据进行数据挖掘，有助于发现与该疾病相关的发病规律、危险因素及其之间的相互影响，为疾病的临床诊断和治疗提供参考。然而，由于临床诊断数据固有的模式多态性、内容不完整性、高维特征空间、高度特征冗余、特征高度相关以及样本类别不平衡等特点，传统的医学统计学方法已经不能满足解决此类复杂问题的需要。

另一方面，随着近年来生物学技术和生物信息学技术的快速发展，人们积累了大量的生物学尤其是分子生物学实验数据，并建立了众多的生物信息学数据库，如核酸序列数据库（GenBank、EMBL 等）、蛋白质序列数据库（PIR、MIPS 等）、基因注释数据库（GO、KEGG 等）、SNP 数据库（Hapmap 等）。为了检测基因的表达水平，人们于 20 世纪 90 年代开发了 DNA 微阵列芯片，即基因芯片，通过 DNA 微阵列实验能够同时测量出成千上万个基因甚至是全基因组的表达水平值，这些数据被称为基因表达数据。基因芯片表达数据是典型的“高维小样本”数据，数据集中的基因个数通常可以达到几千甚至几万，样本数量则只有几十个或上百个，并且

由于随机干扰因素较多，检测数据的误差较大。由于具有相似功能的基因的表达水平高度相关，微阵列表达数据集中存在大量的对分类无意义的基因（噪声基因、冗余基因、不相关基因），这使得传统的分类算法对于分析基因表达数据面临很大的挑战，并导致了“维数灾难”和“过拟合”（Over-fitting）问题^[2]。目前，基因芯片数据的分类和特征提取成为研究的热点和难点^[3-5]。

多年来，有众多的统计学方法和机器学习方法被用于医学数据分类和疾病危险因素分析，包括主成分分析（Principal Components Analysis, PCA）、Logistic 回归（Logistic Regression）、线性判别分析（Linear Discriminant Analysis, LDA）、二次判别分析（Quadratic Discriminant Analysis, QDA）、支持向量机（Support Vector Machine, SVM）、径向基函数神经网络（Basis Function Neural Networks, BFNN）、多层感知器神经网络（Multilayer Perceptrons Neural Networks, MLPNN）、人工神经网络（Artificial Neural Network, ANN）、分类回归树（Classification And Regression Tree, CART）等，并取得了许多创新性的研究成果。然而，由于医学临床数据和微阵列表达数据固有的高维特征空间、高度特征冗余以及样本类别不平衡等特点，特别是由于影响疾病的众多因素或者基因之间存在着复杂的相互作用，特征之间的相关性非常强，许多经典的分类算法在医学数据集上的分类精度并不理想。近年来，随机森林（Random Forest, RF）算法由于具有分类精度高、运算速度快、鲁棒性好等优点，尤其是其能从具有小边际效应和高度相关性的特征集合中识别出主相关特征，被广泛应用于医学数据分析任务中。

针对医学数据所具有的高维特征空间和高度特征冗余问题，在对医学数据进行挖掘时，执行特征选择操作是十分必要的。特征选择技术可以帮助人们理解数据，简化机器学习和数据挖掘模型，降低训练模型的计算时间开销，保持或提高模型的分类或预测性能，有效地避免“维数灾难”的发生^[6]。随机森林算法通过随机扰动样本的方法计算变量重要性分数，有助于人们理解特定的分类变量对于目标变量的重要程度，以变量重要性分数为评价准则对医学数据集进行特征选择，进而搜索与目标变量最相关的特征子集，是探索疾病危险因素的一个有效途径。

本文主要针对医学数据具有的高维特征空间、高度特征冗余、特征间高度相关、样本类别不平衡以及医学数据挖掘结果的可理解性需求等问题，研究基于随机森林的各种特征选择及数据分类算法，在保持或提高分类算法的分类性能的同时，降低算法的运行时间，优化特征子集，使数据挖掘结果具有更好的透明性和可理解性。本课题属于计算机科学、生物医学、生物信息学学科交叉研究，研究成果不仅可以丰富机器学习和数据挖掘算法，促进数据挖掘和机器学习技术在医学领域的应用，

而且有助于丰富医学研究方法，利用数据挖掘技术探索疾病的发病规律、危险因素和生物标记，为医学专家临床诊断病情、确定治疗方案以及进行医学研究提供科学依据和决策支持。因此，本课题既具有较强的理论研究意义，也具有重要的实际应用价值。

1.2 医学数据的特点

1.2.1 多样性和异质性

医学数据的多样性和异质性是其不同于其他领域的数据对象的重要特征。由于医学数据来源于医学成像、化学检验、医生和病人的交流等，原始的医学数据呈现出多种形式，包括数值数据（例如体征参数、化验结果等）、信号数据（例如心电图、脑电图等）、图像数据（例如B超图像、CT图像等）、文本数据（例如患者身份、症状描述、诊断记录等）。这些数据之间存在巨大的异质性，因为对图像数据及其它临床数据的理解是由非结构化语言描述的，难以进行标准化，甚至有时候同一科室的不同医学专家对于同一个病例会给出不同的诊断和治疗意见，他们可能使用不同的名称来描述同一类疾病，或者使用不同的语法结构描述医药条目之间的关系。所以，对原始的医学数据进行数据挖掘是非常困难的，需要对数据进行预处理或研究新的适应医学数据特点的数据挖掘算法。

1.2.2 样本类别不平衡和内容不完整

由于医学研究的特殊性，医学检验成本以及伦理学限制等因素，医学数据库中的数据大多是针对某类疾病患者的。医学研究中应用的样本通常分为案例组和对照组，对照组的数据多是来源于志愿者。这导致医学数据集中样本类别分布的严重失衡，通常是患有某类疾病的样本的数据量远远大于未患病样本的数据量。另外，由于医学案例的有限性，不可能做到任何类型的医学数据都被完整地保存到数据库中，客观数据不完整和疾病主观描述不准确导致医学信息的不完整。同时，由于人为因素，医学数据可能存在偏见和片面的记录，许多医学记录本身的描述就是不确定的和模糊的。因此，医学数据挖掘不同于其他领域的数据挖掘。研究面向样本类别不平衡医学数据分类的分类算法是本文研究的一项重要内容。

1.2.3 特征高维性、冗余性和高度相关性

医学数据库是一个庞大的数据资源，包含大量不同类型的数据记录，通常描述这些

数据的特征数量很大,可以达到几十或上百种,这就导致医学数据集的高维特性。另外,临床治疗中每天都会产生大量相同的或部分相同的数据,通常包含大量的内容重复的、和疾病不相关的或者是结果互相矛盾的记录。例如,对于同一种疾病,不同患者的发病症状、生化检验结果和采取的治疗措施可能都是不同的。这就导致数据集中很多特征是冗余的或者是噪声的。再者,医学数据集中不同的参数和指标之间可能是高度相关的,比如患者的身高、体重和身体质量指数 BMI 之间存在确定的数值关系,再比如糖尿病临床检验中餐后 30 分钟血糖水平、餐后 60 分钟血糖水平、餐后 120 分钟血糖水平、餐后 180 分钟血糖水平等指标之间存在着复杂的关系。另外,随着测序技术的快速发展,生物医学和生物信息学研究呈现勃勃生机,大量的基因数据或遗传数据被收集和发布,如微阵列表达数据、单核苷酸多态性 (SNP) 测序数据、时间序列数据等,这些数据集的特征维数动辄上万,甚至几十万,针对每个特定研究目标,比如某种疾病类型,大量的特征是不相关的、冗余的或者噪声的,部分特征之间存在着复杂的相互作用(基因互作)。医学数据的高维性、冗余性和相关性对数据挖掘技术提出了新的严峻的挑战,设计能够有效处理这类问题的特征选择及数据分类算法是本文的核心研究内容。

1.3 国内外研究现状

1.3.1 医学数据挖掘研究现状

医学数据挖掘的两个重要研究方向分别是临床数据挖掘和生物信息数据挖掘。对于临床诊断数据集,数据挖掘的任务主要是利用特征选择和机器学习算法探索影响某类疾病发生、发展的疾病危险因素,构建疾病分类与预测模型,为医生临床诊断和制定合理的治疗方案提供决策支持。对于生物信息数据集,数据挖掘的任务主要是针对各种癌症、糖尿病及其并发症、白血病、阿尔茨海默综合症等人类复杂疾病,寻找和发现差异表达基因或遗传位点,进而研究疾病的发病规律,寻找有效的治疗方法。

在医疗诊断领域,数据挖掘主要集中在对诊断数据的分析与处理上,通过对诊断数据的提取、预处理,形成诊断数据集,并利用基于数据特征的分类与预测方法,对病症进行实时预测,为医生提供辅助诊断的手段^[7-8]。随着医院医疗信息化建设的快速发展和高通量测序技术的快速进步,各种可用的医学数据极大丰富,医学数据挖掘的任务需求越来越强烈,医学数据挖掘也成为最活跃的研究领域,来自于统计学、医学、计算机科学等领域的专家学者研究和提出了众多的针对医学数据挖掘的算法。Jinho 等人提出了一种基于特征选择的心电图检测缺血的方法,首先采用特征选择技术选取心电图波形形态,然后采用核密度估计 (Kernel Density Estimation, KDE) 和 SVM 模型对未

知样本进行分类,在欧洲 ST-T 数据库上的实验结果表明,KDE 算法的敏感性和特异性分别为 0.939 和 0.912,从 367 个 ST 段缺血样本中成功识别出 349 个;SVM 算法的敏感性和特异性分别为 0.941 和 0.923,从 367 个 ST 段缺血样本中成功识别出 355 个;在该方法中 KDE 分类器可以自动选择内核带宽而不需要任何先验的参数,SVM 也只需要一个参数^[9]。João Maroco 等人利用 MLP 神经网络、BFNN、SVM、CART、卡方自动交互检测决策树(Chi-squared Automatic Interaction Detection Decision Tree, CHAID decision tree)、QUEST 分类树(Quick Unbiased Efficient Statistical Tree, QUEST)和 RF 等 7 种非参数分类器和 Logistic 回归、LDA 以及 QDA 等 3 种传统的分类器对老年痴呆神经心理测试数据进行了分析,实验结果表明,RF 算法和 LDA 算法的准确性、特异性、敏感性优于其他算法^[10]。Baek 等人使用 SVM 分类和特征选择等多种机器学习技术在不规则和不平衡的糖尿病数据集上准确地预测了糖尿病肾病的发病情况。他们收集了 292 例糖尿病患者的临床数据,经过预处理从不规则数据中提取了 184 个特征,在该数据集上,他们比较了 logistic 回归、SVM、代价敏感 SVM 等方法,并采用了特征选择技术以消除冗余,提高分类性能。实验结果显示:组合了 Wrapper 特征选择的 SVM 分类器表现出最佳效果,从 184 个特征中选择出了 39 个特征,分类模型 AUC 值达到 0.969,该方法可以提前 2-3 个月较准确地预测糖尿病肾病的发病^[11]。Massoud 等人利用对医生医疗处方进行数据挖掘来探索医疗诊断决策以弥补医疗临床指南中的知识缺陷,并且以 2 型糖尿病为例给出了实施数据挖掘的方法,通过分析法国国家 2 型糖尿病管理指南,识别出指南中没有包含的或者(已包含)但没有提供参考意见的临床条件,并针对每一个医疗条件,从法国阿维森纳的波比尼医科大学医治的 2 型糖尿病病人数据库中抽取病历,使用决策树学习算法为每个医疗条件探索医生处方,通过对于有 463 个病历的数据库进行挖掘,抽取出 27 条规则,其中 11 条规则是关于疗法类型的,13 条规则是关于每种药物治疗类型选择的,抽取出的规则显示出与新增加到指南中的规则的相似性^[12]。John 等人利用自适应回归模型对美国成年烟民和非抽烟人群潜在危害生物标识进行分析,该研究使用随机森林方法进行初始变量选择,使用多元自适应回归样条方法进行最终统计模型开发,通过对于 3585 位成年烟民和 1077 个非烟民临床暴露研究的数据挖掘分析,生成了预测每种潜在危害生物标识 BOPH 的模型^[13]。与国外的研究工作相比,国内对于医学数据挖掘的研究起步较晚,但近年来发展迅速。廖等人以数据挖掘技术为基础,以激光诱导自体荧光大肠早癌诊断数据为载体,通过分析诊断数据特征,从数据预处理、训练数据集的形成以及分类预测方法三个方面,对大肠早癌诊断数据进行了深入分析研究,形成激光诱导大肠早癌辅助诊断系统,为临床医生提供辅助诊断的手段^[8]。刘等人应用基于职业历史的人工神经网络对煤矿工人肺尘症高发人群进行识别和分类,使用中国铁塔煤矿的纵向统计数据,基于煤炭工人的职业暴露数据,采用贝叶斯学习算法建立

一个三层的人工神经网络，包括 6 个输入变量、15 个隐藏层神经元和 1 个输出神经元；采用灵敏度和 ROC（接受操作特征）分析来解释输入变量的重要性和神经网络的性能；职业特征和预测的或然率值被用于分类不同 CPW 危险层次的煤炭工人^[14]。王等提出了一种基于粗糙集和 SVM 的肝炎诊断算法，在 UCI 数据集上的实验结果表明，与 SVM、神经网络、决策树算法相比，所提出的方法具有更好的准确率^[15]。

在生物医学领域，数据挖掘主要集中在基因序列模式以及基因功能的分析上，其中尤以 DNA 数据分析为重点，通过对致病基因成因的分析，发现疾病诊断、预防和治疗新方法以及新药物。David 等人在一系列仿真基因和蛋白质数据集上研究了随机森林的性能，比较了随机森林在给定基因数据集、蛋白质数据集以及基因-蛋白质数据集上识别相关特征的性能。结果显示：当疾病模型很复杂并且与表型结果相关的数据类型未知的时候，利用多种数据类型进行研究是有益的。研究结果同时显示：随机森林善于从具有微弱主效应和低遗传可能性的高维数据集中识别相关特征^[16]。Ding 等人在肿瘤正常配对序列数据集上使用随机森林算法进行体细胞突变检测，获得了 92.82% 的预测准确率，优于支持向量机的 91.6% 和 logistic 回归的 86.77%。该研究中使用了来源于 48 个乳腺癌基因组的具有 106 个特征的数据集^[17]。Natalia Briones 等人研究了基于数据挖掘在高密度基因变异数据上预测阿尔茨海默病，在只有 3 个实例的全基因组关联研究数据集 GWAS 上使用随机森林方法预测老年痴呆症危险因素，他们首先使用单位点分析（logistic 回归）方法对原始数据（GWAS 数据集）进行过滤选择一个较小的 SPNs 子集，然后采用多位点分析（RF）构建分类器，在选择 SNPs 子集的过程中除了使用 logistic 回归外，还利用了先验的生物学知识、样本分层和链接不平衡方法，实验结果表明 10-折交叉验证的 RF 平均分类正确率达到 90.2%，并且发现了 5 个新的阿尔茨海默病风险基因^[18]。Lee 等人在 7 个微阵列数据集上，比较了 k 近邻、各种线性判别分析、bagging trees、boosting 和 RF 算法，发现 RF 是最有效的方法^[19]。Diaz-Uriarte 等人的研究表明：与 LDA、KNN 和 SVM 相比，RF 在产生较小的基因集合的同时能够更好地保持预测正确率^[20]。Ban 等人使用 SVM 算法对 2 型糖尿病关联 SNP 组合进行了识别，在由 462 个糖尿病患者和 456 个健康人组成的样本集合中，包括每个个体的与 2 型糖尿病相关通路中的 87 个基因的 408 个 SNP，采用了 10-折交叉验证，结果在由 12 个基因的 14 个 SNP 组合构成的数据集上的预测准确率达到 65.3%，表明基于特征选择的 SVM 能够有效地识别识别 2 型糖尿病相关 SNP 组合^[21]。Mark 等人在 8 个乳腺癌微阵列表达数据集上对 RF、logistic 回归、基于径向基函数的 SVM、基于线性核函数的 SVM、基于多项式核函数的 SVM、基于 Sigmoid 核函数的 SVM、单层神经网络 NNET 和基于交叉验证的投票方法 VOTE 的

分类性能进行了比较研究,结果表明 RF 方法和基于投票的方法的性能优于其他方法^[3]。近年来,国内哈尔滨工业大学王亚东教授课题组^[22]、郭茂祖教授课题组^[23]、叶允明教授课题组^[24]、吉林大学梁艳春教授课题组^[25-26]、中南大学王建新教授课题组^[27-28]等人在疾病风险基因识别、风险 SNP 识别、蛋白质互作等方面进行了相关研究,取得一系列高水平的成果。

虽然目前医学数据挖掘在国内外已经取了较多的研究成果,然而现有的研究工作主要存在几个问题:第一,现有的方法很少考虑医学数据集中特征之间的相关性,导致算法的分类性能受到了限制;第二,现有的方法大多是基于低维数据集进行研究,样本容量通常较小,用于训练分类器的数据集难以完整地反映出数据之间的规律,从而导致最终的分类模型预测正确率不高;第三,现有的研究经常是直接将经典的数据挖掘算法应用于医学临床数据或生物信息数据挖掘任务中,没有充分考虑医学数据的特点和算法的适用性,从而导致算法的性能不理想。随着医疗信息化技术和生物信息技术的快速发展,临床诊断数据和生物信息数据的特征维数和样本容量都出现了飞跃式增长,使得现有的许多数据挖掘算法在时间和性能方面都面临新的挑战。

1.3.2 特征选择技术研究现状

近年来,随着社交网络、图像识别、生物信息等技术的快速发展与应用,产生了众多类型的高维甚至是超高维数据集,如文本检索数据集、临床诊断数据集、基因芯片数据集等,对高维数据集进行数据挖掘之前,通常需要进行特征选择。特征选择可以在训练分类模型前剔除不相关的特征、冗余特征和噪声特征,降低分类算法的执行时间,提高分类模型的预测正确率,同时可以简化分类模型、提高模型的可理解性。随着大数据时代的到来,特征选择技术成为机器学习、数据挖掘、模式识别等领域的研究热点。

在数据挖掘中,特征选择可定义为:给定一个学习算法 L ,一个数据集 S ,数据集 S 来自一个具有 n 个特征 $X_1, X_2, X_3, \dots, X_n$,具有类别标记 Y ,以及符合分布 D 的样本空间,则一个最优特征子集 X_{opt} 是使得某个评价准则 $J=J(L, S)$ 最优的特征子集^[29]。从定义可以看出,特征选择本质上是一个搜索优化问题。对大小为 n 的特征集合,搜索空间可以有 2^n-1 种可能的组合,寻找满足要求的最小特征子集是NP完全问题。实际上,当前的各种特征选择方法都是采用启发式搜索算法寻找近似最优子集。一般而言,一个完整的特征选择算法需要确定特征搜索起点和方向、特征搜索策略、特征评估策略、搜索停止准则等4个要素,其中特征搜索策略和特征评估策略是特征选择算法的研究重点。

根据特征选择过程中所采用的搜索策略,可以把特征选择算法分为三类:采用全局最优搜索的特征选择算法、采用随机搜索策略的特征选择算法和采用序列搜索策略的特征选择算法。到目前为止,文献中可见的采用全局最优搜索的特征选择方法只有“分支定界算法”(Branch and Bound Algorithm),它在评估准则对应的目标函数满足单调性的前提下求解最优特征子集,但是这样的前提条件在实际应用中往往很难满足^[30]。采用随机搜索策略的特征选择方法在计算过程中把特征选择问题和遗传算法或随机重采样过程等数据挖掘算法结合,将数据挖掘算法的分类或预测正确率作为衡量特征子集质量的标准,从而得到较好的次优解,但是当数据集特征维数很高时,这类算法的计算时间会非常大^[31]。采用序列搜索策略的特征选择算法包括序列前向搜索(Sequential Forward Searching, SFS)、序列后向搜索(Sequential Backward Searching, SBS)、广义序列前向选择方法(Generalized Sequential Forward Searching, GSFS)和广义序列后向选择方法(Generalized Sequential Backward Searching, GSBS)、增L减R选搜索方法(Plus L Minus R Searching, LRS)及序列浮动搜索方法(Sequential Floating Feature Searching, SFFS)^[32]等。SFS是一种“自下而上”的搜索方法,该方法先把目标特征集合初始化为一个空集,每次向特征集合中增加一个特征,当达到特征评估函数的要求时所得到的特征子集就作为特征选择结果,这类算法的计算量相对较小,缺点是没有充分考虑特征之间的相关性。与此相反,SBS是一种“自上而下”的搜索方法,该方法首先假定整个原始特征集合就是所求的优化特征集,而后在算法的每步运行过程中依次删除一个对特征评估函数贡献最小的特征,直到剩余的特征个数符合要求,这类算法通常比SFS算法计算量大,但考虑了特征之间的相关性,其实际计算性能和鲁棒性优于SFS算法。GSFS和GSBS分别是SFS算法和SBS算法的加速方法,它可以根据特征评估函数一次性向特征集合中增加或删除多个特征,这两种算法考虑到了特征的相互作用,但也存在明显的不足:有时候特征消除操作进行太快,容易丢失重要的变量,导致找不到最优的特征组合,另外由于特征一旦被加入或者被删除以后将不再改变,容易引起所谓“筑巢”效应。为了克服这些缺陷,人们提出了增L减R搜索方法。在增L减R方法中,如果 $L > R$,用SFS方法将L个特征加入到当前特征集中,然后再用SBS方法删除R个最差的特征;反之,如果 $L < R$,则从一个原始特征集开始,使用SBS方法依次删除R个特征,再用SFS方法增加L个特征直到获得满足要求个数的特征。增L减R方法实际上是SBS方法和SFS方法的一种折中,其运算速度比SBS快而效果比SFS好。在此基础上,Pudil等人提出了顺序浮动搜索方法,该方法在特征子集生成过程中,采用浮动的步长,也就是在选择算法的不同步骤,根据特征的统计特点采用不同的L和R。浮动搜索方法减少了不必要的回溯及在需要时增

加回溯的深度,解决了参数 L 和 R 取值难于确定的问题^[32]。以上这些方法分别被用于不同的数据分析任务中,取得了较好的效果。但是对于医学数据集尤其是基因芯片数据集来说,由于存在大量的冗余特征和相关特征,参数设置不当可能会导致错误的结果。另外对于高维小样本数据集,特征选择的时间开销变得非常巨大,从而制约了其使用范围。

根据所采用的特征评价策略,可以将特征选择算法分为Filter式特征选择和Wrapper式特征选择两大类^[33-34]。Filter方法根据某种标准使用特征排序技术进行特征选择,排序标准通常用于计算变量的重要性分数,然后设定一个重要性分数阈值剔除小于该阈值的变量,这其实是一种特征过滤方法。Jiang等人研究了以聚类为基本工具的Filter式特征选择方法,实验表明该算法在性能上比经典的IFN、Relief、ABB等特征选择算法有明显的提高^[35]。谢等人提出了一种基于特征子集区分度(Discernibility of Feature Subsets, DFS)准则的特征选择方法,通过计算特征子集中全部特征对于分类的联合贡献来判断特征子集类间辨别能力大小,并结合顺序前向、顺序后向、顺序前向浮动和顺序后向浮动特征搜索策略,以SVM为分类工具引导特征选择过程^[36]。段等人将粗糙集应用于多标记数据特征选择中,构造了基于邻域粗糙集的多标记分类任务的特征选择算法,并通过实验证明了算法的有效性^[37]。史等人针对网络图像标注问题提出了一种增强稀疏性特征选择算法,应用 $L_{2,1/2}$ 矩阵范数来选取最稀疏和最具判别性的特征,通过共享子空间学习,考虑不同特征之间的关联信息,同时基于图拉普拉斯的半监督学习,使该算法同时利用了有标签数据和无标签数据,并设计了一种有效的迭代算法来最优化目标函数,实验结果表明所提出的方法更适用于大规模网络图像的标注^[38]。

与Filter方法相反,在Wrapper方法中,分类器的分类精度被用作评价特征子集质量的目标函数,各种启发式算法被用于搜索最优特征子集来最大化目标函数值。Guyon等人提出一种用于基因选择的特征选择方法SVM-RFE,该方法采用SVM作为评价特征子集质量的目标函数,采用递归剔除特征变量(Recursive Feature Elimination, RFE)的方法进行特征选择^[39]。Furlanello等人提出一种称为E-RFE的基因选择方法,该方法采用SVM权重分布的信息熵度量成块地剔除不相关的基因以加快递归剔除特征变量的速度^[40]。Yousef等人提出一种新的称为SVM-RCE的特征选择模型用于对癌症进行分类以及识别癌症生物标记,该方法采用基于K均值聚类的递归剔除簇的方法替代递归剔除特征变量方法以加快计算速度^[41]。Niiijima等人提出一种基于拉普拉斯线性判别分析的递归剔除特征变量的特征选择方法^[42]。刘等人提出了一种基于随机复杂度约束的高维特征自动选择算法,从随机复杂度理论的模型冗余度最优下界推导得出了一种基于零-范数约束的特征选择算

法模型,仿真实验表明该算法在常规数据建模中的性能表现优于已有的一些算法^[43]。钱等人提出了一种基于正向近似的通用特征选择加速算法,可以克服非完备决策表现有特征选择算法计算耗时过大的缺陷,加速特征选择过程^[44]。陈等人针对数据分类问题提出了一种快速特征选择和数据分类方法,该方法采用改进的Chi-Merge离散化方法离散化连续型特征变量,统计样本数据在每个特征子集划分下的频数表,并根据频数表计算数据不一致率,利用顺序前向最优搜索的方法,快速确定特征数量由小到大的每一个最优特征子集,根据特征子集对应的数据不一致率差异最小化原则,完成特征个数最小化的最优特征子集筛选^[45]。刘等人提出了一种针对文本分类问题的基于最大边缘相关的特征选择方法,采用 χ^2 统计量处理高维特征空间,利用信息新颖度思想处理高度特征冗余^[46]。

近年来,一些学者提出了组合Filter和Wrapper的特征选择方法,该类方法先用Filter特征选择方法对特征进行预选,剔除部分不相关特征和噪声特征,再用Wrapper特征选择方法在预选出的特征子集上做进一步的特征精选。Peng等人提出了一种基于Fisher测试进行不相关基因过滤和基于Wrapper方法排除冗余基因的组合特征选择方法^[47]。Jose等人提出一种分别剔除不相关特征、冗余特征并选择信息基因的三阶段基因选择方法^[48]。Tang等人提出一种两阶段基因选择算法,在第一阶段先消除不相关基因、冗余基因和噪声基因同时保留信息基因,在第二阶段在进行最优基因子集的选择^[49]。Du等人提出一种多阶段的微阵列表达数据特征选择方法,在不同的阶段分别实现消除不相关基因、噪声基因和冗余基因,并最终确定相关基因最优子集^[25]。黄等人提出了用于蛋白质谱数据识别的二次投影法,该方法对高维数据先进行去噪与T检验降维,再用主成分分析获取第一次投影的低维特征向量,随后用局部线性判别嵌入获取可分性最好的第二次投影特征向量,在卵巢癌蛋白质谱数据上的实验表明该算法识别性能较好^[50]。杨等人融合随机搜索和启发式搜索,提出了一种结合Filter与Wrapper的基于多群体公平模型的特征选择算法,实验结果表明该算法在降低算法执行时间的同时能够获得更高的分类正确率^[51]。

Filter方法和Wrapper方法各有优缺点。一般来说,Filter方法比Wrapper方法的计算速度较快,但是Filter方法独立于后续的分类算法而没有考虑特征子集与分类算法的相互影响,其特征子集质量和分类精度比Wrapper方法较差。Filter方法的一个关键因素是如何度量分类特征对于目标变量的相关性或重要性程度,已有文献中提出了很多种不同的度量方法,包括相关度测量法、距离测量法、信息熵法、t检验等,本文提出的相关算法中均以随机森林变量重要性分数作为特征变量的重要性度量。Filter方法的另外一个问题是如何评价特征子集的质量,通常是通过特征子集上分类器的正确率进行评价,这可能导致最优特征子集的不唯一性,因为可能会有不同的特征组合能够达到相同的分类正确率。

Wrapper方法可以选择出比Filter更优的特征子集，提高分类器的分类精度，但是计算时间开销较大，在维度过高的数据集上难以应用。基于Filter和Wrapper相结合的方法可以在降低时间开销的同时提高分类性能，但是对于有的数据集，Filter方法的性能较差，因此需要加大Filter阈值以提前剔除更多特征，从而可能误删除部分重要的特征，从而降低算法性能。目前，特征选择算法研究大多集中于文本分类、图像识别等领域，而在生物医学、生物信息学等领域的应用研究较少。面对医学临床数据集和基因表达数据集所固有的特征之间的高度相关性和高维小样本特性等特点，当前流行的特征选择算法在特征子集质量、分类器性能和算法执行时间等方面都遇到前所未有的挑战，研究新的适应医学数据特点的特征选择算法迫在眉睫。

1.3.3 类别不平衡数据分类研究现状

类别不平衡问题是机器学习和模式分类中的研究热点之一。当训练数据集中不同类别的样本数目差别悬殊时，分类算法的性能会出现明显下降，此时少数类样本易于被误分为多数类，从而导致较高的假阳性率。这种对样本类别分布不平衡的数据集进行分类的问题就是所谓的不平衡数据分类问题。不平衡数据分类问题广泛存在于现实世界许多领域中，例如：金融欺诈检测、石油勘探、垃圾邮件过滤、文本分类，尤其是生物医学和生物信息学研究中。由于数据采集技术、成本和隐私等因素，医学数据集中经常会出现样本类别不平衡的情况。这里举两个相反的例子。一种是对医学临床数据集，大量的样本来自于患有某类疾病（如心脏病、糖尿病、乳腺癌等）的人群，他们的各种生化指标和正常人的指标可能存在着很大的差异，而来自于正常人群的样本数量通常很少，在这类数据集中，疾病样本类是多数类，正常人样本类是少数类。另一种是医学健康调查数据集，在这类数据集中样本数目通常很大，但是大部分样本来自于正常人群，而患有某类疾病的样本数目相对较小，在这类数据集中，正常人样本是多数类，疾病样本类是少数类。在第一种数据集上训练分类器，分类器更倾向于将未知样本分为疾病样本，即容易将正常人误判为患有疾病；在第二种数据集上训练分类器，分类器更倾向于将未知样本分为正常人样本，即容易将患有疾病的人误判为没有疾病。对于医学数据挖掘来说，不仅关注分类器的总体分类正确率，更加关注分类器的查准率和查全率。因为医学数据分类的误判可能导致延误治疗并危及人的生命安全（如将患病的人误分为正常）或者带来额外的精神和经济负担（如将正常人误分为患病）。

不平衡数据分类问题研究主要集中在样本随机重采样、代价敏感分类算法和集成分

类算法设计等几种不同的技术上。随机重采样通过采样技术平衡训练样本集中不同类别的样本的数量,包括随机向上(过)采样(Random Over Sampling, ROS)和随机向下(欠)采样(Random Under Sampling, RUS)。ROS方法通过复制少数类样本的方式来平衡数据集中样本类别分布,而RUS方法则是通过从多数类样本集中随机地选取一个样本子集来达到同样的目的。这种通过补偿不平衡样本类别分布的随机重采样技术易于实现,能够有效提高不平衡数据集上分类器的分类性能。然而,有研究表明:随机过采样通常会产生负面影响,比如过拟合和额外的时间开销;而随机欠采样由于只利用了多数类样本的一个子集而会导致信息丢失。为了克服随机重采样技术的以上问题,研究者提出了人工合成少数类样本技术(Synthetic Minority Oversampling Technique, SMOTE)。SMOTE通过插值方法改变数据类别的分布。尽管SMOTE方法增加了少数类样本的个数,但是它采用的不是随机复制样本而是人工合成的技术(例如根据现有的少数类样本特征创建新的少数类样本),因此该算法能够有效地避免过适应的问题,但却会因此产生噪声数据^[52]。房等人提出了一种基于SMOTE和随机森林的Web spam检测算法,实验表明可以显著提高分类器的分类效果^[53]。吴等人采用SMOTE算法进行数据的平衡处理后构建随机森林分类器,对癫痫患者发作频率进行预测,取得了较好的效果^[54]。代价敏感分类算法通过为多数类样本和少数类样本赋予不同的权重来解决样本类别不平衡带来的分类性能损失。尹等人提出了一种代价敏感随机森林算法,以随机森林算法框架为基础,利用Bagging平衡数据,并在基分类器属性分裂度量以及评价函数中引入误分类和测试双重代价,使得基决策树分类器在建模过程中向少数类倾斜,提高了随机森林的分类准确率^[55]。代价敏感分类算法中权重的设置是一个关键问题,该类方法已经被证明在性能上等价于随机重采样方法^[56]。

另一类解决不平衡数据分类问题的方法是基于采样技术或装袋技术设计新的集成学习算法。Sangyoon等人提出一种基于主动样本选择(Active Example Selection, EAES)的集成机器学习算法用于不平衡生物医学数据分类,在6个真实的不平衡生物医学数据集上的实验结果显示,EAES方法的性能优于随机欠采样以及基于随机欠采样的集成方法^[57]。Tsymbal等人提出一种基于集成学习思想的特征选择遗传搜索算法,在不平衡数据集上表现出良好的分类性能,但是该算法非常耗时^[58]。Mohammed等人提出了一种基于重复随机重采样的集成学习方法,利用重复随机重采样将训练集划分成多个样本子集,每个样本子集都是一个类别平衡的数据集,在多个数据集上训练随机森林分类器,最后通过投票的方式确定测试样本的类别,在8个慢性病数据集上的实验结果表明,组合了重复随机重采样技术的随机森林算法的分类性能优于SVM、bagging和boosting^[59]。针

对微阵列表达数据基因选择, Ali 等人提出一种平衡迭代随机森林 (Balanced Iterative Random Forest, BIRF) 算法, 该算法根据随机森林变量重要性分数采用后向删除特征方法迭代地删除不相关或不重要的特征, 在训练随机森林时通过调节随机森林参数来克服类别不平衡带来的影响, 实验结果表明 BIRF 方法在不平衡数据集上的性能优于 SVM-RFE, MSVM-RFE (Multi-class SVM-RFE) 和朴素贝叶斯方法 (Naive Bayes, NB) 等方法^[60]。邹等人利用集成机器学习的思想, 将多数类样本集均匀分割并依次与少数类样本集组合, 构成一组新的类别平衡的训练数据集, 然后采用不同原理的分类器在每个训练集上进行训练, 最后通过多数投票决定待测样本的类别; 该算法还采用了 AdaBoost 思想来避免弱分类器对投票效果个影响, 既避免了 AdaBoost 的反复训练, 又利用投票机制有效地缓解了弱分类器的影响, 有效地解决了生物信息学中的 SNP 位点真伪识别、microRNA 前体判别和 snoRNA 识别等问题^[61]。李等人在样本类别不平衡的数据集上通过有放回的抽样方法独立地从数据集大类样本集中随机抽取多个样本子集, 然后将各抽取的样本子集分别与小类样本集组合成多个新的训练样本集, 对多个新样本集的特征子集以集成学习的方式采用投票机制进行投票, 最优特征子集以得票数目超过半数的特征组合构成, 实验结果表明该算法是一种有效的类别不平衡特征选择方法^[62]。

尽管在不同的应用领域提出了很多不同的解决类别不平衡问题的方法, 取得了较好的效果。然而, 每种方法都存在各自的优缺点和适用场合。一方面, 在通过随机重采样解决类别不平衡问题的方法中, 随机过采样会产生过拟合和额外的时间开销, 随机欠采样而会导致信息丢失, SMOTE 会引入噪声数据; 另一方面, 在基于 boosting 的集成学习算法中, 每一次训练分类器都是在前一次的基础上进行的, 由于反复训练增加了时间开销, 无法应用于大规模数据处理。为此, 本文提出了一种基于 Bootstrap 的集成学习算法。与 boosting 算法不同, Bootstrap 算法在采样过程中采用随机独立的方式, 通过有放回地的随机重采样, 可以尽量避免随机欠采样带来的信息损失, 使得基分类器获得更好的随机性和多样性, 通过集成多个基分类器保证了算法整体的正确率, 同时克服了类别不平衡带来的负面影响。本文将在第二章对此进行详细介绍。

1.3.4 随机森林算法研究现状

随机森林是由 Breiman 在 2001 年提出的一种集成机器学习方法, Breiman 在其代表论文《Random Forests》^[63]中对随机森林的基本概念、算法原理、收敛性、正确性进行了定性分析、数学证明和实验验证。Breiman 从理论上证明了随机森林的泛化误差取决于森林中基分类器 (决策树) 的分类强度以及基分类器之间的相关度, 基分类器的分类性

能越好、基分类器之间的相关性越弱,则随机森林的分类性能越好。为此,随机森林组合了 Bagging 技术^[64]和随机子空间方法^[65]来实现基分类器之间的随机性和多样性,首先利用 Bootstrap 技术从原始样本中有放回地随机抽取多个样本,然后对每个 Bootstrap 采样集合进行决策树建模,在训练决策树的过程,在每一次节点分裂时,采用随机子空间方法从一个属性子集中随机选取一个属性进行分割,最后组合多个决策树的预测,通过投票得到最终预测结果。大量的研究表明,相对于其他机器学习算法,RF 具有很多优点:1)能处理多种数据类型,包括定性的数据(比如单核苷酸多态性 SNPs)或者定量的数据(例如微阵列表达水平或高通量蛋白质组数据);2)提供变量重要性度量,为分析和研究特征相对重要程度提供了一种容易理解的途径;3)构建的分类器分类准确性高;4)对于噪声数据和存在缺失值的数据具有很好的鲁棒性;5)具有分析特征之间复杂相互作用的能力;6)随着输入变量数量的增长,具有较快的学习速度,对于超大数据集来说,计算时间是合适的^[66-68]。近十年来,随机森林已经成为机器学习、数据挖掘、模式识别、生物医学、生物信息学及其他各种应用领域的研究热点。当前,关于随机森林的研究主要集中在两个方面:(1)随机森林算法在不同领域的应用研究,尤其是面向高维数据、不平衡数据等特殊数据分类任务的随机森林改进算法研究;(2)随机森林算法本身的性能、参数设置、改进和优化研究。下面分别进行简要的总结和分析。

近年来,随机森林已经被广泛应用于各种分类、预测、变量重要性研究、特征选择以及异常点检测问题中,例如:DNA 绑定蛋白质识别^[69]、视频对象分割^[70]、高光谱数据分类^[71-72]、基于环境条件的空间分布度量预测比利时低谷植被类型^[73-74]、预测中部安第斯山脉东部斜坡的鸟类和哺乳动物的分布^[75]、文献识别工作中的捷克语言建模^[76]、基于单光子发射计算机断层扫描数据诊断老年痴呆症^[77]、遗传多态性识别^[78]、蛋白质序列中长期混乱区域的预测^[79]、基于地球资源卫星图像对农业生产分类^[80]、航天图像分类^[81]、化学中的酚类抗氧化剂分析^[82]、手写数字识别^[83]、潜水脊椎动物的时间深度描述分类^[84]以及很多其他领域。国内关于随机森林算法的研究虽然开始较晚,但近年来增长迅速。王等人提出一种基于随机森林分类器的人脸关键点定位算法^[85]。田等人利用修改的随机森林进行文本分类^[86]。周等人将随机森林的相似度矩阵看作一种特殊的核度量,提出一种特征选择的方法^[87]。王等人针对小样本数据流的在线学习问题提出了一种增量式极端随机森林分类器,实验结果表明所提出的算法在规模适度的样本集上,性能优于贪婪决策树重构算法^[88]。马等人使用随机森林算法预测蛋白质序列中的 RNA-结合残基,取得了较好的预测性能^[89]。余等人针对大规模图像标记,融合标记传播和随机森林技术,使用随机决策树进行样本压缩,使得传统的标记传播方法能够在压缩后的示例上高效执行,以利用未标记数据提高分类性能,然后利用随机森林将标记传播的结果推广到所有未标记示例上^[90]。雷等人研究了随机森林在遥感影像处理中的应用,并针对遥感目标检测的不同条件,提出了霍夫森林(CRIHF)、条件纹元森林(CTE)、四叉树双模态纹元森林

(QT-DMTF)等随机森林改进算法^[91-92]。吴等人研究了高维数据的分类问题,针对多噪声属性的高维数据分类,提出了分层抽样随机森林分类算法(SRF),能够有效处理基因、图像等高维数据分类;针对不平衡文本数据分类,提出了基于分层抽样随机森林的文本分类算法(ForesTexter),能够有效提高不平衡数据中少数类样本的分类精度;针对全基因组数据分析,提出了基于分层抽样随机森林的全基因组数据分析算法(GWA-SRF),避免了穷举搜索最优子空间的计算代价,同时能够自动计算属性重要性和发现与研究疾病相关的重要属性^[24, 93-94]。有研究表明当将随机森林算法应用于类别不平衡的数据集上时,随机森林的分类性能和变量重要性度量的可靠性将受到很大削弱^[60, 66, 95]。尹等人研究了高维不平衡数据分类问题,通过实验对比得出特征选择先于取样更优的结论,在此基础上,针对先特征选择面临的数据不平衡问题,提出了不平衡数据特征选择算法(BRFVS),采用欠采样产生多个平衡数据集,在各个数据集上利用随机森林变量选择方法计算特征重要性度量值,最终的度量值通过对各数据集的度量值加权求和获得,实验表明该算法的分类性能优于普通特征选择后再取样算法的分类性能;针对采样数据可能导致信息损失问题,在基于特征的集成学习框架下,提出了代价敏感随机森林算法(CSRF)和基于集成特征选择的分类算法(IEFS)。其中,CSRF 算法在随机森林的决策树属性分裂度量中引入测试代价和误分类代价,通过调整对小类的关注度提高对小类的正确识别率;IEFS 算法采用 Kohavi-Wolpert 方差作为多样性度量方法,在其中引入奖惩因子增加对小类的关注,并采用爬山法搜索解空间,可以兼顾考虑多样性、准确性和不平衡性。实验结果表明 CSRF 算法在小类的正确识别率方面优于原始的随机森林算法和仅引入误分类代价的随机森林算法;IEFS 算法在分类性能上略差于 CSRF 算法但优于 C4.5 算法和随机森林算法^[96]。特别地,在生物医学和生物信息学领域,随机森林由于能识别多个预测变量之间的相互作用而受到青睐,其变量重要性度量近来已被建议作为高维数据的特征选择工具。David 等人的研究表明随机森林善于从具有微弱主效应和低遗传可能性的高维数据集中识别相关特征^[6]。Ding 等人在肿瘤正常配对序列高维数据集上使用随机森林算法进行体细胞突变检测,获得了较好的预测性能^[17]。Natalia 等人在全基因组关联研究数据集上使用随机森林方法对老年痴呆症危险因素进行预测^[18]。Mohammed^[59]等使用随机森林算法进行疾病预测,结果表明随机森林的分类性能优于支持向量机、bagging 技术和 boosting 技术。针对蛋白锌结合位点预测问题,Zheng 等人提出了基于两阶段随机森林算法的集成计算框架,利用随机森林算法选择贡献度大的特征构建预测模型,实验表明所提出的方法的分类性能优于 SitePredict 方法(一种基于结构的和随机森林算法的蛋白锌结合位点预测方法)和 Zincfinder 方法(一种基于序列的和 SVM 算法的蛋白锌结合位点预测方法)^[97]。针对全基因组关联研究中的因果变异及相关区域排序和识别问题,Roshan 等人研究了基于卡方统计、支持向量机和随机森林的 SNPs

排序方法, 实验表明随机森林和支持向量机在前 $2r$ (r 是 Bonferroni 相关系数小于指定的 P 值的 SNPs 数量) 个特征构成的集合上排序性能相近, 都能够提高排序质量^[98]。

随机森林算法被提出以来, 国内外众多学者针对不同领域的实际需求, 提出了随机森林算法的许多变种和改进算法。针对计算机辅助诊断 (Computer aided Diagnosis, CAD) 中的半监督学习问题, Li 等人提出了一种 co-training-style 的随机森林算法 (Co-Forest)^[99]。该算法首先通过 bootstrap 重采样技术从已标记的样本集合中有放回地抽取 N 个与原始数据集中样本个数相同的样本子集, 在 N 个子集上分别训练决策树基分类器, 在后续 co-training 学习中, 如果 $N-1$ 个基分类器将某个未标记样本标记为同一类别, 则该样本被作为已标记样本加入到原来的样本集合中构成新的训练样本集进行重复训练。实验表明, Co-Forest 算法具有较好的泛化能力。然而, co-training-style 算法的通病是由于未标记样本在学习过程中被错误地标记而导致本监督学习算法的性能不稳定, 在 Co-Forest 算法中相对有限的已标记样本导致基分类器的准确性和多样性收到削弱, 从而降低了 Co-Forest 的泛化性能。为了解决 Co-Forest 算法中误标记噪声问题, Deng 等人提出了一种基于自适应数据剪辑的 Co-Forest (Adaptive Data Editing based Co-Forest, ADE-Co-Forest)^[100]。ADE-Co-Forest 算法采用了 RemoveOnly 数据剪辑技术识别可能误标记的数据, 采用自适应策略控制数据剪辑操作的有效性。在 UCI 数据集和胸 CT 图像肺结节检测数据集上的实验表明, 相对 Co-Forest 算法和 DE-Co-Forest (Co-Forest with Data Editing but without adaptive strategy) 算法, ADE-Co-Forest 算法能够增强学习性能。针对微阵列表达数据集中因存在大量噪声特征导致 RF 算法的性能下降的问题, Amaratunga 等人提出一种称为“富随机森林” (Enriched Random Forest, ERF) 的方法, 采用加权随机采样和特征排序方法提高 RF 的分类性能, 在 10 个真实的基因表达数据集上的实验表明 ERF 方法的分类性能优于基本的 RF 方法^[101]。Breiman 提出的随机森林算法采用 Bagging 技术重采样构成多个采样数据集, 在这些数据集上分别训练决策树分类器, 这些决策树的训练过程是相对独立的, 某些分类性能较差的树加入到森林中后可能降低森林的整体分类性能。针对这一问题, Bernard 等人提出了一种动态随机森林 (Dynamic Random Forests, DRF)^[102] 算法。和基本的随机森林算法不同, 该方法利用顺序前向搜索方法依次将基分类器加入到森林中, 在每次构建基分类器后, 根据基分类器的预测结果调整训练集中样本的权重, 被正确分类的样本的权重降低, 被错误分类的样本的权重增加, 然后重采样得到训练集, 重复训练决策树基分类器, 直到森林中的基分类器个数达到预先设定的值。在 17 个 UCI 数据集和 3 个手写数字识别数据集上的实验表明 DRF 算法的平均错误率低于基本的 RF 算法。DRF 算法考虑了基分类器对森林分类性能的影响, 因此森林中的基分类器并不是完全独立的, 这就降低了基分类器的多样性, 在某些特定的数据集上可能导致过拟合。

除了应用研究外, 对于随机森林算法本身的参数设置、稳定性等方面的研究也是随

机森林算法研究的重要方向和内容。Breiman 提出的随机森林算法中一个重要的参数是 *ntree*, 表示随机森林中决策树基分类器的个数, 一般来讲, 基分类器的数量越多, 算法的分类性能越好, 但同时会导致算法的执行时间增加。在关于随机森林的大多数应用中, *ntree* 一般被设置为 500 或 1000。在疾病自动诊断研究中, 针对随机森林中基分类器数量设置问题, Evanthia 等人提出了一种动态确定随机森林中决策树数量的算法, 该方法首先使用 Breiman 的 RF 算法生成一个具有 10 个决策树的初始的森林, 然后对训练数据进行多项式拟合并选择一个最优拟合(预测值与实际值均方差最小的拟合), 接下来判断是否满足结束条件(原始曲线和拟合曲线上至少有连续 10 个点的误差小于预先指定的阈值), 如果不满足结束条件, 继续增加一棵树, 否则结束训练, 返回最优的基分类器数量, 在 8 个生物学数据集上实验表明该方法能够有效地确定随机森林中决策树的最优数目^[103]。然而, Evanthia 的方法中引入了 4 个新的参数, 这些参数的合理设置需要进一步的研究。*mtry* 是随机森林算法的另一个重要参数, 表示训练决策树过程中节点分裂时随机选择分裂特征的特征子集的大小, 一般被设置为 $\sqrt{N}$, 其中 N 是训练集中所有特征的个数。然而, Wu 等人的研究指出 Breiman 提出的随机森林算法中, 使用缺省的 *mtry* 参数进行特征子空间选择时, 会选择大量不相关的特征进入特征子空间, 从而影响分类器性能, 并提出一种基于分层采样的特征子空间选择方法来构造随机森林分类器, 在帕特森疾病 SNP 数据集和老年痴呆症 SNP 数据集上实验结果表明, 基于分层采样的随机森林方法可以获得更高的分类正确率^[24]。另外, 有研究发现, 随机森林的变量重要性度量在某些情况下存在偏倚(biased), 尤其是在基因及蛋白质等高维小样本数据集上, 随机森林的分类性能受到削弱。Carolin 等人在模拟数据集上证明了当预测变量的度量范围或者类型个数变化很大时, 不合理的预测特征在特征选择中可能被人为地偏爱, 作者还提出了随机森林的一个改进方法, 可以得到更加可靠的变量重要性度量^[104]。Carolin 等人在另外一篇文章中针对原始的随机森林变量重要性度量对相关预测变量存在偏爱的问题, 提出了一个新的有条件排列机制用于计算变量重要性度量, 该方法比原始的边际方法能够更可靠地反映预测变量对响应变量的影响^[105]。Gerard 等人对随机森林分类器性能的一致性进行了研究, 证明随机森林分类器并不是在任何情况下都能提供一致的预测性能^[106]。A. Verikas 等人对基于随机森林变量重要性的变量排序进行了新的测试, 实验表明变量重要性排序依赖于设计随机森林时选择分裂节点的变量个数^[66]。Gray 和 Fan 使用遗传算法 GA 来设计分类森林, 在真实数据集上的实验结果表明通过 GA 进化的随机森林准确性不如 RF^[107]。Rodriguez 等人提出使用循环森林(rotation forest)代替随机森林, 结果表明循环森林比随机森林和 AdaBoost 更准确^[108-109]。Tsymbal 等人提出自适应随机森林, 实验表明该方法比普通的随机森林预测更准确^[110]。Leshem 等人建议将随机森林作为 AdaBoost 算法的弱分类器^[111]。Osman 提出一种具有增量特征选择的在线随机森林技术,

证明在线随机森林获得了与离线随机森林近似的性能^[112]。曹等人对随机森林算法的优化进行了相关研究,针对随机森林不能很好地处理不平衡数据的问题,根据聚类算法思想和物理学重心理论提出了 C_SMOTE 算法,这本质上是一种 SMOTE 算法,与一般的 SMOTE 算法不同,在选取“人造”样本时,C_SMOTE 算法从负类样本的重心出发,有目的地“人造”样本,使得新构造的样本有向重心汇聚的趋势,有效地解决了 SMOTE 算法缺陷,从而提升不平衡数据集上随机森林的分类性能;针对随机森林中基分类器 (C4.5) 算法处理连续变量时间较长的问题,提出了一种降低连续变量取值数量的新算法,通过使用 χ^2 矫正公式解决了 CHI2 算法中的偏差问题,有效地约简数据集中的冗余信息,提升随机森林算法的执行效率;针对随机森林中训练基分类器时采用的节点分裂算法不同导致分类性能不同的问题,提出了一种基于线性组合的节点分裂混合算法,将 C4.5 算法和 CART 算法的节点分裂函数进行线性组合,较好地实现了随机森林算法分类性能的优化^[113]。

综上所述,随机森林是一种优秀的集成机器学习算法,算法本身及其众多的改进算法形成了随机森林算法家族,其分类能力在众多研究领域中得到了验证。同时,随机森林由于能够从具有复杂相互作用的多个预测变量和具有微弱主效应变量的高维数据集中识别主相关变量,其变量重要性分数可以作为特征选择的有效度量,其建立的分类模型具有较好的可理解性,尤其适用于医学数据挖掘与分析任务中。然而,现有的相关研究大多是直接将随机森林算法应用于某类特定领域数据的分类或预测任务中,而没有充分研究其适用性和稳定性。另外,同 SVM、KNN、ANN 等其他优秀的分类算法一样,当面对医学数据集具有的高维或超高维特征空间、存在大量冗余特征、噪声特征和冗余特征以及样本类别不平衡等问题时,随机森林算法的分类性能和执行时间都遇到新的挑战。因此,结合随机森林算法和特征选择技术的基本思想,研究设计能够有效处理医学数据挖掘中高维数据和类别不平衡数据问题的随机森林特征选择及分类算法,并将其应用到疾病危险因素分析中,仍然是一个具有较强创新性和较高研究价值的课题。

1.4 论文研究思路及主要研究内容

医学数据挖掘是数据挖掘技术的一个重要研究方向和研究热点。本文针对医学数据挖掘中疾病危险因素分析和疾病风险基因识别问题,研究了基于随机森林的各种特征选择方法及数据分类算法。本文的研究思路是:一方面,以 UCI 中标准的医学数据集和自主收集的糖尿病及其并发症患者临床数据集为基础,针对医学临床数据集存在的样本类别不平衡问题、高维特征空间和高度特征冗余问题、特征间存在复杂相互作用等问题,研究面向不平衡数据集的随机森林改进算法、基于随机森林的 Filter 式特征选择算法、基于随机森林的 Wrapper 式特征选择算法,通过这些算法有效地识别出影响疾病发生和

发展的疾病主要危险因素并建立疾病分类模型，达到简化模型、提高分类性能、降低计算时间的目的；另一方面，以生物信息数据中的微阵列表达数据集为基础，针对微阵列表达数据集存在的高维小样本、存在大量冗余特征、不相关特征和噪声特征、特征间存在复杂相互作用等问题，研究基于随机森林的 Filter 式和 Wrapper 式相结合的特征选择及分类算法以及适应微阵列表达数据特点的特征搜索策略和特征评价方法，在快速剔除不相关特征和噪声特征的同时，能够有效地剔除冗余特征并从具有复杂相互关系的特征中识别出主相关特征，达到简化分类模型、提高分类性能、降低计算时间的目的。因此，本文的研究路线是从维度相对较低的医学临床数据集到超高维的微阵列表达数据集、从原理相对简单的 Filter 式特征选择到性能较优的 Wrapper 式特征选择再到 Filter 与 Wrapper 相结合的特征选算法的递进研究过程，论文的所有研究工作最终统一于医学数据挖掘中的复杂疾病危险因素分析和风险基因识别，并对疾病类型进行预测，进而为复杂疾病的发病规律研究、诊断和治疗提供决策支持。本文的总体研究方案如图 1.1 所示。




图 1.1 论文的研究方案

Fig. 1.1 The research project of this thesis

具体来说，本文的主要研究内容包括以下 4 个方面：

1. 面向类别不平衡数据集的 RF 分类算法研究

有研究表明随机森林算法在样本类别不平衡数据集上的分类性能会下降, 本文针对医学数据分析中的样本类别不平衡问题, 采用 Bootstrap 随机重采样技术构建类别平衡的数据集, 在多个采样数据集上构建随机森林分类器, 多个分类器通过多数投票方式决定未知样本的类别。在 UCI 标准数据集上对算法性能进行实验验证。

2. 基于 RF 的 Filter 式特征选择算法研究

疾病危险因素分析对于研究疾病的发病规律、制定预防措施和治疗方案具有重要意义, 本文针对医学数据集的高维特征空间和高度特征冗余问题, 提出了一种基于随机森林的 Filter 式特征选择算法, 采用随机森林变量重要性分数作为衡量特征重要性的准则, 对数据集中的特征进行排序, 迭代选择前若干个特征构成特征子集, 采用经典的分类算法的分类精度评价特征子集的质量。在 UCI 标准数据集和糖尿病临床数据集上对算法性能进行实验验证。

3. 基于 RF 的 Wrapper 式特征选择算法研究

针对医学数据集的高维特征空间、高度特征冗余和特征间高度相关, 为了优化特征子集质量, 进一步提高分类正确率, 提出了一种序列前向搜索和序列后向搜索相结合的特征搜索策略和基于随机森林的 Wrapper 式特征选择算法, 采用随机森林变量重要性分数作为衡量特征重要性的准则, 采用经典的分类算法在特征子集上训练分类器, 用分类器的分类精度作为评价特征子集质量的指标。在 UCI 标准数据集、糖尿病临床数据集和微阵列表达数据集上对算法性能进行实验验证。

4. 面向微阵列表达数据的 RF 特征选择算法研究

针对微阵列表达数据集的“高维小样本”和特征之间高度相关等特点, 提出了一种基于 Filter 和 Wrapper 相结合的特征选择方法, 首先采用 Filter 特征选择算法过滤掉和目标变量明显不相关的基因和噪声基因, 然后采用 Wrapper 特征选择算法精选最优特征子集。在 Wrapper 特征选择过程中, 基于随机森林算法变量重要性分数对基因进行排序, 提出了序列前向搜索和序列后向搜索策略相结合、分层剔除不重要特征和冗余特征的特征搜索策略, 在微阵列表达数据集上对算法的性能进行实验验证。

1.5 论文组织结构

论文的组织结构介绍如下:

第 1 章为“绪论”。本章对论文的研究背景和研究意义进行了简要介绍, 详细阐述了医学数据挖掘、特征选择、样本类别不平衡数据分类以及 RF 算法的研究现状及存在的

问题,最后对本论文的研究内容与章节安排进行了介绍。

第2章为“面向类别不平衡数据集的RF分类算法研究”。本章针对样本类别不平衡问题,提出了一种基于Bootstrap随机重采样技术的随机森林改进算法,并在UCI标准数据集和糖尿病临床数据集上进行了实验验证。

第3章为“基于RF的Filter式特征选择算法研究”。本章针对医学数据的高维特征空间和高度特征冗余,提出了一种基于RF的Filter式特征选择算法,并在UCI标准数据集和糖尿病临床数据集上进行了实验验证。

第4章为“基于RF的Wrapper式特征选择算法研究”。本章针对Filter式特征选择算法不能保证得到最优特征子集的问题,提出了一种RF的Wrapper式特征选择算法,提出了序列前向和序列后向相结合的特征搜索策略,并在UCI标准数据集和糖尿病临床数据集上进行了实验验证。

第5章为“面向微阵列表达数据的RF特征选择算法研究”。本章针对微阵列表达数据的“高维小样本”和特征间高度相关等问题,提出了一种结合Filter与Wrapper的RF特征选择算法,提出了结合序列前向搜索与序列后向搜索、分层进行特征选择的特征搜索策略,并在微阵列表达数据集上进行了实验验证。

第2章 面向类别不平衡数据集的 RF 分类算法研究

2.1 引言

医学数据挖掘是数据挖掘技术在医学科学中的重要研究分支，是计算机科学、生物医学和生物信息学领域的重要研究方向。多年来，有众多的专家学者在医学数据挖掘领域取得丰硕的研究成果，朴素贝叶斯模型、人工神经网络、支持向量机等经典分类模型都被广泛应用于医学数据挖掘任务中，表现出较好的性能。朴素贝叶斯分类算法逻辑简单、易于实现且算法的时空开销较小，有研究表明：在某些领域，贝叶斯分类算法的分类性能足以与支持向量机和人工神经网络算法相媲美；然而，朴素贝叶斯算法是在假定数据集中各个属性或特征之间相互独立的前提下提出来的，而医学数据集的固有特点是特征高度冗余和特征间高度相关，这使得朴素贝叶斯算法在医学数据挖掘中的应用受到很大的限制。人工神经网络算法试图通过模拟大脑神经网络处理和记忆信息的方式进行信息处理，具有非线性、自学习和高速寻找优化解的能力，由于人体和疾病的复杂性和不可预测性，医学数据中存在非常复杂的非线性联系，人工神经网络在医学数据挖掘中得到了广泛应用，主要应用在生物信号（脑电信号、心电信号、医学图像等）的检测与分析中；然而，人工神经网络存在计算速度慢、局部收敛和过拟合等问题，对于具有大量不同数据类型的特征和样本容量很大的医学数据集而言，人工神经网络在医学数据挖掘中的应用范围受到了限制；另外，神经网络是高度非线性的复杂系统，模型的可理解性较差，而在医学科学领域，模型的透明性和可理解性是非常重要的。支持向量机分类算法建立在小样本统计理论基础之上，利用内积核函数简化高维空间问题的求解难度，通常能够找到目标函数的全局最小值，且其算法复杂性取决于支持向量的数量而不依赖于样本空间的维度，与神经网络等算法相比具有较好的泛化能力；然而，决定支持向量机性能的关键在于核函数的选取，对于医学数据挖掘任务而言，如何根据实际的数据模型选择合适的核函数来构造支持向量机模型，目前仍然是一个难题；另外，支持向量机的理解需要数据挖掘或机器学习的相关背景知识，同人工神经网络类似，其分类模型的可理解性较差，同样限制了其在医学数据挖掘中的应用。随机森林算法是基于决策树的集成机器学习算法，它组合了Bootstrap随机重采样技术和随机子空间方法，通过Bagging装袋方法从原始训练集中以有放回的方式随机采样产生多个不同的训练数据集，在每一个采样数据集上训练决策树分类器，这些决策树分类器构成“森林”并通过多数投票方式对未知样本的类别作出预测。大量的理论与实践研究表明，随机森林算法不仅具有决

策树算法的模型透明的优点，而且通过随机化技术和基分类器集成使得其能够从具有复杂相互关系的多个特征中有效识别主相关特征，其生成的变量重要性分数可以作为特征选择的依据，生成的模型容易被医学工作者所理解；此外，随机森林算法还具有分类精度高、运算速度快、鲁棒性强等特点。因此，随机森林算法目前已经成为机器学习、数据挖掘、生物医学和生物信息学领域的研究热点，在医学数据挖掘研究中备受青睐。

医学数据集的一个重要特点是样本类别不平衡。例如，一方面，由于某些罕见疾病和预后异常病人的生物医学数据通常难以获得，或者某些生物医学数据常常通过昂贵的实验手段获得，导致该类医学数据集中的不同类别样本的数目是高度不平衡的，患病人群样本是少数类，而正常人群样本是多数类；另一方面，对于某些高发病或复杂疾病，如糖尿病、癌症、老年痴呆症等，医学数据集中包括大量的患病人群的临床诊断数据，而正常人的数据则非常少，在这类不平衡数据集中，患病人群样本是多数类，而正常人群样本是少数类。目前，大多数的数据挖掘算法都是基于数据集中不同类别的样本的数目基本相同的假设，当将这些算法直接应用于样本类别不平衡数据集进行分类时，训练获得的分类器更大程度上是基于多数类样本的信息从而忽略或丢失少数类样本的信息，最终导致少数类样本的预测性能较差。随机森林算法也不例外，有研究表明当随机森林算法应用于样本类别不平衡的数据集时，其分类性能将会严重削弱^[54, 106]。

目前，处理样本类别不平衡分类问题的方法主要有通过随机重采样构建样本类别平衡的数据集、设计价值敏感分类算法及设计集成分类算法等。随机重采样方法通过采样技术平衡训练数据集中不同类别样本的分布，常用方法包括ROS、RUS和SMOTE等。ROS通过复制少数类样本的方式来平衡数据集中的样本类别分布，而RUS则是通过从多数类样本中随机地选取一个样本子集来达到同样的目的。ROS方法存在过拟合和时间开销大的问题，RUS方法则会导致信息丢失。SMOTE通过插值方法以人工合成而不是随机复制的方法改变样本类别的分布，可以有效避免过拟合问题，但是会产生噪声数据。林等人提出了一种处理不平衡数据的降采样方法，利用K-Means聚类提取多数类样本聚类中心与少数类样本一起构成样本类别平衡的训练数据集，并结合了SMOTE过采样算法，在6组UCI数据集和5组生物信息学数据集上的实验表明其所提出的算法在处理类别不平衡问题上的有效性^[115]。针对微阵列表达数据基因选择问题，Ali等人提出了一种平衡迭代随机森林算法（Balanced Iterative Random Forests, BIRF），从不平衡的高通量基因表达数据集中选择和疾病最相关的基因，在4个微阵列表达数据集上的实验结果表明该算法的分类性能优于基于支持向量机和递归特征消除（Support Vector Machine-Recursive Feature Elimination, SVM-RFE）^[39]算法、多类别SVM-RFE算法、基于递归消除的RF算法^[114]

和NB算法^[60]。BIRF算法其实是一种基于随机森林的特征选择算法，它通过调节原始的随机森林算法的两个参数 $cutoff$ （表示不同类别的权重向量）和 $sampsize$ （表示训练决策树的样本数量）来识别和少数类样本最相关的特征，其本质上是一种基于代价敏感的算法。尹等人提出了一种代价敏感随机森林算法CSRFB（Cost-Sensitive Random Forest，CSRFB），该算法在随机森林算法框架基础上，利用Bagging方法平衡数据集中类别分布，并在基分类器属性分裂度量以及评价函数中引入误分类和测试双重代价，使得基决策树分类器在建模过程中向少数类倾斜，在5个UCI数据集上的实验结果表明CSRFB减小了少数类的误分类率^[55]，但该方法可能导致少数类样本的过拟合。有研究表明代价敏感的分类算法在性能上等价于随机重采样方法^[56]。为了弥补降采样方法的信息丢失问题，邹等人提出了一种基于投票机制的集成学习算法，该算法首先将多数类样本随机分成若干份，每一份中样本的数目与少数类样本数目大致相等，然后构建多个类别平衡的训练数据集并用不同的分类算法训练分类器，通过多个不同分类器投票决定新样本的类别，在5个UCI数据集和3个生物信息学数据集上的实验表明该算法在处理类别不平衡问题上的优越性^[61]。针对不平衡生物医学数据分类问题，Sangyoon等人提出了一种基于主动样本选择的集成学习算法EAES（Ensemble Learning with Active Example Selection），该算法在训练基分类器的过程中采用主动样本选择技术选择“有效”的样本训练分类器，并采用增量学习算法来加速主动样本选择的过程，在6组生物医学数据集上的实验结果表明EAES算法优于随机欠采样和基于随机欠采样的集成学习算法^[57]。刘等人提出了一种基于级联模型的类别不平衡数据分类算法BalanceCascade，通过逐步缩小大类别使数据趋于平衡，在此过程中训练得到的一系列分类器通过集成方式对预测样本进行分类，在10组UCI数据集上的实验表明BalanceCascade算法可以有效提高不平衡数据集上的分类性能^[116]。

尽管以上方法在一些具体的样本类别不平衡数据集上取得了较好的实验结果，然而样本类别不平衡数据分类的分类性能仍然还不够理想，具有很大的提升空间，基于随机重采样和价值敏感的算法所固有的弱点依然存在。在通过随机重采样解决类别不平衡问题的方法中，随机过采样会产生过拟合和额外的时间开销，随机欠采样而会导致信息丢失，SMOTE会引入噪声数据。另外，现有的集成学习算法大多是基于Boosting采样，这类算法由于需要反复迭代训练增加了时间开销，无法应用于大规模数据处理。为此，本文提出了一种新的基于集成机器学习思想的随机森林改进算法，该算法采用Bootstrap随机重采样技术有放回地分别从多数类样本中和少数类样本中抽取多个与少数类样本集合大小相等的样本子集，然后将采样的得到的多数类样本集合和少数类样本集合组合成

类别平衡的训练数据集，进而在这些数据集上面训练 RF 分类器，最后，多个 RF 分类器通过多数投票的方式决定未知样本的类别。与 Boosting 算法不同，Bootstrap 算法在采样过程中采用随机独立的方式，通过有放回地的随机重采样使得基分类器获得更好的随机性和多样性；通过集成多个基分类器可以尽量避免随机欠采样带来的信息损失，保证了算法整体的正确率。本章将对此进行详细研究。

2.2 概念定义

为了便于研究，本节给出与研究问题相关的一些基本概念和假设。

定义 2.1 数据集. 数据集是一个以行为记录，列为特征的二维数据表，用三元组 $D = \langle I, X, Y \rangle$ 来表示，其中：(1) I 是记录标识，唯一的标识一个样本；(2) X 是分类特征集合，由 N 个特征组成，记作 $X = \{X_1, X_2, \dots, X_N\}$ ；(3) Y 是目标特征，标识样本的类别。

定义 2.2 分类器. 对于给定数据集 D ，分类器定义为一个以分类特征为自变量，目标特征为因变量的函数 $y = h(x)$ ，对于给定的一个样本 $x = \{x_1, x_2, \dots, x_n\}$ ，通过分类器可以确定其类别 y ，其中， $x \in X$ ， $y \in Y$ 。

准确率 (Accuracy)、灵敏性 (Sensitivity) 和特异性 (Specificity) 是三种评价分类器性能的常用度量标准，可以根据混淆矩阵 (Confusion Matrix) 对它们进行计算^[1]。混淆矩阵用来表示真正的类属性和预测的类属性之间的关系。对于二分类问题，混淆矩阵如图 2.1 所示。在图 2.1 中，给定两个类，一类为正样本 (positives) $C1$ ，一类为负样本 (negatives) $C2$ ，“真正” (true positives, TP) 指分类器正确标记的正样本 (实际为正、预测为正)，“真负” (true negatives, TN) 指分类器正确标记的负样本 (实际为负、预测为负)，“假正” (false positives, FP) 指错误标记的负样本 (实际为负、预测为正)，“假负” (false negatives, FN) 指错误标记的正样本 (实际为正、预测为负)。

		预测的类	
		C1	C2
实际的类	C1	真正(TP)	假负(FN)
	C2	假正(FP)	真负(TN)

图 2.1 二分类的混淆矩阵

Fig 2.1. Confusion matrix of dichotomous

定义 2.3 准确率. 分类器在测试集上的准确率表示分类器正确分类的测试集样本占测试集全体样本的百分比, 它反映了分类器对各类样本的识别情况, 标记为 *Accuracy*, 计算方法如公式 2-1 所示:

$$Accuracy = \frac{TP + TN}{TP + FP + FN + TN} \quad (2-1)$$

定义 2.4 灵敏性. 分类器在测试集上的灵敏性表示分类器正确识别的正样本占测试集全体正样本的百分比, 它反映了分类器对正样本的识别能力, 标记为 *Sensitivity*, 计算方法如公式 2-2 所示:

$$Sensitivity = \frac{TP}{TP + FN} \quad (2-2)$$

定义 2.5 特异性. 分类器在测试集上的特异性表示分类器正确识别的负样本占测试集全体负样本的百分比, 它反映了分类器对负样本的识别能力, 标记为 *Specificity*, 计算方法如公式 2-3 所示:

$$Specificity = \frac{TN}{TN + FP} \quad (2-3)$$

Accuracy 是分类问题中最基本也最常用的分类器性能评价指标, 它从整体上对分类器的分类性能作出评价。然而对于不平衡数据集分类问题, *Accuracy* 通常却不能对分类器的分类性能作出很好的评价。针对不平衡数据分类问题, 模式识别领域的研究人员提出了一些更为合理的评价指标, 常用的评价指标是查全率 *Recall* 和查准率 *Precision*。

定义 2.6 查全率. 查全率定义为正确分类的正样本占正确分类的正样本和错误分类的正样本的比例, 标记为 *Recall*, 计算方法如公式 2-4 所示:

$$Recall = \frac{TP}{TP + FN} \quad (2-4)$$

从定义可以看出, *Recall* 实际上等价于 *Sensitivity*。

定义 2.7 查准率. 查准率定义为正确分类的正样本占正确分类的正样本和错误分类的负样本的比例, 标记为 *Precision*, 计算方法如公式 2-5 所示:

$$Precision = \frac{TP}{TP + FP} \quad (2-5)$$

除了 *Recall* 和 *Precision* 外, 在一些文献中也经常使用真正率 (True Positive Rate, TPR) 来度量类别不平衡问题中分类器的分类性能。

定义 2.8 真正率. 真正率定义为正确分类的某类样本 (正样本或负样本) 占有该

类样本的比例。对于正样本（少数类样本），真正率标记为 $TPRMin$ ；对于负样本（多数类样本），真正率标记为 $TPRMaj$ 。计算方法分别如公式 2-6 和 2-7 所示：

$$TPRMin = \frac{TP}{TP + FN} \quad (2-6)$$

$$TPRMaj = \frac{TN}{TN + FP} \quad (2-7)$$

从定义可以看出， $TPRMin$ 实际上等价于 Recall 和 Sensitivity， $TPRMaj$ 实际上等价于 Specificity。本文在不同的实验中分别使用 Precision、Recall、Accuracy、 $TPRMin$ 和 $TPRMaj$ 评价类别不平衡数据集上分类器的性能。

2.3 随机森林模型

本文的主要目标是以医学数据为对象，研究基于随机森林的特征选择和分类算法。作为本文研究的理论基础，本节主要依据文献[63]讨论随机森林的数学模型。

2.3.1 随机森林的定义

Breiman 在文献[63]中给出了随机森林的形式化定义：

定义 2.9 随机森林. 随机森林是一个由一组决策树分类器构成的集成分类器 $R = \{h(x, \theta_k), k=1, 2, \dots, K\}$ ，其中 $\{\theta_k\}$ 是服从独立同分布的随机向量， K 表示随机森林中决策树的个数，在给定自变量 X 情况下，每个决策树分类器通过投票来决定最优的分类结果。

随机森林是许多决策树集成在一起的分类器，如果把决策树看成分类任务中的一个专家，随机森林就是许多专家在一起对某种任务进行分类。

2.3.2 随机森林的收敛性

定义 2.10 余量函数. 给定一组分类器 $h_1(x), h_2(x), \dots, h_K(x)$ ，每个分类器的训练集都是从原始的服从随机分布的数据集 $D = \langle Y, X \rangle$ 中随机抽样所得，余量函数定义为：

$$mg(X, Y) = \text{av}_k I(h_k(X) = Y) - \max_{j \neq Y} \text{av}_k I(h_k(X) = j) \quad (2-8)$$

式 2-8 中： $I(\cdot)$ 是示性函数。余量函数用于度量平均正确分类数超过平均错误分类数的程度，余量值越大，分类预测越可靠。

定义 2.11 泛化误差. 随机森林的泛化误差定义为：

$$PE^* = P_{X,Y}(mg(X,Y) < 0) \quad (2-9)$$

式2-9中, 下标 X, Y 表示概率 P 覆盖 X, Y 空间。在随机森林中, 当决策树分类器足够多, $h_k(X) = h(X, \theta_k)$ 服从强大数定律。

定理2.1 随着随机森林中决策树数量的增加, 对于几乎所有序列 $\theta_1, \theta_2, \dots, \theta_k$, PE^* 收敛于

$$P_{X,Y}\{P_{\theta}(h(X,\theta)=Y) - \max_{j \neq Y} P_{\theta}(h(X,\theta)=j) < 0\} \quad (2-10)$$

定理2.1表明随机森林不会随着决策树的增加而产生过拟合问题, 而其泛化误差会收敛于一个极限值。定理2.1的具体证明请参阅文献[63]附录1。

2.3.3 随机森林的泛化误差上界

对于随机森林, 考虑到单个分类器的准确性和多个分类器之间的依赖性, 泛化误差存在着一个上界, 理解单个分类器的准确性和多个分类器之间的依赖性之间的相互作用是理解随机森林工作原理的基础。本节进一步研究随机森林中分类器的性能和相关性, 下面对文献[63]中的推导过程作以介绍。

定义2.12 随机森林的边际函数。随机森林的边际函数定义为:

$$mr(X,Y) = P_{\theta}(h(X,\theta)=Y) - \max_{j \neq Y} P_{\theta}(h(X,\theta)=j) \quad (2-11)$$

其中, 组分类器 $\{h(x,\theta)\}$ 的分类性能定义为:

$$s = E_{X,Y}mr(X,Y) \quad (2-12)$$

假设 $s \geq 0$, 即基分类器为弱分类器, 则由切比雪夫不等式可以得到:

$$PE^* \leq \text{var}(mr) / s^2 \quad (2-13)$$

一个更明显的表示 mr 的方差的式子可以通过下面的推导得到: 令

$$\hat{j}(X,Y) = \arg \max_{j \neq Y} P_{\theta}(h(X,\theta)=j)$$

则有,

$$\begin{aligned} mr(X,Y) &= P_{\theta}(h(X,\theta)=Y) - P_{\theta}(h(X,\theta)=\hat{j}(X,Y)) \\ &= E_{\theta}[I(h(X,\theta)=Y) - I(h(X,\theta)=\hat{j}(X,Y))] \end{aligned}$$

定义2.13 原质边际函数 (raw margin function) . 原质边际函数定义为:

$$rmg(\theta, X, Y) = I(h(X, \theta) = Y) - I(h(X, \theta) = \hat{j}(X, Y)) \quad (2-14)$$

从式 2-14 可以看出, $mr(X, Y)$ 是 $rmg(\theta, X, Y)$ 的对于 θ 的期望。对于任意的函数 f , 有恒等式:

$$[E_{\theta} f(\theta)]^2 = E_{\theta, \theta'} f(\theta) f(\theta') \quad (2-15)$$

在式 2-15 中, θ 和 θ' 是服从独立同分布的随机参数, 于是有:

$$mr(X, Y)^2 = E_{\theta, \theta'} rmg(\theta, X, Y) rmg(\theta', X, Y) \quad (2-16)$$

从式 2-16 进而可以推出:

$$\text{var}(mr) = E_{\theta, \theta'} (\text{cov}_{X, Y} rmg(\theta, X, Y) rmg(\theta', X, Y)) = E_{\theta, \theta'} (\rho(\theta, \theta') sd(\theta) sd(\theta')) \quad (2-17)$$

其中, $\rho(\theta, \theta')$ 是当 θ, θ' 确定时 $rmg(\theta, X, Y)$ 和 $rmg(\theta', X, Y)$ 的相关系数, $sd(\theta)$ 是 $rmg(\theta, X, Y)$ 的标准差。于是有:

$$\text{var}(mr) = \bar{\rho} (E_{\theta} sd(\theta))^2 \leq \bar{\rho} E_{\theta} \text{var}(\theta) \quad (2-18)$$

其中, $\bar{\rho}$ 是相关系数的均值。亦即:

$$\bar{\rho} = E_{\theta, \theta'} (\rho(\theta, \theta') sd(\theta) sd(\theta')) / E_{\theta, \theta'} (sd(\theta) sd(\theta'))$$

由于

$$E_{\theta} \text{var}(\theta) \leq E_{\theta} (E_{X, Y} rmg(\theta, X, Y))^2 - s^2 \leq 1 - s^2 \quad (2-19)$$

综合考虑式 2-13、2-18 和 2-19, 可以得到下面的定理:

定理 2.2 随机森林泛化误差的一个上界是:

$$PE^* \leq \bar{\rho} (1 - s^2) / s^2$$

虽然上面的这个上界定的比较宽松, 但是它满足了与其他类型分类器相同的边界条件。这表明随机森林的泛化误差与两个因素相关: 森林中单个分类器的分类性能 s 和各个分类器之间的相关系数 ρ 。为了简化书写和便于理解, 可以使用比值 c/s^2 (分类器之间的

相关性除以分类器的性能的平方)表示随机森林的泛化误差。

定义2.14 c/s²比值。一个随机森林的c/s²比值定义为:

$$c/s^2 = \bar{\rho}/s^2$$

随机森林的泛化误差上界揭示了影响随机森林性能的主要因素,为随机森林的后续改进提供了理论基础。为了提高随机森林的分类正确率,需要通过随机化技术在保持单个分类器分类能力的同时最小化各分类器之间的相关性。也就是说,c/s²值越小,随机森林的分类性能越好。

2.3.4 随机重采样技术

通过前面的分析可知,为了提高随机森林的分类性能,需要采用随机化技术保证森林中多棵树的多样性和单棵树的强度,为此,Breiman在随机森林中联合了Bagging技术和随机子空间技术。Bagging随机重采样技术是由Breiman在1996年根据Boosting技术提出的一种有放回的采样技术,其本质上是Bootstrap采样^[64]。Bootstrap采样采用有放回地抽样方法从原始的样本容量为 N 的训练样本集合 D 中随机抽取 N 个样本生成新的训练样本集,独立抽样 k 次,生成 k 个相互独立的Bootstrap样本集。在Bootstrap采样过程中,每个样本未被抽取的概率为 $(1-1/N)^N$ 。当 N 的值足够大时,

$$\lim_{n \rightarrow \infty} (1-1/N)^N = e^{-1} \approx 0.368, \text{ 这表明原始样本集 } D \text{ 中接近 } 37\% \text{ 的样本不会出现在 Bootstrap}$$

样本中,这些数据成为袋外(Out Of Bag, OOB)数据^[113-114]。随机森林算法正是利用Bootstrap采样技术生成多个训练样本集,构建多个分类器,从而形成“森林”分类器,通过多数投票进行分类。Breiman通过实验证明,OOB误差是无偏估计。

Boosting技术也是一种有放回的采样技术,Boosting方法每一次训练都是在前一次训练基础上进行的,导致算法难以实现并行处理,并且Boosting方法在采样过程中对每个训练集都设置权重,因此每个训练集在投票时的地位是不同的。与Boosting随机重采样不同,Bagging方法在训练过程中采用独立随机的方式进行样本采样,另外Bagging方法采样得到的训练集是没有权重的,而在随机森林中采用Bagging方法采样产生的训练集与原始的训练集有很大不同,新的数据集不是原始数据集的简单复制,而是通过自身样本的重复达到样本空间的重构。由于采样生成的训练集是原始数据集随机采样得到的子集,因此各个新的训练数据集之间存在着一定的差异,从而使得森林中生成的决策树具有较强的随机性^[113]。Breiman通过实验验证了该随机化过程能够在保持单个分类器的分类能力的同时降低分类器之间的相关性,因此可以提高随机森林算法的精度。

解决类别不平衡问题的一种常用方法就是设计基于采样技术的集成机器学习算法。目前,大多数集成学习方法都是采用 Boosting 随机重采样,如前所述,Boosting 方法每一次训练分类器都是在前一次的基础上进行的,由于反复训练增加了时间开销,无法应用于大规模数据处理;另外,Boosting 是一种加权采样方法,对训练集权重的设置破坏了采样产生的训练集的随机性,进而影响基分类器的随机性。受随机森林 Bagging 技术的启发,本文提出了一种基于 Bootstrap 的集成学习算法,Bootstrap 算法在采样过程中采用随机独立的方式,通过有放回地的随机重采样保证基分类器具有更好的随机性和多样性,同时通过集成多个基分类器可以尽量避免随机欠采样带来的信息损失,保证了算法整体的正确率,从而克服样本类别不平衡带来的负面影响。

2.3.5 训练决策树

决策树算法是一种最基本和最常用的分类算法,最早的决策树算法是由 J. Ross Quinlan 提出的,命名为 ID3。后来,Quinlan 提出了 ID3 算法的改进算法 C4.5。1984 年,L. Breiman 等人设计了二叉决策树生成算法,命名为分类与回归树 (Classification and Regression Tree, CART)。决策树的每一个内部节点表示在一个特征上的测试,每一个分支表示一个测试的结果,每一个叶子节点则代表一个类别或类分布。对于一个分类问题,构造一个决策树实际上是对问题进行自顶向下递归分治的过程。给定一个类标号未知的样本 X ,对 X 进行分类,就是在决策树上测试样本的属性值,跟踪其经过的由根节点到叶节点的路径,该叶子节点所表示的类别就是 X 的类标签。大多数决策树构造算法都采用贪心算法,从训练样本集出发,递归地划分成较小的子集,直到所有子集中的样本类别是相同的或者满足某种分布。

不同版本的决策树算法之间的主要差别有两点:一是在创建树时如何选择属性,二是对树如何进行剪枝。ID3 算法用于选择特征的度量为信息增益,每次进行树节点分裂时,ID3 选取信息增益最大的特征作为该节点的分裂特征。C4.5 算法是对 ID3 算法的改进,它在 ID3 算法的基础上增加了某些功能,包括对连续值属性的处理,采用后剪枝技术避免树的不平衡,采用增益率代替信息增益作为属性选择的度量,采用交叉验证克服偏倚等。CART 算法采用 Gini 指标作为属性选择的度量,对于数据集中的数据类型为离散值的特征,在进行树节点分裂时选择产生最小 Gini 指标的特征子集作为该节点的分裂子集;对于数据类型为连续值的特征,选取连续值特征中产生最小 Gini 指标的点作为该特征的分裂点。本文中所用到的 RF 算法的基分类器是 CART 算法,这使得 RF 分类器的可理解性较好,更加适用于医学数据挖掘。然而,与一般的 CART 树不同,在训练随

机森林基分类器过程中,决策树在节点分裂时引入了随机特征变量选取技术,不是所有的特征都参与节点分裂,而是随机地选择若干个特征进行指标计算并最终选择一个特征进行节点分裂,通过这种方法可以降低森林中每棵决策树之间的相关性,同时提升每棵决策树的分类精度,从而提升整个森林的性能。另外,在随机森林中,训练 CART 树不需要对树进行修剪,通过随机化技术和分类器集成可以有效避免“过拟合”。

2.3.6 随机森林算法

如前所述,随机森林算法组合了装袋技术和树节点随机分裂技术,通过在多个随机采样数据集上训练多个决策树分类器,然后通过多数投票决定未知样本的类别。训练随机森林分类模型的基本步骤如下^[63]:

1. 假设给定原始训练数据集 (X, Y) , 样本个数为 N , 标记为 $(x_1, y_1), (x_2, y_2) \dots, (x_N, y_N)$, 采用 Bootstrap 方法通过 N 次有放回地随机采样抽取一个新的样本集合 (X^*, Y^*) , 集合中的样本表示为 $(x_1^*, y_1^*), (x_2^*, y_2^*) \dots, (x_N^*, y_N^*)$; 没有被抽取的样本组成袋外数据集;
2. 在数据集 (X^*, Y^*) 上训练一棵分类回归树;
3. 重复步骤1-2, 生成多棵树, 构成一个森林;
4. 用森林中的每棵树为 OOB 中的样本 x_i 进行分类;
5. 统计每个类别获得的投票数, 得票数最多的类别被认为是样本 x_i 的类别。
6. 计算 OOB 中未被正确分类的样本的比例, 就是随机森林的袋外分类错误率。

以上只是给出了随机森林算法的一个框架性描述, 具体地采用什么样的决策树作为基分类器, 如何构建这些分类树等更多内容, 读者可参照相关文献。本文借鉴随机森林算法随机重采样和基分类器集成的思想, 提出了一种面向不平衡数据分类的随机森林改进算法, 通过有放回地随机采样技术构建多个类别平衡的特征子集, 进而构建多个随机森林分类器, 经过多数投票确定未知样本的类别, 可以看成是对于原始随机森林算法的一个扩展。本文所提出算法的核心算法是随机森林算法在 R 平台上的一个具体实现——randForest 算法。

2.4 面向类别不平衡数据集的 RF 分类算法 BRF

2.4.1 BRF 算法设计

为了解决随机森林分类算法在样本类别不平衡数据集上分类性能降低的问题, 针对

随机欠采样带来的信息损失问题,采用集成机器学习思想,本文提出了一种新的面向类别不平衡数据分类的随机森林改进算法。该算法在训练RF分类器之前,首先利用Bootstrap方法分别从多数类样本集合和少数类样本集合中有放回地随机抽取与少数类样本数量一致的多个样本子集,然后将抽取的各个多数类样本子集与少数类样本子集重新组合,得到多个新的样本类别分布平衡的训练数据集,接下来在这多个训练数据集上分别训练RF分类器,形成一个随机森林的“森林”。当对一个未知样本进行分类或预测时,该样本的类别由多个RF分类器通过多数投票决定。该算法的具体设计如算法2.1所示。

算法2.1: 面向类别不平衡数据集的RF分类算法BRF

输入: 数据集 D , BRF中RF基分类器的个数 nrf

输出: 面向不平衡数据分类的集成分类器 $BRF(x)$, 测试集上的混淆矩阵 $CMATRIX$

步骤:

1. 设置 nrf 的值; // 初始化

2. 将训练集 D 划分为多数类样本子集 $D_{majority}$ 和少数类样本子集 $D_{minority}$;

// 循环训练 nrf 个RF分类器

3. for (i 从 1 到 nrf) // i 为循环变量

4. 对 $D_{majority}$ 进行有放回地随机重采样得到 $D_{majority}^{sampling}$, 满足 $|D_{majority}^{sampling}| = |D_{majority}|$;

5. 对 $D_{minority}$ 进行有放回地随机重采样得到 $D_{minority}^{sampling}$, 满足 $|D_{minority}^{sampling}| = |D_{minority}|$;

6. 生成训练数据集 $D_{train} = |D_{majority}^{sampling}| + |D_{minority}^{sampling}|$;

7. 生成测试数据集 $D_{test} = D - D_{train}$;

8. 在 D_{train} 上训练随机森林分类器 $RF_i(x)$;

9. 在 D_{test} 上对 $RF_i(x)$ 进行测试, 得到混淆矩阵 $CMATRIX_i$;

10. end for

// 集成 nrf 个RF分类器, 得到最终的分器 BRF

11. $BRF(x) = \text{sgn} \sum_{i=1}^{nrf} RF_i(x)$;

// 计算 nrf 个测试集上的平均混淆矩阵, 得到最终的混淆矩阵 $CMATRIX$;

12. $CMATRIX = \frac{1}{nrf} \sum_{i=1}^{nrf} CMATRIX_i$;

13. 输出 $BRF(x)$ 和 $CMATRIX$;

在算法2.1中, 步骤1为初始化, 首先设置面向类别不平衡数据集的集成分类器中RF基分类器的个数。步骤2将原始的训练集划分为多数类样本集合 $D_{majority}$ 和少数类样本集合 $D_{minority}$ 。

算法2.1的步骤3至步骤10是算法的核心。首先, 在步骤4中采用有放回的随机重采样方法从多数类样本集合 $D_{majority}$ 中抽取与少数类样本集合 $D_{minority}$ 大小相同的样本子集 $D_{majority}^{sampling}$; 接着, 在步骤5中采用有放回的随机重采样方法从少数类样本集合 $D_{minority}$ 中抽取与少数类样本集合 $D_{minority}$ 大小相同的样本子集 $D_{minority}^{sampling}$; 在步骤6中, 将 $D_{majority}^{sampling}$ 和 $D_{minority}^{sampling}$ 进行组合得到样本类别平衡的训练数据集 D_{train} , 在步骤7中, 将随机重采样剩下的(没有被选作训练样本)的样本集合作为测试数据集 D_{test} ; 在步骤8中, 在新构建的训练数据集 D_{train} 上训练RF分类器, 在步骤9中, 在测试数据集 D_{test} 上对步骤8中生成的RF分类器进行测试, 计算测试集上的混淆矩阵 $CMATRIX_i$; 重复执行步骤4至步骤9共 nrf 次, 生成 nrf 个RF分类器和混淆矩阵。

最后, 算法的步骤11将步骤3-10生成的 nrf 个RF分类器通过多数投票的方式组合成最终的能够处理类别不平衡问题的随机森林的森林分类器; 步骤12通过求平均值方式计算 nrf 个测试数据集上的混淆矩阵; 步骤13输出 $BRF(x)$ 和 $CMATRIX$ 。

需要说明的是, 算法2.1只适用于二分类问题。如果数据集 D 中的样本类别多于两类, 则认为样本个数最少的类别是少数类(正例), 所有其它的样本放在一起被看做多数类(反例)。

2.4.2 算法分析

2.4.2.1 有效性分析

从定理 2.2 可知, 随机森林的泛化误差与两个因素相关: 森林中单个分类器的分类性能 s 和各个分类器之间的相关系数 ρ 。算法 2.1 中的基分类器实际上是类别平衡数据集上的随机森林分类器, 通过随机森林自身的特性能够有效地保证基分类器的分类强度, 而各个基分类器之间的相关性则通过 Bootstrap 采样进行调节。由于构建类别平衡的数据集采用的是有放回地随机重采样方法, 每一个多数类(或少数类)样本被选中的概率都相同, 某一个多数类(或少数类)样本可能在同一个采样训练数据集中出现多次, 而其它一些多数类(或少数类)样本却被忽略, 从而导致部分多数类(或少数类)样本的信息损失, 但由于 Bootstrap 并不侧重于训练数据集中的任何特定样本, 通过有放回地随机重采样可以降低噪声以及类别不平衡性对特征区分能力所带来的负面影响, 同时可以避

免过拟合的影响。进一步地，通过分类器集成的方式可以有效地弥补欠采样带来的信息损失，有效地提高分类器的分类性能^[57]。

具体地，假设训练集 D_{train} 中多数类样本的数量为 N_{maj} ，少数类样本的数量为 N_{min} ，则多数类样本和少数类样本的不平衡比率 $ratio = N_{maj} / N_{min}$ 。如果采用有放回的随机重采样技术对多数类样本进行采样，采样大小（次数）等于少数类样本的数量 N_{min} ，则多数类中每个样本未被抽取的概率为 $(1 - 1 / N_{maj})^{N_{min}}$ ，将 $ratio = N_{maj} / N_{min}$ 代入上式，每个样本未被抽取的概率可以表示为： $P = (1 - 1 / N_{maj})^{N_{maj} / ratio} = ((1 - 1 / N_{maj})^{N_{maj}})^{1 / ratio}$ 。当 N_{maj} 足够大时， $\lim_{n \rightarrow \infty} (1 - 1 / N_{maj})^{N_{maj}} = e^{-1} \approx 0.368$ 。又 a^x ($0 < a < 1$) 当 $x > 0$ 时是减函数，同时当 $ratio > 0$ 时， $1/ratio$ 是减函数。假设 N_{min} 的值不变，当 N_{maj} 的值越大时， $ratio$ 的值越大， $1/ratio$ 越小， $(1 - 1 / N_{maj})^{N_{maj}}$ 趋向于 0.368，则 P 值越大，即每次采样的信息损失越大，同时采样集合（训练集）的随机性也越大，则基分类器的相关性越小，此时可以通过增加森林中基分类器的个数（即 nrf 的值）来克服信息损失对分类性能的影响，提高 BRF 分类器的分类性能。相反，假设 N_{min} 的值不变，当 N_{maj} 的值越小（但足够大）时， $ratio$ 的值越小， $1/ratio$ 越大， $(1 - 1 / N_{maj})^{N_{maj}}$ 趋向于 0.368，则 P 值越小，即每次采样的信息损失越小，同时采样集合（训练集）的随机性降低，则基分类器的相关性较强，此时也可以通过增加森林中基分类器的个数（即 nrf 的值）来增加基分类器的随机性，从而保证 BRF 分类器的分类性能。由此可以推出，算法 2.1 的适用范围是原始训练集中的样本类别不平衡比率适中的情况，通过增加 nrf 的值可以提高 BRF 分类器的总体性能，当然这将增加算法的执行时间，本文后面的实验结果也验证了这一点。

2.4.2.2 复杂度分析

在算法2.1中，主要的时间开销是训练RF分类器的过程。假设训练数据集D的特征维数为 m ，训练样本个数为 n ，CART算法的时间复杂度为 $O(m * n * (\log n)^2)$ 。RF在构建CART树的过程中，从 m 个特征中随机选择 $mtry$ 个特征计算信息增益，并且对树的生长不进行剪枝，故训练每一个基分类器的计算时间小于 $O(m * n * (\log n)^2)$ 。假设RF分类器中基分类器的个数为 k 个，则RF算法的时间复杂度可以近似为 $O(k * m * n * (\log n)^2)$ ，即在单个采样训练数据集上的计算时间开销为 $O(k * m * n * (\log n)^2)$ 。此外，在对 nrf 个样本类别平衡数据集上训练RF分类器之前需要进行有放回地的随机重采样，每次采样的时间复杂度为

$O(n*m)$ 。最后, 集成 nrf 个基分类器的时间近似为 $O(nrf)$ 。因此算法2.1的时间复杂度为: $nrf * (O(k * m * n * (\log n)^2) + O(n * m) + O(nrf)) \approx O(nrf * k * m * n * (\log n)^2)$, 可见所提出的算法的时间开销基本上是原始的RF算法的 nrf 倍, 在规模适度的数据集上, 其计算时间是可以接受的。

2.5 实验及结果分析

2.5.1 实验设计

本章针对医学数据集中的类别不平衡导致随机森林算法分类性能下降的问题, 研究通过采用 Bootstrap 随机重采样技术和集成机器学习思想, 改进随机森林分类器在类别不平衡数据集上的分类性能。为了验证 BRF 算法的有效性, 本文设计了两组实验: 实验一和实验二。

首先, 通过实验一对采用 Bootstrap 随机重采样方法平衡数据集中样本类别并通过分类器集成提高分类性能的方法的有效性, 与基于简单划分的集成方法、基于 AdaBoost 的集成方法进行实验对比。邹等人在文献[61]提出了一种处理类别不平衡分类问题的集成学习算法 LibID, 将多数类样本分成多份, 每一份的大小与少数类样本数目近似相等, 然后分别与少数类样本组合成多个类别平衡的训练集, 并在不同的训练集上采用不同的分类算法训练分类器, 最后采用基于重复训练错分样本的优化策略, 将多个弱分类器集成为强分类器。刘等人在文献[116]中提出了一种基于级联模型的类别不平衡数据分类算法 BalanceCascade, 该方法通过逐步缩小大类别使数据集趋于平衡, 并采用 AdaBoost 算法训练得到一系列基分类器, 最后通过加权组合将多个弱分类器集成为强分类器。本文采用与文献[61]和文献[116]中同样的数据集对 BRF 算法进行实验验证, 实验结果与对比分析在 2.5.3 小节进行介绍。

其次, 通过实验二对所提出的方法与基于主动样本选择的集成算法进行实验对比。针对生物医学数据不平衡分类问题, Sangyoon 等人在文献[57]中提出了一种基于主动样本选择的集成机器学习算法 EAES, 该算法实际上是一种结合了代价敏感和集成学习算法思想的分类算法, 采用朴素贝叶斯算法作为其基分类器, 采用主动样本选择方法构造训练集, 采用加权投票方法组合基分类器的分类结果; 在 5 个生物医学数据集上的实验结果表明 EAES 方法在类别不平衡数据集上的分类性能优于原始的朴素贝叶斯算法、基于 RUS 的分类算法、单纯的主动样本选择算法和基于 RUS 的集成分类算法。为了验证 BRF 算法的有效性, 本文在同样的生物医学数据集上进行了实验, 实验结果与对比分析

在 2.5.4 小节进行介绍。

2.5.2 实验数据与参数设置

实验一中所用到的 5 个实验数据集分别为避孕流行调查数据集 (cmc)^[117]、乳腺癌患者生存情况数据集 (haberman)^[118]、雷达数据集 (ionosphere)^[119]、字符图像数据集 (letter)^[120]和糖尿病临床数据集 (pima)^[121]，这些数据集来自于 UCI 机器学习数据库，基本信息如表 2.1 所示。

表 2.1 实验一所用的数据集的基本特征

Table 2.1 Summary of UCI datasets in experiment 1

数据集	特征个数	样本个数	正例样本数	反例样本数	正例样本类别	不平衡率
cmc	10	1473	333	1140	2	3.42
haberman	4	306	81	225	2	2.78
ionosphere	35	351	126	225	b	1.79
letter	17	20000	789	19211	A	24.35
pima	9	768	268	500	1	1.87

其中，haberman、ionosphere 和 pima 数据集都是二分类问题，在实验中，少数类样本作为正例样本，多数类样本作为反例样本。cmc 数据集是一个三分类问题，目标变量表示是否使用避孕方法：1 表示无使用、2 表示长期使用、3 表示短期使用；在 1473 个样本中，类别为 1 的样本个数为 629，类别为 2 个样本个数为 333，类别为 3 的样本个数为 511，在本文中，将类别 2 作为少数类（正例），将类别 1 和 3 一起作为多数类（反例）。letter 数据集的目标变量表示英文字符 A-Z，总共有 26 个类别，本文中将 789 个类别为 A 的样本作为少数类（正例），将剩余的 19211 个类别为 B-Z 的其他所有样本作为多数类（反例）。

实验二中所用到的 5 个实验数据集分别为肝炎临床数据集 (Hepatitis)^[122]、帕金森疾病数据集 (Parkinson)^[123]、糖尿病临床数据集 (Diabetes)^[124]、乳腺癌预后图像数据集 (WPBC)^[125]和心脏病图像数据集 (SPECT)^[126]，这 5 个数据集均来自于 UCI 机器学习数据库，其基本信息如表 2.2 所示。

表 2.2 实验二所用的数据集的基本特征

Table 2.2 Summary of UCI datasets in experiment 2

数据集	特征个数	样本个数	正例样本数	反例样本数	正例样本类别	不平衡率
Hepatitis	19	155	32	123	terminal	3.84
Parkinson	22	194	47	147	healthy	3.13
Diabetes	8	768	268	500	diabetes	1.87
WPBC	33	198	47	151	recur	3.12
SPECT	43	267	55	212	normal	3.85

在实验一和实验二中，BRF 算法采用 R 语言编程实现，其基分类器采用 R 软件平台下的 randomForest 程序包。算法的硬件执行环境配置为 Intel Core (TM) 2 Duo CPU E4600@2.40GHz 处理器和 3.75G 内存。randomForest 中的参数 ntree 设置为 1000，mtry 设置为 $\sqrt{n}$ ，其中 n 为原始数据集 D 中分类特征的个数，这两个参数都是采用的 Breiman 提出的建议值，在文献中被广泛使用。

2.5.3 实验一结果及分析

表 2.3 列出了 BalanceCascade^[116]、LibID (once)^[61]、LibID (repeat)^[61]、RF^[63]和本文所提出的 BRF 等 5 种算法在 5 个 UCI 数据集上的查准率。参与比较的算法的基本原理参见本文 2.5.1 小节。为了保证结果的稳定性，每种算法执行 10 次，10 次执行的查准率平均值作为算法总体分类精度。表 2.4 列出了 5 种算法在 UCI 数据集上的查全率。类似的，为了保证结果的稳定性，每种算法执行 10 次，10 次执行的查全率平均值作为算法的总体分类精度。

表 2.3 不同算法的查准率比较

Table 2.3 The precision comparison of different algorithms

Dataset	BalanceCascade	LibID(once)	LibID(repeat)	RF	BRF
cmc	0.35	0.48	0.50	0.56	0.51
haberman	0.36	0.54	0.59	0.44	0.64
ionosphere	0.93	0.94	0.94	0.94	0.96
letter	0.96	0.88	0.85	0.99	0.90
pima	0.60	0.78	0.77	0.70	0.81

表 2.4 不同算法的查全率比较

Table 2.4 The recall comparison of different algorithms

Dataset	BalanceCascade	LibID(once)	LibID(repeat)	RF	BRF
cmc	0.59	0.74	0.67	0.28	0.95
haberman	0.57	0.80	0.84	0.23	0.89
ionosphere	0.89	0.89	0.91	0.87	0.97
letter	0.99	0.99	0.98	0.95	1.00
pima	0.71	0.76	0.81	0.61	0.99

从表 2.3 可以看出，除 letter 数据集外，BRF 算法在其他 4 个实验数据集上的查准率均明显高于 BalanceCascade 和 LibID 算法；在 letter 数据集上，BRF 算法的分类性能低于 BalanceCascade 算法但高于 LibID 算法。我们分析出现这种现象的原因在于 letter 数据集的类别不平衡比率太高（达到 24.35），BRF 算法在 Bootstrap 采样过程中造成的多数类样本的信息损失较大，使得基分类器对多数类样本的分类性能下降，从而导致多数类样本的误分类样本数较大，进而降低了 BRF 算法的查准率。另外，与原始的 RF 算法相比，BRF 算法在 letter 数据集上的查准率低于 RF 算法，我们分析主要原因是：对于原始的 RF 算法而言，letter 数据集是一个强可分的数据集，对于多数类样本，RF 算法具有近乎完美的分类性能，尽管对于少数类的识别能力较差，但由于对于多数类样本的分类正确率非常高，使得对于少数类样本的查准率没有产生太大的影响，因而具有很高的查准率；然而对于 BRF 算法而言，由于多数类样本信息的损失导致多数类样本的分类性能降低，错分为少数类的多数类样本较多，从而降低了少数类样本的查准率。

从表 2.4 可以看出，在所有 5 个实验数据集上，BRF 算法的查全率均明显高于 BalanceCascade、LibID 和原始的 RF 算法，在 letter 数据集和 pima 数据集上甚至获得了近乎完美的结果，这表明 BRF 算法对于少数类样本具有非常强的识别能力。特别的，原始的 RF 算法在除 letter 以外的数据集上的查全率均非常低，这是由于数据集中的样本类别不平衡影响了 RF 算法对于少数类样本的识别能力，而 letter 数据集是一个强可分数据集，样本类别不平衡对分类器识别少数类样本的能力影响相对较小，从而具有较高的查全率；而 BRF 算法由于通过 Bootstrap 采样平衡了训练样本集中多数类和少数类样本的数目，提高了 RF 算法的对少数类样本的分类能力，因此具有很高的查全率，这说明 BRF 算法能够有效地克服样本类别不平衡导致分类器对少数类样本的识别能力降低的问题。

综合表 2.3-2.4 可以得出结论：在多数数据集上，BRF 算法能够在保持或提高少数类

样本查准率的同时，有效地提高少数类样本的查全率。另外，在有些数据集上，由于多数类样本信息的损失，导致 BRF 算法对于多数类样本的识别能力降低，从而降低对于少数类样本的查准率，但能够明显提高少数类样本的查全率。

2.5.4 实验二结果及分析

表 2.5 列出了朴素贝叶斯 (NB)^[57]、降采样 (RUS)^[57]、主动样本选择 (AES)^[57]、基于降采样的集成算法 (ERUS)^[57]、基于主动样本选择的集成算法 (EAES)^[57]、随机森林 (RF)^[63]和基于 Bootstrap 采样的随机森林集成算法 (BRF) 等 7 种算法在 5 个实验数据集上的分类正确率，表 2.6 列出了上述 7 种算法在 5 个实验数据集上少数类的真正率和多数类的正真率。其中，所有实验结果均是 10 次运行的平均值。参与比较的算法的基本原理参见本章 2.5.1 小节的相关介绍。

表 2.5 不同算法的分类正确率比较

Table 2.5 The comparison of Accuracy of different algorithms

Dataset	NB	RUS	AES	ERUS	EAES	RF	BRF
Hepatitis	0.837	0.818	0.935	0.811	0.928	0.852	0.914
Parkinson	0.687	0.687	0.768	0.692	0.814	0.852	0.923
Diabetes	0.751	0.745	0.779	0.743	0.784	0.776	0.911
WPBC	0.672	0.617	0.737	0.616	0.818	0.808	0.942
SPECT	0.689	0.660	0.772	0.663	0.798	0.813	0.869

如表 2.5 所示，除 Hepatitis 数据集外，在其他 4 个实验数据集上，BRF 算法的分类正确率均明显高于其他算法；在 Hepatitis 数据集上，RF 算法和 BRF 算法均高于 NB、RUS 和 ERUS 算法但低于 AES 和 EAES 算法，同时 BRF 算法明显高于 RF 算法，这可能是由于基于主动样本选择的算法更适合于 Hepatitis 数据集。在所有 5 个数据集上，BRF 算法的分类正确率均明显高于原始的 RF 算法，这表明 BRF 算法能够有效地解决 RF 算法在类别不平衡数据集上分类性能下降的问题。由于引入了 Bootstrap 随机重采样对训练集中的样本类别进行了平衡，能够有效地提高单个 RF 分类器对于少数类的分类能力，同时通过基分类器集成克服了随机重采样造成的信息损失，因此可以从总体上提高 RF 分类器的分类能力。这一点与本章算法分析中的结论是一致的。

表 2.6 不同算法的真正率比较

Table 2.6 The comparison of True Positive Rate of different algorithms

Dataset	Class	NB	RUS	AES	ERUS	EAES	RF	BRF
Hepatitis	Min	0.675	0.775	0.875	0.775	0.875	0.531	1.00
	Maj	0.877	0.829	0.951	0.821	0.943	0.935	0.892
Parkinson	Min	0.865	0.890	0.955	0.910	0.935	0.531	1.00
	Maj	0.625	0.619	0.706	0.619	0.774	0.935	0.894
Diabetes	Min	0.601	0.686	0.687	0.683	0.702	0.612	0.992
	Maj	0.832	0.776	0.828	0.776	0.828	0.864	0.874
WPBC	Min	0.470	0.530	0.575	0.560	0.620	0.213	1.00
	Maj	0.734	0.641	0.788	0.635	0.880	0.993	0.921
SPECT	Min	0.877	0.930	0.967	0.930	1.00	0.236	0.996
	Maj	0.642	0.590	0.722	0.595	0.746	0.962	0.830

表 2.6 展示了不同算法在 5 个实验数据集上分别对少数类样本和多数类样本的识别能力。从实验结果可以看出，除 Hepatitis 数据外，在其他 4 个实验数据集上，BRF 算法无论对于少数类样本还是对于多数类样本的识别能力均高于其他算法；在 Hepatitis 数据集上，BRF 算法对于多数类样本的识别能力低于 AES 和 EAES 算法但高于其他算法，但对于少数类样本的识别能力明显高于 AES、EAES 和其他所有算法，这可能是由于基于主动样本选择的算法更适合于分类 Hepatitis 数据集。在几乎所有数据集上，BRF 算法对于多数类样本的分类能力均低于原始的 RF 算法，这是由于 BRF 算法的随机重采样过程导致了多数类样本的信息损失；但是在所有数据集上，BRF 算法对于少数类样本的分类能力明显高于原始的 RF 算法，这说明 BRF 算法对于提高类别不平衡数据集上少数类样本的分类能力是有效的。

综合表 2.5-2.6 可以得出结论：BRF 算法在样本类别不平衡数据集上会降低 RF 算法对于多数类样本的分类能力，但可以显著提高 RF 算法对于少数类样本的分类能力，同时 BRF 算法能够从整体上提高 RF 算法的分类正确率。

2.5.5 参数设置讨论

在 BRF 算法中，有一个重要的参数 *nrf*，即 BRF 集成分类器中基分类器（RF 分类器）的个数。通过前面的算法分析可以知道，BRF 算法通过 Bootstrap 随机重采样来平衡训练数据集中的样本类别，从而提高单个 RF 分类器对于少数类样本的分类能力，但

同时会导致多数类样本的信息损失，这个问题可以通过多个分类器集成进行缓解，因此，BRF 集成分类器中 RF 基分类器的数量对 BRF 算法的性能具有重要的影响。一般而言，BRF 中基分类器的个数越少，分类器集成决策的可靠性越低；BRF 中基分类器的个数越多，分类器集成决策的可靠性越高。但是，也不是基分类器的个数越多越好，因为如前面算法复杂度分析所讨论的，BRF 算法的时间复杂度基本上是原始 RF 算法时间复杂度的 nrf 倍，因此 BRF 中基分类器的个数越多，则算法的执行时间越长，并且当算法的分类性能达到一定程度之后，通过增加基分类器的数量将不会对提升分类器性能产生影响。

本节将通过实验方法研究 nrf 参数设置对于 BRF 分类器性能的影响。在 Hepatitis、Parkinson、Diabetes、WPBC 和 SPECT 数据集上进行实验，分别设置 BRF 中 nrf 的值为 3、5、7、9、11、13、15、17、19，计算 BRF 在不同数据集和不同 nrf 值条件下的分类正确率、查准率、查全率、少数类样本真正率、多数类样本真正率，共 45 组实验，每组实验均运行 BRF 算法 10 次，10 次实验结果的平均值作为该组实验最终的结果。5 个数据集上的实验结果分别如图 2.2-2.6 所示。




图 2.2 在 Hepatitis 数据集上的实验结果

Fig 2.2. The experiment result on Hepatitis dataset




图 2.3 在 Parkinson 数据集上的实验结果

Fig 2.3. The experiment result on Parkinson dataset




图 2.4 在 Diabetes 数据集上的实验结果

Fig 2.4. The experiment result on Diabetes dataset




图 2.5 在 WPBC 数据集上的实验结果

Fig 2.5. The experiment result on WPBC dataset




图 2.6 在 SPECT 数据集上的实验结果

Fig 2.6. The experiment result on SPECT dataset

从图 2.2-2.6 可以看出, 在所有 5 个数据集上, 随着 nrf 值的增加, 分类器的准确率、查准率、查全率、少数类的真正率、多数类的真正率均呈现增长趋势, 直到达到一个最大值之后, 基本上趋于稳定, 这个结果与理论分析的结论是一致的。另外, 从图中还可以看出, 在 5 个实验数据集上, BRF 分类器均获得很高的查全率、准确率、少数类真正率和多数类真正率, 但是少数类的查准率较低, 如前面所分析的, BRF 中随机重采样导致多数类信息的损失, 使得多数类样本被分为少数类样本的数目增加, 从而降低了少数类样本的查准率。通过增加 BRF 中基分类器的个数, 可以一定程度上提高查准率。然而, 如何在保证查全率的前提下进一步提高查准率, 是一个需要进一步研究的方向。

2.6 本章小结

样本类别不平衡数据分类问题是机器学习和模式分类的重要研究方向, 本章针对医学数据分类中因为样本类别不平衡导致随机森林分类性能下降的问题, 结合 Bootstrap 随机重采样和集成机器学习思想, 提出了一种面向样本类别不平衡医学数据分类问题的随机森林改进算法。在第 2.1 节对当前处理类别不平衡医学数据分类问题的相关研究进行了总结并提出存在的问题; 在第 2.2 节给出了所研究问题相关的基本概念和假设; 在第 3.3 节对随机森林的基本概念和算法原理进行了介绍; 在第 2.4 小节给出了 BRF 算法的具体设计并对算法进行了正确性分析和复杂度分析; 最后在第 2.5 小节通过实验对 BRF 算法的性能进行了验证和分析。理论分析和实验结果表明 BRF 算法在类别不平衡医学数据集上能够在保持或提高分类器整体性能的前提下有效地提高少数类样本的识别能力。然而, BRF 算法中随机重采样过程会导致多数类样本信息损失, 从而影响少数类样本的查准率, 如何更好地提高分类器的查准率是一个需要进一步研究的方向。

第3章 基于RF的Filter式特征选择算法研究

3.1 引言

疾病危险因素分析和疾病类型预测是医学数据挖掘领域的重要研究方向^[128]。人类复杂疾病和多发疾病严重影响着人们的身体健康和生命安全,如乳腺癌、心脏病、老年痴呆症、糖尿病及其并发症等,在全球范围内有着非常高的发病率。通常,有众多的因素可以影响疾病的发生和发展,统称为疾病危险因素。这些危险因素分为可控制的危险因素和不可控制的危险因素,如果能够准确地识别出可控制的危险因素并采取有针对性的预防和治疗,疾病的发病率和死亡率可以大幅度降低^[129-130]。在医学数据挖掘领域,通常是机器学习专家与医学专家合作,针对某类疾病的临床诊断数据或生物学数据进行挖掘,识别影响疾病的危险因素或生物标记物,建立疾病分类或预测模型,进而探索疾病的发病规律,寻找合适的预防和治疗方案。

多年来,有众多的统计学方法和机器学习方法被用于医学数据分类和疾病危险因素分析,包括主成分分析、LDA、QDA、SVM、MLP、ANN、CART等,取得了很多创新性的研究成果。然而,由于医学数据所固有的异质性、内容不完整性、特征空间高维性、相关性和冗余性等特点,经典的分类算法在医学数据集上的分类精度有时候并不理想;另外,当所处理的医学数据集的维数非常大时,算法的性能和执行时间都面临严峻的挑战,引起“维数灾难”。在对医学数据集进行挖掘分析时,在训练分类或预测模型之前或者训练模型的过程中,通过特征选择技术可以剔除冗余特征、噪声特征和不相关特征,识别出和目标变量最相关的特征变量,降低分类或预测模型的复杂度,生成易于理解的模型,同时提高模型的分类或预测精确度,减少训练和执行模型的时间。通过特征选择技术选择出的和目标变量最相关的特征子集,对于研究疾病危险因素具有十分重要的参考价值。因此,特征选择技术是医学数据挖掘中一个重要的研究内容,具有很强的理论研究和实践应用价值。

随机森林算法具有分类精度高、运算速度快、鲁棒性好等优点,善于从具有小边际效应和复杂相互作用的特征集合中识别出主相关特征,因此非常适用于医学数据挖掘任务。尤其是随机森林算法通过随机扰动样本的方法计算数据集中每个特征的变量重要性分数,有助于人们理解特定的分类特征对于目标变量的影响程度。利用随机森林变量重要性分数可以作为特征选择的评价准则,通过各种特征搜索策略识别出与目标变量最相关的特征子集,是探索疾病危险因素的一个有效途径。

本章首先介绍特征选择的基本概念和原理，在此基础上，针对医学数据挖掘中疾病危险因素分析的实际需求和医学临床数据集上分类器分类性能不高的问题，重点研究基于 RF 的 Filter 式特征选择算法。Filter 式特征选择技术可以在训练分类或预测模型之前剔除噪声特征和不相关特征，识别出与目标变量最相关的最优特征子集，在此基础上训练分类或预测模型，在保持或提高分类或预测性能的同时简化模型，降低算法执行时间。目前，基于 Filter 式的特征选择算法大多是基于统计学方法（如 T 测试、Fisher 测试等），对于特征之间存在复杂相互关系的医学数据集来说，统计测试难以准确地刻画分类特征对于目标变量的相对重要性，从而影响特征选择结果的可靠性。本文所提出的基于随机森林变量重要性分数的 Filter 式特征选择，利用了随机森林善于处理特征之间具有复杂相互作用的数据的优势，以随机森林变量重要性分数为依据，迭代选择最优特征子集，最终产生分类精度高和可理解性好的算法模型。

3.2 算法基础及相关工作

3.2.1 特征选择的概念

在机器学习和数据挖掘领域，特征选择可以定义为一个寻找最优特征子集的过程：给定一个学习算法 L ，一个数据集 S ，数据集 S 来自一个具有 n 个特征 $X_1, X_2, X_3, \dots, X_n$ ，具有类别标记 Y ，以及符合分布 D 的样本空间，则一个最优特征子集 X_{opt} 是使得某个评价准则 $J=J(L, S)$ 最优的特征子集。

对于大小为 n 的特征集合，搜索空间可以有 2^n-1 种可能的组合，在实际应用中，寻找满足要求的最小特征子集是NP完全问题，当前的各种特征选择方法大都是采用启发式搜索算法寻找近似最优子集。特征选择的一般过程可用图3.1表示。




图 3.1 特征选择的过程

Fig 3.1 The process of feature selection

如图3.1所示,特征选择过程一般包括搜索策略、评价函数、停止准则和验证过程等4个部分。假设原始的特征集合中特征个数为 n ,搜索策略就是从 2^n-1 个特征子集中搜索最优特征子集所采取的搜索方法,负责为评价函数提供特征子集,通常可以分为穷举搜索、序列搜索和随机搜索等3类;评价函数是用于评价一个特征子集好坏程度的一个准则,根据评价方式不同一般分为Filter方法和Wrapper方法;停止准则是与评价函数相关的,决定什么时候停止搜索(结束算法的执行),一般是给算法的评价函数值设定一个阈值,当评价函数值达到这个阈值后就可停止搜索;验证过程是在验证数据集上验证选择出来的特征子集的有效性。其中,特征搜索策略和评价函数是特征选择算法的关键。

3.2.2 特征选择的分类

3.2.2.1 按搜索策略分类

目前,在各种特征选择算法中采用的搜索策略可以分为全局搜索、随机搜索和序列搜索等3类^[13]。

1. 全局搜索

全局搜索策略包括广度优先搜索、分支定界搜索和定向搜索等。广度优先搜索广度优先遍历特征子空间,属于穷举搜索,时间复杂度为 $O(2^n)$,适用性不高。分支定界搜索在穷举搜索的基础上加入分支定界条件:对于某些不可能搜索出比当前找到的最优解更优的解的分支进行剪枝,其时间复杂度虽然小于穷举搜索但仍然非常大。

2. 随机搜索

随机搜索策略在特征选择过程中将特征选择和模拟退火算法、遗传算法以及随机重采样等算法相结合,根据特征子集在训练集上的分类性能作为特征子集的评价准则,通常可以得到一个近似最优解。然而,随机搜索的主要问题是实验过程依赖于随机因素,实验结果难以重现;另外,当特征空间维度较高时,算法的时间复杂度依然非常大。

3. 序列搜索

序列搜索策略是当前特征选择算法中采用最广泛的搜索策略,主要有以下几种算法:

(1) 序列前向选择 SFS。假设原始的特征集合为 F ,搜索得到的特征子集为 X ,SFS算法首先设置 $X=\emptyset$,然后每次选择一个特征 $x \in F-X$,将其加入特征子集 X ,使得特征子集评价函数 $J(X)$ 最优。SFS没有充分考虑特征之间的相关性,它只能加入特征而不能去除特征,从而导致特征子集中包含冗余特征。例如:如果某个特征 x_1 依赖于特征 x_2 和 x_3 ,通过执行SFS首先将 x_1 加入特征子集 X ,后来又将 x_2 和 x_3 加入到特征子集 X ,

则在特征子集 X 中, x_1 特征就是冗余的。

(2) 序列后向选择 SBS。假设原始的特征集合为 F , 搜索得到的特征子集为 X , SBS 算法首先设置 $X=F$, 然后每次删除一个特征 $x \in X$, 得到新的特征子集 X , 使得特征子集评价函数 $J(X)$ 最优。SBS 算法只能删除特征而不能加入特征, 从而可能导致重要信息的损失。例如: 如果两个特征 x_1 和 x_2 是密切相关且共同作用于目标变量, 而 x_1 和 x_2 单独对于目标变量的影响并不明显, 则采用 SBS 算法可能依次剔除 x_1 和 x_2 , 从而导致重要特征的误删除。SFS 与 SBS 算法都属于贪心算法, 容易限于局部最优解。在采用同样的评价函数的时候, SBS 算法的实际计算性能和鲁棒性优于 SFS 算法。

(3) 广义序列前向选择 GSFS。GSFS 算法是 SFS 算法的加速算法, 它根据评价函数一次性向特征子集 X 中加入 r 个特征, 使得新的特征子集 X 对应的特征评价函数 $J(X)$ 最优。GSFS 算法相对于 SFS 算法在计算量上要小些, 但是仍然难以解决 SFS 算法中特征冗余的问题。

(4) 广义序列后向选择 GSBS。GSBS 算法是 SBS 的加速算法, 它根据评价函数从特征子集 X 中一次性删除 r 个特征, 使得新的特征子集 X 对应的特征评价函数 $J(X)$ 最优。GSBS 算法是一种可以应用于实际的特征选择任务中的特征选择方法, 其计算速度和性能相对较好。与 SBS 算法类似, 其问题是有时候特征剔除的过快导致重要特征的丢失, 从而找不到最优特征子集。

(5) 增 L 去 R 选择算法 LRS。当 $L>R$ 时, LRS 算法从空集开始, 每次先向特征子集 X 中加入 L 个特征, 然后再从 X 中剔除 R 个特征, 使得新的特征子集 X 对应的评价函数 $J(X)$ 最优; 当 $L<R$ 时, LRS 算法从全集开始, 每次先从特征子集 X 中剔除 R 个特征, 然后再向 X 中加入 L 个特征, 使得新的特征子集 X 对应的评价函数 $J(X)$ 最优。LRS 算法结合了 SFS 与 SBS 算法的思想, 其运算速度比 SBS 快, 算法性能比 SFS 好, 但是 LRS 算法中 L 与 R 的设置是算法的关键。

(6) 序列浮动选择。序列浮动选择算法是 LRS 算法的发展, 与 LRS 的不同在于序列浮动选择过程中 L 与 R 的值不是固定的, 而是变化的 (“浮动” 的), 在每轮特征选择过程中, 可以根据特征的统计特点动态设置 L 和 R 的值。序列浮动选择结合了 SFS、SBS、LRS 等算法的特点, 并弥补了它们的缺点; 然而同 LRS 算法类似, 序列浮动选择算法中如何合理地设置 L 和 R 的值仍是一个困难。

3.2.2.2 按评价方式分类

按照特征选择过程中采用的评价方式, 可以将特征选择算法分为基于 Filter 的特征选择算法 (过滤器)、基于 Wrapper 的特征选择算法 (封装器) 以及 Filter 和 Wrapper 相结合的特征选择算法^[131]。

1. 基于 Filter 的特征选择算法

基于 Filter 的特征选择算法使用变量排序技术作为特征选择的准则，通常采用某种合适的排序标准对变量进行打分，通过事先设置的阈值来删除分数较小的变量，这实际上是一种基于过滤的方法，因为在训练分类模型之前，一些不相关的变量可以被过滤掉。Filter 方法独立于后续的机器学习算法，通过分析特征子集内部的特点或统计规律来衡量特征子集的质量，其基本过程如图 3.2 所示。




图 3.2 Filter 特征选择原理

Fig 3.2 The principle of feature selection based Filter

Filter 方法能够很快地排除一部分非关键的噪声特征，缩小最优特征子集的搜索范围，可以作为特征过滤器；但是，其主要问题是不能保证选择出规模较小的最优特征子集。本章将针对医学数据挖掘中的疾病危险因素分析和疾病类型预测问题，研究基于随机森林的 Filter 式特征选择算法。

2. 基于 Wrapper 的特征选择算法

Wrapper 方法依赖于后续的机器学习算法，在特征选择过程中直接使用选择出来的特征子集训练学习模型，并根据该学习模型在测试集上的性能评价特征子集的质量，其基本过程如图 3.3 所示。

相对于基于 Filter 的特征选择算法，基于 Wrapper 的特征选择算法通常可以选择出更优的特征子集，但其计算速度通常较慢，计算效率不如 Filter 方法。本文第 4 章将针对医学数据挖掘中的疾病危险因素分析和疾病类型预测问题，主要研究基于随机森林的 Wrapper 式特征选择算法。




图 3.3 Filter 特征选择原理

Fig 3.3 The principle of feature selection based Wrapper

3. Filter 和 Wrapper 相结合的特征选择算法

针对高维医学数据集，例如微阵列基因表达数据集，特征维数通常达到几万甚至几十万，其中包含大量的噪声特征和不相关特征，直接在原始的高维数据集上运行 Wrapper 算法在运算时间和模型性能上都不可取，而仅仅依靠 Filter 算法也难以识别出真正重要的特征。通过结合 Filter 和 Wrapper 特征选择算法，可以较好地解决高维医学数据的特征选择和分类问题。结合 Filter 和 Wrapper 的特征选择算法的基本过程是：首先使用 Filter 算法对特征进行预选（过滤），快速剔除噪声特征和不相关特征，降低数据集的维度；然后采用 Wrapper 算法对特征进行精选，识别出最相关的特征子集并训练学习模型。本文第 5 章将针对微阵列基因表达数据挖掘问题，主要研究基于随机森林的 Filter 和 Wrapper 相结合的特征选择及分类算法。

3.2.3 特征相关性度量

在特征选择过程中，一个重要的因素是如何度量特征之间的相关性。下面首先给出特征相关性的定义。

定义 3.1 特征相关性. 在数据集 $D = \langle X, Y \rangle$ 上, 一个分类特征 $x \in X$ 包含的对于区分目标特征 Y 的有用的信息定义为 x 与 Y 的特征相关性。

定义 3.2 特征不相关. 在数据集 $D = \langle X, Y \rangle$ 上, 一个分类特征 $x \in X$ 如果与目标特征 Y 之间是条件独立的, 则 x 与 Y 是不相关的。

有众多的文献提出了各种不同的特征相关性度量准则^[132-136],常用的特征相关性度量准则包括相关性、距离和互信息等^[137-138]。

3.2.3.1 相关性准则 (Correlation criteria)

采用相关性度量特征子集的好坏程度基于下面的假设：好的特征子集中包含的特征与目标特征的相关度较高，同时特征之间的相关度较低。最简单的相关准则是皮尔森相关系数 (Pearson Correlation Coefficient)，定义为：

$$R(i) = \frac{\text{cov}(x_i, Y)}{\sqrt{\text{var}(x_i) * \text{var}(Y)}} \quad (3-1)$$

在式 3-1 中， x_i 表示第 i 个特征， Y 表示目标特征（类标签）， $\text{cov}()$ 是协方差， $\text{var}()$ 是方差。相关准则只适用于检测分类特征和目标特征之间的线性依赖关系^[6]。

3.2.3.2 距离度量 (Distance Metrics)

采用距离度量特征子集的好坏程度基于下面的假设：好的特征子集中属于同一类别的样本之间的距离尽可能小，属于不同类别的样本之间的距离尽可能大。常用的距离度量包括欧氏距离、切比雪夫距离、马氏距离等。

1. 欧氏距离

两个 n 维向量 $X_1 = \{x_{11}, x_{12}, \dots, x_{1n}\}$ 和 $X_2 = \{x_{21}, x_{22}, \dots, x_{2n}\}$ 之间的欧氏距离的计算公式如式 3-2 所示：

$$D_{X_1, X_2} = \sqrt{\sum_{k=1}^n (x_{1k} - x_{2k})^2} \quad (3-2)$$

2. 切比雪夫距离

两个 n 维向量 $X_1 = \{x_{11}, x_{12}, \dots, x_{1n}\}$ 和 $X_2 = \{x_{21}, x_{22}, \dots, x_{2n}\}$ 之间的切比雪夫距离的计算公式如式 3-3 所示：

$$D_{X_1, X_2} = \max_i (|x_{1i} - x_{2i}|) \quad (3-3)$$

3. 马氏距离

假设有 M 个样本向量 $X_1 \sim X_m$ ，协方差矩阵记为 S ，均值记为向量 μ ，则其中样本向量 X 到 μ 的马氏距离的计算公式如式 3-4 所示：

$$D_X = \sqrt{(X - \mu)^T S^{-1} (X - \mu)} \quad (3-4)$$

样本向量 X_i 和 X_j 之间的马氏距离的计算公式如式 3-5 所示：

$$D_{XY} = \sqrt{(X_i - X_j)^T S^{-1} (X_i - X_j)} \quad (3-5)$$

3.2.3.3 互信息 (Mutual Information, MI)

信息理论排序准则使用两个特征之间的依赖关系来描述互信息。首先, 香农对于信息熵的定义如下:

$$H(Y) = -\sum_y p(y) \log(p(y)) \quad (3-6)$$

式 3-6 表示了 Y 中的不确定性 (信息量)。对于变量 X , 条件信息熵定义为:

$$H(Y|X) = -\sum_x \sum_y p(x, y) \log(p(y|x)) \quad (3-7)$$

式 3-7 表示对于给定变量 X , 输出 Y 的不确定性减少, 这种减少量表示为:

$$I(Y, X) = H(Y) - H(Y|X) \quad (3-8)$$

式 3-8 表示 Y 和 X 之间的互信息, 如果 X 独立于 Y , 则 $MI = 0$, 如果 Y 依赖于 X , 则 $MI > 0$ [6]。

Pearson 相关系数、距离度量和互信息等度量不能区分具有相互关系的变量, 选择出的特征子集中可能包含冗余变量; 另外, 在特征排序中对于单独的信息量较少但是和其他特征一起的信息量较多的特征, 有可能被误删除。本文采用随机森林变量重要性分数作为评价特征相关性的度量准则, 随机森林算法既充分考虑了单个特征对目标特征的单独作用同时考虑了多个特征对目标特征的共同作用, 尤其适用于描述医学数据集中特征之间的相关性, 下一节将详细介绍随机森林变量重要性分数。

3.2.4 变量重要性分数

RF 算法在训练分类器的过程中同时计算变量的重要性分数, RF 变量重要性分数已经被广泛应用于各种特征选择应用中。RF 提供了 4 种变量重要性分数供选择, 下面介绍最常用的两种: Gini 重要性分数和基于置换的变量重要性分数 [139]。

3.2.4.1 Gini 重要性分数

Gini 重要性分数是 RF 算法最经常使用的变量重要性度量。Gini 重要性分数直接从 RF 中的决策树的 Gini 指标获得。RF 分类器在决策树节点分裂过程中使用 Gini 指标 (Gini index) 来选择分裂特征。Gini 指标用于度量分配到树的某个节点的样本的纯度水平。例如, 在二分类中, p 代表分配到某个树节点 k 的正样本的比例, $1-p$ 代表该节点的负样本的比例, Gini 指标 m 定义如下:

$$G_k = 2p(1-p) \quad (3-9)$$

根据式3-9, 一个节点的纯度越高, Gini指标值越小。在每次节点分裂时选择一个特征使得分裂之后的两个子节点的Gini值小于父节点。在一棵树中, 一个特征的Gini重要性分数定义为用该特征进行分裂的所有节点上从父节点到子节点的Gini值减少量的和。在一个森林中, 一个特征的整体重要性分数定义为森林中所有树上特征重要性分数的平均值。作为一种简单的特征重要性度量, Gini特征重要性分数在生物数据挖掘中非常流行。然而有研究表明, 当预测变量是分类类型时, Gini重要性分数偏爱类别较多的变量^[139]。

3.2.4.2 基于排列的变量重要性分数

基于置换的变量重要性分数可以定义为在袋外数据(OOB)上当变量发生轻微扰动前后分类模型的分类正确率的平均减少量。基于排列的变量重要性度量既考虑到每一个变量单独的影响, 又考虑了多个变量之间的相关作用, 它采用了直觉排列策略, 在已有的关于RF的文献里比Gini重要性分数使用更广泛^[132]。给定Bootstrap样本集合 $D_b, b = 1, 2, \dots, B$, B 是随机采样次数, 特征 $X_j (j = 1, \dots, N)$ 基于置换的变量重要性分数表示为 $\bar{D}_j$, $\bar{D}_j$ 的计算过程如算法3.1所示:

算法 3.1: 计算基于排列的变量重要性分数

输入: 训练数据集 D , 随机采样次数 B ;

输出: 基于置换的变量重要性分数 $\bar{D}$;

步骤:

1. 对训练集 D 进行Bootstrap随机重采样 B 次, 得到 B 个样本子集 D_b ;
2. 设置 $b = 1$;
3. 在样本集合 D_b 上训练决策树 T_b , 袋外数据标记为 L_b^{oob} ;
4. 在袋外数据 L_b^{oob} 上, 应用 T_b 对数据进行分类, 正确分类的样本个数标记为 R_b^{oob} ;
5. 对特征 $X_j, j = 1, \dots, N$, 随机地扰动 L_b^{oob} 中每一个样本直到它与目标变量的原始关系被打断, 扰动后的数据集标记为 L_{bj}^{oob} ;
6. 在扰动数据集 L_{bj}^{oob} 上, 应用 T_b 对数据进行分类, 正确分类的样本个数标记为 R_{bj}^{oob} ;

如果特征 X_j 与目标变量相关,那么分类器的分类性能将明显降低;

7. 对于 $b = 2 \dots B$, 重复第3-6步;

8. 按照下面的公式计算特征 X_j 的变量重要性分数: $\overline{D_j} = \frac{1}{B} \sum_{b=1}^B (R_b^{oob} - R_{bj}^{oob})$;

9. 输出 $\overline{D} = \{\overline{D_1}, \overline{D_2}, \dots, \overline{D_N}\}$ 。

在算法3.1中,第1步首先对原始的训练数据集 D 进行Bootstrap随机重采样,得到一组样本子集 D_b , $b = 1, 2, \dots, B$;在第2至第4步在采样集合上训练决策树模型并使用该模型对测试集(袋外数据)中的样本进行标记;第5步针对某个特征 X_j 对测试集的样本进行扰动,然后第6步在扰动后的数据集上对样本进行标记;对所有采样数据集,重复步骤3-6,针对所有特征 X_j , $j = 1, \dots, N$,均实现扰动并标记;在第8步中计算每个特征的 X_j 的变量重要性分数;最后,第9步输出计算结果。

3.2.5 多元自适应回归样条 MARS

MARS 是由 Freidman 提出的一种非线性和非参数的回归模型,是一种专门针对高维数据拟合的回归方法。多元自适应回归样条模型最初是受递归分割算法中的 CART 和广义加性模型思想启发建立的,是具有连续导数的连续型模型。由于多元自适应回归样条善于寻找最优的变量交互性,因此可以处理隐藏高维数据的复杂数据结构,并且高效地揭示重要的数据形式和数据关系。MARS 能够很好地描述依赖变量和多个预测变量之间的关系,近年来被广泛应用于各种数据挖掘任务中,包括疾病风险预测、人类遗传学分析和食品科学等^[140]。John H Warner 等人利用 MARS 对美国成年烟民和非抽烟人群潜在危害生物标识进行分析,生成了预测每种潜在危害生物标识 BOPH 的模型^[13]。本文在评价 Filter 特征选择方法选择出的特征子集质量时,分别使用 RF、MARS、C4.5 和 SVM 分类器的分类精度作为评价指标。下面简要介绍 MARS 算法的基本原理。

MARS 方法是一种局部回归方法,通过样条函数(又称为基函数)来模拟复杂线性关系。它将整个非线性模型划分为若干区域,在每个特定区域内由一段线性回归直线来拟合。基函数定义如下:

$$(x-t)_+ = \begin{cases} x-t & x > t \\ 0 & otherwise \end{cases} \quad (3-10)$$

对于一个依赖变量(目标变量) y ,可以表示成 m 项,如公式 3-11 所示:

$$y = f(x) = \beta_0 + \sum_{m=1}^M \beta_m H_{km}(x_{v(km)}) \quad (3-11)$$

其中, m 是模型中含有的基函数的数目, β_0 和 β_m 分别是从小训练数据集估计的参数。函数 H 的定义如公式 3-12 所示:

$$H_{km}(x_{v(km)}) = \prod_{k=1}^K h_{km} \quad (3-12)$$

其中, $v(k, m)$ 是独立变量的标识, K 是结点数, $x_{v(k, m)}$ 是第 m 项乘积的第 k 个预测变量。生成 MARS 模型的基本步骤如下:

1. 一组基函数以加权之和的形式引入到 MARS 模型中。搜索每个独立变量和每个结点的位置, 并对于最优独立变量和最优结点位置进行反复搜索。对模型贡献度最大的独立变量将被优先选择。

2. 剪枝过程, 将造成模型过度拟合的基函数删除。该过程采用的是后向的删除方法, 每次删除一个对模型贡献最小的基函数。这一剪枝过程是基于广义交互验证 (GCV) 标准进行的。GCV 定义如下:

$$GCV = \frac{\sum_{i=1}^N (y_i - f(x_i))^2}{\left(1 - \frac{C}{N}\right)^2} \quad (3-13)$$

其中, $C = 1 + cd$, n 是数据集中样本的个数, c 是惩罚因子, 即对每个基函数进行优化所需要的成本, c 值越大, 则越多的基函数被排除在外, d 是模型中非常数的基函数的数目。

3. 通过交互验证从模型中选取较小的 MARS 模型作为最优模型。选择最优模型思想是: 在预测误差符合的基础上, 选择出最简单的模型。具有交互验证的最小误差均方根 (RMSECV) 的模型就是最优模型。RMSECV 定义如下:

$$RMSECV = \sqrt{\frac{\sum_i^n (y_i - \hat{y}_{-i})^2}{n}} \quad (3-14)$$

y_i 是第 i 个对象的依赖变量值, $\hat{y}_{-i}$ 是移除第 i 个样本之后依赖变量的预测值。

3.3 基于 RF 的 Filter 式特征选择算法

3.3.1 算法设计

基于 RF 的 Filter 特征选择算法的基本思想是：首先使用 RF 算法对原始数据集中的分类特征进行初步筛选，根据 RF 变量重要性分数对所有分类特征进行排序，然后迭代地选择变量重要性分数最大的前 top 个特征作为预测变量训练分类器模型，最后根据分类器的分类精度在多个特征子集中选择最优特征子集。为了最小化参数选择引起的模型偏差，并便于和其他算法的性能进行比较，在计算 RF 变量重要性分数和构建分类模型的过程中均采用 10 折交叉验证法。具体来说，首先将数据集划分成 10 等份，采用分层采样保证划分的子集与原来的数据集的类分布相同，使用其中的 9 份作为训练集训练预测模型，剩下的一份作为测试集，验证模型的预测性能。迭代执行 10 次，选择 10 次中 RF 在训练数据集上分类正确率最高的一次迭代产生的变量重要性分数作为评价特征重要性的标准，计算 10 次迭代中测试集的分类正确率的平均值作为特征子集质量的评价标准，最终选择平均分类正确率最高的特征子集作为最优特征子集。在上面的特征选择方法中，可以采用不同的数据分类算法构建分类模型，此处以 MARS 分类器为例，介绍对应的特征选择算法，采用其他的分类分类器与此类似。

假设原始数据集 $D = \langle X, Y \rangle$ 中，样本个数为 n ，分类特征个数为 m 。在 Filter 特征选择过程中，每次选取前 $k \cdot \text{step}$ 个特征组成特征子集， $k=1, 2, \dots, m/\text{step}$ ，其中参数 step 用于设置迭代选择特征子集的过程中，特征个数增加的尺度，在本文中 step 默认设置为 3，即每个特征子集中分别包含 Top 3、Top 6、Top 9...个特征，最后选择出分类正确率最大的特征子集作为最优特征子集，标记为 $\text{Opt} = \{x_1, x_2, \dots, x_{\text{top}}\}$ ，该子集上的最大分类正确率作为所提出算法最终的分类精度，标记为 GmaxAccuracy 。该算法的具体实现如算法 3.2 所示。

算法 3.2： 基于 RF 和 MARS 的 Filter 式特征选择算法 RF&MARS

输入：训练数据集 D ，参数 step ；

输出：最优特征子集 Opt ，分类器 $y = f(x)$ ，最大分类正确率 GmaxAccuracy ；

步骤：

1. 初始化：

1.1 $\text{GmaxAccuracy} \leftarrow 0$ ；

1.2 $\text{LmaxAccuracy} \leftarrow 0$ ； // LmaxAccuracy 表示 10 折交叉验证中的最大分类精度

1.3 $\text{LAccuracy} \leftarrow 0$ ； // LAccuracy 表示 10 折交叉验证中每一次迭代的分类精度

```

1.3  Opt <- NULL;
1.4  Fsort <- NULL;      //Fsort 表示 10 折中分类器精度最大的特征排序
2.   在原始的训练集上训练随机森林分类器并计算变量重要性分数;
2.1   采用分层采样将训练集 D 划分为 10 等份, 标记为  $D = D_1 \cup D_2 \dots \cup D_{10}$ ;
2.2   for (i 从 1 到 10)
2.2.1   在集合(D - Di) 上训练随机森林分类器, 标记为 rf;
2.2.2   在集合 Di 上使用 rf 对样本进行预测, 预测正确率保存为 LAccuracy;
2.2.3   比较本轮迭代中的预测正确率 LAccuracy 是否大于 10 次迭代中的最大预测
        正确率 LmaxAccuracy, 如果是, 则将当前预测正确率保存为 LmaxAccuracy;
        同时采用 rf 生成的变量重要性分数对所有特征降序排序, 排序结果保存为
        向量  $F_{sort} = \{x_1', x_2', \dots, x_m'\}$ ;
2.3   end for
3.   for (ft 从 1 到  $\text{length}(D) / \text{step}$ )      //ft 为循环变量,
3.1   根据 Fsort 排序结果, 从原始数据集中选择前 ft*step 个特征构成新的数据集 D';
3.2   采用分层采样将数据集 D' 划分为 10 等份, 标记为  $D' = D'_1 \cup D'_2 \dots \cup D'_{10}$ ;
3.3   for (i 从 1 到 10)
3.3.1   在集合 (D' - D'i) 上训练 MARS 模型, 标记为 yi;
3.3.2   在集合 D'i 上使用 yi 对样本进行预测, 预测正确率保存为 acci;
3.3.3   计算 10 次迭代中 MARS 的平均分类正确率  $\overline{acc}_f = \overline{acc}_f + acc_i / 10$ ;
3.4   end for
4. end for
5. 计算 ft 次循环中最大的 MARS 平均分类正确率  $GmaxAccuracy = \max(\overline{acc}_f)$ ;
6. 具有最大 GmaxAccuracy 的特征子集为最优特征子集, 存储为 Opt;
7. 在最优特征子集构成的数据集上训练分类器, 标记为  $y = f(x)$ ;
8. 输出 Opt、 $y = f(x)$  和 GmaxAccuracy;
9. end.

```

在算法 3.2 中, 首先在第 1 步对相关变量进行初始化; 在第 2 步在原始数据集上训练随机森林并计算变量重要性分数, 依据各个特征的变量重要性分数对所有特征进行降序排序, 为了保证排序结果的可靠性, 采用 10 折交叉验证方法, 10 次迭代中分类正确率最大的一次迭代得到的变量重要性分数被作为特征排序的依据; 第 3 步是选择特征子集的过程, 通过循环依次选择前 $ft \cdot step$ 个特征构成特征子集, 在特征子集上训练 MARS 分类器, 以 MARS 分类器的分类正确率作为评价特征子集质量的准则, 为了保证结果的稳定性和可靠性, 采用 10 折交叉验证方法, 将 10 次迭代中生成的 MARS 模型的平均分类正确率作为评价特征子集质量的依据; 在第 5、6、7 步中, 分别计算 ft 个特征子集上 MARS 分类正确率最高的特征子集以及该特征子集上的分类模型和分类正确率; 最后在第 8 步中输出最优特征子集、分类模型和最大分类正确率。

3.3.2 算法分析

3.3.2.1 正确性分析

基于 Filter 的特征选择算法根据特征之间的统计信息或相关性对特征进行筛选, 可以快速地剔除和目标特征不相关的特征或噪声特征, 有效地识别出和目标特征最相关的特征。医学数据集是一类特殊的数据集, 其特征之间往往存在复杂的相互作用, 采用相关性、距离度量或互信息等准则难以充分表现特征之间的相互作用。随机森林算法由于在训练模型的过程中既考虑了单个特征对于目标特征的影响又考虑了多个特征之间的关系, 其变量重要性分数是一种更为可靠的特征相关性的度量, 尤其适用于医学数据集。RF 变量重要性分数在很多文献中被用于评价特征之间的相关性, 其有效性在理论和实践方面都得到了验证^[139]。算法 3.2 采用 RF 变量重要性分数作为评价特征相关性的标准对特征进行排序, 迭代地选取前若干个特征构成特征子集, 在每一个特征子集上构建分类器, 用分类器的分类正确率评价特征子集的质量。该算法在遵循一般的 Filter 特征选择方法的基础上, 引入了随机森林变量重要性分数度量特征之间的相关性, 使用了 10 折交叉验证, 可以更好地保证算法的稳定性。基于随机森林的 Filter 式特征选择可以在构建分类器模型之前过滤掉一部分不相关的特征和噪声特征, 并且由于随机森林的优势能够有效处理特征之间的相互作用, 可以提高特征子集质量和分类性能。因此, 从理论上分析, 本文提出的算法能够有效地选择出较优的特征子集并提高分类正确率。这一点在后面的仿真实验中也得到了验证。

3.3.2.2 时间复杂度分析

在算法3.2中，算法的主要时间开销是训练RF分类器和MARS分类器的过程。假设训练数据集D的特征维数为m，训练样本个数为n，RF中基分类器的个数为k个，则RF算法的时间复杂度可以近似为 $O(k*m*n*(\log n)^2)$ 。此外，用于评价特征子集质量的MARS分类器模型的时间复杂度为： $O(n*m)$ 。最后，算法迭代执行的次数为 $ft = m / step$ ，且搜索特征子集过程中采用了10折交叉验证。因此算法3.1的时间复杂度近似为：

$$10 * O(k * m * n * (\log n)^2) + n / step * 10 * O(n * m) \approx O(10 * k * m * n * (\log n)^2 + 10 / step * m * n^2)$$

，可见算法3.2的时间开销是原始RF算法的10倍左右，其计算速度是可以接受的。

3.4 仿真实验及结果分析

3.4.1 实验数据及参数设定

本节选用3个UCI标准数据集Heart、WPBC、WDBC和1个真实的糖尿病临床数据集（HYDD）对所提出的基于RF的Filter式特征选择算法进行实验验证，数据集的基本信息如表3.1所示。

表 3.1 数据集基本信息

Table 3.1 Summary of Datasets

NO.	Dataset	Nominal attributes	Continuous attributes	Instance size	Number of Class
1	Heart	7	6	270	2
2	WPBC	1	33	198	2
3	WDBC	1	31	569	2
4	HYDD	5	41	1910	2

3.4.2 特征选择与分类性能分析

首先在4个实验数据集上分别运行随机森林算法（RF）、多元自适应回归样条算法（MARS）、决策树算法（C4.5）和支持向量机算法（SVM），统计各种算法的分类精度；然后执行本文所提出的基于随机森林的Filter特征选择算法，在Filter特征选择过程中分别取特征变量重要性分数前3n（n为自然数）个特征构成不同的特征子集，分别以RF、MARS、C4.5和SVM算法作为衡量特征子集质量的分类器，计算不同特征子集上各分类

算法的分类正确率，最终选择分类精度最高的特征子集作为最优特征子集。

表3.2列出了各种算法在4个数据集上的特征选择结果和分类精度，所有数据都是测试集上的结果。

表3.2 8种算法在UCI数据集上的分类性能比较

Table 3.2 The comparison of classification performance of eight algorithms on UCI dataset

dataset	RF		RF&RF		MARS		RF&MARS	
	Feature	Accuracy	Feature	Accuracy	Feature	Accuracy	Feature	Accuracy
Heart	13	0.8371	13	0.8371	13	0.8889	10	0.9074
WPBC	34	0.7878	22	0.8177	34	0.725	16	0.85
WDBC	31	0.9605	22	0.9677	31	0.9561	16	0.9825
HYDD	46	0.7883	10	0.7989	46	0.6754	10	0.7958
	C4.5		RF&C4.5		SVM		RF&SVM	
	Feature	Accuracy	Feature	Accuracy	Feature	Accuracy	Feature	Accuracy
Heart	13	0.7667	4	0.8414	13	0.9074	13	0.9074
WPBC	34	0.7042	31	0.7694	34	0.675	10	0.8250
WDBC	31	0.9310	16	0.9531	31	0.9649	25	0.9912
HYDD	46	0.7022	7	0.7635	46	0.7540	16	0.7850

由表3.2可以看出：在WPBC、WDBC和HYDD数据集上，经过Filter式特征选择的分类算法RF&RF、RF&MARS、RF&C4.5、RF&SVM的分类精度明显高于直接在原始数据集上执行RF、MARS、C4.5和SVM算法，同时选择出了比原始数据集明显较少的特征子集。以WPBC数据集为例，RF、MARS、C4.5和SVM在全部34个分类特征构成的数据集上的分类正确率分别为：0.7878、0.725、0.7042和0.675，利用本文所提出的特征选择方法，RF&RF、RF&MARS、RF&C4.5、RF&SVM选择出的特征个数分别为：22、16、31和10，对应特征子集上的分类正确率分别为：0.8177、0.85、0.7694和0.8250，平均高出约3-15个百分点，这说明所提出的算法在减少了分类特征的同时有效地提高了分类器的分类精度。在Heart数据集上，RF&RF算法和RF&SVM算法选择出的特征子集与原始的特征集合一样，分类正确率当然也与原始的RF算法和SVM一样，我们分析这是因为Heart数据集中的特征维数较低且大多数特征为强相关特征，所以采用不采用特征选择的效果是一样的；RF&MARS算法在Heart数据集上选择出了与原始的特征集合大小相差不大的特征子集，分类正确率提高并不明显，同样是因为特征集合中的特征多为强相关特征，且MARS的分类正确率已经达到一个较高的水平；RF&C4.5算法在Heart数据集上选择除

了比原始特征集合小很多的特征子集，且分类正确率比原始的C4.5算法高出很多，这是因为C4.5算法对于处理Heart这样的数据集分类性能较低，经过特征选择降低了模型的复杂度，从而提高了C4.5算法的分类正确率，由于丢失了部分重要的特征，因此总体上的分类正确率却低于RF&MARS算法和RF&SVM算法，这也表明基于Filter的方法在某些情况下会陷入局部最优解。从总体的分类精度来看，RF、MARS、SVM三种算法的性能不相上下，C4.5算法的分类性能相对以上三种方法较低。

为了进一步验证所提出的特征选择算法的性能，本文与文献[36]中提出的特征选择算法进行了比较，结果如表3.3所示。

表 3.3 本文算法与其它算法的分类性能比较

Table 3.3 The comparison of classification performance of the proposed algorithm and other algorithms

特征选择 方法	WDBC数据集		WPBC数据集		Heart数据集	
	特征数	正确率	特征数	正确率	特征数	正确率
DFS-SFS	28	0.6468	29	0.7630	13	0.5388
CFS-SFS	14	0.6309	6	0.7734	12	0.5388
Pab-SFS	15	0.6309	6	0.7578	12	0.5388
DFS-SBS	27	0.6468	28	0.7630	12	0.5388
CFS-SBS	11	0.6361	8	0.7630	11	0.5388
Pab-SBS	24	0.6469	11	0.7580	11	0.5388
DFS-FFS	9	0.6918	9	0.7630	10	0.5388
CFS-FFS	6	0.7496	4	0.7734	9	0.5388
Pab-FFS	6	0.7496	4	0.7578	9	0.5388
DFS-BFS	4	0.6292	4	0.7630	3	0.5388
CFS-BFS	3	0.6274	2	0.7630	5	0.5388
Pab-BFS	3	0.6292	3	0.7680	4	0.5388
RF&RF	22	0.9677	22	0.8177	13	0.8371
RF&MARS	16	0.9825	16	0.85	10	0.9074
RF&C4.5	16	0.9531	31	0.7694	4	0.8414
RF&SVM	25	0.9912	10	0.8250	13	0.9074

表3.3中，特征选择方法DFS-SFS、CFS-SFS、Pab-SFS分别表示基于特征子集区分度（Discernibility of Feature Subset, DFS）和序列后向搜索的特征选择方法、基于特征相

关性 (Correlation based Feature Selector, CFS) 和序列前向搜索的特征选择方法、基于皮尔森相关系数特征相关性 (Correlation based Feature Selector based on the absolute of Pearson's correlation coefficient, CFSPabs) 和序列前向搜索的特征选择方法; 特征选择方法DFS-SBS、CFS-SBS、Pab-SBS分别表示基于DFS和序列后向搜索的特征选择方法、基于CFS和序列后向搜索的特征选择方法、基于CFSPabs和序列后向搜索的特征选择方法; 特征选择方法DFS-FFS、CFS-FFS、Pab-FFS分别表示基于DFS和序列前向浮动搜索的特征选择方法、基于CFS和序列前向浮动搜索的特征选择方法、基于CFSPabs和序列前向浮动搜索的特征选择方法; 特征选择方法DFS-BFS、CFS-BFS、Pab-BFS分别表示基于DFS和序列后向浮动搜索的特征选择方法、基于CFS和序列后向浮动搜索的特征选择方法、基于CFSPabs和序列后向浮动搜索的特征选择方法; RF&RF、RF&MARS、RF&C4.5、RF&SVM分别表示基于随机森林变量重要性分数和RF分类器的Filter特征选择算法、基于随机森林变量重要性分数和MARS分类器的Filter特征选择算法、基于随机森林变量重要性分数和C4.5分类器的Filter特征选择算法、基于随机森林变量重要性分数和SVM分类器的Filter特征选择算法。在文献[36]中, 各种特征选择算法使用的分类算法都是SVM算法。

从表3.3可以看出, 本文所提出的基于随机森林变量重要性分数的特征选择算法RF&RF、RF&MARS、RF&C4.5和RF&SVM算法在选择出的特征子集大小与文献[36]中的方法相差不大的情况下, 分类正确率明显高于文献[36]中的方法, 这表明本文所提出的方法是有效的。特别地, 当所采用的分类器均为SVM分类算法时, 经过基于随机森林变量重要性分数的特征选择后的SVM分类准确率明显高于基于特征子集区分度、基于特征相关性和基于皮尔森相关系数特征相关性的特征选择算法。

3.4.3 参数设置分析

基于Filter的式特征选择算法的阈值 (特征子集中的特征个数) 设置是一个困难, 一般来说是根据变量的重要性程度并结合领域专家的经验进行设置。本文按固定的步长 (缺省为3) 来选择特征子集, 即每次运行算法时, 分别取前 $3n$ (n 为自然数) 个特征作为特征子集训练分类模型, 最终选择大小合适、分类正确率高的特征子集作为最优特征子集。图3.4-3.7展示了所选择的特征数与分类器分类性能的关系。




图 3.4 四种特征选择算法在 Heart 数据集上的特征选择过程

Fig. 3.4 The process of feature selection of four feature selection algorithms on Heart dataset




图 3.5 四种特征选择算法在 WPBC 数据集上的特征选择过程

Fig. 3.5 The process of feature selection of four feature selection algorithms on WPBC dataset




图 3.6 四种特征选择算法在 WDBC 数据集上的特征选择过程

Fig. 3.6 The process of feature selection of four feature selection algorithms on WDBC dataset




图 3.7 四种特征选择算法在 HYDD 数据集上的特征选择过程

Fig. 3.7 The process of feature selection of four feature selection algorithms on HYDD dataset

从图3.4-3.7可以看出, 基于随机森林变量重要性分数进行特征选择, 在有效地剔除不相关特征和冗余特征的同时能够维持或提高分类器的分类性能。从图中还可以看出, 使用RF、MARS、SVM分类算法作为评价特征子集质量的标准, 其性能要优于C4.5算法, 基于RF的算法性能更稳定。另外, 数据集的维数越高, 特征选择的作用越明显, 在特征维数不是很高的数据集上, 本文提出的阈值设置原则能够较准确地考察不同特征的重要性。然而, 这只是根据实验结果得出的经验值, 如何更合理地确定Filter阈值, 是一个值得进一步研究的问题。

3.4.4 在糖尿病临床数据集上的结果分析

医学数据挖掘的一个重要目的是分析疾病危险因素, RF 变量重要性分数为分析疾病危险因素提供了一个简单有效的度量。本文所提出的算法在选择出最优特征子集的同时计算出了每个特征的重要性分数, 这有助于人们更好地理解影响某类疾病的主要因素及其相对重要性, 这对医学数据挖掘来言是很重要的。外周血管疾病 (Peripheral Arterial Disease, PAD) 是全身动脉粥样硬化的一种常见表现, 是老年人常见的一种动脉疾病, 也是常见的糖尿病并发症。降低糖尿病发病率、预防糖尿病并发症是医学研究的一项重要任务^[41]。有很多危险因素会增加糖尿病并发症的发病几率, 通过对大量的临床医学数据进行分析, 准确地识别影响糖尿病并发症的重要危险因素, 对于探索糖尿病并发症的发病机制, 有效地预防和治疗糖尿病并发症具有重要的意义。临床医学数据具有变量维数高、类别不平衡、变量间存在复杂相关作用等特点, 导致传统的统计学方法在准确识别疾病危险因素上面临很大的困难。为了研究糖尿病及其并发症的危险因素和发病规律, 我们从黑龙江省某三级甲等医院内分泌科收集整理了 2006-2010 年间的糖尿病及其并发症住院患者的临床诊断数据集 (HYDD), 包括 1910 个样本、46 个分类特征和 1 个目标特征, 46 个分类特征的基本信息如表 2.2 所示, 1 个目标特征表示患者是否患有外周动脉疾病, 0 表示没有 PAD (正例样本), 1 表示有患有 PAD (反例样本)。HYDD 中各个特征名称、意义及其取值范围等基本信息如表 3.4 所示。本节, 我们采用本文所提出的基于 RF 的 Filter 式特征选择算法 RF&MARS 算法和 HYDD 数据集来分析 PAD 疾病危险因素。

表 3.4 糖尿病临床数据集的特征基本描述

Table 3.4 The summary of variable characteristics in diabetes mellitus clinical dataset

变量名	类别	范围/均值	变量名	类别	范围/均值
Sex	性别	F, Male	INS180	餐后 180 分钟胰岛素	31.68
Age	年龄	52.56	FCP	空腹 C 肽	1.610
HOD	糖尿病病史	6.579	CP30	餐后 30 分钟 C 肽	2.885
HBPH	高血压史	N,L,M,S	CP60	餐后 60 分钟 C 肽	4.175
FH	家族史	H,D,B,N	CP120	餐后 120 分钟 C 肽	5.375
WH	饮酒史	N,L,M,S	CP180	餐后 180 分钟 C 肽	4.555
CH	吸烟史	N,L,M,S	HbA1c	糖化血红蛋白	8.746
Height	身高	168.6	TC	总胆固醇	5.35
Weight	体重	72.94	TG	甘油三酸酯	2.398
Waist	腰围	89.3	HDL.C	高密度脂蛋白	1.187
Hip	臀围	94.16	LDL.C	低密度脂蛋白	3.455
SP	收缩压	138.0	VLDL.C	超低密度脂蛋白	0.4626
DP	舒张压	82.18	Apo.A	载脂蛋白 A	1.283
HR	心律	79.45	Apo.B	载脂蛋白 B	0.9428
BMI	身体质量指数	25.55	BUN	血尿素氮	6.081
FPG	空腹血糖	6.942	Cr	血肌酐	77.66
BG30	餐后 30 分钟血糖	11.61	UA	尿酸	308.98
BG60	餐后 60 分钟血糖	14.87	ALT	谷丙转氨酶	31.42
BG120	餐后 120 分钟血糖	14.48	AST	谷草转氨酶	24.82
BG180	餐后 180 分钟血糖	11.03	GGT	C-谷氨	44.29
FINS	空腹胰岛素	11.76	Fib	纤维蛋白原	3.569
INS30	餐后 30 分钟胰岛素	27.64	HOMA	稳态模型胰岛素抵抗	3.673
INS60	餐后 60 分钟胰岛素	42.94	PAD	外周动脉疾病	No, Yes
INS120	餐后 120 分钟胰岛素	45.09			

注：表中 N, L, M, S, H D and B 分别表示：无、低度、中度、重度、高血压、糖尿病、高血压+糖尿病。

在 HYDD 数据集上的实验结果如图 3.8 所示。图 3.8 展示了影响 PAD 的前 10 个危险因素，在这 10 个特征组成的数据子集上构建的分类模型的分类正确率达到 0.7958。从图 3.8 可以看出，影响 PAD 发病率排名第一的因素是年龄，其变量重要性分数达到了

43.667, 是排名第二位的变量 ALT 重要性分数(12.873)的 3 倍多, 这与现有的关于 PAD 危险因素的医学研究成果是高度一致的。医学研究表明, 随着年龄的增长, 糖尿病患者发生动脉疾病的危险性也在增加, 当患者年龄超过 50 岁时, 会更容易患有 PAD^[142]。从实验结果来看, 丙氨酸氨基转移酶 ALT 是第二重要的 PAD 危险因素, 因为本研究中某些样本为糖尿病患者, 非酒精性脂肪肝的发病率很高, 我们推测 ALT 水平升高是糖尿病患者发生 PAD 的一个重要危险因素。最近的研究表明, ALT 是肝损伤的迹象, 且与血管内皮功能障碍和血管硬化相关, 这个结果与我们的研究结果是一致的^[143]。我们还获得一个重要的发现, INS60 也是一个重要的 PAD 危险因素, 这个结果已经被体内研究和体外研究所确认。胰岛素是一种有效的增强胶原合成的生长因子, 它刺激血管平滑肌细胞增殖, 这是一种动脉粥样硬化的过程。其他的危险因素包括: 高血压、高胆固醇和甘油三酯等。总体上, 本文的实验结果与现有的医学研究结果是高度一致的, 这表明我们提出的基于随机森林的特征选择算法是合理的, 适合于疾病危险因素分析。




图3.8 影响PAD的前10个危险因素

Fig3.8 The top 10 risk factors of PAD

3.5 本章小结

本章针对医学数据集的高维特征空间及特征高度相关导致分类器性能下降的问题, 提出了一种基于随机森林的Filter式特征选择及分类方法。Filter方法可以较快地滤除与目

标变量不相关或不重要的特征，本章所提出的算法利用随机森林变量重要性分数选择前Top个特征训练分类器。在UCI标准数据集和糖尿病临床数据集上的实验结果表明，所提出的算法可以有效地选择出和目标变量相关的预测变量，算法的分类性能优于单独使用经典的分类算法。本文在糖尿病临床数据集上利用所提出的特征选择方法对PAD危险因素进行了研究，找出了影响PAD的前10个危险因素。实验结果表明年龄、丙氨酸氨基转移酶和餐后60分钟胰岛素水平都是重要的PAD危险因素，这和现有的医学研究结论是高度一致的，这从临床的角度验证了本文所提出算法的有效性。

本文所提出的算法是一种Filter式特征选择算法，与其他的Filter特征选择算法一样，需要确定特征选择的阈值。本文中依次选取变量重要性分数最大的前3n个特征构成待选特征子集，通过迭代实验选择最优特征子集，算法中的step参数设置为3，这是根据本文所用的数据集的大小确定的一个经验值。如何更加智能地设置阈值，仍然是一个有待研究的课题。

第4章 基于 RF 的 Wrapper 式特征选择算法研究

4.1 引言

基于 Filter 的特征选择方法独立于后续的机器学习算法,可以较快地排除一部分非关键性的噪声特征,缩小最优特征子集搜索范围,但基于 Filter 的特征选择方法的阈值难以确定,阈值选择不当会严重影响特征子集的质量和分类精度。由于医学数据集中的特征之间往往高度相关,有时候基于 Filter 的特征选择方法并不能保证选择出最优的特征子集,或者会产生多个分类能力相同但是特征不同的特征子集。基于 Wrapper 特征选择算法在选择特征的过程中直接用所选的特征子集来训练分类器,根据分类器在测试集的性能表现来评价该特征子集的优劣,该方法在计算效率上不如 Filter 方法,但其所选的优化特征子集的规模相对要小一些。在基于 Wrapper 的特征选择过程中,特征子集的搜索策略和评价方法是最重要的因素。在众多的特征搜索策略中,序列搜索由于能够在降低计算时间开销的同时获得较好的结果而被广泛使用,典型的特征搜索策略包括 SFS、SBS、SFFS 和 LRS 等。如第 3 章所讨论的, SFS 在搜索最优特征子集的过程中,每次增加一个特征到特征子集中而从不从特征子集删除特征,因此可能会将冗余特征引入特征子集; SBS 只从特征子集删除特征而从不向特征子集增加特征,因此重要的特征可能因为没有考虑特征之间的相关性而被误删除; SFFS 算法比朴素的 SFS 算法更加灵活,但是无论 SFS 还是 SFFS 都可能因为将高度相似的特征引入到特征子集而产生嵌套子集; LRS 试图通过增加 L 个特征同时删除 R 个特征的方法来避免产生嵌套子集,然而 LRS 方法的参数 L 和参数 R 的设置仍是一个难题。另外,采用什么样的分类算法作为特征子集评价准则,也对特征选择结果和最终的分类模型性能具有非常重要的影响,当前常用的分类模型包括决策树算法、支持向量机算法、人工神经网络算法和随机森林算法等。

本章将重点研究基于 RF 的 Wrapper 式特征选择算法,首先针对基于 Filter 式的特征选择算法选择出的特征子集不能保证最优的问题,研究采用广义序列后向选择 GSBS 搜索策略和 RF 变量重要性分数评价准则的 Wrapper 式特征选择,可以提高特征子集的质量和分类模型的性能。然后,针对 SBS 只能删除特征带来的误删除和 SFS 只能加入而引入噪声以及未考虑特征间相互作用的问题,提出了一种新的结合 SBS 和 SFS 的序列联合搜索策略 (Sequence Joint Searching, SJS), 以提供更加灵活的特征搜索,在选择最重要特征的同时较快地剔除不相关特征和噪声特征。另外,本章还将研究采用不同的分类器作为特征子集评价函数时,基于 RF 的 Wrapper 式特征选择算法的特征选择和分类性能。

4.2 基于 RF 和 GSBS 的 Wrapper 式特征算法

4.2.1 算法设计

本节提出了一种基于随机森林变量重要性分数和GSBS搜索策略的Wrapper式特征选择算法RF-GSBS。该算法首先利用随机森林算法的变量重要性度量对特征进行排序，然后采用广义序列后向搜索方法，每次从特征集合中去掉 L 个最不重要（默认 $L=1$ ）的特征，逐次进行迭代，并计算分类正确率，最终得到变量个数最少、分类正确率最高的特征集合作为特征选择结果。为了保证实验结果的稳定性，算法采用了10折交叉验证方法，在每一次迭代中，将数据集划分成10等份，利用其中的9份作为训练集用于构建随机森林分类器，剩余的1份作为验证集数据进行验证。在10折交叉验证过程中，选择测试集上分类准确率最高的一次迭代产生的变量重要性分数作为删除特征的依据，将10次迭代的平均分类准确率作为该轮迭代的分类精度。具体过程如算法4.1所示。

算法4.1：基于RF与GSBS的特征选择算法RF-GSBS

输入：原始数据集 D ;

输出：验证集上的最大分类正确率 $TGMaxAcc$ 及其对应的特征子集 $FGSort$;

步骤:

1. 初始化：读入原始数据集 D ，设置 $TGMaxAcc=0$ ， $FGSort=Null$;
2. for (ft 从 1 到 $\lfloor N/L \rfloor$) // ft 代表循环变量， N 代表数据集中所有特征个数
 // L 为 GSBS 参数，即每次删除的特征数量
 - 2.1 采用分层采样技术将数据集 D 划分为 10 等份，表示为： $D = D_1 \cup D_2 \cup \dots \cup D_{10}$;
 - 2.2 设置 1 次特征选择过程中最大分类准确率 $TLMaxAcc = 0$;
 - 2.3 设置 1 次特征选择过程中 10 次迭代的平均分类准确率 $TLMeanAcc=0$;
 - 2.4 设置 10 次迭代中每次训练得到的分类器的分类准确率向量 $TLAcc[1:10]=0$;
 - 2.5 for (i 从 1 到 10)
 - 2.5.1 在数据集 $(D-D_i)$ 上训练随机森林分类器，标记为 rf ;
 - 2.5.2 在数据集 D_i 上利用 rf 对样本进行预测，分类准确率记为 $TLAcc$;
 - 2.5.3 计算 10 次迭代中 rf 的平均分类准确率，记为 $TLMeanAcc$;

- 2.5.4 计算10次迭代中 rf 的最高分类准确率, 记为 $TLMaxAcc$;
- 2.5.5 以10次迭代中 rf 分类准确率最高的一次迭代中的变量重要性分数为依据对特征子集中的特征降序排序, 结果标记为 $Fsort$;
- 2.5.6 根据 $Fsort$ 从数据集 D 中剔除最不重要的 L 个特征, 得到新的数据集 D ;
- 2.6 end for
3. end for
4. 找出 ft 次循环产生的特征子集中 rf 平均分类准确率最高的特征子集, 标记为 $FGSort$, 对应的最高 rf 最高分类准确率标记为 $TGMaxAcc$;
5. 输出 $FGSort$ 和 $TGMaxAcc$;
6. end.

在算法4.1中, 在第1步中设置全局变量最大分类正确率 $TGMaxAcc$ 和及其对应的特征子集 $FGSort$; 在第2步中, 首先采用10折交叉验证训练随机森林分类器, 将10次迭代中随机森林分类器分类准确率最高的一次迭代产生的变量重要性分数作为特征排序的依据, 并将10次迭代中随机森林分类器的平均分类准确率作为该轮特征选择产生的特征子集上的分类准确率; 然后, 根据特征排序结果, 从原始的数据集中删除最不重要的 L 个特征得到新的数据集, 重新执行前面的步骤, 直到循环结束 (特征集合中的特征数目为0); 在第4步中, 统计所有轮特征选择过程中平均分类准确率最大时的特征子集作为最优特征子集, 对应的分类准确率为该特征选择算法得到的最大分类准确率。

4.2.2 时间复杂度分析

本文所提出的随机森林特征选择方法中基分类器选择CART算法。假设训练数据集的特征维数为 m , 训练样本个数为 n , CART算法的时间复杂度为 $O(m \cdot n \cdot (\log n)^2)$ 。随机森林在构建CART树的过程中, 从 m 个特征中随机选择 m_{try} 个特征计算信息增益, 并且对树的生长不进行剪枝, 故训练每一个基分类器的计算时间小于 $O(m \cdot n \cdot (\log n)^2)$, 假设随机森林中基分类器的个数为 k 个, 则随机森林算法的时间复杂度可以近似为 $O(k \cdot m \cdot n \cdot (\log n)^2)$ 。在本实验中, 采用广义序列后向选择策略 (默认 $L=1$) 进行特征选择需要循环 $m-2$ 次, 每一轮循环中采用10折交叉验证, 需运行随机森林算法10次, 每轮循环需对特征子集进行排序, 采用快速排序算法的平均时间复杂度为 $O(m \cdot \log m)$, 根据排序后的特征集

合生成新的训练数据集需要进行 $m-2$ 次，每次计算时间为常数，故总的时间复杂度可以近似表示为： $O((m-2)*(10*O(kmn(\log n)^2)+O(m\log m)+m-2))\approx O(km^2n(\log n)^2)$ ，由此可见，RFFS算法的时间复杂度与特征维数 m 成近似平方关系，与数据集样本个数 n 成近似立方关系，运算时间是可以接受的，算法具有较好的扩展性。

4.3 RF-GSBS 算法实验分析

4.3.1 实验数据与环境

本文的算法采用 R 语言进行实现，随机森林核心算法采用 R 软件中的 randomForest 程序包，其中 *mtry* 参数取 Breiman 建议的默认值 $\sqrt{n}$ （ n 为训练数据集中特征的个数），*ntree* 参数设置为 1000。实验的硬件环境为 Intel Core(TM) 2 Duo CPU E4600@2.40GHz, 3.75G 的内存，操作系统为 Microsoft Windows 7，绘图软件采用 Matlab7.0。

为了验证所提出的算法的有效性，从 UCI 数据集中选取了 6 个有代表性的医学数据集进行实验，这些数据集在文献中被广泛引用。表 4.1 列出了这些数据集的基本特征。

表 4.1 数据集基本信息

Table 4.1 Summary of Datasets

NO.	Dataset	Nominal attributes	Continuous attributes	Instance size	Number of Class
1	Breast	1	9	699	2
2	Diabetes	0	8	768	2
3	Heart	7	6	270	2
4	Liver	0	6	345	2
5	Wpbc	1	33	198	2
6	Wdbc	1	31	569	2

其中，Breast 数据集是来自于临床案例的乳腺癌数据集，共包含 699 个样本、9 个数值变量和 1 个分类变量，目标变量是样本的类别：良性的和恶性的；Diabetes 是糖尿病数据集，该数据集是一个约束选择的数据集，包括 768 个大于 21 岁的皮马印第安人后裔的样本数据，每个样本包括 8 个数值变量和 1 个分类变量；Heart 是一个心脏病数据集，包含 270 个样本、6 个数值特征和 7 个分类特征；Liver 是一个肝功能紊乱数据集，共包含 395 个样本，其中 6 个数值变量和一个目标变量；Wpbc 是威斯康星州预后乳腺癌数

据集，共包含 198 个样本、33 个数值变量和一个分类变量：Wdbc 是威斯康辛州诊断乳腺癌数据集，共包含 569 个样本、31 个数值变量和 1 个分类变量：良性的和恶性的。

4.3.2 评价函数的性能分析

在特征选择算法 RF-GSBS 中，使用特征子集上构建的分类器的分类正确率来评价特征子集的质量，为了更加深入探索基于随机森林的特征选择算法的有效性，我们在实验中分别采用支持向量机和随机森林分类算法作为特征子集评价算法，对应的特征选择算法分别标记为 RF-SVM 和 RF-RF。在这两种算法中，均采用 SBS 进行最优特征子集选择，实验结果如表 4.2 所示。其中 SF 列表示选择出的特征子集大小，Acc 表示在最有特征子集对应的数据集上的分类正确率。

表 4.2 RF-RF 和 RF-SVM 算法的性能比较

Table 4.2 Performance comparison of RF-RF and RF-SVM algorithms

Dataset	RF-RF		RF-SVM	
	SF	Acc	SF	Acc
Breast	6	0.982	5	0.985
Diabetes	5	0.79	5	0.811
Heart	6	0.923	6	0.896
Liver	6	0.743	5	0.768
Wpbc	24	0.816	27	0.929
Wdbc	11	0.980	22	1

从表 4.2 可以看出，从平均分类正确率来看，RF-SVM 算法的分类性能整体上略优于 RF-RF 算法，但是 RF-RF 算法选择的特征子集整体上比 RF-SVM 算法较小。这可能是因为用于评价特征重要性的 RF 算法与用于评价特征子集质量的分类器算法不同，可以避免采用同一种算法带来的偏差，RF-SVM 算法相当于集成了 RF 与 SVM 的优势，从而提高了分类算法的分类正确率。

4.3.3 特征选择过程分析

本节考察所提出的基于 RF 变量重要性分数的 Wrapper 式特征选择算法的特征选择过程。首先，通过实验研究了特征子集中的特征数量与分类器分类性能的关系，实验结果如图 4.1-4.6 所示。




图 4.1 在 Breast 数据集上 RF-RF 和 RF-SVM 算法分类性能比较

Fig. 4.1 The classification accuracy of RF-RF and RF-SVM algorithm on Breast dataset




图 4.2 在 Diabetes 数据集上 RF-RF 和 RF-SVM 算法分类性能比较

Fig. 4.2 The classification accracy of RF-RF and RF-SVM algorithm on Diabetes dataset




图 4.3 在 Heart 数据集上 RF-RF 和 RF-SVM 算法分类性能比较

Fig. 4.3 The classification accuracy of RF-RF and RF-SVM algorithm on Heart dataset




图 4.4 在 Liver 数据集上 RF-RF 和 RF-SVM 算法分类性能比较

Fig. 4.4 The classification accuracy of RF-RF and RF-SVM algorithm on Liver dataset




图 4.5 在 WPBC 数据集上 RF-RF 和 RF-SVM 算法分类性能比较

Fig. 4.5 The classification accracy of RF-RF and RF-SVM algorithm on WPBC dataset




图 4.6 在 WDBC 数据集上 RF-RF 和 RF-SVM 算法分类性能比较

Fig. 4.6 The classification accracy of RF-RF and RF-SVM algorithm on WDBC dataset

考察 RF-RF 和 RF-SVM 的特征选择过程,从图 4.1-图 4.6 可以看出,在除 Wpbc 数据集外的其它所有数据集上,随着最不相关特征(变量重要性分数最小的特征)的依次剔除,RF-RF 和 RF-SVM 的分类正确率呈现先升后降的趋势,这表明通过特征选择可以有效地剔除不相关特征和冗余特征并提高分类器性能,当特征子集大小达到一个特定值时,如果进一步地进行特征搜索则会误删除部分重要的特征,从而减低分类器的分类性能。在 WPBC 数据集上,随着特征选择过程中不重要特征的依次剔除,RF-RF 算法的分类准确率逐渐提高,当特征子集中的特征个数达到 20 时,RF-RF 算法的分类准确率达到最大值,然后随着特征的剔除,分类准确率开始下降;而 RF-SVM 算法的分类准确率在特征选择的初期变化不大,而在特征子集中的特征数达到 27 后即开始出现下降趋势。在 Wpbc 数据集上的结果可能是由于 SVM 分类器更适合处理 Wpbc 分类问题,其分类准确率明显高于 RF 分类器,其特征选择结果也更可靠一些。从整体上来说,根据随机森林变量重要性分数和序列后向选择策略进行特征选择,能够有效地识别并消除冗余和不相关特征,从而提高分类器的分类性能。

另外,考察 RF-RF 和 RF-SVM 的分类精度,从图 4.1、4.3 和 4.6 可以看出,RF-RF 算法和 RF-SVM 算法在 Breast、Heart 和 Wdbc 数据集上的分类正确率不相上下,在不断剔除特征的过程中,特征子集上的分类正确率均出现先升后降的趋势,说明将随机森林变量重要性度量作为特征选择的依据是合理的;从图 4.4 和 4.5 可以看出,在 Liver 和 Wpbc 数据集上,RF-SVM 算法的分类性能优于 RF-RF 算法;从图 4.2 可以看出,在 Diabetes 数据集上,RF-RF 算法的分类准确率优于 RF-SVM 算法;从整体上来看,RF-RF 算法和 RF-SVM 算法的分类性能相差不大。最后,从图 4.1-4.6 还可以看出,RF-RF 算法比 RF-SVM 算法相对稳定,随着数据集中特征的减少,RF-RF 算法的分类正确率波动不大,而 RF-SVM 算法的分类正确率波动较大。

4.3.4 算法的有效性分析

为了更好地验证基于 RF 和 GSBS 的特征选择算法的有效性,本文在 UCI 数据集上与 CBFS 算法^[144]和 AMGA^[145]算法进行了对比实验。CBFS 算法是一种基于聚类的过滤式特征选择算法,利用不同簇间在各个特征上的差异定义的区分度作为特征可分性判据,然后按可分性判据的大小进行特征重要性排序,根据重要性的变化规律选取特征子集,然后在选择出来的特征子集上训练 C4.5 分类器,用于评价特征选择算法的性能^[144]。AMGA 算法是一种基于自适应多种群遗传算法的特征选择算法,采用多种群规划模型和

动态操作算法从多维特征集合中寻找最优特征子集，能够自适应地调整多个种群的运行状态，有效地控制早熟收敛，增强了局部搜索能力^[145]。AMGA 算法结合了 SVM 算法，通过 SVM 评价特征子集的分类精度，构建适应度函数。表 4.3 列出了 RF-SVM 算法和 CBFS 算法、AMGA 算法在 UCI 实验数据集上的实验结果，其中 SF 列表示选出的最优特征子集中的特征个数，Acc 列表示算法在实验数据集上的分类性能。

表 4.3 不同算法的性能比较

Table 4.3 Performance comparison of different algorithms

Dataset	CBFS		AMGA		RF-SVM	
	SF	Acc	SF	Acc	SF	Acc
Breast	6	0.943	6	0.991	6	0.982
Diabetes	4	0.670	5	0.804	5	0.811
Heart	9	0.791	9	0.915	6	0.923
Liver	3	0.618	—	—	5	0.768

从表 4.3 可以看出，RF-SVM 算法在 Breast、Diabetes、Heart 和 Liver 数据集上的分类正确率分别为 98.2%、81.1%、92.3%和 76.8%，选择出的特征个数分别为 6、5、6 和 5。与 CBFS 算法相比，在选择出的特征个数相差不大的情况下，RF-SVM 算法的分类性能明显优于 CBFS 算法的分类性能。与 AMGA 算法相比，RF-SVM 算法在 Breast 数据集上选择的特征个数与 AMGA 算法相等，分类性能略低于 AMGA 算法；在 Diabetes 数据集上，RF-SVM 算法选择的特征个数与 AMGA 算法相等，分类性能略高于 AMGA 算法；在 Heart 数据集上，RF-SVM 算法选择比 AMGA 算法选择了更少的特征数目，却获得更高的分类精度。实验结果表明，RF-SVM 算法不仅能够选择出较优的特征子集，而且能够获得较高的分类性能。

4.3.5 参数 L 的设置讨论

在 RF-GSBS 算中，L 值的设置是一个问题。一般而言，L 的值越大，在每次迭代过程中删除的特征就越多，算法的执行速度就越快，但同时有些重要的特征可能被提前误删除。另一方面，较小的 L 值可以实现一种更加精细的选择，但是会增加算法的执行时间。在 6 个 UCI 数据集上，分别设置 L 的值为 1，2，3，4，和 5，执行 RF-GSBS 算法，实验结果如图 4.7 所示。




图 4.7 分类性能随 L 值变化情况

Fig. 4.7 The relationship between classification performance and L values

从图 4.7 可以看出, 在所有实验数据集上, 随着 L 值的增加, 算法的分类正确率呈现下降的趋势。也就是说, 当 L 的值设置为 1 的时候, RF-GSBS 算法的结果最好, 这时, GSBS 搜索策略实际上演变成了 SBS 搜索策略。这可能是因为实验数据集的维数较小, 如果 L 的值增加, 每次删除的特征数量就增加, 尽管这可以有效地删除不相关特征和冗余特征, 但是也容易误删除重要的特征变量。然而, 如果数据集的维数特别高, 较大的 L 值可以较快地移除冗余特征和不相关特征, 有效地提高算法的分类性能, 当数据集维数非常大的时候, L 的值可以设置为 $\sqrt{n}$, n 是特征维数, 因为本章实验数据集的维数相对较小, 故而将 L 默认设置为 1。

4.4 基于 RF 的序列联合特征搜索策略

医学数据集的一个重要特点是特征间的高度相关。为了克服 SBS 只能删除特征带来的误删除和 SFS 只能加入特征而引入噪声以及未考虑特征间相互作用的问题, 本文提出了一种新的结合序列后向搜索方法和序列前向搜索方法的序列联合搜索策略 SJS, 并基于该特征搜索策略提出了一种新的 Wrapper 式特征选择算法 RF-SJS。

4.4.1 算法设计

RF-SJS 算法的基本思想是：首先运行 RF 算法计算每个特征的重要性分数，然后对所有特征根据其变量重要性分数进行排序。为了保证系统的稳定性和可靠性，在每次迭代过程中，都运行随机森林 10 次，10 次产生重要性分数的平均值作为该特征的重要性度量。接下来，利用结合了广义序列后向搜索策略和序列前向搜索策略的 SJS 搜索策略产生特征子集。具体地说，将生成两个新的数据子集，其中一个子集从原始数据集合中移除了 L 个最不重要的特征（重要性分数最小）和 1 个最重要的特征，另一个子集则只删除最不重要的特征。第一个数据子集被用来训练随机森林，并为下一次迭代计算变量的重要性。第二个数据子集用于训练支持向量机分类器，并评估所选出的特征子集的质量。同样，为了保证计算结果的稳定性，在利用支持向量机计算分类精度时，使用了 10 折交叉验证方法。迭代执行上面的步骤，直到特征子集的大小（特征数量）满足要求（本文中设置特征子集中的特征数的最小值是 5）。最后，支持向量机分类器分类准确率最高的特征子集作为最优特征子集，同时计算得到各特征变量的重要性分数。

给定训练数据集 D ，按变量重要性分数排序生成的特征子集标记为 $TmpFeatureSet$ ；在搜索特征子集的过程中，首先采用 GSBS 算法从特征子集上只删除最不重要的 L 个特征，生成的特征子集作为最优特征子集标记为 $OptFeatureSet$ ，用于训练 SVM 分类器；然后从特征子集上删除最重要的 1 个特征和最不重要的 L 个特征生成另一个特征子集 $TmpFeatureSet$ ，用于训练 RF 分类器，其变量重要性分数用于下一轮的特征选择。最后，在所有的最优特征子集上，选择分类正确率最高的特征子集作为全局最优特征子集 $GloOptFeatureSet$ ，对应的 SVM 分类正确率标记为 $MaxAccuracy$ ，特征子集中各个特征的变量重要性分数保存为一个向量 $FeatureScore$ ；算法的具体实现流程如算法 4.2 所示。

算法 4.2：基于 RF 和 SJS 的特征选择方法 RF-SJS

输入：原始数据集 D ，特征集合 S ，参数 L ；

输出：最大分类准确率 $MaxAccuracy$ ，最优特征子集 $GloOptFeatureSet$ ，最优特征子集中每个特征的变量重要性分数 $FeatureScore$ ；

步骤：

1. 初始化：

1.1 设置最大分类正确率初值： $MaxAccuracy \leftarrow 0$ ；

1.2 设置临时变量（用于训练 SVM）： $OptFeatureSet \leftarrow S$ ；

- 1.3 设置临时变量（用于训练RF）： $TmpFeatureSet \leftarrow S$;
- 1.4 设置最优特征子集 $GloOptFeatureSet \leftarrow Null$;
2. while ($OptFeatureSet$ 中的特征个数 > 5)
 - 2.1 for (i 从 1 到 10)
 - 2.1.1 在特征集合 $TmpFeatureSet$ 构成的数据集上训练随机森林分类器，记为 rf ;
 - 2.1.2 计算 $TmpFeatureSet$ 中所有特征的变量重要性分数，记为向量 F_{score}^i ;
 - 2.2 end for
 - 2.3 计算10次运算中特征的平均变量重要性分数，标记为 $RFAverageScore$;
 - 2.4 根据 $RFAverageScore$ 进行特征排序，结果记为： $SortedFeatureSet$;
 - 2.5 从 $SortedFeatureSet$ 中删除 L 个变量重要性分数最小的特征，新的特征集合记为 $OptFeatureSet$ ，用于训练SVM分类器;
 - 2.6 采用分层采样将 $OptFeatureSet$ 对应的数据集 D' 划分为10等份，表示为：

$$D' = O_1 \cup O_2 \dots \cup O_{10};$$
 - 2.7 for (i 从 1 到 10)
 - 2.7.1 在 $(D'-O_i)$ 上训练SVM分类器，标记为 sv ;
 - 2.7.2 在 O_i 上利用 sv 进行分类，分类准确率记为 $TLAcc$;
 - 2.8 end for;
 - 2.9 计算10次迭代中的平均分类准确率，标记为 $SVMAverageAccuracy$;
 - 2.10 从 $SortedFeatureSet$ 中删除 L 个重要性分数最小的特征和1个变量重要性分数最大的特征，新的特征集合标记为 $TmpFeatureSet$ ，用于训练RF分类器;
3. end while;
4. 统计第2步所有循环产生的特征子集上的SVM最大分类准确率 $MaxAccuracy$;
5. $MaxAccuracy$ 对应的特征子集为最优特征子集，标记为 $GloOptFeatureSet$;
6. 输出 $MaxAccuracy$ 和 $GloOptFeatureSet$;
7. end.

在算法4.2中, 首先在第1步进行相关变量的初始化; 在第2步中循环搜索最优特征子集, 首先采用10折交叉验证训练随机森林分类器, 并计算变量重要性分数, 10次迭代的平均变量重要性分数作为特征排序的依据; 在对特征进行排序后, 在第2.5-2.9步中, 从排序特征集合中删除L个最不重要的特征得到一个新的特征集合 *OptFeatureSet*, 在其对应的数据集上训练SVM分类器, 并将10折交叉验证的平均分类准确率作为该特征集合上的SVM分类准确率; 在第2.10步中, 从排序集合中删除L个最不重要的特征和一个最重要的特征, 得到一个新的特征集合 *TmpFeatureSet*, 训练RF分类器并计算变量重要性分数, 用于下一轮特征选择; 最后在第4-5步中统计所有轮特征选择中SVM分类正确率最大的特征子集, 在第6步中输出特征选择和分类结果。

4.4.2 时间复杂度分析

RF-SJS算法中的时间开销主要是训练RF与SVM的时间开销。考虑算法中训练数据集的特征个数为 m , 样本的个数为 n , 随机森林中CART决策树的个数为 k , 则RF的时间复杂度可以近似为 $O(k * m * n * (\log n)^2)$ 。另外, SVM的最坏时间复杂度为 $O(N_{sv}^3)$, 其中 N_{sv} 是支持向量的个数。RF-SJS迭代次数为 $ft = m / L$, 其中 L 为GSBS每次删除的特征数目, 默认为 $L=1$; 即 $ft = m$; 每次训练RF和SVM重复执行10次。RF-SJS总的时间复杂度约为:

$$O(m * (10 * O(kmn(\log n)^2) + O(m \log m) + 10 * O(N_{sv}^3))) \approx O(10k * m^2 n (\log n)^2 + 10 * O(N_{sv}^3))$$
 通过上式可以看出, 本文所提出的算法的时间复杂度与训练集中特征的个数 m 成平方关系, 对于一般的医学数据集, 该算法的运算时间是可以接受的。

4.5 仿真实验及结果分析

4.5.1 实验数据集

为了验证所提出的算法的有效性, 我们仍然使用的上一小节中引用的UCI标准数据集进行实验, 同时增加了1个糖尿病临床数据集(HYDD)和1个微阵列表达数据集(急性淋巴细胞白血病数据集 ALL)。糖尿病临床数据集来自于黑龙江省某三级甲等医院内分泌科, 具体信息参见第2章, 经过数据预处理后, 数据集中共包含2型糖尿病相关的1910个样本和46个分类特征。微阵列表达数据集中包含128个患有急性淋巴细胞白血病的不同个体的12625个基因, 其中包括33个T细胞急性淋巴细胞白血病和95个B细胞急性淋巴细胞白血病。数据在预处理阶段进行了正则化处理。数据以 *exprSet* 形式存储。本文专注于B细胞急性淋巴细胞白血病分析, 基因突变是研究的目标对象。所以我

们选择了 94 个 B 细胞急性淋巴细胞白血病样本，目标变量是急性淋巴细胞白血病的类型，是一个四分类问题。

4.5.2 UCI 数据集和 HYDD 数据集上的实验

表 4.4 列出了 RF-SJS 算法与 CBFS 算法^[144]和 AMGA 算法^[145]的对比实验结果，其中，Feature 列标识最优特征子集中的特征个数，Acc 列标识测试数据集上的分类正确率，CBFS 和 AMGA 算法的基本原理已经在 4.3.4 小节中进行了介绍，在此不再赘述。

表 4.4 RF-SJS, CBFS 和 AMGA 算法在 UCI 数据集上的性能比较

Table 4.4 The performance of RF-SJS, CBFS and AMGA on UCI datasets

数据集	CBFS		AMGA		RF-SJS	
	Feature	Acc	Feature	Acc	Feature	Acc
Breast	6	0.943	5	0.991	5	0.985
Diabetes	4	0.670	5	0.804	4	0.811
Heart	9	0.791	8	0.915	3	0.963
Liver	3	0.628	—	—	3	0.768

从表 4.4 可以看出，在所有数据集上，RF-SJS 算法选择出了比 CBFS 算法更小的特征子集，并且其分类正确率显著高于 CBFS 算法。和 AMGA 算法相比，在 Breast 数据集上 RF-SJS 算法得到了相同的特征子集但是其分类正确率略低，这可能是实验误差导致的；在 Diabetes 和 Heart 数据集上，RF-SJS 算法选择除了比 AMGA 更小的特征子集，且其分类正确率高于 AMGA 算法。另外，从实验结果可以看出，数据集的维数越高，RF-SJS 算法的性能优势体现的越明显。由此可以看出，在所选择的数据集上，本文所提出的算法无论是在选择出的特征子集的质量上还是分类正确率方面，表现出的性能均优于已有的算法。

表4.5列出了RF-SJS与DFS-SFS^[36]、CFS-SFS^[36]、CFSPabs-SFS^[36]、DFS-SBS^[36]、CFS-SBS^[36]和CFSPabs-SBS^[36]等算法的比较结果。在表4.5中，DFS-SFS、CFS-SFS 和 CFSPabs-SFS分别采用特征子集区分度、特征之间的相关性和基于Pearson相关系数的特征之间的相关性作为特征相关性评价准则，并分别采用序列前向特征选择和序列后向特征选择作为特征搜索策略，以SVM分类器作为特征子集评价函数。RF-SJS算法采用随机森林变量重要性分数作为特征相关性评价准则，采用结合了SBS和SFS的序列联合搜索策

略SJS作为特征搜索策略，以SVM分类器作为特征子集评价函数。

表 4.5 RF-JS, DFS, CFS 和 CFSPab 算法在 UCI 数据集上的性能比较

Table 4.5 The Performance Comparison among RF-JS, DFS, CFS and CFSPabs on UCI datasets

数据集	RF-SJS		DFS-SFS		CFS-SFS		CFSPabs-SFS	
	Feature	Acc	Feature	Acc	Feature	Acc	Feature	Acc
Wdbc	9	0.983	28	0.647	14	0.631	15	0.631
Wpbc	6	0.854	29	0.763	6	0.773	6	0.758
Heart	3	0.963	13	0.539	12	0.539	12	0.539
数据集	RF-SJS		DFS-SBS		CFS-SBS		CFSPabs-SBS	
	Feature	Acc	Feature	Acc	Feature	Acc	Feature	Acc
Wdbc	9	0.983	27	0.647	11	0.636	24	0.647
Wpbc	6	0.854	28	0.763	8	0.763	11	0.758
Heart	3	0.963	12	0.539	11	0.539	11	0.539

从表4.5可以看出，在所有比较的数据集上，RF-SJS算法选择的特征子集大大小于文献[36]中的算法，同时RF-SJS算法的分类正确率显著高于文献[36]中的算法，这充分表明本文所提出的算法无论在特征子集质量还是分类能力上均具有良好的性能。

另外，本文在UCI数据集上对第3章提出的基于RF的Filter式特征选择算法与本章提出的基于RF和SBS的Wrapper式特征选择算法、基于RF和SJS的Wrapper式特征选择算法进行了比较，结果如表4.6所示。

表 4.6 4SVM, RF&SVM, RF-SVM 和 RF-SJS 算法的性能比较

Table 4.6 The comparison of performance of SVM, RF&SVM, RF-SVM and RF-SJS

dataset	SVM		RF&SVM		RF-SVM		RF-SJS	
	Feature	Accuracy	Feature	Accuracy	Feature	Accuracy	Feature	Accuracy
Heart	13	0.907	13	0.907	6	0.896	3	0.963
WPBC	34	0.675	10	0.825	27	0.929	6	0.854
WDBC	31	0.965	25	0.991	22	1	9	0.983
HYDD	46	0.723	16	0.785	15	0.802	12	0.832

从表4.6可以看出，本文所提出的基于RF和SVM的Filter式特征选择算法RF&SVM在

分类正确率等于或高于单独使用SVM算法的同时,选择出了更小的特征子集;基于RF和SBS的Wrapper式特征选择RF-SVM总体上来说选择的特征子集比RF&SVM更小,分类正确率却高于RF&SVM算法;基于RF和联合搜索策略的RF-SJS算法在Heart、WDBC和HYDD数据集上在保持或明显提高分类正确率的同时,比RF&SVM和RF-SVM算法选择出了更小的特征子集,这表明本文所提出的SJS特征搜索策略是有效的;在WPBC数据集上,RF-SJS算法的分类性能低于RF-SVM算法但高于SVM和RF&SVM算法,RF-SJS选择出的特征子集明显小于其他算法,这可能是由于SJS搜索策略导致了部分重要特征的信息损失。总体上,基于RF和联合搜索策略的RF-SJS算法能够在保持或提高分类准确率的同时选择出更优的特征子集。另外,基于随机森林的算法能够提供每个特征的变量重要性分数,变量重要性分数越高,说明该特征对于目标变量的影响越大,这有助于医学专家对数据挖掘结果进行理解。

4.5.3 ALLb 数据集上的实验

ALLb 数据集是一个急性淋巴细胞白血病数据集,在 ALLb 数据集上,本文进一步研究在 RF-SJS 中不同分类器的性能,并对所提出的特征选择方法与其他特征选择方法进行比较。ALLb 是一个微阵列表达数据集,包含了 94 个 B 细胞急性淋巴细胞白血病样本,每个样本包含 12625 个基因。这是一个四分类问题,目标变量有 4 种类别: ALL/AF4、BCR/ABL、E2A/PBX1 和 NEG。该数据集的维度非常大,在训练分类模型之前非常有必要进行特征选择。首先基于基因数据的分布情况使用统计方法过滤掉一部分明显不相关的基因,使数据集的维数从 12625 降低到 3970。接下来,在过滤后的基因数据集上,分别执行因子分析方法(AVONA)、基于随机森林的过滤式特征选择方法(FFSRF)、基于组合特征聚类的过滤式特征选择方法(FFSFC)和本文提出的特征选择方法(RF-SJS)。在这些方法中,分别使用 KNN、randomForest 和 SVM 作为特征子集评价函数。为了与 FFSRF 相对应,此处将本文所提出的特征选择方法命名为 WFSRF。结果,AVONA 选择除了 752 个基因,FFSRF 和 FFSFC 都选择了 30 个基因,WFSRF 分别选择了前 50 个和前 20 个基因,各种算法的分类性能如表 4.7 所示。

从表 4.7 可以看出,本文提出的算法的分类性能从整体上优于 ANOVA、FFSRF 和 FFSFC。考察分别使用 KNN、randomForest 和 SVM 作为特征子集评价函数,从实验结果可以看出,RF-SJS 算法在分类性能上优于其他所有算法。另外,作为特征子集评价函数来说,在 RF-SJS 算法中,randomForest 和 SVM 的性能差别不大,但是都优于 KNN

算法。

表 4.7 KNN, RF 和 SVM 算法在 Allb 数据集上的性能比较

Table 4.7 Performance of KNN, RF and SVM algorithm on ALLb dataset

classifier feature selection	KNN	randomForest	SVM
ANOVA.752	0.8298	0.7979	0.8617
FFSRF.30	0.8830	0.8723	0.8617
FFSFC.30	0.8617	0.8298	0.8511
WFSRF.20	0.8421	0.8947	0.8947
WFSRF.50	0.8947	0.9475	0.9475

4.6 本章小结

针对医学数据集的高维特征空间和高度特征冗余，本章提出了基于随机森林和广义序列后向搜索的 RF-GSBS 算法，首先基于随机森林算法计算每个特征的变量重要性分数，然后采用 GSBS 方法每次剔除 L 个最不重要的特征直到特征子集中的特征数目达到要求，然后在每一个特征子集上训练 RF 或 SVM 分类器，使用分类器的分类正确率作为评判特征子集质量的目标函数，在 UCI 标准数据集上对算法的性能进行了研究，实验结果表明，RF-GSBS 算法的总体性能优于文献中已有的方法。

针对医学数据集中特征之间的高度相关问题，本文进一步地提出了基于序列前向搜索和广义序列后向搜索的联合搜索策略，并提出了基于 RF 和 SJS 的 Wrapper 式特征选择算法 RF-SJS，在 UCI 标准数据集和糖尿病临床数据集上的实验结果表明，SJS 策略可以提供更灵活的特征搜索，选择出更优的特征子集，进一步提高分类器的分类精度。另外，在急性淋巴细胞白血病数据集上，本文对 RF-SJS 算法的性能进行了测试，同时考察了 KNN、RF 和 SVM 用作特征子集评价函数的性能，实验结果表明，RF-SJS 算法可以从高维小样本数据集中更好地选择出最优特征子集，提高分类器的分类精度；另外，作为特征子集评价函数，RF 算法和 SVM 算法的性能基本上相当，但是均优于 KNN 算法。

第5章 面向微阵列表达数据的 RF 特征选择算法研究

5.1 引言

生物信息学数据挖掘是医学数据挖掘的重要分支，随着生物学技术的快速发展，生物信息学数据挖掘成为了研究的热点。生物学数据的典型特征是“高维小样本”，其来源主要有两个，一是医学或生命科学研究人员通过生物医学实验从人类或其它生物中采集实验样本，经过传统测序或高通量测序技术获取的生物信息数据，这类数据的成本很高，代价昂贵；更为常见的来源是从生物信息数据库中获取的数据源，例如EBI、Genbank等，都是主流的生物信息学数据库。无论通过何种渠道获取数据，所得到的数据通常都是粗糙的、不完整的、含有噪声的。因此，使用生物学数据进行数据挖掘前需要对原始的数据进行预处理，通过数据清洗、过滤消除不合法数据和噪声数据。生物信息学数据通常以微阵列表达数据形式存储。微阵列表达数据是一个 $N \times (M+1)$ 的矩阵，矩阵中的每一行表示一个样本，除最后列外的每一列表示该样本一个基因，每一个元素 $g_{i,j}$ 是一个数值，表示第 i 个样本第 j 个基因的基因表达水平，最后一列表示第 i 个样本的类标签，如图5.1所示^[139]。

M genes				label	N Samples
$g_{1,1}$	$g_{1,2}$	...	$g_{1,M}$	c_1	
$g_{2,1}$	$g_{2,2}$	...	$g_{2,M}$	c_2	
...	...	...	...	...	
$g_{N,1}$	$g_{N,2}$	...	$g_{N,M}$	c_N	

图 5.1 微阵列基因表达数据示意图

Fig.5.1 The chart of micro-array expreesion datasets

本章针对微阵列表达数据的“高维小样本”特性，研究了基于随机森林的特征选择及分类方法，提出了组合 Filter 式特征选择和 Wrapper 式特征选择的方法框架；分析了 Wrapper 式特征选择算法中各种特征搜索策略的优缺点，结合序列前向特征搜索策略和序列后向搜索策略提出一种分层搜索策略，并对不同的分类器作为特征子集评价函数的性能进行了比较研究，在 5 个典型的微阵列表达数据集上进行了实验分析。

5.2 相关工作

生物信息学研究任务中的高维小样本数据对特征选择技术提出迫切需求。特征选择技术在原始数据的特征集合中选择一个特征子集, 该子集能够有效地描述原始数据的特性, 同时剔除噪声数据和不相关特征的影响, 提供良好的预测能力。通过特征选择, 大量冗余的、不相关的和噪声特征在训练分类器模型前被移除, 这有助于理解数据、降低计算开销、降低“维数灾难”的影响, 同时提高预测性能^[6]。近年来, 随着微阵列表达数据分析的需求, 特征选择技术已经成为生物信息分析的重要工具, 被应用于各种癌症分类、生物网络推导、表达相关性分析和疾病生物标记识别中等。尽管已经有很多面向生物信息学数据的特征选择算法, 然而除了文献[25, 49]之外, 很少有算法能够真正有效地剔除冗余基因和噪声基因。更重要的是, 微阵列表达数据中多个基因之间往往存在复杂的相互作用, 基因-基因之间的这种相互作用对疾病分类和基因选择具有重要的影响。然而, 当前流行的单变量特征选择方法并没有考虑到基因之间的这种相互作用。

SVM是最流行的分类算法之一, 被广泛应用于许多特征选择方法中, 例如SVM-RFE (Support Vector Machine-Recursive Feature Elimination, SVM-RFE) 和SVM-RCE。然而, 有研究表明, 当数据集包含大量冗余特征或高度相关特征的时候, SVM的分类精度将大大降低^[68]。作为最优秀的分类算法之一, 随机森林算法具有其他算法所不具有的得天独厚的优势。首先, 它能有效地识别多个特征之间的复杂相互作用。其次, 它是一种非参数化的、可理解的、高效的算法, 适合处理高维小样本数据和多种结构的数据。第三, 在众多的机器学习算法中, 它提供了独一无二的预测精度和模型可理解性的组合。近年来, 随机森林算法已经成为一种流行的工具被广泛应用于各种机器学习任务中, 尤其是在生物信息学研究中, 例如微阵列表达数据的样本分类, 利用变量重要性度量来识别疾病危险因素, 或者在全基因组关联研究中识别疾病关联基因。Diaz-Uriarte等人对基于RF的Filter算法进行了研究, 结果表明RF的分类精度可以和DLDA (Diagonal Linear Discriminant Analysis, DLDA), KNN和SVM算法相媲美, 所提出的方法能够产生非常小的基因子集同时保持模型的分类精度^[114]。Amaratunga等人提出一种称为“富随机森林” (Enriched Random Forest, ERF) 的方法, 采用加权随机采样和特征排序方法提高RF的分类性能, 在真实的基因表达数据集上进行了实验。然而在这些方法中, 选择出的基因的个数是被随意设置的^[101]。Pang等人基于随机生存森林 (Random Survival Forests, RSF) 的迭代消除特征的方法来识别预后基因, 这实际上是Diaz-Uriarte方法的一个扩展, 该方法根据变量重要性分数对特征变量进行排序, 每次剔除分数最低的20%的基因, 20%是

Diaz-Uriarte方法中的缺省值^[146]。Dessi等人提出一种基于随机森林的预过滤(pre-filtering)特征选择方法用于微阵列表达数据分类,他们从实验的角度对随机森林算法进行检验,研究了过滤过程对于随机森林算法分类性能的影响。然而,该方法最关键的一个问题就是用于对排序后的特征变量进行分割的阈值的设置^[147]。Ali Anaissi等人提出一种平衡迭代随机森林(Balanced Iterative Random Forest, BIRF)算法用于从不平衡的高通量基因表达微阵列数据集中发现与疾病最相关的基因,实验结果显示BIRF方法的性能超越了当前流行的许多算法,包括SVM-RFE, MSVM-RFE (Multi-class SVM-RFE)和朴素贝叶斯方法(Naive Bayes, NB),尤其是在不平衡数据集上^[60]。然而, BIRF算法的局限在于由于需要对数据集进行分解,无法产生全局相关的随机森林模型。

本章提出了一种新的组合Filter和Wrapper的特征选择算法,该算法在训练分类模型之前首先基于Filter方法过滤明显不相关的基因和噪声基因,然后在Wrapper特征选择过程中,在训练分类模型的同时搜索最优特征子集。本章还提出了一种新的分层特征搜索策略,它组合了广义序列后向搜索和广义序列前向搜索策略。另外,本章还研究了用作特征子集评价函数的不同分类算法的性能,包括RF、KNN、SVM和CART。

5.3 面向微阵列表达数据的RF特征选择算法

基因表达数据集通常包含成千上万个基因,大部分基因都是不相关的基因和噪声基因,为了更准确和更快速地从基因表达数据中识别出有意义的基因,我们提出了一种新的组合式特征选择方法。首先,我们根据基因表达水平分布采用四分间距(Inter-quartile Range, IQR)和因子分析(AVONA)来消除明显不相关的基因和部分噪声基因,然后通过一种新的基于随机森林和分层特征搜索策略的Wrapper式特征选择方法来消除冗余基因和选择相关基因子集。在Wrapper特征选择过程中,执行RF算法来计算每一个特征(基因)的变量重要性分数作为特征选择的准则,并使用多种分类算法作为评价特征子集质量的特征评价函数,包括RF, SVM, KNN和CART。Wrapper特征选择算法的输入为Filter特征选择(基因过滤)后的基因表达数据集合,在特征选择的过程中迭代地删除不重要的基因同时选择重要的基因。在每一次迭代中,所有的特征根据特征变量重要性分数被排序,并根据信息量采用等宽离散化方法进行分组。然后,在每一组上面分别采用GSBS特征搜索策略排除不相关的冗余的特征,同时采用GSFS特征搜索策略来选择最相关的特征。结果,产生两个特征子集,其中一个子集同时删除了最重要的和最不重要的特征,该集合接下来被用于下一轮特征选择,训练随机森林并计算变量重要性分数;另一个特

征子集删除了最不重要的特征但保留了最重要的特征，该集合被作为最优特征子集，训练分类器、在测试数据集上计算分类精度并作为评价最优特征子集的标准。最终，将得到具有最高分类精度的特征子集作为全局最有特征子集。该方法的整体框架如图5.2所示。




图5.2 面向微阵列表达数据的特征选择算法框架

Fig. 5.2 The framework of feature selection method for micro-array expression datasets

5.3.1 基因过滤

微阵列表达数据通常包含数以万计的基因，直接在这样的数据集上进行wrapper特征选择是非常耗时的，甚至在某些数据集上是难以实现的。为了降低计算时间开销和存储

空间需求,我们在进行Wrapper特征选择之前先对原始的数据集执行Filter特征选择,过滤掉大多数不相关的基因和噪声基因。首先,本文基于所有基因的表达水平分布使用四分位距方法来过滤掉明显不相关的基因,所有表达水平低于总体IQR 1/5的基因在这一步被过滤掉。接下来我们继续采用单因素方差分析(AVONA)进一步进行基因过滤。AVONA方法基于这样的假设:如果一个基因表达水平的分布在目标变量的所有可能值上类似,则可以确定这个基因对于区分这些目标变量值没有帮助。

5.3.2 分层特征搜索策略

由于微阵列表达数据集的“高维小样本”特性以及多个特征(基因)之间往往存在着复杂的相互作用,现有的特征搜索策略在微阵列表达数据分析中的效果都受到了限制。本章,我们提出一种新的组合了广义序列前向搜索和广义序列后向搜索的分层特征搜索策略(Stratify Searching, SS)。本文在特征选择过程中,对特征空间进行分组,然后在每一组上面分别进行特征选择。首先,在训练数据集上训练随机森林模型,计算训练集上每一个特征的变量重要性分数,并根据其变量重要性分数对所有特征进行排序;然后,采用等宽离散化方法将特征空间分为若干个组。接下来,在每一个分组上根据给定的参数采用GSBS删除最不重要的特征(具有最小的变量重要性分数),同时在整个特征空间中采用GSFS选择最重要的特征(具有最大的变量重要性分数)。

具体来说,给定一个数据集 $S = \{X = (X_1, X_2, \dots, X_n), Y\}$,其中 $X_1, X_2, \dots, X_n$ 是分类变量, Y 是目标变量。由随机森林算法计算得到的变量 X 的变量重要性分数表示为 $VIS = \{VIS_1, VIS_2, \dots, VIS_n\}$ 。采用最大最小正则化方法对 VIS 进行正则化,将 VIS_i ($i=1, 2, \dots, n$)的值映射到 $[0.0, 1.0]$ 范围之内,正交化的变量重要性分数表示为 $NVIS$ 。正交化公式如下所示: $NVIS_i = (VIS_i - \min(VIS)) / (\max(VIS) - \min(VIS))$ 。

在对特征的变量重要性分数进行正交化以后,采用等宽离散化算法将特征空间发分为若干个组,每一组所包含的特征的总信息含量是相同的。分组过程如下所示:

1. 根据 $NVIS$ 对特征空间内的所有特征按递减顺序排序;
2. 应用等宽离散化方法将 $NVIS$ 的取值范围 $[0.0, 1.0]$ 划分为 $gnum$ 个子域空间,其中每一个子域空间的信息量宽度为 $1/gnum$, $gnum$ 是分组的个数。
3. 按照下面的公式将特征空间 X 划分为 $gnum$ 个特征分组 $F_1, F_2, \dots, F_{gnum}$,

$$F_k = \{X_i : (gnum - k) / gnum \leq NVIS_i < (gnum - k + 1) / gnum\}, \quad \text{中}, k=1, 2, \dots, gnum,$$
 显然,有 $F_1 \cup F_2 \cup \dots \cup F_{gnum} = X$ 。

上面提出的分层特征搜索策略,可以快速地剔除不相关基因和冗余基因,在分组过程中需要一个参数向量 $rvec = \{n_1, n_2 \dots n_{gnum}\}$,它表示在每次迭代进行特征选择的过程中在每一个分组上面删除的特征的个数,即每次迭代采用GSBS方法在第1到第 $gnum$ 组上分别删除 n_1 到 n_{gnum} 个最不重要的特征,采用GSFS方法在整个特征空间上选择最重要的 n_{imp} 个特征。

5.3.3 特征子集评价函数

在用Wrapper方法对基因进行精选的过程中,使用当前最常使用的分类器CART、RF、KNN和SVM分类算法的分类准确率对特征子集的质量进行评价。SVM将原始的训练数据集映射到一个高维空间,然后在这个空间中搜寻一个最佳分割超平面用于对样本进行分类。近年来,SVM已经被广泛研究与应用,因为它能在大多数情况下找到目标函数的全局最优解,并且算法的时间复杂度不依赖于训练数据集的维数。本章,我们分别采用不同的分类模型作为特征子集评价函数,包括CART、RF、KNN和SVM,并且在多个微阵列表达数据集上比较它们的分类能力。

5.3.4 基于分层特征搜索策略的 RF 特征选择算法

本节总结所提出的基于分层特征搜索策略的Wrapper式特征选择算法,命名为Stratify-RF。Stratify-RF算法的执行流程如下:首先,在训练集上运行RF算法,计算每一个特征的变量重要性分数,根据变量重要性分数对所有特征进行排序。接下来,所有特征的变量重要性分数被正则化到 $[0.0, 1.0]$ 值域空间,采用等宽离散化方法将整个特征集合划分为若干个特征分组。接下来采用GSBS特征搜索策略从每一个特征分组中删除若干个最不重要的特征,同时采用GSFS特征搜索策略选择若干个最重要的特征,结果得到两个特征子集。其中一个特征子集删除了最重要的特征和最不重要的特征,该特征子集用于下一轮特征选择过程中计算变量重要性分数;另一个特征子集删除了最不重要的特征但保留了最重要的特征,该特征子集用于训练分类器并评价特征子集的分类能力。当特征子集的维数达到预先设定的阈值以后,调用第4章提出的基于随机森林的Wrapper式特征选择算法对特征进行精选。最后,具有最高的分类精度的特征子集被作为最优特征子集。为了保证算法的稳定性和可靠性,在训练随机森林和特征子集评价函数(分类器)时,采用10折交叉验证,10次变量重要性分数的平均值被用于特征排序,10次分类正确率的平均值被用于评价特征子集质量。算法的具体设计如算法5.1所示。

算法5.1: 基于RF和分层特征搜索策略的特征选择算法Stratify-RF

输入: 原始的训练数据集 S_{train} ; 特征分组个数 $gnum$; 每组每次删除特征的个数, 向量 $rvec$;

输出: 最高分类精度 $MaxAccuracy$; 最优特征子集 $SortedFeatureSet$; 最优特征子集中特征的变量重要性分数 $FeatureScore$;

步骤:

1. 初始化:

1.1 设置最大分类准确率的初值: $MaxAccuracy = 0$;

1.2 设置最优特征子集的初值: $SortedFeatureSet = Feature[S_{train}]$;

1.3 设置临时变量 $SforImportance = S_{train}$; // $SforImportance$ 表示删除了最重要和最不重要特征后的数据集合;

1.4 设置临时变量 $iteration = 0$; // $iteration$ 统计算法迭代次数

2. while ($SortedFeatureSet$ 中的特征个数 $\geq threshold$) // $threshold$ 为阈值
//当特征子集中的特征数大于阈值时, 采用分层搜索, 否则调用 RF-SJS 算法精选

2.1 采用分层采样将 $SforImportance$ 分为 10 等份: $SforImportance = S_1 \cup S_2 \dots \cup S_{10}$;

2.2 for (i 从 1 到 10)

2.2.1 在数据集($SforImportance - S_i$)训练随机森林分类器, 标记为 rf ;

2.2.2 计算 rf 生成的每个特征的变量重要性分数, 标记为 $rf\$score$;

2.3 end for;

2.4 计算 10 折交叉验证生成的变量重要性分数的平均值, 标记为
 $RFAverageScore[iteration]$;

2.5 根据 $RFAverageScore[iteration]$ 对特征降序排序, 结果标记为
 $SortedFeatureSet[iteration]$;

2.6 采用最大最小正交化方法对 $SortedFeatureSet[iteration]$ 中特征的变量重要性分数进行正则化;

2.7 采用等宽离散化方法将 $SortedFeatureSet[iteration]$ 中的特征按照变量重要性分数分成 $gnum$ 个分组: $SortedFeatureSet[iteration] = F1 \cup F2 \cup \dots \cup F_{gnum}$;

2.8 对于每一个分组, 根据参数 $rvec$ 剔除若干个最不重要的特征:

$$F_i = F_i - \{X_{worst}^1, X_{worst}^2, \dots, X_{worst}^{rvec[i]}\}; \quad // rvec = \{1, 2, \dots, gnum\} \text{ 表示在} \\ // \text{不同分组上剔除特征的个数}$$

- 2.9 剔除特征后的数据集标记为 $SforPrediction = F_1 \cup F_2 \cup \dots \cup F_{gnum}$;
// $SforPrediction$ 用于训练分类器以评价特征子集质量
- 2.10 从 $SforPrediction$ 中删除最重要的特征得到数据集 $SforImportance$;
// $SforImportance$ 用于下一轮训练 RF
- 2.11 采用分层采 $SforPrediction$ 划分为 10 等份: $SforImportance = S_1 \cup S_2 \dots \cup S_{10}$;
- 2.12 for (i 从 1 到 10)
 - 2.12.1 在数据集($SforImportance - S_i$)上训练 RF 分类器或其它分类器以评价特征子集质量;
 - 2.12.2 在数据集 S_i 上利用上一步生成的分类器对样本进行分类, 分类准确率标记为 $pre.accuracy$;
- 2.13 end for
- 2.14 计算 10 次迭代的平均分类准确率, 标记为 $AverageAccuracy[iteration]$;
- 2.15 重新设置 $SortedFeatureSet = SforImportance$;
- 2.16 $iteration++$;
3. end while;
4. if ($SortedFeatureSet$ 中的特征个数 $< threshold$)
 - 4.1 在 $SortedFeatureSet$ 数据集上调用 RF-SJS 算法精选特征; // 参见第 4 章
5. 计算所有迭代产生的特征子集上的最大平均分类准确率, 标记为:
 $MaxAccuracy = \max (AverageAccuracy [iteration]);$ // $iteration$ 表示所有迭代;
6. 具有最大分类准确率的特征子集记为最优特征子集 $SortedFeatureSet$;
7. 最优特征子集对应的变量重要性分数记为 $FeatureScore$;
8. 输出最大分类准确率 $MaxAccuracy$, 最优特征子集 $SortedFeatureSet$,
变量重要性分数 $FeatureScore$;
9. end.

在算法5.1中, 第1步是初始化操作; 第2步是特征粗选操作, 2.1-2.4步采用10折交叉验证计算随机森林变量重要性分数, 2.5步中根据变量重要性分数对特征进行排序, 2.6步中采用最大最小正交化方法对变量重要性分数进行正则化, 2.7步中采用等宽离散化方法对特征进行分组, 2.8-2.9步中在不同的分组上采用不同的参数剔除最不重要的特征, 得到新的数据集 $SforPrediction$, 用于训练分类器以评价特征子集的质量, 2.10步中在

*SforPrediction*基础上删除本轮最重要的特征得到新的特征集合*SforImportance*, 用于训练随机森林以进行下一轮特征选择; 2.11-2.14步中采用10折交叉验证在数据集*SforPrediction*上训练分类器并计算其分类准确率, 作为评价特征子集质量的准则; 2.15-2.16步为下一轮循环准备数据; 在第4步中, 当特征子集中的特征数目小于设定的阈值时, 调用第4章中的RF-SJS特征选择算法进行特征精选; 第5-7步中, 计算所有迭代中产生的特征子集中具有最大分类准确率的特征子集及其对应的变量重要性分数; 最后, 在第8步中输出结果。另外, 在算法5.1中, *threshold*是预先设置的参数, 表示进入特征精选过程时特征空间的维数, 在本文中, 其值设置为50。

5.3.5 算法的时间复杂度分析

在 Stratify-RF 算法中, RF 算法采用 CART 作为基分类器。假设原始的训练样本集合中特征维数为 n , 样本的数量为 m , 则 CART 算法的时间复杂度为 $O(nm(\log m)^2)$ 。假设森林中 CART 树的个数为 k , 则 RF 算法的时间复杂度近似为 $O(knm(\log m)^2)$ 。在特征选择过程中, 如果特征分组的个数 $gnum$ 被设置为 $\sqrt[3]{n}$, 每一次迭代过程中每个分组删除特征数目 $rvec$ 被设置为 $(1, 2, \dots, \lceil \sqrt[3]{n} \rceil)$, 则迭代进行特征选择的次数可以按下面的公式计算:

$$t = \frac{n}{1/2(1 + \lceil \sqrt[3]{n} \rceil) * \lceil \sqrt[3]{n} \rceil} \leq \frac{2n}{2^{1/3}\sqrt[3]{n}} = 2\sqrt[3]{n} \quad (5-1)$$

每次迭代中, 采用快速排序方法对特征进行排序, 其平均时间复杂度为 $O(n \log n)$, 进行特征分组和构建新数据集的时间为常数; 另外, 以采用 RF 分类器作为特征子集评价函数为例, 在训练随机森林和特征子集评价函数分类器的过程中均采用 10-折交叉验证。因此, RF-RFE 算法总的时间复杂度可以用下面的公式进行计算:

$$O\left(2n^{1/3} * \left(10 * O(knm(\log m)^2) + O(n \log n) + O(knm(\log m)^2)\right)\right) \approx O\left(kn^{4/3}m(\log m)^2\right) \quad (5-2)$$

从公式 5-2 可以看到, Stratify-RF 算法的时间复杂度与数据集中的特征个数近似成正比, 而微阵列表达数据集中的样本个数通常较小, 所以算法总体的计算时间是可接受的, 适合于处理微阵列表达数据分析问题。

5.4 实验分析

本节在 5 个微阵列表达数据集上对 Stratify-RF 方法与 Multi-stage^[25]、SVM-RFE^[39]、SVM-RCE^[41]、GA-KNN^[148]、mRMR^[149]、Ensemble^[150]等 6 个特征选择方法的性能进行比较。Multi-stage 方法是一种面向微阵列表达数据分析的特征选择方法,该方法考虑了原始数据集中所有类型的基因病在算法的不同阶段分别剔除不相关的基因、噪声基因和冗余基因,最终选择出相关基因子集。Multi-stage 方法首先通过 Filter 方法过滤掉明显不相关的基因,然后通过 SVC-KM (Support Vector Cluster and K-mean Cluster) 聚类剔除噪声基因和冗余基因,最后通过 SVM-RFE 方法选择最终的相关(信息)基因子集。SVM-RFE 是一种基于递归消除特征的特征选择方法,实际上是基于广义序列后向搜索策略和 SVM 分类器评价特征子集的一种 Wrapper 式特征选择算法。SVM-RCE 是一种基于递归聚类消除的特征选择方法,首先对于特征子集进行聚类,然后在每一个聚类上面利用序列搜索策略进行特征选择,以 SVM 分类器评价特征子集的质量。GA-KNN 方法组合了遗传算法和 K 近邻算法进行基因识别,以 GA 算法为搜索工具,以 KNN 算法作为特征子集评价函数,选择在多个特征子集中出现频率最高的特征构成最优特征子集。mRMR (Minimum Redundanc - Maximum Relevance) 一种基于最小冗余度最大相关性的特征选择方法,通过最大化分类特征与目标特征之间的相关性来实现特征子集中特征之间的最小冗余,可以降低 Filter 特征选择中特征之间的冗余度。Ensemble 方法是 ArrayMining.net 提供的一种基因选择方法,它集成了经验贝叶斯 t-统计、微阵列统计分析、基于相关性的特征选择、基于随机森林的排序方法和偏最小二乘过滤等特征选择方法,通过计算每种方法基因排序的累加和得到最终的基因排序结果。Stratify-RF 方法是本文提出的基于分层特征选择策略的基因选择方法,在 Stratify-RF 方法中,参数 gnum 和 revc 分别设置为 10 和 (1, 2, 3, 4, 5, 6, 7, 8, 9, 10)。本节还对所提出的分层特征选择策略与序列后向搜索策略 SBS 和序列前向搜索策略 SFS 进行了比较,以及对作为特征子集评价函数的 SVM、RF、KNN 和 CART 的性能进行了比较研究。所有算法都采用 R 语言实现并在 R3.0.2 软件上执行,使用的计算环境配置为: Intel Core (TM) 2 Duo CPU E4600 处理器、4G 内存。

5.4.1 实验数据集

本章采用文献[25]中的五个微阵列表达数据集来对算法进行验证,这些数据集的原始信息如表 5.1 所示。

表 5.1 实验用到的原始数据集特征

Table 5.1 Description of the original datasets

Dataset	Genes	Samples(+/-)	Classes
Leukaemia	7129	72(47/25)	ALL/AML
Prostate	12600	102(52/50)	tumour/normal
Breast	24481	97(46/51)	relapse/non-relapse
Nervous	7129	60(21/39)	survivors/failures
DLBCL	6817	58(32/26)	cured/fatal

其中：

Leukemia 数据集是由Golub等人在1999年提供的，它包含47个急性淋巴细胞白血病（ALL）和25个急性髓细胞性白血病（AML）患者的7129个基因的表达水平。这个数据集的原始数据可通过下面的网址获得：

<http://www.genome.wi.mit.edu/cgi-bin/cancer/datasets.cgi>.

Prostate 数据集是由Singh等人在2002年提供的，它包含136个样本的12600个基因的表达水平，其中包括77个前列腺肿瘤样本（tumour）和59个正常样本（normal）。这个数据集的原始数据可通过下面的网址获得：

<http://www-genome.wi.mit.edu/cgi-bin/cancer/datasets.cgi>.

Breast 数据集是由Laura J. van't Veer 等人在2002年提供的，用于乳腺癌病人的结果预测。它包含97个乳腺癌患者的样本数据，其中46个患者在5年内发生了癌细胞转移（relapse），51个患者在诊断为乳腺癌至少5年后仍然保持健康（non-relapse），每个样本中包含24481个基因表达数据。这个数据集的原始数据可以通过下面的网址获得：

<http://www.rii.com/publications/2002/vantveer.htm>

Nervous 数据集是由Scott L. Pomeroy等人在2002年提供的，用于中枢神经系统的胚胎性肿瘤的结果预测。它包含60个患者的样本数据，其中21个数据来自于接受治疗后存活的患者（survivors），39个患者因病死亡，每个患者的检测数据包含7129个基因的表达数值。Nervous 数据集可以通过以下链接进行下载：

<http://www-genome.wi.mit.edu/mpr/CNS/>

DLBCL 数据集是由Cortez等人在2007年提供的，用于研究弥漫性大B细胞淋巴瘤（DLBCL）的不同类型的，它包含58个样本的6817个基因的表达数据，其中包括32个治愈患者的数据（cured）和26个致命患者的数据（fatal）。这个数据集的原始数据可以通过下面的网址获得：<http://www.broadinstitute.org/cgi-bin/cancer/datasets.cgi>.

5.4.2 参数设置讨论

在所提出的 Stratify-RF 特征选择方法中，有两个重要的参数：*gnum* 和 *rvec*，前者表示特征选择过程中对特征进行分组的数量，后者表示每一个分组上在一次迭代特征选择过程中删除的特征的个数。这两个参数的大小依赖于数据集的特征维度。数据集的维度越高，里面包含的不相关特征和冗余特征就越多，为了更快更合理地进行特征选择，特征分组的个数可以大一些。作为一个特例，如果只有一个分组，所提出的方法就演变成序列后向选则。通常，*gnum* 的值可以被设置为 $\sqrt[3]{N}$ ，其中 *N* 是微阵列表达数据集中基因的个数。本文中，基因过滤后数据集的维度在 1000~3000 之间，因此 *gnum* 被设置为 10，即在特征选择过程中，将特征空间分为 10 个组。不难理解，分组越多，特征选择所需要的时间越少。因为如果分组数目较大，一次特征选择过程中删除的特征数目就较多，算法的执行速度就较快。根据实验测试，我们将参数 *rvec* 设置为 (1, 2, 3, 4, 5, 6, 7, 8, 9, 10)，能够在保持特征之间重要关系的同时有效地剔除冗余特征和不相关特征。

5.4.3 基因过滤结果

经过基因过滤前后，五个数据集中的基因个数对比如表5.2所示。从表5.2可以看出，经过Filter特征选择之后，数据集中的特征数目减少了约80%-90%，大量的噪声基因和不相关基因被滤除，为后续的Wrapper特征选择减轻了负担。

表 5.2 经过基因过滤后的数据集特征

Table 5.2 Description of the datasets after gene filtering

Dataset	Original Genes (OG)	Selected Genes (SG)	SG/OG
Leukaemia	7129	1185	16.62%
Prostate	12600	2797	22.20%
Breast	24481	2299	9.39%
Nervous	7129	1576	24.63%
DLBCL	6817	1036	15.20%

5.4.4 特征选择算法的性能比较

此处，本小节先用 SVM 作为特征子集评价函数，具有最高的 SVM 分类正确率的特征子集被认为是最优特征子集。在五个微阵列表达数据集上各种特征选择算法的实验结果如表 5.3 所示。

表 5.3 不同特征选择算法的分类性能

Table 5. 3 The accuracies of different feature selection methods

Methods	Leukaemia	Prostate	Breast	Nervous	DLBCL
SVM-RFE	93.89	82.65	56.99	68.58	69.80
GA-KNN	89.03	89.53	66.46	85.86	81.25
mRMR	94.91	81.72	62.41	83.42	83.22
SVM-RCE	93.13	86.80	67.13	84.00	85.43
Ensemble	93.61	90.75	69.19	83.67	86.35
Multi-stage	97.59	93.45	82.84	93.17	88.74
Stratify-RF	100	95.24	85	91.67	91.67

从表 5.3 可以看出，在 Leukaemia、Prostate、Breast 和 DLBCL 数据集上，Stratify-RF 方法的平均分类正确率高于 SVM-RFE、GA-KNN、mRMR、SVM-RCE、Ensemble 和 Multi-stage 方法。对于 Nervous 数据集，Stratify-RF 算法的分类准确率略低于 Multi-stage 方法，但高于其他的方法，这说明所提出的特征选择方法具有良好的分类性能。

5.4.5 分层特征搜索策略的性能分析

为了进一步地检验所提出的方法的性能，我们对所提出的分层特征搜索策略与序列后向搜索策略 SBS 和序列前向搜索策略的分类能力和执行时间进行了比较。在所有方法的实现中，采用 RF 变量重要性度量作为评价特征重要性的指标，采用 SVM 分类算法训练分类器来评价特征子集的质量。各种特征搜索策略的分类正确率如表 5.4 所示。其中，分类准确率为 10 次实验结果的平均值，在每一次实验中，原始数据被随机划分为 80% 的训练集和 20% 的测试集。

表 5.4 不同特征搜索策略的分类正确率

Table 5.4 The accuracies of the different feature searching strategies

Methods	Leukaemia	Prostate	Breast	Nervous	DLBCL
SBS	98.75	94.76	81.70	85.29	87.64
SFS	98.82	96.28	84.25	81.72	89.29
Stratify-SVM	100	95.24	85	91.67	91.67

从表 5.4 可以看出，在 Leukaemia、Breast、Nervous 和 DLBCL 数据集上，采用所提出的分层特征搜索策略，SVM 的分类性能明显高于 SBS 和 SFS，但在 Prostate 数据集上，其分类正确率略低于 SFS。

为了更深入地比较 SBS、SFS 和 Stratify 三种特征搜索策略的性能，本文对各种方法的执行过程进行了统计。在五个数据集上，SBS、SFS、Stratify-SVM 方法的特征选择过程分别如图 5.3-5.7 所示，其中 SBS 和 SFS 策略的特征子集评价函数也是 SVM 分类器。




图 5.3 在 Leukemia 数据集上 SBS、SFS 和 Stratify 算法分类性能比较

Fig. 5.3 The classification accracy of SBS, SFS and Stratify algorithm on Leukemia dataset




图 5.4 在 Prostate 数据集上 SBS、SFS 和 Prostate 算法分类性能比较

Fig. 5.4 The classification accracy of SBS, SFS and Stratify algorithm on Prostate dataset




图 5.5 在 Breast 数据集上 SBS、SFS 和 Stratify 算法分类性能比较

Fig. 5.5 The classification accracy of SBS, SFS and Stratify algorithm on Breast dataset




图 5.6 在 Nervous 数据集上 SBS、SFS 和 Stratify 算法分类性能比较

Fig. 5.6 The classification accuracy of SBS, SFS and Stratify algorithm on Nervous dataset




图 5.7 在 DLBCL 数据集上 SBS、SFS 和 Stratify 算法分类性能比较

Fig. 5.7 The classification accuracy of SBS, SFS and Stratify algorithm on DLBCL dataset

从图 5.3 可以看出, 本文提出的 Stratify-SVM 算法在 Leukemia 数据集上的分类性能呈现出先升后降然后再升到趋于稳定, 表明随着冗余基因和不相关基因的删除, 分类器的性能得到了提高, 当特征子集中的基因数目下降到一定数量 (小于 50) 之后, 系统性

能明显下降。这一结果与基于 SFS 和 SBS 的算法的结果是一致的。从图中还可以看到，基于分层剔除冗余特征策略的算法的分类正确率高于基于 SFS 和 SBS 的算法。从图 5.4、5.6、5.7 可以看出这一趋势更加明显，表明本文所提出的分层特征搜索策略是有效的，算法的分类性能优于基于 SBS 和 SFS 的方法。另外，从图 5.5 可以看出，在 Breast 数据集上，虽然 Stratify-SVM 的最高分类正确率高于基于 SBS 和 SFS 的算法（当特征个数为 40 时），但是在其他大小的特征子集上，Stratify-SVM 的最高分类正确率低于基于 SBS 和 SFS 的算法，这可能是因为 Breast 数据集中各个基因的信息分布不均衡，分层剔除带来了部分信息损失，关于数据集中基因信息的分布情况需要进一步研究。

与 SBS 和 SFS 算法相比，本文所提出的分层剔除不相关特征和冗余特征的特征搜索策略的一大优势是算法的执行速度较快。在 5 个实验数据集上，基于三种特征搜索策略的特征选择算法执行时间如表 5.5 和图 5.8 所示。

表 5.5 不同特征搜索策略的执行时间比较

Table 5.5 The time for different feature searching strategies

Methods	Leukaemia(s)	Prostate (s)	Breast (s)	Nervous (s)	DLBCL (s)
SBS	1650.70	24182.67	7998.17	2171.38	436.07
SFS	707.34	33261.62	13458.72	4604.39	1001.46
Stratify-SVM	125.77	3643.77	1928.2	387.94	73.89




图 5.8 SBS、SFS 和 Stratify 算法的执行时间比较

Fig. 5.8 The comparison of time consumed by SBS, SFS and Stratify algorithm

从表 5.5 和图 5.8 可以看出,采用分层特征搜索策略,特征选择过程所需要的计算时间显著低于 SBS 和 SFS。具体来说,Stratify 方法的执行速度比 SBS 快 4-13 倍,比 SFS 方法快 6-12 倍。综合考虑上面的分析,本文所提出的基于分层的特征特征搜索策略对分类器的分类性能有了较大的提高的同时降低了计算时间开销。

5.4.6 特征子集评价算法研究

本节研究不同分类器作为特征子集评价函数的分类性能。在所提出的特征选择算法中,分别应用 C4.5、RF、KNN 和 SVM 分类算法作为特征子集评价函数,在五个微阵列表达数据集上进行实验,比较不同分类器的分类性能。四种分类算法在五个实验数据集上的平均分类正确率如表 5.6 所示,特征选择过程如图 5.9-5.13 所示。

表 5.6 不同特征子集评价算法的分类性能

Table 5.6 The performance of the different feature subset evaluation methods

Methods	Leukaemia	Prostate	Breast	Nervous	DLBCL
C4.5	86.67	90.48	65	75	75
KNN	93.33	95.24	75	58.33	91.67
RF	100	71.43	75	66.67	83.33
SVM	100	95.24	85	91.67	91.67




图 5.9 在 Leukemia 数据集上四种分类器分类性能比较

Fig. 5.9 The performance comparison of four classifiers on Leukemia dataset




图 5.10 在 Prostate 数据集上四种分类器分类性能比较

Fig. 5.10 The performance comparison of four classifiers on Prostate dataset




图 5.11 在 Breast 数据集上四种分类器分类性能比较

Fig. 5.11 The performance comparison of four classifiers on Breast dataset




图 5.12 在 Nervous 数据集上四种分类器分类性能比较

Fig. 5.12 The performance comparison of four classifiers on Nervous dataset




图 5.13 在 DLBCL 数据集上四种分类器分类性能比较

Fig. 5.13 The performance comparison of four classifiers on DLBCL dataset

从表 5.6 可以看出, 当用作特征子集评价函数时, SVM 分类算法在大多数数据集上表现出最高的分类正确率。RF 的分类性能比 SVM 较低, 但是差别不大。而 C4.5 的分类正确率明显低于 RF 和 SVM。令人意外的是, 在 Prostate 数据集上, C4.5 的分类性能优于 RF, 这可能是因为 C4.5 算法更适合于该特定数据集。

从图 5.9 到图 5.13 可以看出, 在 Leukemia 数据集(图 5.9)和 Breast 数据集(图 5.11)上, RF 作为特征子集评价函数与 SVM 作为特征子集评价函数, 二者之间分类性能大致相当。而在其他三个数据集上, 采用 SVM 作为特征子集评价函数, 算法的分类性能明显优于 C4.5、KNN 和 RF 算法。另外, 通过图 5.10、5.12 和 5.13 可以看出, 基于 SVM 分类器的算法的稳定性明显优于 C4.5、KNN 和 RF 算法。另外, 一个有意思的结果是, 从图 5.10 还可以看出, 在 Prostate 数据集上, C4.5 算法作为特征子集评价函数, 表现出了仅次于 SVM 的性能, 在特征子集中的基因数目较少时, 其分类正确率甚至高于 SVM; 而在其它四个数据集上, C4.5 算法的分类性能是最差的。这让人很自然的想到, C4.5 算法可能更适合于 Prostate 数据集。更进一步的研究将针对更多分类算法在更多数据集上进行实验分析。

5.5 本章小结

面向微阵列表达数据分析, 本文提出了一种新的基于随机森林的组合式特征选择方法, 算法组合了 Filter 式特征选择和 Wrapper 式特征选择, 组合序列前向特征搜索策略和序列后向搜索策略, 提出了一种分层搜索特征子集的新型特征搜索策略, 该方法可以更加灵活有效地剔除不相关基因和冗余基因。在 5 个微阵列表达数据集上的实验结果表明, 所提出的算法无论是在提高分类器的分类性能还是降低算法执行时间方面都具有较好的效果。本章还研究了 C4.5、RF、KNN 和 SVM 算法分别作为特征子集评价函数的性能, 实验结果显示 SVM 分类器更加适合用作所提出算法的特征子集评价函数。

尽管所提出的算法表现出了很好的性能, 但仍然需要进一步的研究, 比如在更多数据集上对算法的性能进行验证。另外, 相关参数的设置问题, 比如 *gnum* 和 *rvec*, 值得进一步研究。

结 论

医学数据挖掘是机器学习和数据挖掘的重要研究方向,对于探索疾病发病规律、疾病危险因素及寻找治疗方案具有重要的研究价值。目前医学数据挖掘正逐渐从临床医学数据挖掘发展到生物信息学数据挖掘,医学数据固有的高维特征空间、高度特征冗余、样本类别不平衡等特点以及对数据挖掘结果可理解性的要求,使传统的数据挖掘算法在分类性能和分类时间上都面临着巨大挑战。本文主要研究了面向类别不平衡数据分类的随机森林算法、基于随机森林的 Filter 式特征选择方法、基于随机森林的 Wrapper 式特征选择方法、基于随机森林的 Filter 和 Wrapper 相结合的特征选择方法,重点研究了特征选择过程中最重要的两个要素:特征搜索策略和特征子集评价函数。针对医学数据特点分别提出了序列前向搜索和序列后向搜索相结合的联合特征搜索策略和分层特征搜索策略。具体来说,本文的研究工作取得了如下创新性成果:

(1) 提出了一种面向类别不平衡数据分类的随机森林改进算法,解决了随机森林算法在类别不平衡数据集上查全率低的问题。

针对医学数据集存在的样本类别不平衡问题,提出了一种基于有放回随机重采样和集成机器学习思想的随机森林改进算法,通过有放回地随机重采样构建多个类别平衡的数据集,在每个数据集上分别训练随机森林分类模型,多个分类模型通过多数投票决定未决样本的类别。有放回地随机重采样可以增强“森林”中基分类器的多样性,平衡的训练数据集可以保证基分类器的分类强度,基分类器的集成可以补偿随机采样带来的信息损失及“过拟合”等问题。实验结果表明,本文所提出的方法在分类精度尤其是查全率上优于传统的方法。

(2) 提出了一种基于随机森林变量重要性分数的 Filter 式特征选择算法,能够快速排除不相关特征和噪声特征的同时有效识别主相关特征。

针对医学数据集存在的高维特征空间和特征间高度相关问题,提出了一种基于随机森林变量重要性分数的 Filter 式特征选择算法。该算法首先利用随机森林变量重要性分数对数据集中的全体特征排序,然后迭代选取打分最高的前 Top 个特征构成特征子集训练分类器。由于随机森林变量重要性分数在考虑单个特征对于目标变量的影响的同时考虑了多个特征之间的相互作用,更适用于评价医学数据集中各个特征之间的相关性。实验结果表明,本文所提出的方法能够在快速排除不相关特征和噪声特征的同时有效地识别主相关特征。

(3) 提出了一种基于随机森林的 Wrapper 式特征选择算法, 解决了传统算法没有充分考虑特征之间高度相关和高度冗余而导致特征子集容易陷入局部最优的问题。

针对传统的 Filter 方法没有充分考虑特征之间的冗余和 Wrapper 方法没有充分考虑特征之间的相关性的问题, 提出了一种基于随机森林变量重要性分数的 Wrapper 式特征选择和数据分类方法, 结合序列前向搜索策略和序列后向搜索策略提出了一种新的联合特征搜索策略, 充分考虑了特征之间的相关性, 在剔除冗余特征和不相关特征的同时可以有效地选择与目标变量密切相关的关键特征。实验结果表明, 基于随机森林变量重要性分数和联合特征搜索策略的方法能够提高特征子集的质量和分类模型的精度。

(4) 提出了一种基于 Filter 与 Wrapper 相结合的随机森林特征选择算法, 解决了微阵列表达数据分析中分类精度低的问题。

针对微阵列表达数据集中存在大量噪声特征、冗余特征和不相关特征导致分类器性能下降的问题, 提出了一种新的基于 Filter 和 Wrapper 相结合的随机森林特征选择方法, 结合广义序列后向搜索和序列前向搜索策略提出了一种新的分层剔除和选择特征的特征搜索策略, 充分考虑了特征之间的相关性, 可以快速剔除不相关特征和冗余特征。实验结果表明, 本文所提出的方法能够有效地提高模型的分类准确率。

本文提出的 BRF、RF&MARS、RF-SBS、RF-SJS 和 Stratify-RF 等基于随机森林的特征选择和分类算法可以有效地提高分类器的性能并简化分类模型。然而, 本文在以下方面仍存在一些问题尚未解决:

(1) 如何更加合理地选择和设置分层特征搜索过程中的相关参数: 本文仅仅根据实验研究提出了相关参数的经验值, 然而对于这些参数设置的合理性需要更多的实验进行验证, 也需要从理论上对相关方法进行深入的研究。

(2) 如何更加有效地融入医学专家的经验从而进一步地提高特征选择和分类算法的性能, 如何直观地将医学数据挖掘的结果展现给医学专家进而在医学临床中加以应用? 都需要进一步的研究。

另外, 本文所提出的方法还只是在有限数据集上进行的实验研究, 方法的有效性需要在更多数据集上和医学临床实践中加以验证。

参考文献

- [1] Ian H. Witten, Eibe Frank 著. 董琳等译. 数据挖掘: 实用机器学习技术. 机械工业出版社, 2007: 4-5 页, 110-118 页
- [2] 祁云嵩. 微阵列表达数据分析中的基因选择及样本分类方法研究. 南京理工大学博士学位论文. 2011: 7-8 页
- [3] Mark Burton, Mads Thomassen, Qihua Tan, et al. Gene Expression Profiles for Predicting Metastasis in Breast Cancer: A Cross-Study Comparison of Classification Methods. *The Scientific World Journal*, 2012: 1-11P
- [4] Alireza Mehridehnavi, Lia Ziaei. Minimal gene selection for classification and diagnosis prediction based on gene expression profile. *Advanced Biomedical Research*, 2013, 5: 1-11P
- [5] 王文俊. 基因表达数据的相似性度量和特征提取研究. 西安电子科技大学博士学位论文. 2011: 2 页
- [6] Girish Chandrasheka, Ferat Sahin. A survey on feature selection methods, *Computers and Electrical Engineering*, 2014, 40: 16-28P
- [7] Dayle Sampson, Tony J. Parker, Zee Upton, Cameron P. Hurst. A comparison of methods for classifying clinical samples based on proteomics data: a case study for statistical and machine learning approaches. *PLoS one*, 2011, 6(9): 1-11P
- [8] 廖志芳. 大肠早癌辅助诊断数据挖掘方法研究. 中南大学博士学位论文. 2008: 2 页, 10-11 页
- [9] Jinho Park, Witold Pedrycz, Moongu Jeon. Ischemia Episode Detection in ECG using Kernel Density Estimation, Support Vector Machine and Feature Selection. *BioMedical Engineering OnLine*, 2012: 1-17P
- [10] João Maroco, Dina Silva, Ana Rodrigues, et al. Data mining methods in the prediction of Dementia: A real-data comparison of the accuracy, sensitivity and specificity of linear discriminant analysis, logistic regression, neural networks, support vector machines, classification trees and random forests. *BMC Research Notes* 2011 4: 1-14P
- [11] Baek Hwan Cho, Hwanjo Yu, Kwang-Won Kim, et al. Application of irregular and unbalanced data to predict diabetic nephropathy using visualization and feature selection methods. *Artificial Intelligence in Medicine*, 2008, 42: 37-53P
- [12] Massoud Toussi, Jean-Baptiste Lamy, Philippe Le Toumelin, et. Using data mining techniques to explore physicians' therapeutic decisions when clinical guidelines do not

- provide recommendations: methods and example for type 2 diabetes. BMC Medical Informatics and Decision Making, 2009, 6: 1471-2288P
- [13] John H Warner, Qiwei Liang, Mohamadi Sarkar, et al. Adaptive regression modeling of biomarkers of potential harm in a population of U.S. adult cigarette smokers and nonsmokers. BMC Medical Research Methodology, 2010: 3-5P
- [14] Hongbo Liu, Zhifeng Tang, Yongli Yang, Dong Weng, et. Identification and classification of high risk groups for Coal Workers' Pneumoconiosis using an artificial neural network based on occupational histories: a retrospective cohort study. BMC Public Health, 2009, 09: 1-8P
- [15] 王刚, 刘元宁, 陈慧灵, 董浩, 朱晓冬. 粗糙集与支持向量机在肝炎诊断中的应用. 吉林大学学报(工学版), 2011, 41(1): 160-164
- [16] David M. Reif, Alison A. Motsinger, Brett A. McKinney, et al. Feature Selection using a Random Forests Classifier for the Integrated Analysis of Multiple Data Types. CIBCB, 2006:1-8P
- [17] Jiarui Ding, Ali Bashashati, Andrew Roth, et al. Feature-based classifiers for somatic mutation detection in tumor normal paired sequencing data. BIOINFORMATICS, 2012, 2(28):167-175P
- [18] Natalia Briones, Valentin Dinu. Data mining of high density genomic variant data for prediction of Alzheimer's disease risk. BMC Medical Genetics, 2012, 13:7P
- [19] Lee J W, Lee J B, Park M, et al. An extensive comparison of recent classification tools applied to microarray data[J]. Computational Statistics & Data Analysis, 2005, 48(4):869-885.
- [20] Diaz-Uriarte R, Andres S A D. Variable selection from random forests: application to gene expression data[C]// Spanish Bioinformatics Conference. 2005.
- [21] Hyo-Jeong Ban, Jee Yeon Heo, Kyung-Soo Oh, Keun-Joon Park. Identification of Type 2 Diabetes-associated combination of SNPs using Support Vector Machine. BMC Genetics, 2010, 11:26
- [22] Liu Y, Li B, Tan R, Zhu X, Wang Y. A gradient-boosting approach for filtering de novo mutations in parent-offspring trios. Bioinformatics, 2014, 30(13): 1830-6P
- [23] Xu Y, Guo M, Liu X, Wang C, Liu Y. Inferring the soybean (Glycine max) microRNA functional network based on target gene network. Bioinformatics, 2014, 30(1): 94-103P
- [24] Qingyao Wu, Yunming Ye, Yang Liu, Michael K. Ng. SNP Selection and classification of Genome-Wide SNP Data Using Stratified Sampling Random Forests. IEEE TRANSACTIONS ON NANOBIOSCIENCE, 2012, 11(3): 216-227P

- [25] Du, W., Sun, Y., Wang, Y., Cao, Z., Zhang, C. and Liang, Y. A novel multi-stage feature selection method for microarray expression data analysis. *Int. J. Data Mining and Bioinformatics*, 2013, 7(1): 58–77P
- [26] Zhongbo C, Yan W, Ying S, Wei D, Yanchun L. A novel filter feature selection method for paired microarray expression data analysis. *Int. J. of Data Mining and Bioinformatics*, 2015, 12(4): 363 - 386P
- [27] Jianxin Wang, Min Li, Jianer Chen, Yi Pan. A Fast Hierarchical Clustering Algorithm for Functional Modules Discovery in Protein Interaction Networks. *IEEE/ACM Transactions on Computational Biology and Bioinformatics*, 2010, 08
- [28] Jianxin Wang, Binbin Liu, Min Li, Yi Pan. Identifying protein complexes from interaction networks based on clique percolation and distance restriction. *BMC Genomics*, 2010, 11: 1-11P
- [29] 蒋胜利. 高维数据的特征选择与特征提取研究. 西安电子科技大学博士学位论文, 2011: 6-11 页
- [30] Narendra P M, Fukunaga K. A Branch and Bound Algorithm for Feature Subset Selection. *IEEE Trans. on Computer*, 1977, 26(9):917-922P
- [31] Tsymbal A, Puuronen S. Ensemble feature selection with the simple bayesian classification. *Information Fusion*, 2010, 4(2): 87-100P
- [32] Pudil P, Novovicova, et al. Floating Search Methods for Feature Selection. *Pattern Recognition Letters*, 1994, 15(11):1119-1125P
- [33] 王玲, 刘善军, 陈兵林, 姬长英. 混合过滤器和封装器启发式判别籽棉成熟度. *计算机研究与发展*, 2013, 50 (2): 269-277
- [34] Inza I, Larranaga P, Blanco R. Filter versus wrapper gene selection approaches in DNA microarray domains. *Artificial Intelligence in Medicine*, 2004, 31(2): 91-103P
- [35] JIANG Sheng-yi, ZHENG Qi, ZHANG Qian-sheng. Clustering-based feature selection. *ACTA ELECTRONICA SINICA*, 2008, 36(12):157-160P
- [36] 谢娟英, 谢维信. 基于特征子集区分度与支持向量机的特征选择算法. *计算机学报*, 2014, 37 (8): 1704-1718 页
- [37] 段洁, 胡清华, 张灵均, 等. 基于邻域粗糙集的多标记分类特征选择算法. *计算机研究与发展*. 2015, 52 (1): 56-65 页
- [38] 史彩娟, 阮秋琦. 基于增强稀疏性特征选择的网络图像标注. *软件学报*, 2015, 26 (7): 1800-1811 页
- [39] Guyon, I., Weston, J., Barnhill, S. and Vapnik, V. Gene selection for cancer

- p>classification using support vector machines,
- Machine Learning*
- , 2002, 46: 389-422P
- [40] Furlanello, C., Serafini, M., Merler, S. and Jurman, G. Entropy-based gene ranking without selection bias for the predictive classification of microarray data. *BMC Bioinformatics*, 2003, 4: 54P
 - [41] Yousef, M., Jung, S., Showe, L.C. and Showe, M.K. Recursive cluster elimination (RCE) for classification and feature selection from gene expression data. *BMC Bioinformatics*, 2007, 8: 144P
 - [42] Niijima, S. and Okuno, Y. Laplacian linear discriminant analysis approach to unsupervised feature selection. *IEEE Transactions on Computational Biology and Bioinformatics*, 2009, 6: 605–614P
 - [43] 刘峤, 王娟, 陈伟, 秦志光. 基于随机复杂度约束的高维特征自动选择算法. *电子学报*, 2011, 39 (2): 370-374 页
 - [44] 钱宇华, 梁吉业, 王锋. 面向非完备决策表的正向近似特征选择加速算法. *计算机学报*, 2011, 34 (3): 435-442 页
 - [45] 陈铁明, 马继霞, Samuel H. Huang, 蔡家楣. 一种新的快速特征选择和数据分类方法. *计算机研究与发展*, 2012, 49 (4): 735-745 页
 - [46] 刘赫, 张相洪, 刘大有等. 一种基于最大边缘相关的特征选择方法. *计算机研究与发展*, 2012, 49 (2): 354-360 页
 - [47] Peng, Y.X., Li, W.Y. and Liu, Y.. A hybrid approach for biomarker discovery from microarray gene expression data for cancer classification. *Cancer Informatics*, 2006, 2: 301-311P
 - [48] Jose, B. and Draper, B.A. Feature selection from huge feature sets. *Eighth International Conference on Computer Vision*, Vancouver, BC, Canada, 2001: 159-165P
 - [49] Tang, Y.C., Zhang, Y.Q. and Huang, Z. Development of two-stage SVM-RFE gene selection strategy for microarray expression data analysis, *IEEE Transactions on Computational Biology and Bioinformatics*, 2007, 4: 365-381P
 - [50] 黄东山. 特征选择及半监督分类方法研究. 华中科技大学博士学位论文, 2011, 05: 3-10 页
 - [51] 杨昱, 冯翔, 虞慧群. 基于多群体公平模型的特征选择算法. *计算机研究与发展*, 2015, 52 (8): 1742-1756 页
 - [52] CHAWLA N V, BOWYER K W, HALL L O, et al. SMOTE: synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 2002, 16: 321-357P
 - [53] 房晓南, 张化祥, 高爽. 基于 SMOTE 和随机森林的 Web spam 检测. *山东大学学*

- 报 (工学版), 2013, 43 (1): 1-7 页
- [54] 吴庆忠, 车峰远, 薛付忠. 基于非平衡数据的癫痫发作预警模型研究. 山东大学学报 (医学版), 2012, 50 (2): 141-148
- [55] 尹华, 胡玉平. 一种代价敏感随机森林算法. 武汉大学学报 (工学版), 2014, 47 (5): 707-711 页
- [56] 于旭. 模式分类中训练样本集的构造方法研究. 哈尔滨工程大学博士学位论文, 2012, 11: 5-8 页
- [57] Sangyoon Oh, Min Su Lee, Byoung-Tak Zhang. Ensemble Learning with Active Example Selection for Imbalanced Biomedical Data Classification. IEEE/ACM Transactions on Computational Biology and Bioinformatics, 2011, 8(2): 316-325P
- [58] Tsymbal A, Puuronen S. Ensemble feature selection with the simple bayesian classification. Information Fusion, 2010, 4(2): 87-100P
- [59] Mohammed Khalilia, Sounak Chakraborty, Mihail Popescu. Predicting disease risks from highly imbalanced data using random forest. BMC Medical Informatics and Decision Making, 2011, 11: 51P
- [60] Ali Anaissi, Paul J Kennedy, Madhu Goyal, Daniel R Catchpoole. A balanced iterative random forest for gene selection from microarray data. BMC Bioinformatics, 2013, 14: 261P
- [61] 邹权, 郭茂祖, 刘扬等. 类别不平衡的分类方法及在生物信息学中的应用. 计算机研究与发展, 2010, 47 (8): 1407-1414 页
- [62] 李霞, 王连喜, 蒋盛益. 面向不平衡问题的集成特征选择. 山东大学学报 (工学版), 2011, 41 (3): 7-22 页
- [63] L.Breiman, Random forests. Machine Learning, 2001, 45: 5-32P
- [64] L.Breiman, Bagging predictors. Machine Learning, 1996, 24(2):123-140P
- [65] T.K.Ho, The random subspace method for constructing decision forests. IEEE Transactions on Pattern Analysis and Machine Intelligence, 1998, 20(8): 832-844P
- [66] A. Verikas, A.Gelzinis, M.Bacauskiene. Mining data with random forests: A survey and results of new tests. Pattern Recognition, 2011, 44: 330-349P
- [67] Carolin Strobl, Anne-Laure Boulesteix, Thomas Kneib, Thomas Augustin, Achim Zeileis. Conditional variable importance for random forests. BMC Bioinformatics, 2008, 9: 307P
- [68] Liu Huiqing, Li Jinyan. A comparative study on feature selection and classification methods using gene expression profiles and proteomic patterns. Genome Informatics,

2012, 13: 51-60P

- [69] G.Nimrod, A.Szilagyi, C.Leslie, N.Ben-Tal. Identification of DNA-binding proteins using structural, electrostatic and evolutionary features. *Journal of Molecular Biology*, 2009, 387(4): 1040-1053P
- [70] H.T.Chen, T.L.Liu, C.S.Fuh. Segmenting highly articulated video objects with weak-prior random forests. *Lecture Notes in Computer Science*, 2006, 3954: 373-385P
- [71] J.Ham, Y.Chen, M.M.Crawford, J.Ghosh. Investigation of the random forest framework for classification of hyper-spectral data. *IEEE Transactions on Geoscience and Remote Sensing*, 2005, 43(3): 492-501P
- [72] M.M.Crawford, J.Ham, Y. Chen, J. Ghosh. Random forests of binary hierarchical classifiers for analysis of hyperspectral data. *2003IEEE Workshop on Advances in Techniques for Analysis of Remotely Sensed Data*, IEEE, Greenbelt, MD, USA 2004: 337-345P
- [73] J.Peters, B.DeBaets, N.E.C.Verhoest, R.Samson, S.Degroeve, P.DeBecker, W. Huybrechts. Random forests as a tool for ecohydrological distribution modelling. *Ecological Modelling*, 2007, 207: 304-318P
- [74] J.Peters, N.E.C.Verhoest, R.Samson, M.VanMeirvenne, L.Cockx, B.De Baets. Uncertainty propagation in vegetation distribution models based on ensemble classifiers. *Ecological Modelling*, 2009, 220: 791-804P
- [75] P.A.Hernandez, I.Franke, S.K.Herzog, et al. Predicting species distributions in poorly-studied landscapes. *Biodiversity and Conservation*, 2008, 17: 1353-1366P
- [76] I.Oparin, O.Glembek, L.Burget, J.Cernocky. Morphological random forests for language modeling of inflectional languages. *2008 IEEE Workshop on Spoken Language Technology, SLT2008*, IEEE, Goa, India, 2008: 189-192P
- [77] J.Ramirez, J.M.Gorritz, R.Chaves, et al. SPECT image classification using random forests. *Electronics Letters*, 2009, 45(12): 604-605P
- [78] A.G.Heidema, J.M.A.Boer, N.Nagelkerke, et al. The challenge for genetic epidemiologists: how to analyze large numbers of SNPs in relation to complex diseases. *Accident Analysis and Prevention*, 2006, 7(23): 1-15P
- [79] P.Han, X.Zhang, R.S.Norton, Z.P.Feng. Large-scale prediction of long disordered regions in proteins using random forests. *BMC Bioinformatics*, 2009, 10 (8): 1-9P
- [80] J.D.Watts, R.L.Lawrence, P.R.Miller, C.Montagne. Monitoring of cropland practices for carbon sequestration purposes in north central Montana by landsat remote sensing. *Remote Sensing of Environment*, 2009, 113: 1843-1852P

- [81] S.R.Joelsson, J.A.Benediktsson, J.R.Sveinsson. Feature selection for morphological feature extraction using random forests. Seventh Nordic Signal Processing Symposium, IEEE, NewYork, Reykjavik, Iceland 2006: 138-141P
- [82] S.Gupta, S.Matthew, P.M.Abreu, J.A.deSousa. QSAR analysis of phenolic antioxidants using MOLMAP descriptors of local properties. Bioorganic & Medicinal Chemistry, 2006, 14: 1199-1206P
- [83] S.Bernard, L.Heutte, S.Adam. Using random forests for handwritten digit recognition. Ninth International Conference on Document Analysis and Recognition, Curitiba, Brazil 2007: 1043-1047P
- [84] M.Thums, C.J.A.Bradshaw, M.A.Hindell. A validated approach for supervised dive classification in diving vertebrates. Journal of Experimental Marine Biology and Ecology, 2008, 363: 75-83P
- [85] 王丽婷, 丁晓青, 方驰. 基于随机森林的人脸关键点精确定位方法. 清华大学学报(自然科学版), 2009, 49 (4): 543-546 页
- [86] 田宝明, 戴新宇, 陈家骏. 一种基于随机森林得多视角文本分类方法. 中文信息学报, 2009, 4 (23): 48-54 页
- [87] 周绮凤, 洪文财, 杨帆, 罗林开. 基于随机森林相似度矩阵差异性的特征选择. 华中科技大学学报 (自然科学版), 2010, 38 (4): 58-61 页
- [88] 王爱平, 万国伟, 程志全, 李思昆. 支持在线学习的增量式极端随机森林分类器. 软件学报, 2011, 22 (9): 2059-2074 页
- [89] 马昕, 郭静, 孙啸. 蛋白质中 RNA-结合残基预测的随机森林模型. 东南大学学报, 2012, 42 (1): 50-54 页
- [90] 余俏俏, 俞扬, 姜远, 周志华. 一种基于标记传播的大规模图像分类方法. 计算机研究与发展, 2012, 49 (11): 2289-2295 页
- [91] Lei Z, Fang T, Huo H, et al. Rotation-Invariant Object Detection of Remotely Sensed Images Based on Texton Forest and Hough Voting[J]. IEEE Transactions on Geoscience & Remote Sensing, 2012, 50(4): 1206-1217P
- [92] Zhen Lei, Tao Fang, and Deren Li. Land Cover Classification for Remote Sensing Imagery Using Conditional Texton Forest with Historical Land Cover Map. IEEE Geosci. Remote Sens. Lett., 2011, 8 (4) : 720-724P
- [93] Yunming Ye, Qingyao Wu, Joshua Zhexue Huang, and Michael K. Ng. Stratified Sampling for Feature Subspace Selection in Random Forests for High Dimensional Data. Pattern Recognition, 2013, 46(3): 769-787P

- [94] Qingyao Wu, Yunming Ye, Haijun Zhang, Michael K. Ng and Shenyang Ho. ForesTexter: An Efficient Random Forest Algorithm for Imbalanced Text Categorization. *Knowledge Based Systems*, 2014, 67(9): 105–116P
- [95] Wouter G. Touw, Jumamurat R. Bayjanov, Lex Overmars et al. Data mining in the life science with random forest: a walk in the park or lost in the jungle. *Briefings in Bioinformatics*, 2012, 7: 1-12P
- [96] 尹华. 面向高维和不平衡数据分类的集成学习研究. 武汉大学博士学位论文, 2012, 04
- [97] Cheng Zheng, Mingjun Wang, Kazuhiro Takemoto, Tatsuya Akutsu, Ziding Zhang, Jiangning Song. An integrative computational framework based on a two-step random forest algorithm improves prediction of Zinc-Binding Sites in Proteins. *PLoS ONE*, 7 (11): 1-15P
- [98] Usman Roshan, Satish Chikkagoudar, Zhi Wei, Kai Wang, Hakon Hakonarson. Ranking causal variants and associated regions in genome-wide association studies by the support vector machine and random forest. *Nucleic Acids Research*, 2011, 39(9): 1-8P
- [99] M., Li, Z.H. Zhou. Improve computer-aided diagnosis with machine learning techniques using undiagnosed samples. *IEEE Transactions on System, Man, and Cybernetics*, 2007, 37(6): 1088-1098
- [100] Chao Deng, M. Zu Guo. A new co-training-style random forest for computer aided diagnosis. *J Intell Inf Syst*, 2011, 36: 253-281P
- [101] Amaratunga, D., Cabrera, J., Lee, Y.. Enriched random forests. *Bioinformatics*, 2008, 24(18): 2010-2014P
- [102] Simon Bernard, Sebastien Adam, Laurent Heutte. Dynamic random forests. *Pattern recognition Letters*, 2012, 33(12):1580-1586P
- [103] Evanthia E. Trupoliti, Dimitrios I. Fotiadis, George Manis. Automated Diagnosis of Diseases Based on the Number of Trees in Random Forests Algorithm. *IEEE Transactions on information technology in biomedicine*, 2012, 16(4): 615-622P
- [104] Carolin Strobl, Anne-Laure Boulesteix, Achim Zeileis, Torsten Hothorn. Bias in random forest variable importance measures: Illustrations, sources and a solution. *BMC Bioinformatics* 2007, 8: 25P
- [105] Carolin Strobl, Anne-Laure Boulesteix, Thomas Kneib, et al. Conditional variable importance for random forests. *BMC Bioinformatics*, 2008, 9: 307P
- [106] Gerard Biau, Luc Devroye, Gabor Lugosi. Consistency of Random Forests and Other Averaging Classifiers. *Journal of Machine Learning Research*, 2008 (9): 2015-2033P

- [107] J.B.Gray, G.Fan. Classification tree analysis using TARGET. Computational Statistics & Data Analysis, 2008, 52: 1362-1372P
- [108] J.J.Rodrguez, C.J.Alonso. Rotation-based ensembles, Current Topics in Artificial Intelligence. Lecture Notes in Computer Science, 2003, 3040: 498-506P
- [109] J.L.Rodrguez, L.I.Kuncheva, C.J.Alonso. Rotation forest: a new classifier ensemble method. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2006, 28(10): 1619-1630P
- [110] A.Tsymbal, M.Pechenizkiy, P.Cunningham. Dynamic integration with random forests. Lecture Notes in Artificial Intelligence, Springer-Verlag, Berlin, Heidelberg, 2006: 801-808P
- [111] G.Leshem, Y.Ritov. Traffic flow prediction using adaboost algorithm with random forests as a weak learner, in: Proceedings of World Academy of Science. Engineering and Technology, Bangkok, Thailand, 2007: 193-198P
- [112] H.E.Osman. Online random forests based on CorrFS and CorrBE. 2008 IEEE Computer Society Conference on Computer Vision and Pattern Recognition, IEEE, Anchorage, AK, USA, 2008: 863-869P
- [113] 曹正凤. 随机森林算法优化研究. 首都经济贸易大学博士学位论文, 2014, 03: 1-4 页
- [114] R. Díaz-Uriarte, A. de Andrés. Gene selection and classification of microarray data using random forest. BMC Bioinformatics, 2006, 7(1): 3P
- [115] 林舒杨, 李翠华, 江弋, 林琛, 邹权. 不平衡数据的降采样方法研究. 计算机研究与发展, 2011, 48: 47-53 页
- [116] 刘胥影, 吴建鑫, 周志华. 一种基于级联模型的类别不平衡数据分类方法. 南京大学学报(自然科学), 2006, 42 (2): 148-155 页
- [117] Lim T S, Loh W Y, Shih Y S. A Comparison of Prediction Accuracy, Complexity, and Training Time of Thirty-Three Old and New Classification Algorithms. Machine Learning, 2000, 40(3): 203-228P
- [118] Decoste D. Anytime Interval-Valued Outputs for Kernel Machines: Fast Support Vector Machine Classification via Distance Geometry. Proceedings of ICML-02. 2002: 99-106P
- [119] Zhou Z H, Jiang Y. NeC4.5: neural ensemble based C4.5[J]. IEEE Transactions on Knowledge & Data Engineering, 2004, 16(6): 770-773P
- [120] Peltonen J, Klami A, Kaski S. Improved learning of Riemannian metrics for exploratory

- analysis. Neural Networks, 2004, 17(8-9): 1087-1100P
- [121] Smith J W, Everhart J E, Dickson W C, et al. Using the ADAP Learning Algorithm to Forecast the Onset of Diabetes Mellitus. Proc Annu Symp Comput Appl Med Care, 1988: 261-265P
- [122] Zhou Z H, Jiang Y, Chen S F. Extracting Symbolic Rules from Trained Neural Network Ensembles. Ai Communications, 2003, 16(1): 3-15P
- [123] Little M A, Mcsharry P E, Roberts S J, et al. Exploiting Nonlinear Recurrence and Fractal Scaling Properties for Voice Disorder Detection. Biomedical Engineering Online, 2007, 23(3): 23P
- [124] Skurichina M, Kuncheva L I, Duin R P W. Bagging and Boosting for the Nearest Mean Classifier: Effects of Sample Size on Diversity and Accuracy. Multiple Classifier Systems. Springer Berlin Heidelberg, 2002: 62-71P
- [125] Balázs Kégl T L, Lugosi G. Data-dependent margin-based generalization bounds for classification. Journal of Machine Learning Research, 2003, 3(1): 368-384P
- [126] Domeniconi C, Yan B. Nearest neighbor ensemble. Pattern Recognition, 2004, 1: 228-231P
- [127] Busygin S, Jacobsen G, Ag C. Double Conjugated Clustering Applied to Leukemia Microarray Data. Siam Icdm Workshop on Clustering High Dimensional Data, 2002P
- [128] Carlos Ordonez, CesarA. Santana, Leviende Bral. Discovering interesting association rules in medical data. In ACM SIGNOD Workshop on Research Issues on Data Mining and Knowledge Discovery(DMK02000), 2000:78-85P
- [129] Shah B. Relationship between diabetes and age in human metatarsal bones. The 17th Southern Biomedical Engineering Conference, 1998: 2-32P
- [130] Harris ND, Ireland RH, Marques JLB, et al. Can changes in QT interval be used to predict the onset of Hypoglycemia in type 1 diabetes. Computers in Cardiology, 2010, 27: 375-378P
- [131] 计智伟, 胡珉, 尹建新. 特征选择算法综述. 电子设计工程, 2011, 9(19): 46-51 页
- [132] Kohavi R, John GH. Wrappers for feature subset selection. Artif Intell , 1997, 97: 273-324P
- [133] Langley P. Selection of relevant features in machine learning. In: AAAI fall symp relevance, 1994
- [134] Blum AL, Langley P. Selection of relevant features and examples in machine learning. Artif Intell, 1997, 97: 245-70P
- [135] John GH, Kohavi R, Pfleger K. Irrelevant features and the subset selection problem. In:

- Proc 11th int conf mach learn, 1994: 121-9P
- [136] Guyon I, Elisseeff A. An introduction to variable and feature selection. J Mach Learn Res, 2003, 3: 1157-82P
- [137] Battiti R. Using mutual information for selecting features in supervised neural net learning. IEEE Trans Neural Networks, 1994: 5P
- [138] Forman G. An extensive empirical study of feature selection metrics for text classification. J Mach Learn Res, 2003, 3: 1289-306P
- [139] Qi, Y. . Random forest for Bioinformatics. Ensemble Machine Learning, 2012: 307-323P
- [140] 杜元园. 基于多元自适应回归样条的民营企业信用评级研究. 吉林大学硕士学位论文, 2007: 16-22 页
- [141] Hasan A Alzahrani, Dong Wang, Balkees A Bakhotmah. Risk factors for peripheral disease among patients with diabetes in Saudi Arabia. Vascular Medicine, 2014: 1-9P
- [142] Hiatt WR. Medical treatment of peripheral arterial disease and claudication. N Engl J Med 2001, 344(21):1608-1621P
- [143] Debabrata Mukherjee. Peripheral and cerebrovascular atherosclerotic disease in diabetes mellitus. Best Practice & Research Clinical Endocrinology & Metabolism, 2009, 23(3):335-345P
- [144] 蒋盛益, 郑琪, 张倩生. 基于聚类的特征选择算法. 电子学报, 2008, 36 (12): 157-160 页
- [145] 刘元宁, 王刚, 朱晓冬, 等. 基于自适应多种群遗传算法的特征选择. 吉林大学学报(工学版), 2011, 41 (6): 1690-1693 页
- [146] Pang, H, George L.S., Hui, K, and Tong, T.. Gene Selection Using Iterative Feature Elimination Random Forests for Survival Outcomes. IEEE/ACM TRANSACTIONS ON COMPUTATIONAL BIOLOGY AND BIOINFORMATICS, 2012, 9(5): 1422-1431P
- [147] Dessì N, Milia G, Pes B. Pre-filtering Features in Random Forests for Microarray Data Classification. New Frontiers in Mining Complex Patterns, 2012: 60P
- [148] Li, L.P., Weinberg, C.R., Darden, T.A. and Pedersen, L.G. Gene selection for sample classification based on gene expression data: study of sensitivity to choice of parameters of the GA/KNN method. Bioinformatics, 2001, 17: 1131-1142P
- [149] Ding, C. and Peng, H.C. Minimum redundancy feature selection from microarray gene expression data. Journal of Bioinformatics and Computational Biology, 2005, 3:

185-205P

- [150] Glaab, E., Garibaldi, J.M. and Krasnogor, N. ArrayMining: a modular web-application for microarray analysis combining ensemble and consensus methods with cross-study normalization. BMC Bioinformatics, 2009, 10: 358

攻读博士学位期间发表的论文和取得的科研成果

攻读博士学位期间发表及录用的论文:

- [1] Dengju Yao, Jing Yang, Xiaojuan Zhan, Xiaorong Zhan, Zhiqiang Xie. A novel random forests-based feature selection method for microarray expression data analysis. *International Journal of Data Mining and Bioinformatics*. 2015, 13(1): 84-101 (SCI: 000359009200007)
- [2] Yao Dengju, Yang Jing, Zhan Xiaojuan. A Novel Method for Disease Diagnosis: Hybrid of Random Forest and Multivariate Adaptive Regression Splines. *Journal of Computers*. 2013, 8(1):170-177 (EI: 20130415927690)
- [3] Yao Dengju, Yang Jing, Zhan Xiaojuan. An Improved Random Forest Algorithm for Class-Imbalanced Data Classification and its Application in PAD Risk Factors Analysis. *Open Electrical & Electronic Engineering Journal*. 2013, 7: 62-70 (EI: 20132616449848)
- [4] 姚登举, 杨静, 詹晓娟. 基于随机森林的特征选择算法. *吉林大学学报(工学版)*, 2014, 44(1): 137-141(EI: 20140517253054)
- [5] Yao Dengju, Yang Jing, Zhan Xiaojuan. Predicting Breast Cancer Survivability Using Random Forest and Multivariate Adaptive Regression Splines. *Proceedings of 2011 International Conference on Electronic and Mechanical Engineering and Information Technology (EMEIT2011)*, 2011,08: 2204-2207 (EI:20114014403445)
- [6] Jing Yang, Dengju Yao, Xiaojuan Zhan, Xiaorong Zhan. Predicting Disease Risks Using Feature Selection Based on Random Forest and Support Vector Machine. *Proceedings of 10th International Symposium on Bioinformatics Research and Applications, ISBRA 2014*, 2014, Zhangjiajie, China (EI:20143518107847)

攻读博士学位期间参与的科研项目:

- [1] 国家自然科学基金项目 (61073043): 面向数据流的双重隐私保护技术研究。
- [2] 国家自然科学基金项目 (61073041): 基于迁移学习的异构聚类多关系社会网络划分方法。
- [3] 黑龙江省自然科学基金项目 (F201313): 面向高维小样本和类别不平衡数据分析的随机森林分类算法研究

致 谢

乌飞兔走，斗转星移。弹指一挥间，博士学习已经进行了五年。在学位论文即将完成之日，心潮澎湃，感慨良深。首先真诚的感谢我的导师杨静教授，从论文的选题、创作到定稿的全过程中，给了我精心的指导和无私的帮助。杨老师以渊博的理论知识 and 实践经验为我们指明了科学研究的方法和方向，以踏实严谨的工作态度和真诚坦荡的处事风格为我们树立了学习的榜样。借此论文完成之际，向杨老师致以最崇高的敬意和最诚挚的祝福！

同时，我要感谢张健沛教授。在整个博士研究生学习阶段，张健沛教授给与了我很大的帮助。张老师治学严谨、学识渊博、思维活跃、平易近人，是我们尊敬的师长和学习的楷模。在此，向张老师表示深切的谢意！祝您身体健康，万事如意！

另外，我还要感谢实验室王勇、李泓波、杨高明、杨海陆、李文平、辛宇、王超、王旭、张冰和谢静等同学的帮助，感谢他们在论文工作中有益的讨论！

感谢我的父母多年来对我的养育之恩以及在我博士研究生期间帮助我照看幼子，使我得以有充分的时间进行学习和研究；感谢我的爱人对我求学过程的理解、支持和默默的奉献！

最后，再次向所有直接或间接帮助过我的老师和同学，以及评阅本文的各位专家、教授表示诚挚的感谢！

